

# Analyse des données

Octobre 2019

Itheri YAHIAOUI  
CReSTIC-Université de Reims  
[itheri.yahiaoui@univ-reims.fr](mailto:itheri.yahiaoui@univ-reims.fr)

## Objectifs du module

- Apprendre les différentes techniques de l'analyse des données uni-variées, bi-variées et multi-variées ;
- Apprendre les bases de l'analyse descriptive et exploratoire.

## Organisation du cours

- CM : 20h
- TD : 10h

## Évaluation

- Première session :
  - Un examen écrit terminal (EET) de 1h30 : 50% ;
  - Un projet+CR : 50% (30 + 20) ;
- Deuxième session :
  - Un projet+CR : 50% ;
  - Un EET de 1h30 : 50%.

## Plan du cours

- Statistique descriptive (notions de population, caractère, variable statistique, ... ) ;
- Analyse des données uni-variées (moyenne, médiane, quartiles, variance, étendu, mode, histogramme, ... ) ;
- Analyse des données bi-variées (étude de corrélation, étude de l'indépendance, analyse de la variance) ;
- Analyse des données multi-variées et visualisation (analyse en composantes principales et ses variantes).

## Références bibliographiques

- G. Saporta (2011). Probabilités, analyse des données et Statistique. Edition TECHNIP ;
- B. Escofier, J. Pages (2016). Analyses factorielles simples et multiples. Dunod ;
- F. Husson, S. Lê, J. Pages (2017). Exploratory Multivariate Analysis by Example Using R. CRC Press ;
- A. Chekroun (2017). Statistique descriptive. Polycopié ;
- Sites web :  
“[http ://eric.univ-lyon2.fr/~ricco/cours/index.html](http://eric.univ-lyon2.fr/~ricco/cours/index.html)”,  
“[http ://www.rdatamining.com/docs/data-exploration-and-visualization-with-r](http://www.rdatamining.com/docs/data-exploration-and-visualization-with-r)”,

La statistique est l'étude de la collecte de données, leur analyse, leur traitement, l'interprétation des résultats et leur présentation afin de rendre les données compréhensibles par tous. C'est à la fois une science, une méthode et un ensemble de techniques.

## Épreuve statistique

La statistique descriptive vise à étudier les caractéristiques d'un ensemble d'observations comme les mesures obtenues lors d'une expérience. L'expérience est l'étape préliminaire à toute étude statistique. De manière générale, la méthode statistique est basée sur le concept suivant.

- **Définition** : L'épreuve statistique est une expérience que l'on provoque.

## Population

On appelle population un ensemble d'objets sur lesquels on fait des observations statistiques. Cet ensemble sera noté  $\Omega$ .

- **Exemple 1** : On considère l'ensemble des étudiants d'un certain pays. On s'intéresse aux nombres de frères et soeurs de chaque étudiant. Dans ce cas  $\Omega :=$  l'ensemble des étudiants.
- **Exemple 2** : Si l'on s'intéresse maintenant à la circulation automobile dans une ville, la population est alors constituée de l'ensemble des véhicules susceptibles de circuler dans cette ville à une date donnée. Dans ce cas  $\Omega :=$  l'ensemble des véhicules.

## Individu (unité statistique)

Une population est composée d'individus. Les individus qui composent une population statistique sont appelés unités statistiques.

- **Définition** : On appelle individu tout élément de la population  $\Omega$ , il est noté  $\omega$ .

### Remarque 1 :

L'ensemble  $\Omega$  peut être un ensemble de personnes, de choses ou d'animaux ... L'unité statistique est un objet pour lequel nous sommes intéressés à recueillir de l'information.

## Caractère (variable statistique)

La statistique descriptive, comme son nom l'indique cherche à décrire une population donnée. Nous nous intéressons aux caractéristiques des individus qui peuvent prendre différentes valeurs.

- **Définition** : On appelle caractère (ou variable statistique, dénotée V.S.) toute application

$$X : \Omega \rightarrow C$$

L'ensemble  $C$  est dit : ensemble des valeurs du caractère  $X$  (c'est ce qui est mesuré ou observé sur les individus).

- **Exemples** : Taille, température, nationalité, couleur des yeux, catégorie socioprofessionnelle ...

## Cardinal d'un ensemble

Soit  $\Omega$  un ensemble. On appelle cardinal de  $\Omega$ , et on note  $\text{Card}(\Omega)$ , le nombre d'éléments de  $\Omega$ .

## Modalités

Les modalités d'une variable statistique sont les différentes valeurs que peut prendre celle-ci.

- **Exemples :**

- Soit la V.S.  $X$  donnant la "situation familiale" :

Les modalités sont "célibataire", "marié", "divorcé".

- Soit la V.S.  $X$  donnant la "catégories

socio-professionnelles" :

Les modalités sont "employé", "ouvriers", "retraités", ...

Les modalités sont les différentes situations dans lesquelles les individus peuvent se trouver à l'égard du caractère considéré.

## Types des caractères

Nous distinguons deux catégories de caractères : les caractères qualitatifs et les caractères quantitatifs.




FIGURE: Types des caractères

- **Caractère qualitatif** : Un caractère est dit qualitatif lorsque ses valeurs (ses modalités) ne sont pas des nombres (ce sont des noms, des chaînes de caractères ou des codes) ; les opérations mathématiques entre les modalités n'ont aucun sens. On distingue par ailleurs deux types de caractères qualitatifs : caractère qualitatif ordinal (lorsque les modalités peuvent être classées dans un certain ordre), et caractère qualitatif nominal (les différentes modalités ne peuvent être ordonnées) ;

**Exemple 1** : Considérons le caractère donnant l'état d'une maison, avec les modalités : ancienne, dégradée, nouvelle, rénovée. (c'est un caractère qualitatif nominal).

**Exemple 2** : Considérons le caractère donnant la mention obtenue à l'issue d'un examen écrit, avec les modalités : insuffisant, moyen, assez bien, bien, très bien, excellent. (c'est un caractère qualitatif ordinal).

- **Caractère quantitatif** : Un caractère est dit quantitatif lorsque ses modalités sont mesurables (c-à-d qu'elles peuvent être représentées par des nombres). On distingue les caractères quantitatifs discrets (lorsque le nombre des valeurs est fini ou infini dénombrable) et les caractères quantitatifs continus (lorsque le nombre des valeurs est infini non-dénombrable).

# Étude d'une variable statistique discrète

- Notons  $\Omega$  l'ensemble des individus d'une population ;
- On dit qu'une variable aléatoire (ou statistique)  $X$ , définie sur  $\Omega$ , est **discrète**, lorsque l'ensemble des valeurs possibles de  $X$ , noté  $X(\Omega) := \{X(\omega) \text{ tel que } \omega \in \Omega\}$ , est un ensemble **discret**, i.e., fini ou infini dénombrable ;
- Par exemple, les variables aléatoires donnant la note à un examen, le nombre d'enfants d'une famille, le nombre d'appels téléphoniques à un service, ... sont des variables statistiques discrètes.

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡

Voici un exemple pour illustrer les notations précédentes et les notions à suivre

### Exemple 1 : nombre d'enfants par famille

Une enquête réalisée dans une ville porte sur le nombre d'enfants à charge par famille. On note  $X$  la V.S. donnant le nombre d'enfants par famille, les résultats sont présentés dans ce tableau :

|                  |    |    |    |    |    |   |   |
|------------------|----|----|----|----|----|---|---|
| $x_i$            | 0  | 1  | 2  | 3  | 4  | 5 | 6 |
| $n_i$ (effectif) | 18 | 32 | 66 | 41 | 32 | 9 | 2 |

Nous avons

$\Omega$  : la population des familles

$X$  : le nombre d'enfants par famille

$$X : \omega \in \Omega \mapsto X(\omega);$$

On lit, à la famille  $\omega$ , on associe  $X(\omega)$  = le nombre d'enfants de cette famille  $\omega$ .

### Définition : Effectif

i.e., le nombre d'individus de l'échantillon qui ont la même valeur  $x_i$ .

$$n_i := \text{Card} \{ \omega \in \Omega_N : X(\omega) = x_i \},$$




FIGURE:  $n_j$  est le nombre d'individus  $\omega$  prenant la valeur  $x_j$ .

- Dans l'exemple précédent,  $n_3 = 66$  est le nombre de familles ayant  $x_3 = 2$  enfants :

|                  |     |    |     |
|------------------|-----|----|-----|
| $x_i$            | ... | 2  | ... |
| $n_i$ (effectif) | ... | 66 | ... |

## Définition : Effectif cumulé

Pour chaque valeur  $x_i$ , on appelle effectif cumulé  $N_i$  de  $x_i$  le nombre entier

$$N_i := \sum_{j=1}^i n_j = n_1 + \cdots + n_i,$$

i.e., la somme de l'effectif de  $x_i$  et des effectifs de toutes les valeurs qui précèdent  $x_i$ .

- Dans l'exemple précédent,  $N_2 = 50$  est l'effectif cumulé de la valeur  $x_2 = 1$  ; il représente le nombre de familles de l'échantillon ayant un nombre d'enfants inférieur ou égal à  $x_2 = 1$  :

| $x_i$                   | 0  | 1  | 2   | 3   | 4   | 5   | 6   |
|-------------------------|----|----|-----|-----|-----|-----|-----|
| $N_i$ (effectif cumulé) | 18 | 50 | 116 | 157 | 189 | 198 | 200 |

- **Interprétation** :  $N_i$  est le nombre d'individus de l'échantillon dont la valeur du caractère est inférieur ou égale à  $x_i$ . De ce fait, l'effectif total de l'échantillon est

$$N := \text{Card}(\Omega_N) = \sum_{i=1}^n n_i = N_n.$$

Dans l'exemple précédent, nous avons

$$N = 200 = \sum_{i=1}^7 n_i = N_7.$$

## Définition : Fréquence

Pour chaque valeur  $x_i$ , on appelle fréquence de  $x_i$  le nombre réel positif

$$f_i := \frac{n_i}{N} \in [0, 1].$$

La fréquence d'une valeur est le rapport de l'effectif de cette valeur par l'effectif total  $N$  de l'échantillon  $\Omega_N$ .

- **Remarque** : On peut remplacer  $f_i$  par  $f_i \times 100$  qui représente alors un pourcentage.
- **Interprétation** :  $f_i \times 100$  est le pourcentage des individus  $\omega$  de l'échantillon  $\Omega_N$  tel que  $X(\omega) = x_i$ .

Dans l'exemple précédent, la fréquence de la valeur  $x_3 = 2$  est  $f_3 = n_3/N = 66/200 = 0.33$  ; il y a 33% de familles dont le nombre d'enfants est égal à 2. Ce pourcentage est calculé comme suit ( $N = 200$ )

|                                    |     |                         |     |
|------------------------------------|-----|-------------------------|-----|
| $x_i$                              | ... | 2                       | ... |
| $n_i$ (effectif)                   | ... | 66                      | ... |
| $f_i := \frac{n_i}{N}$ (fréquence) | ... | $\frac{66}{200} = 0.33$ | ... |

Nous pouvons conclure la propriété suivante

$$\sum_{i=1}^n f_i = 1.$$

En effet,

$$\sum_{i=1}^n f_i = \sum_{i=1}^n \frac{n_i}{N} = \frac{1}{N} \sum_{i=1}^n n_i = \frac{N}{N} = 1.$$

## Définition : Fréquence cumulée

Pour chaque valeur  $x_i$ , on définit

$$\begin{aligned} F_i &:= \sum_{j=1}^i f_j = f_1 + \cdots + f_i \\ &= \frac{n_1}{N} + \cdots + \frac{n_i}{N} = \frac{N_i}{N}. \end{aligned}$$

Cette quantité s'appelle la fréquence cumulée de  $x_i$ .

- **Interprétation** :  $F_i$  est la proportion des individus  $\omega$  de l'échantillon tels que  $X(\omega)$  est inférieure ou égale à  $x_i$ .
- Dans l'exemple précédent,  $F_4 := \sum_{i=1}^4 f_i = f_1 + f_2 + f_3 + f_4 = \frac{18}{200} + \frac{32}{200} + \frac{66}{200} + \frac{41}{200} = \frac{157}{200} = 0.785$ ; il y a 78.5% de familles dont le nombre d'enfants est inférieur ou égale à 3.

## Exemple 2 : Nombre d'erreurs d'assemblage par appareil

On a relevé le nombre d'erreurs d'assemblage sur un ensemble d'appareils ( $N = 396$  appareils) :

| $x_i$ : nombre d'erreurs | $n_i$ (effectif) | $N_i$ | $f_i$ (fréquence) | $F_i$ |
|--------------------------|------------------|-------|-------------------|-------|
| 0                        | 101              | 101   | 0.26              | 0.26  |
| 1                        | 140              | 241   | 0.35              | 0.61  |
| 2                        | 92               | 333   | 0.23              | 0.84  |
| 3                        | 42               | 375   | 0.10              | 0.94  |
| 4                        | 18               | 393   | 0.05              | 0.99  |
| 5                        | 3                | 396   | 0.01              | 1     |

Nous avons 94% des appareils qui ont un nombre d'erreurs d'assemblage inférieur ou égal à 3.

Dans la suite, nous allons voir comment traduire des tableaux statistiques en graphiques permettant de représenter et résumer visuellement l'information apportée par les données.

## Représentation graphique des séries statistiques

On distingue les méthodes de représentation d'une variable statistique en fonction de la nature de cette variable (qualitative ou quantitative). Les représentations recommandées et les plus fréquentes sont les tableaux et les diagrammes (graphes).

Le graphique est un support visuel qui permet :

- **La synthèse** : visualiser d'un seul coup d'œil les principales caractéristiques ;




FIGURE: Caractéristiques des graphiques

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ◻ ↺ 🔍 ↻

## Représentation d'un caractère qualitatif

À partir d'observations d'une variable qualitative (sur  $N$  individus), deux diagrammes permettent de représenter cette variable : le diagramme en bandes (dit tuyaux d'orgue) et le diagramme à secteurs angulaires (dit camembert) :

- **Tuyaux d'orgues** : Nous portons en abscisses les modalités, de façon arbitraire, et en ordonnées des rectangles dont la longueur est proportionnelle aux effectifs (ou aux fréquences) de chaque modalité




FIGURE: Tuyaux d'orgues

- **Diagramme circulaire (camembert)** : Les diagrammes circulaires, consistent à partager un disque en secteurs correspondant aux modalités observées et dont la surface est proportionnelle à l'effectif, ou à la fréquence, de la modalité :




FIGURE: Diagramme circulaire (camembert)

Le degré d'un secteur, associé à une modalité  $i$ , est déterminé à l'aide de la règle de trois de la manière suivante

$$\begin{array}{ll} N & \rightarrow 360^\circ \\ n_i & \rightarrow d_i \text{ (degré de la modalité } i), \end{array}$$

Donc,

$$d_i = \frac{n_i \times 360}{N}.$$

## Représentation d'un caractère quantitatif discret

À partir de l'observation d'une variable quantitative discrète, deux diagrammes permettent de représenter cette variable : le diagramme en bâtons et le diagramme cumulé. Pour l'illustration, nous reprenons l'exemple précédent (du caractère  $X$  : nombre d'enfants par famille)

| $x_i$            | 0    | 1    | 2    | 3     | 4     | 5     | 6    |
|------------------|------|------|------|-------|-------|-------|------|
| $n_i$ (effectif) | 18   | 32   | 66   | 41    | 32    | 9     | 2    |
| $f_i$            | 0.09 | 0.16 | 0.33 | 0.205 | 0.16  | 0.045 | 0.01 |
| $F_i$            | 0.09 | 0.25 | 0.58 | 0.785 | 0.945 | 0.99  | 1    |

- **Diagramme en bâtons** : les valeurs  $x_i$  sont représentées sur l'axe des abscisses, et à chaque valeur  $x_i$ , on associe un bâton de hauteur proportionnelle à l'effectif  $n_i$  de  $x_i$  :




FIGURE: Diagramme en bâtons

## Représentation sous forme de courbe et fonction de répartition

Soit la fonction

$$\begin{aligned} F_X(\cdot) &: \mathbb{R} \rightarrow [0, 1] \\ x &\mapsto F_X(x) \end{aligned}$$

où  $F_X(x) :=$  pourcentage des individus  $\omega$  dont la valeur du caractère  $X(\omega) \leq x$ .

La fonction  $F_X(\cdot)$  s'appelle **la fonction de répartition** du caractère  $X$ .

- **Remarque** : Pour tout  $i \in \{1, \dots, n\}$ , on a

$$F_X(x_i) = F_i.$$

La courbe d'équation  $y = F_X(x)$  passe donc par tous les points de coordonnées  $(x_1, F_1), \dots, (x_n, F_n)$ .

La fonction  $F_X(\cdot)$ , du caractère  $X$  de l'exemple précédent, est représentée dans la figure ci-dessous, avec  $F_X(x) = 0$  si  $x < 0$ ,  $F_X(x) = 0.09$  si  $x \in [0, 1[$ , ...,  $F_X(x) = 0.99$  si  $x \in [5, 6[$ ,  $F_X(x) = 1$  si  $x \geq 6$




FIGURE: Représentation par la courbe cumulative

- De manière générale, on a,  $\forall x \in \mathbb{R}$ ,

$$F_X(x) = \begin{cases} 0 & \text{si } x < x_1, \\ F_1 & \text{si } x_1 \leq x < x_2, \\ F_2 & \text{si } x_2 \leq x < x_3, \\ \vdots & \vdots \quad \quad \quad \vdots \\ F_{n-1} & \text{si } x_{n-1} \leq x < x_n, \\ 1 & \text{si } x \geq x_n. \end{cases}$$

En particulier,  $F_X(x_i) = F_i$  pour tout  $i \in \{1, 2, \dots, n\}$ .

- C'est une fonction croissante, constante par intervalle (fonction étagée), et continue à droite en tout point  $x_0$  de  $\mathbb{R}$ , i.e.,

$$\lim_{x \rightarrow x_0^+} F_X(x) = F_X(x_0), \quad \forall x_0 \in \mathbb{R}.$$

- Les points de discontinuité de  $F_X(\cdot)$  correspondent aux valeurs prises par  $X$ .

- Les amplitudes des sauts sont égales aux fréquences :

$$F_X(x_i) - F_X(x_i^-) = f_i, \quad \forall i = 1, \dots, n,$$

où

$$F_X(x_i^-) := \lim_{x \rightarrow x_i^-} F_X(x),$$

la limite à gauche de  $F_X(\cdot)$  en  $x_i$ ,  $\forall i = 1, \dots, n$ .

## Caractéristiques de tendance centrale (Paramètres de position)

Les indicateurs statistiques de tendance centrale (dits aussi de position) considérés fréquemment sont la moyenne, la médiane et le mode.

- **Le mode** : Le mode d'une variable statistique est la valeur qui a le plus grand effectif (ou la plus grande fréquence). Il est souvent dénoté par  $M_0$ . Dans l'exemple précédent, le mode est égal à 2, la valeur ayant le plus grand effectif :




FIGURE: Diagramme en bâtons

- On peut avoir plusieurs modes.

- **La médiane** : On appelle médiane, de la variable statistique  $X$ , la valeur  $M_e$  qui vérifie la relation suivante

$$F_X(M_e^-) < 0.5 \leq F_X(M_e^+) = F_X(M_e),$$

où  $F_X(\cdot)$  est la fonction de répartition de  $X$ .

- La médiane partage l'échantillon en deux parties de même effectif.
- Dans l'exemple précédent, nous avons  $M_e = 2$ . En effet, on a

$$F_X(2^-) = 0.25 < 0.5 \leq F_X(2^+) = F_X(2) = 0.58.$$

- **La moyenne** : On appelle moyenne “empirique” de  $X$ , la quantité

$$\bar{x} := \frac{1}{N} \sum_{i=1}^n n_i x_i = \sum_{i=1}^n f_i x_i,$$

avec  $N = \text{card}(\Omega_N)$  (la taille de l'échantillon).

- Dans l'exemple précédent, nous avons

$$\bar{x} = \frac{1}{200} \sum_{i=1}^7 n_i x_i = \dots = 2.46 :$$

Cela signifie q'une famille de cette ville a “en moyenne” 2.46 enfants !

## Caractéristiques de dispersion

Les indicateurs statistiques de dispersion usuels sont l'étendue, la variance et l'écart- type.

- **L'étendue** : C'est la différence entre la plus grande valeur et la plus petite valeur du caractère :

$$e := \max(x_i) - \min(x_i).$$

Il donne une première idée de la dispersion des observations. C'est un indicateur très rudimentaire et il existe des indicateurs de dispersion plus élaborés.

- **La variance** : On appelle variance "empirique" de la variable statistique  $X$ , le nombre positif

$$\text{Var}(X) := \sum_{i=1}^n f_i (x_i - \bar{x})^2.$$

C'est la moyenne des carrés des écarts à la moyenne  $\bar{x}$ .

Le théorème suivant (Théorème de König-Huygens) donne une identité remarquable reliant la variance et la moyenne, parfois plus pratique dans le calcul de la variance.

### Théorème

Soit  $(x_i, n_i), i = 1, \dots, n$ , une série statistique de moyenne  $\bar{x}$  et de variance  $\text{Var}(X)$ . Alors, on a

$$\text{Var}(X) = \left( \sum_{i=1}^n f_i x_i^2 \right) - \bar{x}^2.$$

- **L'écart-type** : La quantité positive

$$\sigma_X := \sqrt{\text{Var}(X)}$$

s'appelle l'écart-type "empirique" de  $X$ .

Le paramètre  $\sigma_X$  mesure la distance moyenne entre  $\bar{x}$  et les valeurs de  $X$ . Il sert à mesurer la dispersion d'une série statistique autour de sa moyenne.

- Plus il est petit, plus les caractères sont concentrés autour de la moyenne (on dit que la série est homogène).
- Plus il est grand, plus les caractères sont dispersés autour de la moyenne (on dit que la série est hétérogène).




FIGURE: La dispersion d'une série statistique autour de sa moyenne

Nous rappelons qu'une variable statistique quantitative concerne une grandeur mesurable. Ses valeurs sont des nombres exprimant une quantité et sur lesquelles les opérations arithmétiques (addition, multiplication, etc,...) ont un sens.

## Définition

On appelle variable statistique continue (ou caractère continu) toute application de  $\Omega$  à valeurs réelles et qui prend un nombre infini et "non dénombrable" de valeurs.

## Exemple


Soit  $\Omega$  l'ensemble des nouveaux nés au C.H.U d'une certaine ville, pendant les 3 premiers mois de 2017. Nous considérons la variable statistique  $X$  donnant le poids (en kg) d'un nouveau né. Nous avons obtenu

$$x_{min} = 2.701 \quad \text{et} \quad x_{max} = 5.001.$$

## Classe de valeurs

On appelle classe de valeurs de  $X$  un intervalle de type  $[a, b[$  tel que  $X \in [a, b[$  si et seulement si  $a \leq X(\omega) < b$ , c'est à dire, que les valeurs du caractère sont dans la classe  $[a, b[$ .

- Lorsque la variable statistique est numérique continue, on regroupe ses valeurs dans des classes, souvent des intervalles, notés  $C_k := [L_k, L_{k+1}[$ , avec
  - $L_k$  : borne inférieure ;
  - $L_{k+1}$  : borne supérieure ;
  - $a_k := L_{k+1} - L_k$  : son amplitude, ou sa longueur ;
  - $c_k := (L_k + L_{k+1})/2$  : son centre :



## Remarque

On supposera dans tous les cas étudiés que la distribution à l'intérieur des classes est uniforme (voir figure ci-dessous). Cette hypothèse permet de justifier le fait qu'on choisisse le centre des classes comme représentant.




FIGURE: Distribution uniforme sur les intervalles

## Nombre de classes

En combien de classes partageons-nous les valeurs ? La réponse n'est pas unique. Notons  $N$  la taille de l'échantillon. Nous considérons les trois choix possibles suivants du nombre  $k$  de classes :

(1)

$$k = \sqrt{N}.$$

Si  $\sqrt{N}$  n'est pas entier, on prend la partie entière (de  $\sqrt{N}$ ) ou la partie entière  $+1$  :

$$k = [\sqrt{N}] \quad \text{ou} \quad k = [\sqrt{N}] + 1;$$

(2) la formule de Sturge

$$k = 1 + 3.3 \log_{10}(N);$$

(3) la formule de Yule

$$k = 2.5 \sqrt[4]{N}.$$

## Remarque

Les deux dernières formules (de Sturge et Yule) donnent presque le même nombre de classes pour  $N < 200$ .

## Définition

Rappelons que l'étendu d'une variable statistique  $X$  est défini par

$$e := x_{\max} - x_{\min}.$$

Souvent on considère des classes de même amplitude définie par


$$a_i := \frac{\text{étendu}}{\text{nombre de classes}} = \frac{x_{\max} - x_{\min}}{k}.$$

## Effectif d'une classe

La quantité

$$n_i := \text{Card} \{ \omega \in \Omega \text{ tel que } X(\omega) \in C_i \}$$

s'appelle effectif de la classe  $C_i := [L_i, L_{i+1}[$ .



**FIGURE:** Effectif d'une classe : le nombre d'individus prenant des valeurs appartenant à la classe.

## Fréquence d'une classe

Le nombre

$$f_i := \frac{n_i}{N}$$

est appelé fréquence de la classe  $C_i$ .

## Effectif cumulée d'une classe

On appelle effectif cumulé de la classe  $C_i$  la quantité

$$N_i := \sum_{j=1}^i n_j.$$

## Fréquence cumulé d'une classe

On appelle fréquence cumulée de la classe  $C_i$  la quantité

$$F_i := \sum_{j=1}^i f_j.$$

## Remarques


Comme dans le chapitre précédent, on utilise les notations suivantes

- $n_i$  : le nombre d'individus de l'échantillon dont les valeurs des caractères sont dans la classe  $C_i$  ;
- $f_i$  : le pourcentage des  $\omega$  de l'échantillon tels que  $X(\omega) \in C_i$  ;
- $N_i$  : est égale au  $\text{Card}\{\omega \in \Omega_N; X(\omega) \in C_1 \cup C_2 \cup \dots \cup C_i\}$  ;
- $F_i$  : est le pourcentage des  $\omega \in \Omega_N$  tels que

$$X(\omega) \in C_1 \cup \dots \cup C_i.$$

## Représentation graphique d'un caractère continu

- **Histogramme des fréquences (ou effectifs)** : Nous pouvons représenter un tableau statistique par un histogramme. Nous reportons les classes sur l'axe des abscisses et, au-dessus de chacune d'elles, nous traçons un rectangle dont l'aire est proportionnelle à la fréquence  $f_i$  (ou l'effectif  $n_i$ ) associée :



**FIGURE:** Histogramme des fréquences (ou des effectifs)

- Fonction de répartition** : On appelle fonction de répartition  $F_X(\cdot)$  de la variable statistique  $X$  la fonction  $F_X : \mathbb{R} \rightarrow [0, 1]$  et qui à tout  $x \in \mathbb{R}$  associe la valeur  $F_X(x)$  donnant le pourcentage d'individus  $\omega$  dont la valeur du caractère  $X(\omega) \leq x$ . Plus précisément,

$$F_X(x) = \begin{cases} 0, & \text{si } x < L_0, \\ f_1 \frac{(x-L_0)}{L_1-L_0}, & \text{si } L_0 \leq x < L_1, \\ \vdots & \vdots \\ F_i + f_{i+1} \frac{(x-L_i)}{L_{i+1}-L_i} & \text{si } L_i \leq x < L_{i+1}, \\ \vdots & \vdots \\ 1 & \text{si } x \geq L_n. \end{cases}$$

- Les valeurs de  $F_X(x)$  précédentes sont calculées par interpolation linéaire (voir figure ci-dessous). Nous avons déjà  $F(L_i) = F_i, \forall i$ . De plus, nous avons, pour tout  $x \in [L_i, L_{i+1}]$ ,

$$\tan(\alpha) = \frac{F(L_{i+1}) - F(L_i)}{L_{i+1} - L_i} = \frac{F(x) - F(L_i)}{x - L_i}.$$

D'où

$$F(x) = F_i + f_{i+1} \frac{(x - L_i)}{L_{i+1} - L_i}.$$




FIGURE: Calcul de  $F_X(\cdot)$  par interpolation

- La fonction de répartition  $F_X(\cdot)$  est croissante, nulle avant  $L_0$ , constante égale à 1 après  $L_n$ , et joint les points  $(L_0, 0)$ ,  $(L_1, F_1)$ ,  $\dots$ ,  $(L_n, 1)$  par des segments de droites :



FIGURE: La courbe des fréquences cumulées

## Paramètres de tendance central

On note par  $c_i$  le centre de la classe  $C_i$ , et par  $f_i$  la fréquence de la classe  $C_i$ .



FIGURE: Le centre de la classe

- **La moyenne** : On définit la moyenne “empirique” de  $X$  par

$$\bar{x} := \sum_{i=1}^n f_i c_i.$$

La définition suivante permet de comprendre la démarche à suivre pour calculer le mode d'une manière exacte et qui se trouve dans une des classes appelée "classe modale".

- **Le mode** : On définit la classe modale comme étant la classe des valeurs de  $X$  qui a le plus grand effectif (ou la plus grande fréquence). La quantité

$$M_0 := L_i + \frac{\Delta_1}{\Delta_1 + \Delta_2} a_i$$

s'appelle le mode "empirique" de  $X$ , avec (voir figure ci-dessous)

- $L_i$  : la borne inférieure de la classe modale ;
- $a_i$  : l'amplitude de la classe modale ;
- $\Delta_1 := n_0 - n_1$ ,  $\Delta_2 := n_0 - n_2$  ou  $\Delta_1 := f_0 - f_1$ ,  $\Delta_2 := f_0 - f_2$  ;
- $n_0$  et  $f_0$  sont l'effectif et la fréquence de la classe modale ;
- $n_1$  et  $f_1$  sont l'effectif et la fréquence de la classe qui précède la classe modale ;
- $n_2$  et  $f_2$  sont l'effectif et la fréquence de la classe qui suit la classe modale.




FIGURE: Le mode d'une variable statistique continue

### Remarque

L'expression du mode donnée ci-dessus est déterminée à partir de l'intersection des deux segments représentés dans la figure ci-dessus. Cette notion n'est pas unique.

- **La médiane** : La médiane “empirique” de  $X$  est la valeur  $M_e$  telle que  $F_X(M_e) = 0.5$ . Elle est définie de manière unique.

Nous pouvons la déterminer graphiquement ou par calcul :

- **Première méthode** : Graphiquement à partir de la formule

$$\tan(\alpha) = \frac{F(L_{i+1}) - F(L_i)}{L_{i+1} - L_i} = \frac{0.5 - F(L_i)}{M_e - L_i}.$$

Plus précisément, dans la figure ci-dessous, nous prenons  $F(x) = 0.5$  et  $x = M_e$ .

- **Deuxième méthode** : En utilisant directement la fonction de répartition donnée par

$$F(x) = f_{i+1} \frac{x - L_i}{L_{i+1} - L_i} + F_i,$$

nous retrouvons donc

$$0.5 = f_{i+1} \frac{M_e - L_i}{L_{i+1} - L_i} + F_i$$

D'où

$$M_e = \frac{0.5 - F_i}{f_{i+1}}(L_{i+1} - L_i) + L_i.$$




FIGURE: Calcul de la médiane par interpolation

## Paramètres de dispersion

- **La variance** : La variance “empirique” de  $X$  est la quantité positive définie par

$$\begin{aligned}\text{Var}(X) &:= \sum_{i=1}^n f_i (c_i - \bar{x})^2 \\ &= \left( \sum_{i=1}^n f_i c_i^2 \right) - \bar{x}^2.\end{aligned}$$

- **L'écart-type** : La quantité

$$\sigma_X := \sqrt{\text{Var}(X)}$$

s'appelle l'écart-type “empirique” de la variable statistique  $X$ .

On généralise la notion de la médiane dans ce qui suit

- **Quartiles** : Pour  $i \in \{1, 2, 3\}$ , la quantité  $Q_i$  telle que

$$F(Q_i) = \frac{i}{4}$$

s'appelle le  $i^{\text{eme}}$  quartile.

Pour  $i = 2$ , on retrouve la médiane

$$Q_2 = M_e.$$

Le calcul des quartiles  $Q_i$  se fait exactement comme le calcul de la médiane (graphiquement ou analytiquement).

- **Interprétation** : Il y a 25% d'individus de l'échantillon dont la valeur du caractère est dans l'intervalle  $[L_0, Q_1]$ . De même pour les autres quartiles. Ces intervalles s'appellent "intervalles interquartiles".




FIGURE: Les quartiles

Un même individu peut être étudié à l'aide de plusieurs caractères (ou variables statistiques). Par exemple, les salariés en regardant leur ancienneté et leur niveau d'étude, la croissance d'un enfant en regardant son poids et sa taille. Dans la suite, nous introduisons l'étude globale des relations entre deux variables statistiques.

Soient  $\Omega$  une population, et  $Z := (X, Y)$  l'application définie par

$$\begin{aligned} Z &: \Omega \rightarrow \mathbb{R}^2 \\ \omega &\mapsto Z(\omega) := (X(\omega), Y(\omega)). \end{aligned}$$

Elle est appelée couple de variables statistiques.

## Exemples

- On observe simultanément sur un échantillon de 200 foyers, le nombre d'enfants  $X$  et le nombre de chambres  $Y$  ;
- On observe sur un échantillon de 20 foyers, le revenu mensuel  $X$  et les dépenses mensuelles  $Y$  ;
- Une entreprise mène une étude sur la liaison entre les dépenses mensuelles en publicité  $X$  et le volume des ventes  $Y$  qu'elle réalise.

## Représentation des séries statistiques à deux variables

Les séries statistiques à deux variables peuvent être présentées de deux façons :

- **Présentation 1** : A chaque  $\omega_i$ , on associe  $(x_i, y_i) := (X(\omega_i), Y(\omega_i))$  :

$$\omega_i \mapsto (x_i, y_i) := (X(\omega_i), Y(\omega_i)).$$

On rassemblera les données dans un tableau comme suit

|               |               |               |          |               |
|---------------|---------------|---------------|----------|---------------|
| $\omega_i$    | $\omega_1$    | $\omega_2$    | $\cdots$ | $\omega_N$    |
| $X(\omega_i)$ | $X(\omega_1)$ | $X(\omega_2)$ | $\cdots$ | $X(\omega_N)$ |
| $Y(\omega_i)$ | $Y(\omega_1)$ | $Y(\omega_2)$ | $\cdots$ | $Y(\omega_N)$ |

## Exemple

Soit le couple de variables statistiques  $(X, Y)$  donnant, respectivement, le nombre d'heures de préparation à l'examen d'algèbre et la note obtenue à cet examen. On a observé  $(X, Y)$  sur un ensemble  $\Omega_N$  de 8 étudiants et on a obtenu la série statistique

| $\omega_i$    | $\omega_1$ | $\omega_2$ | $\omega_3$ | $\omega_4$ | $\omega_5$ | $\omega_6$ | $\omega_7$ | $\omega_8$ |
|---------------|------------|------------|------------|------------|------------|------------|------------|------------|
| $X(\omega_i)$ | 8          | 2          | 6          | 6          | 11         | 10         | 7          | 2          |
| $Y(\omega_i)$ | 9          | 10         | 11         | 7          | 14         | 16         | 12         | 5          |

Nous pouvons traduire le tableau associe dans une figure appelée “le nuage de points” ou “diagramme de dispersion” (voir figure ci-dessous). Cette représentation est obtenue en représentant dans un repère cartésien chaque couple d'observation  $(x_i, y_i)$  par un point :




FIGURE: Représentation sous forme de nuage de points

- **Présentation 2** : Soit le couple de variables statistiques  $Z := (X, Y)$ . On observe ce couple sur un échantillon  $\Omega_N$  de  $N$  individus choisis de manière aléatoire et indépendante de la population  $\Omega$ . Notons par  $x_1, \dots, x_k$  et  $y_1, \dots, y_\ell$ , respectivement, les valeurs (différentes) prise par  $X$  et  $Y$ . Les valeurs prises par  $Z$  seront notées

$$z_{i,j} := (x_i, y_j), \quad i = 1, \dots, k, j = 1, \dots, \ell.$$

On définit également les effectifs (voir figure ci-dessous)


$$n_{i,j} := \text{Card}\{\omega \in \Omega_N; Z(\omega) = z_{i,j}\}, \quad i = 1, \dots, k, j = 1, \dots, \ell,$$

et les fréquences

$$f_{i,j} := \frac{n_{i,j}}{N}, \quad i = 1, \dots, k, j = 1, \dots, \ell,$$

avec

$$N = \text{Card}(\Omega_N) = \sum_{i=1}^k \sum_{j=1}^{\ell} N_{i,j} = \sum_{j=1}^{\ell} \sum_{i=1}^k N_{i,j}.$$



**FIGURE:**  $n_{i,j}$  : le nombre d'individus de l'échantillon prenant simultanément les valeurs  $x_i$  et  $y_j$ .

Les données peuvent être organisées dans un tableau, appelé tableau de contingence, prenant la forme

| $X Y$                     | $[L'_1, L'_2[$ ou $y_1$        | $\cdots$ | $[L'_\ell, L'_{\ell+1}[$ ou $y_\ell$ | $X$                            |
|---------------------------|--------------------------------|----------|--------------------------------------|--------------------------------|
| $[L_1, L_2[$ ou $x_1$     | $n_{1,1}$ ou $f_{1,1}$         | $\cdots$ | $n_{1,\ell}$ ou $f_{1,\ell}$         | $n_{1,\cdot}$ ou $f_{1,\cdot}$ |
| $\vdots$                  | $\vdots$                       | $\vdots$ | $\vdots$                             | $\vdots$                       |
| $[L_k, L_{k+1}[$ ou $x_k$ | $n_{k,1}$ ou $f_{k,1}$         | $\cdots$ | $n_{k,\ell}$ ou $f_{k,\ell}$         | $n_{k,\cdot}$ ou $f_{k,\cdot}$ |
| $Y$                       | $n_{\cdot,1}$ ou $f_{\cdot,1}$ | $\cdots$ | $n_{\cdot,\ell}$ ou $f_{\cdot,\ell}$ | $N$                            |

TABLE: Tableau de contingence

- Notons que

$$\sum_{i=1}^k \sum_{j=1}^{\ell} f_{i,j} = \sum_{j=1}^{\ell} \sum_{i=1}^k f_{i,j} = 1.$$

## Lois marginales

Sur la marge du tableau de contingence, on peut extraire les données seulement par rapport à  $X$ , et seulement par rapport à  $Y$  (voir le tableau de contingence précédent).

(1) Effectifs et fréquences de  $Y : \forall j = 1, \dots, \ell$ , on a

$$n_{\cdot,j} := \sum_{i=1}^k n_{i,j}, \quad f_{\cdot,j} := \frac{n_{\cdot,j}}{N} = \sum_{i=1}^k f_{i,j};$$

(2) Effectifs et fréquences de  $X : \forall i = 1, \dots, k$ , on a

$$n_{i,\cdot} := \sum_{j=1}^{\ell} n_{i,j}, \quad f_{i,\cdot} := \frac{n_{i,\cdot}}{N} = \sum_{j=1}^{\ell} f_{i,j}.$$

## Remarque

Nous avons les propriétés suivantes

$$\sum_{i=1}^k n_{i,\cdot} = \sum_{j=1}^{\ell} n_{\cdot,j} = N, \quad \sum_{i=1}^k f_{i,\cdot} = \sum_{j=1}^{\ell} f_{\cdot,j} = 1.$$

## Caractéristique des séries marginales

Dans le cas d'une variable statistique à deux dimensions  $X$  et  $Y$ , les moyennes sont données respectivement par

$$\bar{x} := \frac{1}{N} \sum_{i=1}^k n_{i,\cdot} x_i = \sum_{i=1}^k f_{i,\cdot} x_i \quad (\text{moyenne de } X)$$

et

$$\bar{y} := \frac{1}{N} \sum_{j=1}^{\ell} n_{\cdot,j} y_j = \sum_{j=1}^{\ell} f_{\cdot,j} y_j \quad (\text{moyenne de } Y).$$

## Remarque

Dans le cas continu,  $x_i$  et  $y_j$  représentent respectivement le centre des classes de  $X$  et  $Y$ , c'est à dire,

$$x_i := \frac{L_i + L_{i+1}}{2} \quad \text{et} \quad y_j := \frac{L_j + L_{j+1}}{2}.$$

## Variances et écarts-type

Nous définissons maintenant la variance de  $X$  et la variance de  $Y$  comme suit

$$\text{Var}(X) := \overline{x^2} - (\bar{x})^2, \quad \text{avec} \quad \overline{x^2} := \frac{1}{N} \sum_{i=1}^k n_{i,\cdot} x_i^2 = \sum_{i=1}^k f_{i,\cdot} x_i^2,$$

$$\text{Var}(Y) := \overline{y^2} - (\bar{y})^2, \quad \text{avec} \quad \overline{y^2} := \frac{1}{N} \sum_{j=1}^{\ell} n_{\cdot,j} y_j^2 = \sum_{j=1}^{\ell} f_{\cdot,j} y_j^2.$$

Les écarts-type de  $X$  et de  $Y$  sont donnés, respectivement, par

$$\sigma_X := \sqrt{\text{Var}(X)}, \quad \sigma_Y := \sqrt{\text{Var}(Y)}.$$

## Les séries conditionnelles

La notion de série conditionnelle est essentielle pour comprendre l'analyse de la régression. Un tableau de contingence se compose en autant de séries conditionnelles suivant chaque ligne et chaque colonne.

- **Série conditionnelle par rapport à  $X$**  : Elle est notée par  $X|y_j$ , et est appelée la série conditionnelle de  $X$  sachant que  $Y = y_j$ . Nous calculons dans ce cas les fréquences conditionnelles  $f_{i|j}$ , pour  $i = 1, \dots, k$ , par

$$f_{i|j} := \frac{n_{i,j}}{n_{\cdot,j}} := \frac{f_{i,j}}{f_{\cdot,j}}.$$

Nous définissons la moyenne conditionnelle  $\bar{x}_{|j}$ , c'est à dire la moyenne des valeurs de  $X$  sous l'évènement  $Y = y_j$ , par

$$\bar{x}_{|j} := \sum_{i=1}^k f_{i|j} x_i = \frac{1}{n_{\cdot j}} \sum_{i=1}^k n_{i,j} x_i, \quad j = 1, \dots, \ell.$$

De même l'écart-type conditionnel est défini par

$$\sigma_{X|j} := \sqrt{\text{Var}(X)_{|j}} = \sqrt{\sum_{i=1}^k f_{i|j} (x_i - \bar{x}_{|j})^2} = \sqrt{\overline{x^2}_{|j} - (\bar{x}_{|j})^2},$$

$$j = 1, \dots, \ell.$$

- **Série conditionnelle par rapport à  $Y$**  : Elle est notée par  $Y|X_i$ , et est appelée la série conditionnelle de  $Y$  sachant  $X = x_i$ . Nous calculons aussi dans ce cas la fréquence conditionnelle  $f_{j|i}$ , pour  $j = 1, \dots, \ell$ , par

$$f_{j|i} := \frac{n_{i,j}}{n_{i,\cdot}} = \frac{f_{i,j}}{f_{i,\cdot}}.$$

La moyenne conditionnelle  $\bar{y}_{|i}$ , sachant  $X = x_i$ , est définie par

$$\bar{y}_{|i} := \sum_{j=1}^{\ell} f_{j|i} y_j = \frac{1}{n_{i,\cdot}} \sum_{j=1}^{\ell} n_{i,j} y_j.$$

De même l'écart-type conditionnel, sachant  $X = x_i$ , est défini par

$$\sigma_{Y|i} := \sqrt{\text{Var}(Y)_{|i}} = \sqrt{\sum_{j=1}^{\ell} f_{j|i} (y_j - \bar{y}_{|i})^2} = \sqrt{y^2_{|i} - (\bar{y}_{|i})^2},$$

$$i = 1, \dots, k.$$

## Notion de covariance

La covariance de  $X$  et  $Y$ , notée  $\text{Cov}(X, Y)$ , est définie par

$$\begin{aligned}\text{Cov}(X, Y) &:= \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^{\ell} n_{i,j} (x_i - \bar{x})(y_j - \bar{y}) \\ &= \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^{\ell} n_{i,j} x_i y_j - \bar{x} \bar{y} \\ &=: \overline{xy} - \bar{x} \bar{y}.\end{aligned}$$

La covariance est un paramètre qui donne la variabilité de  $X$  par rapport à  $Y$ .




FIGURE: La covariance et la variabilité

## Remarques

- Dans le cas où nous avons un tableau de données brutes “representation 1” (nous n'avons pas d'effectifs), nous avons les formules suivantes

$$\bar{x} := \frac{1}{N} \sum_{i=1}^N X(\omega_i) \quad \text{et} \quad \bar{y} := \frac{1}{N} \sum_{i=1}^N Y(\omega_i).$$

De plus, nous avons

$$\overline{xy} := \frac{1}{N} \sum_{i=1}^N X(\omega_i) Y(\omega_i).$$

- La covariance généralise la notion de variance. En effet, on a

$$\text{Cov}(X, X) = \text{Var}(X).$$

## Définition

On dit que deux séries statistique (associées à deux variables statistiques  $X$  et  $Y$ ) sont indépendantes si et seulement si, pour tout  $i$  et  $j$ ,

$$f_{i,j} = f_{i,\cdot} \times f_{\cdot,j},$$

où de manière équivalente

$$N \times n_{i,j} = n_{i,\cdot} \times n_{\cdot,j}.$$

Si les deux séries sont indépendantes, alors on a  $\text{Cov}(X, Y) = 0$ .  
La réciproque n'est pas toujours vraie.

## Ajustement linéaire

Dans le cas où on peut mettre en évidence l'existence d'une relation linéaire significative entre deux caractères quantitatifs continus  $X$  et  $Y$  (la silhouette du nuage de points est étirée dans une direction), on peut chercher à formaliser la relation moyenne qui unit ces deux variables à l'aide d'une équation de droite qui résume cette relation. Nous appelons cette démarche l'ajustement linéaire.

- **Coefficient de corrélation** : Le coefficient de corrélation (de Pearson) permet de mesurer la relation linéaire entre deux caractères (lorsque cette relation est monotone). Il est défini par

$$\rho_{XY} := \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$


## Propriétés du coefficient de corrélation

- On a :


$$|\rho_{xy}| \leq 1,$$

avec égalité si et seulement si la liaison est parfaitement linéaire (la droite d'ajustement passe par tous les points) ;


- Plus le module de  $\rho_{XY}$  est proche de 1 plus  $X$  et  $Y$  sont liées linéairement ;
- Plus le module de  $\rho_{XY}$  est proche de 0 plus il y a absence de liaison linéaire entre  $X$  et  $Y$ .



**FIGURE:** À gauche, le coefficient de corrélation est proche de 1. À droite, le coefficient de corrélation est proche de 0.



**FIGURE:** Exemples de diagrammes de dispersion avec différentes valeurs de coefficient de corrélation



**FIGURE:** La corrélation reflète la non-linéarité et la direction d'une relation linéaire mais pas la pente de cette relation ni de nombreux aspects des relations non linéaires (en bas). La figure au centre a une pente de 0, mais dans ce cas, le coefficient de corrélation est indéfini car la variance de  $Y$  est nulle.

## Droite de régression

L'idée est de transformer un nuage de points en une droite. Celle-ci doit être la plus proche possible de chacun des points. On cherchera donc à minimiser les écarts entre les points et la droite.




FIGURE: La droite de régression

Cette méthode vise à expliquer un nuage de points par une droite qui lie  $Y$  à  $X$ , c'est à dire,  $Y = aX + b$ , telle que la distance entre le nuage de points et la droite soit minimale. Ainsi, la méthode des moindres carrés consiste à chercher la valeur des paramètres  $a$  et  $b$  qui minimise la somme des erreurs élevées au carré. L'erreur quadratique moyenne est définie par

$$U(a, b) := \frac{1}{N} \sum_{i=1}^N e_i^2,$$

où

$$|e_i| = |y_i - y_i^*| = |y_i - a x_i - b|$$

qui représente la différence entre le point réellement observé  $y_i$  et le point prédit par la droite  $y_i^* := a x_i + b$ .

La méthode des moindres carrés consiste donc à minimiser la fonction  $U(a, b)$  en  $a$  et  $b$ . Nous avons la condition de minimisation suivante,

$$\frac{\partial U}{\partial a} = \frac{\partial U}{\partial b} = 0,$$

avec

$$U(a, b) = \frac{1}{N} \sum_{i=1}^N (y_i - ax_i - b)^2.$$

L'équation  $\frac{\partial U}{\partial a} = 0$  implique  $b = \bar{y} - a\bar{x}$ . L'équation  $\frac{\partial U}{\partial b} = 0$  implique

$$a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}.$$

Donc, la droite de régression, qui rend la distance, entre elle et les points, minimale, est

$$Y = aX + b$$

avec

$$a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \quad \text{et} \quad b = \bar{y} - a\bar{x}.$$

## Remarque

Le coefficient de corrélation  $\rho_{XY}$  permet de justifier le fait de l'ajustement linéaire. On adopte les critères numériques suivants

- Si  $|\rho_{XY}| < 0.7$ , alors l'ajustement linéaire est refusé ;
- Si  $|\rho_{XY}| \geq 0.7$ , alors l'ajustement linéaire est accepté.




FIGURE: La région d'acceptation ou de refus de l'ajustement linéaire