

Analyse univariée



Mme Yahiaoui:

- Statistiques pour l'informatique -

2024-2025

28

Les types de variables

Variables nominales

Variables ordinales

Variables discrètes

Variables continues

?

Les statistiques descriptives

Le tableau statistique

Les représentations graphiques

Les mesures de tendance centrale

Les mesures de dispersion

Mme Yahiaoui:

- Statistiques pour l'informatique -

29

Les variables nominales

Mme Yahiaoui:

- Statistiques pour l'informatique -

2024-2025

30




Mme Yahiaoui:

- Statistiques pour l'informatique -

2024-2025

31



32

Les statistiques descriptives

Soit un échantillon $\Omega_N := \{\omega_1, \omega_2, \dots, \omega_N\}$ collecté lors d'une épreuve statistique.

N représente la taille de l'échantillon, $N = \text{Card}(\Omega_N)$.
 ω_i représente le $i^{\text{ème}}$ individu de l'échantillon.

On observe la variable aléatoire X sur chacun des individus :

$$X : \Omega_N \rightarrow C$$

33

Tableau statistique

- Il permet d'organiser les données et de résumer l'information observée sur un échantillon ou une population.
- Pour les variables qualitatives il comporte :
 - Les modalités** : les différentes valeurs possibles prise par la variable.
 - Effectif** : le nombre d'individus correspondant à chaque modalité.
 - Fréquence** : la proportion d'individus correspondant à chaque modalité.
 - Fréquence en pourcentage** : les fréquences exprimées en %.

34

Modalités

- La variable aléatoire observée X est une application de l'ensemble échantillon vers l'ensemble des modalités

$$X : \Omega_N \rightarrow C$$

$$X(\Omega_N) := \{X(\omega) \text{ tel que } \omega \in \Omega_N\}$$

$$X(\Omega_N) := \{X(\omega_1), X(\omega_2), X(\omega_3), \dots, X(\omega_N)\}$$

$$X(\Omega_N) := \{x_1, x_2, x_3, \dots, x_n\} \quad n \leq N$$

$$C := \{x_1, x_2, x_3, \dots, x_n\}$$

- Une modalité x_i est une valeur possible que peut prendre une variable statistique.
- $n = \text{Card}(X(\Omega_N)) = \text{Card}(C)$

35

Les effectifs

- L'effectif d'une modalité est le nombre d'individus de la population ou de l'échantillon qui présentent cette modalité.
- On note par « n_i » l'effectif de la modalité x_i dans l'échantillon.

$$n_i = \text{Card} \{ \omega \in \Omega_N : X(\omega) = x_i \}$$

- La somme des effectifs donne la taille de la population ou de l'échantillon.

$$N = \sum_{i=1}^n n_i$$

36

Les fréquences

- La fréquence d'une modalité est la proportion d'individus présentant cette modalité par rapport à l'effectif total.

$$f_i = \frac{n_i}{N}, \text{ avec } 0 \leq f_i \leq 1$$

- La somme des fréquences vaut 1 :

$$\sum_{i=1}^n f_i = 1$$

37

Les fréquences en pourcentage

- La fréquence en pourcentage est la fréquence multipliée par 100, ce qui permet une lecture plus intuitive.

$$fp_i (\%) = f_i \times 100 = \frac{n_i}{N} \times 100$$

- La somme des fréquences en % vaut 100% :

$$\sum_{i=1}^n fp_i (\%) = 100\%$$

38

Les mesures de tendance centrale

- Les mesures de tendance centrale permettent de résumer une série statistique par une valeur « représentative » ou « typique ».
- Pour une variable nominale, seul le mode peut être calculé.

- Le mode



- La moyenne arithmétique



- La médiane



39

Le mode pour une variable qualitative


- Le **mode** est la modalité qui possède l'**effectif le plus élevé**.
- C'est la modalité la plus fréquente observée dans la population ou l'échantillon.
- Si n_i est l'effectif associé à la valeur x_i , alors:

$$M = \text{Mode}(X) = x_j \text{ tel que } n_j = \max \{ n_1, n_2, \dots, n_k \}$$

40

Représentations graphiques pour variables qualitatives

► Diagramme en bandes




► Diagramme en secteurs angulaires



41

Diagramme en bandes « Tuyaux d'orgue »

- C'est une représentation des effectifs (ou fréquences ou fréquences en pourcentage) par des **rectangles verticaux contigus**, de même largeur, dont la hauteur est proportionnelle à la valeur représentée.
- Aspect visuel proche d'un histogramme, mais ici les rectangles sont séparés et servent aux données qualitatives.




42

Diagramme en secteurs angulaires « camembert »

- C'est un cercle découpé en secteurs, chaque secteur représentant une modalité.
- La surface (angle) de chaque secteur est proportionnelle à la fréquence.
- Très adapté pour les **variables qualitatives**.
- Pour une modalité x_i de fréquence f_i :

$$\theta_i = f_i \times 360^\circ = \frac{n_i}{N} \times 360^\circ$$



43

- Exemples de variables nominales :
 - Marque du téléphone d'un échantillon d'étudiants
 - Marque de voiture d'un échantillon d'étudiants
 - Sports pratiqués par un échantillon d'étudiants
 - Marque d'ordinateurs d'un échantillon d'étudiants
 - Réseau social le plus utilisé par un échantillon d'étudiants
 - Type de logement d'un échantillon d'étudiants
- L'échantillon est construit à partir des réponses données par les étudiants.
- Calcul du tableau statistique
- Représentation graphique de la variable statistique
 - Diagramme en bandes « tuyaux d'orgues »
 - Diagramme circulaire « diagramme à secteurs angulaires ou camembert »
- Calcul du mode

44

Exemple d'étude d'une variable nominale

- L'épreuve statistique a porté sur l'analyse des sports pratiqués par un échantillon de 20 étudiants. Voici les réponses enregistrées

$\Omega_N = [\text{"Football", "Football", "Basket", "Natation", "Football", "Basket", "Tennis", "Natation", "Football", "Basket", "Natation", "Football", "Basket", "Tennis", "Football", "Basket", "Natation", "Tennis", "Football", "Basket"}]$

- $N = \text{Card}(\Omega_N) = 20$
- $C = X(\Omega_N) = \{ \text{"Football", "Basket", "Natation", "Tennis"} \}$
- $n = \text{Card}(C) = 4$

45

Tableau statistique


Les modalités « x_i »	Les effectifs « n_i »	Les fréquences « f_i »	Les pourcentages « $fp_i \%$ »
"Football"	7	0.30	30 %
"Basket"	6	0.35	35 %
"Natation"	4	0.20	20 %
"Tennis"	3	0.15	15 %

46

Calcul du mode

Les modalités « x_i »	Les effectifs « n_i »	Les fréquences « f_i »	Les pourcentages « $fp_i \%$ »
Mode = "Football" ⚽	7 $\text{Max}(n_i)$	0.30 $\text{Max}(f_i)$	30 % $\text{Max}(fp_i)$
"Basket"	6	0.35	35 %
"Natation"	4	0.20	20 %
"Tennis"	3	0.15	15 %


47




48

Les variables ordinales

49



50



51

Les mesures de tendance centrale et de dispersion

- Une série d'une variable ordinale peut être résumée par le **mode** et parfois la **médiane** selon l'échantillon étudié.
- Il est aussi parfois possible de calculer les mesures de dispersion **Q1** et **Q3** mais pas **EIQ**.

► Le mode ✓

► La médiane ?

► La moyenne ✗

Q1 ?

Q2 ?

EIQ ✗

52

Opération et modalités

- Il est possible d'établir un classement des modalités d'une variable ordinale, de la plus petite modalité à la plus grande ou inversement.
- Les opérations arithmétiques comme la somme, la moyenne ou autre opération n'ont pas de sens strict pour les variables ordinales.
- Les écarts entre les modalités **ne sont pas nécessairement égaux**.

53

La médiane = le deuxième quartile

- La médiane est la valeur qui partage une série ordonnée en deux parties de même effectif.
 - 50% des observations sont **inférieures** ou égales à la médiane.
 - 50% des observations sont **supérieures** ou égales à la médiane.
- Pour calculer la médiane, on ordonne la série des observations

$X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \dots X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega) \ X(\omega)$
 50% 50%
 Me = Q₂

54

La médiane d'une variable ordinale

- Si N est impair : On prend la valeur au milieu de la série.

$$Me \text{ (Médiane)} = \frac{x_{N+1}}{2} \quad \checkmark$$

- Si N est pair : On regarde les deux valeurs centrales ?


$$\text{Si } \frac{x_N}{2} = \frac{x_{N+1}}{2} \text{ alors } Me \text{ (Médiane)} = \frac{x_N}{2} = \frac{x_{N+1}}{2} \quad \checkmark$$

Sinon impossible de calculer la médiane Me ✗

55

Le premier quartile Q_1

- Le premier quartile Q_1 est la valeur qui partage une série ordonnée en deux parties telles que :
 - 25% des observations sont **inférieures** ou égales à Q_1 .
 - 75% des observations sont **supérieures** ou égales à Q_1 .
- Pour calculer la médiane, on ordonne la série des observations



56

Le premier quartile Q_1 d'une variable ordinale

- La position de la valeur Q_1 est $\frac{N+1}{4}$ dans la série ordonnée.
- $$\text{pos}(Q_1) = \frac{N+1}{4}$$
- Si $\text{pos}(Q_1)$ est un entier : On prend la valeur de la série correspondante à cette position.

$$Q_1 = x_{\frac{N+1}{4}} \quad \checkmark$$

- Si $\text{pos}(Q_1)$ n'est pas un entier : On arrondit au **rang inférieur** et au **rang supérieur** (les deux observations encadrantes).


$$\text{rang inférieur} = \lfloor \frac{N+1}{4} \rfloor ; \text{rang supérieur} = \lceil \frac{N+1}{4} \rceil$$

- Si les deux valeurs sont **identiques** : $Q_1 = x_{\text{rang inférieur}} = x_{\text{rang supérieur}}$ $\checkmark$
- Sinon **impossible** de calculer Q_1 $\times$

57

Le troisième quartile Q_3

- Le troisième quartile Q_3 est la valeur qui partage une série ordonnée en deux parties telles que :
 - 75% des observations sont **inférieures** ou égales à Q_3 .
 - 25% des observations sont **supérieures** ou égales à Q_3 .
- Pour calculer la médiane, on ordonne la série des observations



58

Le troisième quartile Q_3 d'une variable ordinale

- La position de la valeur Q_3 est $\frac{3(N+1)}{4}$ dans la série ordonnée.
- $$\text{pos}(Q_3) = \frac{3(N+1)}{4}$$
- Si $\text{pos}(Q_3)$ est un entier : On prend la valeur de la série correspondante à cette position.

$$Q_3 = x_{\frac{3(N+1)}{4}} \quad \checkmark$$

- Si $\text{pos}(Q_3)$ n'est pas un entier : On arrondit au **rang inférieur** et au **rang supérieur** (les deux observations encadrantes).

$$\text{rang inférieur} = \lfloor \frac{3(N+1)}{4} \rfloor ; \text{rang supérieur} = \lceil \frac{3(N+1)}{4} \rceil$$

- Si les deux valeurs sont **identiques** : $Q_3 = x_{\text{rang inférieur}} = x_{\text{rang supérieur}}$ $\checkmark$
- Sinon **impossible** de calculer Q_3 $\times$

59

- **Exemples de variables ordinales :**
 - La période de la journée où les étudiants révisent leurs cours
 - La fréquence de travail dans la BU
 - Mention obtenue au bac
 - Niveau de satisfaction de la formation ou d'un cours
 - Perception de la difficulté d'un cours
 - Participation en classe
 - Appréciation de la cantine universitaire
- **L'échantillon est proposé par les étudiants.**
- **Calcul du tableau statistique**
- **Représentation graphique de la variable statistique**
 - Diagramme en bandes « tuyaux d'orgues »
 - Diagramme circulaire « diagramme à secteurs angulaires ou camembert »
- **Calcul du mode et calcul de la médiane, du Q1 et Q3 si possible.**

60

Exemple d'étude d'une variable ordinale

- L'épreuve statistique porte sur l'analyse du niveau d'épices de 24 plats mondiaux.

Plats = ["Pizza Margherita", "Sushi", "Paella", "Falafel", "Ratatouille", "Pad Thai", "Curry indien", "Chili con carne", "Shakshuka", "Biryani", "Kimchi", "Mapo Tofu", "Tacos al pastor", "Couscous royal", "Sichuan Hot Pot", "Vindaloo", "Sambal", "Jerk Chicken", "Laab", "Phall Curry", "Butter Chicken", "Tom Yum", "Enchiladas", "Massaman Curry"]

OriginePlats = ["Italie", "Japon", "Espagne", "Moyen-Orient", "France", "Thaïlande", "Inde", "Mexique/USA", "Afrique du Nord", "Inde/Pakistan", "Corée du Sud", "Chine (Sichuan)", "Mexique", "Maghreb", "Chine (Sichuan)", "Inde (Goa)", "Indonésie/Malaisie", "Jamaïque", "Laos/Thaïlande", "Royaume-Uni (indienne)", "Inde", "Thaïlande", "Mexique", "Thaïlande"]

61

Exemple d'étude d'une variable ordinale

L'échantillon Ω_N comportera les niveaux d'épices des 24 plats retenus.

Ω_N = ["Doux", "Doux", "Doux", "Doux", "Doux", "Épicé", "Épicé", "Épicé", "Épicé", "Épicé", "Piquant", "Piquant", "Piquant", "Piquant", "Extra-fort", "Extra-fort", "Extra-fort", "Extra-fort", "Extra-fort", "Doux", "Épicé", "Piquant", "Épicé"]

- $N = \text{Card}(\Omega_N) = 24$
- $C = X(\Omega_N) = \{ \text{"Doux", "Épicé", "Piquant", "Extra-fort"} \}$
- **Relation d'ordre :** "Doux" < "Épicé" < "Piquant" < "Extra-fort"
- $n = \text{Card}(C) = 4$

62

Tableau statistique


Les modalités « x_i »	Les effectifs « n_i »	Les fréquences « f_i »	Les pourcentages « $fp_i\%$ »
"Doux"	6	0.25	25 %
"Épicé"	6	0,25	25 %
"Piquant"	5	0.2083	20.83 %
"Extra-fort"	7	0.2917	29.17 %

63


Calcul du mode

Les modalités « x_i »	Les effectifs « n_i »	Les fréquences « f_i »	Les pourcentages « $fp_i\%$ »
"Doux"	6	0.25	25 %
"Épicé"	6	0,25	25 %
"Piquant"	5	0.2083	20.83 %
Mode="Extra-fort" 	7 ^{Max(n_i)}	0.2917 ^{Max(f_i)}	29.17 % ^{Max(fp_i)}


64

Calcul de la médiane « Q_2 »Il n'est pas possible de calculer Me « Q_2 »


65

Calcul du premier quartile: Q_1 Il n'est pas possible de calculer Q_1 


66

Calcul du troisième quartile: Q_3
 Il est possible de calculer
 $Q_3 = \text{"Extra-fort"}$


67



68



69