



Les variables discrètes

70



71



72

Tableau statistique

- ▶ Contrairement aux variables qualitatives, on peut effectuer des opérations sur les modalités d'une variable quantitative (ex. somme, moyenne).
- ▶ En plus des colonnes déjà présentes (modalités, effectifs, fréquences, fréquences en %), on trouve :
 - ▶ **Effectifs cumulés** : nombre total d'individus jusqu'à une valeur donnée.
 - ▶ **Fréquences cumulées** : proportion d'individus jusqu'à une valeur donnée.
 - ▶ **Fréquences cumulées en %** : fréquences cumulées exprimées en pourcentage.

73

Effectifs cumulés

- L'**effectif cumulé** d'une modalité x_i est la somme des effectifs de toutes les modalités **jusqu'à** x_i .

$$N_i = \sum_{j=1}^i n_j$$

- Le **dernier effectif cumulé** vaut l'**effectif total**.

$$N_n = N$$

74

Fréquences cumulées

- La **fréquence cumulée** d'une modalité x_i est la somme des fréquences de toutes les modalités **jusqu'à** x_i .

$$F_i = \sum_{j=1}^i f_j = \frac{N_i}{N}$$

- La **dernière fréquence cumulée** vaut 1 :

$$F_n = 1$$

75

Fréquences en pourcentage cumulées

- La **fréquence en pourcentage cumulée** d'une modalité x_i est la somme des fréquences en pourcentage % **jusqu'à** x_i .

$$FP_i = \sum_{j=1}^i fp_j = 100\% \times \frac{N_i}{N}$$

- La **dernière valeur** est toujours 100% :

$$FP_n = 100\%$$

76

Les mesures de tendance centrale

- Les **mesures de tendance centrale** permettent de résumer une série statistique par une **valeur « représentative »** ou « **typique** ».

- Ces mesures sont :

- Le **mode** ✓

- La **moyenne arithmétique** ✓

- La **médiane** ✓

77

Le mode

- Le **mode** est la **valeur** qui possède l'**effectif le plus élevé**.
- C'est donc la **valeur la plus fréquente** observée dans la série.

- Si n_i est l'effectif associé à la valeur x_i , alors:

$$M(\text{Mode}) = x_j \text{ tel que } n_j = \max \{ n_1, n_2, \dots, n_k \}$$

78

La moyenne arithmétique

- La **moyenne arithmétique** $\bar{x}$ est égale à la somme de toutes les observations, divisée par le nombre total d'individus.

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N X(\omega_i) \quad \bar{x} = \frac{1}{N} \sum_{i=1}^n (n_i \cdot x_i)$$

$$\bar{x} = \sum_{i=1}^n (f_i \cdot x_i)$$

$$N = \text{Card}(\Omega_N)$$

$$n = \text{Card}(C) = \text{Card}(X(\Omega_N))$$

79

La médiane = Le deuxième quartile Q_2

- Pour calculer la **médiane**, on ordonne la série des observations.

- Si N est impair : La médiane correspond à l'**observation centrale**.

$$Me(\text{Médiane}) = x_{\frac{N}{2}+1}$$

- Si N est pair : La médiane correspond à la **moyenne des deux observations centrales**.

$$Me(\text{Médiane}) = \frac{1}{2} (x_{\frac{N}{2}} + x_{\frac{N}{2}+1})$$


80

Calcul de la médiane à partir du tableau statistique

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
val ₁	n_1	N_1	f_1	F_1	$fp_1\%$	$FP_1\%$
val ₂	n_2	N_2	f_2	F_2	$fp_2\%$	$FP_2\%$
val ₃	n_3	N_3	f_3	F_3	$fp_3\%$	$FP_3\%$
...	...	...	...	...	...	...
Me(Médiane) = val _m	n_m	$N_m \geq N/2$	f_m	$F_m \geq 0.5$	$fp_m\%$	$FP_m\% \geq 50\%$
...	...	...	...	...	...	...
val _{n-2}	n_{n-2}	N_{n-2}	f_{n-2}	F_{n-2}	$fp_{n-2}\%$	$FP_{n-2}\%$
val _{n-1}	n_{n-1}	N_{n-1}	f_{n-1}	F_{n-1}	$fp_{n-1}\%$	$FP_{n-1}\%$
val _n	n_n	N_n	f_n	F_n	$fp_n\%$	$FP_n\%$

81

Calcul de la médiane à partir de la représentation graphique de la fonction de répartition



82

Les mesures de dispersion

► Les mesures de dispersion permettent de **quantifier l'étalement ou la variabilité** des valeurs d'une série statistique autour de sa tendance centrale.

- E : l'étendue
- Q_1 : le premier quartile
- Q_3 : le troisième quartile
- EIQ : l'écart inter-quartiles
- EM : l'écart moyen
- EAM : l'écart absolu moyen
- $Var(X)$: la variance
- s ou σ : l'écart type

83

Etendue

- L'**étendue** est la différence entre la plus grande et la plus petite valeur observée dans la série.
- Elle indique l'**amplitude totale** des valeurs observées, c'est-à-dire l'écart entre les extrêmes. Elle donne une idée rapide de la "largeur" des données.

$$E \text{ (étendue)} = \max(x_i) - \min(x_i)$$

- L'**étendue est très sensible aux valeurs aberrantes** : une seule donnée atypique peut fortement augmenter l'étendue et donner une impression de grande dispersion, même si la majorité des données sont regroupées.


84

Calcul du premier quartile à partir de tableau statistique

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
val_1	n_1	N_1	f_1	F_1	$fp_1\%$	$FP_1\%$
val_2	n_2	N_2	f_2	F_2	$fp_2\%$	$FP_2\%$
val_3	n_3	N_3	f_3	F_3	$fp_3\%$	$FP_3\%$
...	...	...	...	...	...	...
$Q_1 = val_q$	n_q	$N_q \geq N/4$	f_q	$F_q \geq 0,25$	$fp_q\%$	$FP_q\% \geq 25\%$
...	...	...	...	...	...	...
val_{n-2}	n_{n-2}	N_{n-2}	f_{n-2}	F_{n-2}	$fp_{n-2}\%$	$FP_{n-2}\%$
val_{n-1}	n_{n-1}	N_{n-1}	f_{n-1}	F_{n-1}	$fp_{n-1}\%$	$FP_{n-1}\%$
val_n	n_n	N_n	f_n	F_n	$fp_n\%$	$FP_n\%$

86

Calcul du premier quartile à partir de la représentation graphique de la fonction de répartition




87

Calcul du troisième quartile à partir de tableau statistique

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
val_1	n_1	N_1	f_1	F_1	$fp_1\%$	$FP_1\%$
val_2	n_2	N_2	f_2	F_2	$fp_2\%$	$FP_2\%$
val_3	n_3	N_3	f_3	F_3	$fp_3\%$	$FP_3\%$
...	...	...	...	...	...	...
$Q_3 = val_i$	n_i	$N_i \geq 3N/4$	f_i	$F_i \geq 0,75$	$fp_i\%$	$FP_i\% \geq 75\%$
...	...	...	...	...	...	...
val_{n-2}	n_{n-2}	N_{n-2}	f_{n-2}	F_{n-2}	$fp_{n-2}\%$	$FP_{n-2}\%$
val_{n-1}	n_{n-1}	N_{n-1}	f_{n-1}	F_{n-1}	$fp_{n-1}\%$	$FP_{n-1}\%$
val_n	n_n	N_n	f_n	F_n	$fp_n\%$	$FP_n\%$

89

Calcul du troisième quartile à partir de la représentation graphique de la fonction de répartition



90

EIQ : l'écart inter quartiles

- L'écart interquartile « EIQ » est la différence entre le troisième quartile Q_3 et le premier quartile Q_1 .
- Il mesure la **dispersion de la moitié centrale des données**, autrement dit, il indique dans quel intervalle se situent les **50% d'observations centrales**.

$$EIQ = Q_3 - Q_1$$

- Il est **moins sensible aux valeurs aberrantes** que l'étendue, car il ignore les 25% plus petits et les 25% plus grands.

91

L'écart moyen

- Ecart_moyen « EM » : L'écart moyen est la **moyenne arithmétique** des **écarts à la moyenne**.

$$EM = \overline{(X - x)}$$

- L'Ecart_moyen est **nulle par définition**.

$$EM = \frac{1}{N} \sum_{i=1}^n n_i \cdot (x_i - x) = \sum_{i=1}^n f_i \cdot (x_i - x) = 0$$

92

L'écart absolu moyen

- Ecart_absolu_moyen « EAM » : C'est la **moyenne arithmétique** des **écarts absolus à la moyenne**

$$EAM = \overline{|X - x|}$$

- L'écart absolu moyen mesure la **distance moyenne en valeur absolue** des observations à la moyenne.

$$EAM = \frac{1}{N} \sum_{i=1}^n n_i \cdot |x_i - x| = \sum_{i=1}^n f_i \cdot |x_i - x|$$

- La valeur absolue **supprime les signes négatifs** et **garde la même unité** que la variable X.

93

La variance

- La **variance (Var(X))** : C'est la **moyenne arithmétique** des **carrés** des **écarts des observations à la moyenne**.

$$\text{Var}(X) = \sigma^2 \text{ ou } s^2 = \overline{(X - x)^2}$$

- La **variance** mesure la **dispersion moyenne au carré** des valeurs autour de la moyenne.

$$\text{Var}(X) = \sigma^2 \text{ ou } s^2 = \frac{1}{N} \sum_{i=1}^n n_i \cdot (x_i - x)^2 = \sum_{i=1}^n f_i \cdot (x_i - x)^2$$

- L'élévation au carré sert à **supprimer les signes négatifs** et à **accentuer les écarts importants**.

94

L'écart type

- La variance ne garde pas la même unité que la variable X, elle est exprimée au carré de l'unité.

- Pour revenir à l'unité initiale, on calcule la racine de la variance, c'est l'écart-type.

- **Exemple** : si X en kg -> Var(X) en kg² mais l'écart-type en kg.

- L'écart-type, noté « s » pour un échantillon ou « σ » pour une population, mesure la **dispersion moyenne des valeurs autour de la moyenne**, exprimée dans l'unité de la variable.

$$s \text{ ou } \sigma = \sqrt{\text{Var}(X)} = \sqrt{\frac{1}{N} \sum_{i=1}^n n_i \cdot (x_i - x)^2} = \sqrt{\sum_{i=1}^n f_i \cdot (x_i - x)^2}$$

Dans ce cours, on normalise toujours par N pour simplifier

95

Mesure de dispersion relative

- Le **coefficient de variation** est le **rapport entre l'écart-type et la moyenne**, souvent exprimé en pourcentage.

$$CV = \frac{\sigma}{x} \text{ ou } CV = \frac{s}{x} \times 100\%$$

- Il mesure la **dispersion relative** des données par rapport à la moyenne.
- Non pertinent si la moyenne est proche de zéro (le CV devient très grand ou non interprétable).

96

Représentations graphiques

- Diagramme en bâtons** : c'est la représentation de base pour les variables discrètes.
- Boîte à moustaches** : utile pour comparer plusieurs distributions.
- Diagramme de la fonction de répartition** : permet de visualiser la probabilité cumulée d'obtenir une valeur $\leq x$.

97

Diagramme en bâtons

- C'est une représentation graphique où les valeurs « modalités » sont placées sur l'axe des abscisses et les effectifs ou fréquences ou fréquences en pourcentage sur l'axe des ordonnées.
- Chaque **valeur possible (modalité)** est associée à un **trait vertical (bâton)**.
- La hauteur du bâton est proportionnelle à l'effectif ou à la fréquence ou à la fréquence en pourcentage.

98

Diagramme en bâtons




Diagramme des effectifs (ou fréquence ou fréquence en pourcentage %)

99

Boite à moustaches


- Représentation graphique de la dispersion et des quartiles d'une série quantitative.
- La **boîte** est délimitée par $[Q_1, Q_3]$, avec une **ligne médiane** à Q_2 .
- Les **moustaches** s'étendent de $x_{\min}$ à $x_{\max}$.
- L'écart interquartile est visible :

$$EIQ = Q_3 - Q_1$$

- Idéale pour visualiser la **variabilité**, la **symétrie** et la présence de **valeurs aberrantes**.

100

Boite à moustaches




101

Digramme de la fonction de répartition

- Permet de visualiser la probabilité (ou fréquence) cumulée d'obtenir une valeur $\leq x$.
- Pour la **variable discrète**, la fonction de répartition est une **fonction en escalier** (non continue).
- Chaque saut correspond à l'ajout de la fréquence de la valeur observée.
- $F(x) = 0$ pour les valeurs **avant le minimum**
- $F(x) = 1$ pour les valeurs **au-delà du maximum**.

102

Digramme de la fonction de répartition



103

- **Exemples de variables discrètes**
 - Le nombre de stylos qu'a un étudiant
 - Nombre de livres empruntés à la BU
 - Nombre d'absences en cours
 - Nombre de langues étrangères parlées
 - Nombre de crédits ECTS validés par un étudiant
 - Nombre de stages effectués durant le cursus
 - Nombre de diplômes obtenus par un étudiant
 - Nombre de clubs ou associations étudiantes auxquels un étudiant participe
- **L'échantillon est proposé par les étudiants.**
- **Calcul du tableau statistique**
- **Représentation graphique de la variable statistique**
 - Diagramme en bâtons.
 - Boîte à moustaches
- **Calcul des mesures de tendance centrale**
 - Le mode, la médiane et la moyenne
- **Calcul des mesures de dispersion**
 - Etendu, Variance, écart-absolu, l'écart-type, $EQ = (Q_3 - Q_1)$.

104

Exemple d'étude d'une variable ordinale

► L'épreuve statistique porte sur l'étude du nombre de pièces pour des tiges de fleurs en lego.

► L'échantillon Ω_N comporte 12 tiges de fleurs.

$\Omega_N = [69, 120, 87, 71, 105, 69, 120, 105, 71, 105, 87, 105, 120]$


► $N = \text{Card}(\Omega_N) = 12$

► $C = X(\Omega_N) = \{69, 71, 87, 105, 120\}$

► $n = \text{Card}(C) = 5$



105



106

Le tableau statistique

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
69	2	2	0,154	0,154	15,38%	15,38%
71	2	4	0,154	0,308	15,38%	30,77%
87	2	6	0,154	0,462	15,38%	46,15%
105	4	10	0,308	0,769	30,77%	76,92%
120	3	13	0,231	1	23,08%	100%

107

Le mode

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
69	2	2	0,154	0,154	15,38%	15,38%
71	2	4	0,154	0,308	15,38%	30,77%
87	2	6	0,154	0,462	15,38%	46,15%
Mode = 105	Max(n_i) 4	10	Max(f_i) 0,308	0,769	Max(fp_i) 30,77%	76,92%
120	3	13	0,231	1	23,08%	100%

108

La moyenne


$$\bar{x} = \frac{1}{N} \sum_{i=1}^N X(\omega_i) = \frac{69+69+71+71+87+87+105+105+105+105+120+120+120}{12}$$

$$\bar{x} = \frac{1}{N} \sum_{i=1}^n (n_i \times x_i) = \frac{(2 \times 69) + (2 \times 71) + (2 \times 87) + (4 \times 105) + (3 \times 120)}{12}$$

$$\bar{x} = \sum_{i=1}^n (f_i \times x_i) = (0,154 \times 69) + (0,154 \times 71) + (0,154 \times 87) + (0,308 \times 105) + (0,231 \times 120)$$

$$\bar{x} = 94,923$$

109




110


Calcul de la médiane à partir du tableau statistique

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
69	2	2	0,154	0,154	15,38%	15,38%
71	2	4	0,154	0,308	15,38%	30,77%
87	2	6	0,154	0,462	15,38%	46,15%
Me = 105	4	10 $\geq 6,5$	0,308	0,769 $\geq 0,5$	30,77%	76,92% $\geq 50\%$
120	3	13	0,231	1	23,08%	100%

111



112




113

Le premier quartile

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
69	2	2	0,154	0,154	15,38%	15,38%
$Q_1 = 71$	2	4 $\geq 3,25$	0,154	0,308 $\geq 0,25$	15,38%	30,77% $\geq 25\%$
87	2	6	0,154	0,462	15,38%	46,15%
105	4	10	0,308	0,769	30,77%	76,92%
120	3	13	0,231	1	23,08%	100%

114




116

Le troisième quartile

Modalités x_i	Effectifs n_i	Effectifs cumulés N_i	Fréquences f_i	Fréquences cumulées F_i	Pourcentages $fp_i\%$	Pourcentages cumulés $FP_i\%$
69	2	2	0,154	0,154	15,38%	15,38%
71	2	4	0,154	0,308	15,38%	30,77%
87	2	6	0,154	0,462	15,38%	46,15%
$Q_3 = 105$	4	10 $\geq 9,75$	0,308	0,769 $\geq 0,75$	30,77%	76,92% $\geq 75\%$
120	3	13	0,231	1	23,08%	100%


117

Troisième quartile à partir du diagramme de la fonction de répartition




119

Etendue et EIQ




120

Les écarts




121

Ecart Moyen vs Ecart Absolu Moyen




122

Variance et écart type



123

L'écart absolu et écart-type



124

Coefficient de variation


► $CV = \frac{\sigma}{x}$ ou $CV = \frac{s}{x} \times 100\%$

► $CV = 19,43 / 94,923 = 0,2046 \Rightarrow 20,46\%$

► 20% est généralement considéré comme **modéré** : il indique une variabilité notable, mais pas excessive.


125

Diagrammes en bâtons




126

Boîte à moustaches



127

Fonction de répartition



128