

Chapitre 5

L'analyse de corrélation

205

Plan du chapitre

- ▶ Introduction
- ▶ Qu'est-ce que l'analyse de corrélation ?
- ▶ Les différents types d'analyses de corrélation
 - ▶ **Corrélation entre variables quantitatives continues**
 - ▶ Corrélation entre variables qualitatives
 - ▶ Corrélation entre variables mixtes
- ▶ Différence entre corrélation et causalité

206

Introduction

- ▶ Un aspect fondamental de l'analyse de données consiste à étudier et comprendre les relations entre les variables.
- ▶ L'analyse de corrélation vise à mesurer la relation statistique entre deux variables.
- ▶ Alors que la covariance indique uniquement la direction de la relation (positive ou négative), la corrélation en précise à la fois la direction et l'intensité.
- ▶ Corrélation ne signifie pas causalité : une corrélation entre deux variables ne signifie pas que l'une cause l'autre


207

C'est quoi l'analyse de corrélation

- ▶ C'est une méthode statistique utilisée pour mesurer la relation entre deux variables.
- ▶ Elle cherche à répondre aux questions suivantes :
 - ▶ Y a-t-il une relation entre deux variables ?
 - ▶ Quel type de relation observe-t-on: linéaire, monotone, quadratique ou autre ?
 - ▶ Quelle est l'intensité de cette relation : forte ou faible ?
 - ▶ La corrélation est-elle positive (croissante) ou négative (décroissante) ?


208

Exemples de courbes de deux variables qui ont les mêmes tendances



209


Exemples de courbes de deux variables qui ont des tendances inverses



210


Type de relation selon la forme du lien entre les deux variables

- **Corrélation linéaire** (mesurée par Pearson) : plus X augmente, plus Y augmente ou diminue **de façon proportionnelle**.
- **Corrélation monotone** (mesurée par Spearman ou Kendall) : plus X augmente, plus Y tend à augmenter (ou diminuer), **mais pas forcément de façon linéaire**.
- **Corrélation quadratique** : Y varie avec X de manière en U ou en n. (ex : stress vs performance — loi de Yerkes-Dodson).
- **Corrélation exponentielle / logarithmique** : Relation non linéaire avec croissance rapide ou ralentissement progressif (ex : propagation d'une épidémie).





211

Exemples de relations (linéaire, monotone, quadratique, polynomiale, etc)




212

Corrélation linéaire ou monotone



213

Quelle est la force de la corrélation en les deux variables



214


Quelle est l'intensité de la corrélation entre les deux variables

- Le coefficient de corrélation est entre -1 et 1 => $r \in [-1, 1]$

Valeur absolue de la corrélation $ r $	L'intensité de la corrélation
$0.0 \leq r < 0.1$	Pas de corrélation
$0.1 \leq r < 0.3$	Corrélation faible
$0.3 \leq r < 0.5$	Corrélation moyenne
$0.5 \leq r < 0.7$	Corrélation élevée
$0.7 \leq r \leq 1$	Corrélation très élevée


215

Corrélation croissante ou décroissante




217

Exemples de corrélation positive



218

Exemples de corrélation négative



219

Les types d'analyse de corrélation de variables continues

- Corrélation pour variables quantitatives continues
 - Corrélation linéaire
 - Coefficient de Pearson (r) : mesure la force et la direction d'une relation linéaire entre deux variables quantitatives continues.
 - Corrélation monotone
 - La corrélation de Spearman (ρ ou « rho ») : évalue la relation monotone (croissante ou décroissante) entre deux variables.
 - Sans ex aequo : calcul direct sur les rangs.
 - Avec ex aequo : ajustement des rangs moyens.
 - La corrélation de Kendall (τ ou « tau ») : mesure la concordance entre les paires d'observations
 - Tau-a : utilisé sans ex aequo
 - Tau-b : utilisé avec ex aequo


220

Corrélation entre variables quantitatives

- La corrélation mesure le degré d'association entre deux variables quantitatives.
 - Elle indique si et comment deux variables varient ensemble.
 - Elle donne à la fois une **intensité** (faible, moyenne, forte) et une **direction** (positive ou négative).
- Différents **coefficients de corrélation** permettent d'évaluer cette relation.
- Le choix du coefficient dépend :
 - du **type de relation** attendue (linéaire ou non linéaire)
 - et des **caractéristiques des données** (présence d'extrêmes, ex aequo, etc.)


221

Choix du coefficient de corrélation



222

Choix du coefficient de corrélation



223

Le coefficient de Pearson

- C'est une mesure statistique qui quantifie la relation **linéaire** entre deux variables.
- Le coefficient de Pearson nous indique l'intensité de la corrélation linéaire et sa direction.
- Le coefficient de Pearson est sensible aux valeurs aberrantes (outliers).
- Le coefficient de Pearson correspond à la covariance normalisée et il prend des valeurs dans l'intervalle [-1,1]
- Pour le calculer on utilise la formule suivante:


$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \cdot \sum(y_i - \bar{y})^2}} = \frac{\text{Cov}(X,Y)}{\text{std}(X)\text{std}(Y)}$$

224


Le coefficient de Pearson

- Les valeurs de la corrélation de Pearson sont comprises entre **-1 et +1** :
- **r = +1** → corrélation parfaitement **positive**
- **r = -1** → corrélation parfaitement **négative**
- **r = 0** → **absence** de corrélation linéaire


225




226



227




228



229

Un exemple pour montrer l'impact des valeurs aberrantes sur le coefficient de Pearson



230

Conditions d'utilisation de la corrélation de Pearson

- ▶ La corrélation de Pearson est une méthode paramétrique.
- ▶ Elle repose sur deux hypothèses principales:
 - ▶ **Hypothèse de normalité**
 - ▶ Les variables X et Y doivent suivre (ou approximativement suivre) une distribution normale.
 - ▶ La loi normale est caractérisée par ses paramètres (moyenne « μ » et écart-type « σ »).
 - ▶ **Hypothèse de linéarité**
 - ▶ Pearson mesure uniquement la force d'une relation linéaire.
 - ▶ Cette relation peut être décrite par une équation du type : $y = ax + by$ où le paramètre a est la pente de la droite et le paramètre b est l'ordonnée à l'origine.
- ▶ Pearson fonctionne bien si les variables X et Y suivent (ou approximativement) une loi normale.

231

La corrélation de Spearman

- ▶ La corrélation de rang de Spearman est l'équivalent non paramétrique de la corrélation de Pearson
- ▶ La différence principale entre les deux est que la corrélation de Pearson utilise directement les valeurs des données, tandis que Spearman utilise les rangs des données.
- ▶ La corrélation de Spearman correspond à la corrélation de Pearson appliquée aux rangs des données : on projette les données de l'espace initial vers l'espace des rangs.
- ▶ Le coefficient de Spearman est moins sensible aux valeurs aberrantes que celui de Pearson.

232

La corrélation de Spearman

- ▶ Il indique l'intensité et la direction de la corrélation entre deux variables.
- ▶ De même que Pearson, le coefficient de Spearman prend des valeurs dans l'intervalle $[-1, 1]$.
- ▶ Spearman est recommandé :
 - ▶ lorsque les données sont ordinales (classements, notes, échelles de satisfaction),
 - ▶ lorsque la relation entre variable est monotone mais non linéaire,
 - ▶ lorsqu'il existe des valeurs aberrantes.

233

Formules de calcul du coefficient de Spearman (sans ex aequo)

- Formule générale (basée sur les rangs) :

$$\rho_s = \frac{\sum (R_{X_i} - \bar{R}_X)(R_{Y_i} - \bar{R}_Y)}{\sqrt{\sum (R_{X_i} - \bar{R}_X)^2 \cdot \sum (R_{Y_i} - \bar{R}_Y)^2}} = \frac{Cov(R_X, R_Y)}{std(R_X)std(R_Y)} \Rightarrow \rho_s \in [-1, 1]$$

R_{X_i} : rang de la i-ème valeur de X .

R_{Y_i} : rang de la i-ème valeur de Y .

- Formule simplifiée (lorsqu'il n'y a pas de rangs ex aequo)

$$\rho_s = 1 - \frac{6 \cdot \sum d_i^2}{N(N^2 - 1)} \Rightarrow \rho_s \in [-1, 1]$$

$d_i = R_{X_i} - R_{Y_i}$: différence des rangs pour chaque observation

N : taille de l'échantillon

234

Formules de calcul du coefficient de Spearman (avec ex aequo)

- Ajustement des rangs

- En cas d'**ex æquo**, attribuer la **moyenne des rangs** aux valeurs concernées.

- Calculer ensuite la corrélation de Pearson sur les rangs ajustés :

$$\rho_s = \frac{\sum_{i=1}^N (R_{X_i}^{adj} - \bar{R}_X^{adj})(R_{Y_i}^{adj} - \bar{R}_Y^{adj})}{\sqrt{\sum_{i=1}^N (R_{X_i}^{adj} - \bar{R}_X^{adj})^2 \sum_{i=1}^N (R_{Y_i}^{adj} - \bar{R}_Y^{adj})^2}} = \frac{Cov(R_X^{adj}, R_Y^{adj})}{std(R_X^{adj})std(R_Y^{adj})}$$

$R_{X_i}^{adj}$: rang ajusté de la i-ème valeur de X .

$R_{Y_i}^{adj}$: rang ajusté de la i-ème valeur de Y .

235

Formules de calcul du coefficient de Spearman (avec ex aequo)

- Formule ajustée de Spearman

$$\rho_s = \frac{\frac{N(N^2-1)}{6} - \sum a_i^2 - T_X - T_Y}{\sqrt{(\frac{N(N^2-1)}{6} - 2T_X)(\frac{N(N^2-1)}{6} - 2T_Y)}} \quad \text{avec} \quad T = \sum_j \frac{t_j^3 - t_j}{12}$$

Où

N : taille de l'échantillon

$d_i = R_{X_i}^{adj} - R_{Y_i}^{adj}$: différence entre les rangs ajustés.

t_j : nombre d'éléments ex æquo dans le groupe j.

T_X et T_Y : corrections liées aux ex æquo dans X et Y

236

Calcul de T_X et T_Y

- Pour calculer T_X et T_Y , on utilisera la formule suivante: $T = \sum_j \frac{t_j^3 - t_j}{12}$
- Pour T_X on s'intéressera aux blocs de doublons pour les rangs ajustés de X.
 - On définit le nombre de blocs de doublons pour les rangs ajustés de X.
 - Pour chaque bloc, on calcule le terme $\frac{t_j^3 - t_j}{12}$
 - On somme les termes pour obtenir T_X
- Pour T_Y on s'intéressera aux blocs de doublons pour les rangs ajustés de Y.
 - On définit le nombre de blocs de doublons pour les rangs ajustés de Y.
 - Pour chaque bloc, on calcule le terme $\frac{t_j^3 - t_j}{12}$
 - On somme les termes pour obtenir T_Y

237

Exemples de relations monotones (non forcément linéaires)

- **Classement au marathon (rang d'arrivée) et classement au 10 km préparatoire :**
 - corrélation monotone : un meilleur classement à l'un tend à correspondre à un meilleur classement à l'autre, mais **les temps ne sont pas proportionnels**.
- **Niveau de satisfaction client (notes de 1 à 5) et probabilité de recommander un produit :**
 - relation monotone croissante : plus la satisfaction est élevée, plus la recommandation est probable.

238

Exemple de calcul de la corrélation de Spearman « Sans ex aequo »

Coureur	X : Temps Course 1 (min)	Y : Temps Course 2 (min)
1	30	29
2	32	35
3	35	34
4	40	37
5	45	50
6	50	55

239

Exemple de calcul du coefficient de Spearman avec la formule de Pearson appliquée sur les rangs « Sans ex aequo »

Coureur	R _x	R _y	(R _{xi} - $\bar{R}_x$)	(R _{yi} - $\bar{R}_y$)	(R _{xi} - $\bar{R}_x$) (R _{yi} - $\bar{R}_y$)	(R _{xi} - $\bar{R}_x$) ²	(R _{yi} - $\bar{R}_y$) ²
1	1	1	-2,5	-2,5	6,25	6,25	6,25
2	2	3	-1,5	-,5	0,75	2,25	0,25
3	3	2	-0,5	-1,5	0,75	0,25	2,25
4	4	4	0,5	0,5	0,25	0,25	0,25
5	5	5	1,5	1,5	2,25	2,25	2,25
6	6	6	2,5	2,5	6,25	6,25	6,25
	$\bar{x} = 3,5$	$\bar{y} = 3,5$			$\Sigma = 16,5$	$\Sigma = 17,5$	$\Sigma = 17,5$

$$\rho_s = \frac{\sum (R_{xi} - \bar{R}_x)(R_{yi} - \bar{R}_y)}{\sqrt{\sum (R_{xi} - \bar{R}_x)^2} \cdot \sqrt{\sum (R_{yi} - \bar{R}_y)^2}} = \frac{16,5}{\sqrt{17,5 \times 17,5}} \approx +0,943$$

240

Exemple de calcul directe de Spearman avec la formule « Sans ex aequo »

Coureur	R _x	R _y	d = R _x - R _y	d ² = (R _x - R _y) ²
1	1	1	0	0
2	2	3	-1	1
3	3	2	1	1
4	4	4	0	0
5	5	5	0	0
6	6	6	0	0

$$\Sigma d_i^2 = 2$$

$$\rho_s = 1 - \frac{6 \times \Sigma d_i^2}{N \times (N^2 - 1)} = 1 - \frac{6 \times 2}{6 \times (36 - 1)} \approx 0,943$$

241

Exemple de calcul de la corrélation de Spearman

« Avec ex aequo »

$$\Omega_N = [I_1, I_2, I_3, I_4, I_5, \dots, I_{20}]$$

 I_i (Individu i) : Etudiant i

X : Notes du Projet 1

Y : Notes du Projet 2

$$N = 20$$

Ω_N	X	Y
I ₁	10	3
I ₂	10	8
I ₃	10	12
I ₄	2	7
I ₅	5	7
I ₆	14	7
I ₇	6	4
I ₈	6	4
I ₉	1	15
I ₁₀	3	14
I ₁₁	4	10
I ₁₂	7	11
I ₁₃	8	6
I ₁₄	9	9
I ₁₅	11	2
I ₁₆	12	5
I ₁₇	13	9
I ₁₈	16	9
I ₁₉	4	1
I ₂₀	4	13

242

Rangs de X

Ω_N	I ₁	I ₂	I ₃	I ₄	I ₅	I ₆	I ₇	I ₈	I ₉	I ₁₀	I ₁₁	I ₁₂	I ₁₃	I ₁₄	I ₁₅	I ₁₆	I ₁₇	I ₁₈	I ₁₉	I ₂₀
X	10	10	10	2	5	14	6	6	1	3	4	7	8	9	11	12	13	16	4	4
Position	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
X _{trié}	1	2	3	4 = 4 = 4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Ω_N	I ₉	I ₄	I ₁₀	I ₄	I ₁₉	I ₂₀	I ₅	I ₇	I ₈	I ₁₂	I ₁₃	I ₁₄	I ₁	I ₂	I ₃	I ₁₅	I ₁₆	I ₁₇	I ₆	I ₁₈
R _X	1	2	3	4	4	4	7	8	8	10	11	12	13	13	13	16	17	18	19	20

243

Rangs de Y

Ω_N	I ₁	I ₂	I ₃	I ₄	I ₅	I ₆	I ₇	I ₈	I ₉	I ₁₀	I ₁₁	I ₁₂	I ₁₃	I ₁₄	I ₁₅	I ₁₆	I ₁₇	I ₁₈	I ₁₉	I ₂₀
Y	3	8	12	7	7	7	4	4	15	14	10	11	6	9	2	5	9	9	1	13
Position	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Y _{trié}	1	2	3	4 = 4	5	6	7	7 = 7 = 7	8	9	9 = 9 = 9	10	11	12	13	14	15	16	17	18
Ω_N	I ₁₉	I ₁₅	I ₁	I ₇	I ₈	I ₁₆	I ₁₃	I ₄	I ₅	I ₆	I ₂	I ₁₄	I ₁₇	I ₁₈	I ₁₁	I ₁₂	I ₃	I ₂₀	I ₁₀	I ₉
R _Y	1	2	3	4	4	6	7	8	8	8	11	12	12	12	15	16	17	18	19	20

244

Exemple de calcul de la corrélation de Spearman

« Avec ex aequo »

$$\Omega_N = [I_1, I_2, I_3, I_4, I_5, \dots, I_{20}]$$

 I_i (Individu i) : Etudiant i

X : Notes du Projet 1

Y : Notes du Projet 2

R_X : Rangs de XR_Y : Rangs de Y

Ω_N	X	Y	R _X	R _Y
I ₁	10	3	13	3
I ₂	10	8	13	11
I ₃	10	12	13	17
I ₄	2	7	2	8
I ₅	5	7	7	8
I ₆	14	7	19	8
I ₇	6	4	8	4
I ₈	6	4	8	4
I ₉	1	15	1	20
I ₁₀	3	14	3	19
I ₁₁	4	10	4	15
I ₁₂	7	11	10	16
I ₁₃	8	6	11	7
I ₁₄	9	9	12	12
I ₁₅	11	2	16	2
I ₁₆	12	5	17	6
I ₁₇	13	9	18	12
I ₁₈	16	9	20	12
I ₁₉	4	1	4	1
I ₂₀	4	13	4	18

245

Rangs de X ajusté par la moyenne des rangs
« Avec ex aequo »

Ω_N	I_1	I_2	I_3	I_4	I_5	I_6	I_7	I_8	I_9	I_{10}	I_{11}	I_{12}	I_{13}	I_{14}	I_{15}	I_{16}	I_{17}	I_{18}	I_{19}	I_{20}
X	10	10	10	2	5	14	6	6	1	3	4	7	8	9	11	12	13	16	4	4
Position	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
X_trié	1	2	3	4	4	4	5	6	6	7	8	9	10	10	10	11	12	13	14	16
Ω_N	I_9	I_4	I_{10}	I_4	I_{19}	I_{20}	I_5	I_7	I_8	I_{12}	I_{13}	I_{14}	I_1	I_2	I_3	I_{15}	I_{16}	I_{17}	I_6	I_{18}
R_X^{adj}	1	2	3	5	5	5	7	8.5	8.5	10	11	12	14	14	14	16	17	18	19	20
				(4+5+6)/3 = 5				(8+9)/2 = 8.5					(13+14+15)/3 = 14							

246

Rangs de Y ajusté par la moyenne des rangs
« Avec ex aequo »

Ω_N	I_1	I_2	I_3	I_4	I_5	I_6	I_7	I_8	I_9	I_{10}	I_{11}	I_{12}	I_{13}	I_{14}	I_{15}	I_{16}	I_{17}	I_{18}	I_{19}	I_{20}
Y	3	8	12	7	7	7	4	4	15	14	10	11	6	9	2	5	9	9	1	13
Position	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Y_trié	1	2	3	4	4	5	6	7	7	7	8	9	9	9	10	11	12	13	14	15
Ω_N	I_{19}	I_{15}	I_1	I_7	I_8	I_{16}	I_{13}	I_4	I_5	I_6	I_2	I_{14}	I_{17}	I_{18}	I_{11}	I_{12}	I_3	I_{20}	I_{10}	I_9
R_Y^{adj}	1	2	3	4.5	4.5	6	7	9	9	9	11	13	13	13	15	16	17	18	19	20
				(4+5)/2 = 4.5				(8+9+10)/3 = 9				(12+13+14)/3 = 13								

247

Ω_N	X	Y	R_X	R_Y	R_X^{adj}	R_Y^{adj}
I_1	10	3	13	3	14	3
I_2	10	8	13	11	14	11
I_3	10	12	13	17	14	17
I_4	2	7	2	8	2	9
I_5	5	7	7	8	7	9
I_6	14	7	19	8	19	9
I_7	6	4	8	4	8.5	4.5
I_8	6	4	8	4	8.5	4.5
I_9	1	15	1	20	1	20
I_{10}	3	14	3	19	3	19
I_{11}	4	10	4	15	5	15
I_{12}	7	11	10	16	10	16
I_{13}	8	6	11	7	11	7
I_{14}	9	9	12	12	12	13
I_{15}	11	2	16	2	16	2
I_{16}	12	5	17	6	17	6
I_{17}	13	9	18	12	18	13
I_{18}	16	9	20	12	20	13
I_{19}	4	1	4	1	5	1
I_{20}	4	13	4	18	5	18

$\Omega_N = [I_1, I_2, I_3, I_4, I_5, \dots, I_{20}]$
X : Notes du Projet 1
Y : Notes du Projet 2
 R_X : Rangs de X
 R_Y : Rangs de Y
 R_X^{adj} : Rangs ajustés de X
 R_Y^{adj} : Rangs ajustés de Y

248

Calcul du coefficient de Spearman avec la formule de Pearson appliquée au rangs ajustés « Avec ex aequo »

$$\rho_s = \frac{\sum_{i=1}^N (R_{X_i}^{adj} - \overline{R_X^{adj}})(R_{Y_i}^{adj} - \overline{R_Y^{adj}})}{\sqrt{\sum_{i=1}^N (R_{X_i}^{adj} - \overline{R_X^{adj}})^2 \sum_{i=1}^N (R_{Y_i}^{adj} - \overline{R_Y^{adj}})^2}} = \frac{Cov(R_X^{adj}, R_Y^{adj})}{std(R_X^{adj})std(R_Y^{adj})}$$

$R_{X_i}^{adj}$: rang ajusté de la i-ème valeur de X .
 $R_{Y_i}^{adj}$: rang ajusté de la i-ème valeur de Y .

249

Q _N	R _X ^{adj}	R _Y ^{adj}	(R _X ^{adj} - $\overline{R_X^{adj}}$)	(R _Y ^{adj} - $\overline{R_Y^{adj}}$)	(R _X ^{adj} - $\overline{R_X^{adj}}$) (R _Y ^{adj} - $\overline{R_Y^{adj}}$)	(R _X ^{adj} - $\overline{R_X^{adj}}$) ²	(R _Y ^{adj} - $\overline{R_Y^{adj}}$) ²
I1	14	3	3.5	-7.5	-26.25	12.25	56.25
I2	14	11	3.5	0.5	1.75	12.25	0.25
I3	14	17	3.5	6.5	22.75	12.25	42.25
I4	2	9	-8.5	-1.5	12.75	72.25	2.25
I5	7	9	-3.5	-1.5	5.25	12.25	2.25
I6	19	9	8.5	-1.5	-12.75	72.25	2.25
I7	8.5	4.5	-2	-6.0	12	4	36
I8	8.5	4.5	-2	-6.0	12	4	36
I9	1	20	-9.5	9.5	-90.25	90.25	90.25
I10	3	19	-7.5	8.5	-63.75	56.25	72.25
I11	5	15	-5.5	4.5	-24.75	30.25	20.25
I12	10	16	-0.5	5.5	-2.75	0.25	30.25
I13	11	7	0.5	-3.5	-1.75	0.25	12.25
I14	12	13	1.5	2.5	3.75	2.25	6.25
I15	16	2	5.5	-8.5	-46.75	30.25	72.25
I16	17	6	6.5	-4.5	-29.25	42.25	20.25
I17	18	13	7.5	2.5	18.75	56.25	6.25
I18	20	13	9.5	2.5	23.75	90.25	6.25
I19	5	1	-5.5	-9.5	52.25	30.25	90.25
I20	5	18	-5.5	7.5	-41.25	30.25	56.25
$\overline{R_X^{adj}} = 10.5$ $\overline{R_Y^{adj}} = 10.5$			$\Sigma = -174.5$		$\Sigma = 660.5$	$\Sigma = 660.5$	

250

Coefficient de Spearman avec la formule de Pearson pour l'exemple « Avec ex aequo »

$$\rho_s = \frac{\sum_{i=1}^N (R_{X_i}^{adj} - \overline{R_X^{adj}}) (R_{Y_i}^{adj} - \overline{R_Y^{adj}})}{\sqrt{\sum_{i=1}^N (R_{X_i}^{adj} - \overline{R_X^{adj}})^2 \sum_{i=1}^N (R_{Y_i}^{adj} - \overline{R_Y^{adj}})^2}} = \frac{\text{Cov}(R_X^{adj}, R_Y^{adj})}{\text{std}(R_X^{adj}) \text{std}(R_Y^{adj})}$$

$$\rho_s = \frac{-174.5}{\sqrt{660.5 \times 660.5}} \approx -0.264$$

251

Q _N	X	Y	R _X	R _Y	R _X ^{adj}	R _Y ^{adj}	d _{adj} = R _X ^{adj} - R _Y ^{adj}	d ² _{adj}
I1	10	3	13	3	14	3	11	121
I2	10	8	13	11	14	11	3	9
I3	10	12	13	17	14	17	-3	9
I4	2	7	2	8	2	9	-7	49
I5	5	7	7	8	7	9	-2	4
I6	14	7	19	8	19	9	10	100
I7	6	4	8	4	8.5	4.5	4	16
I8	6	4	8	4	8.5	4.5	4	16
I9	1	15	1	20	1	20	-19	361
I10	3	14	3	19	3	19	-16	256
I11	4	10	4	15	5	15	-10	100
I12	7	11	10	16	10	16	-6	36
I13	8	6	11	7	11	7	4	16
I14	9	9	12	12	12	13	-1	1
I15	11	2	16	2	16	2	14	196
I16	12	5	17	6	17	6	11	121
I17	13	9	18	12	18	13	5	25
I18	16	9	20	12	20	13	7	49
I19	4	1	4	1	5	1	4	16
I20	4	13	4	18	5	18	-13	169
$\sum_{i=1}^{20} d_{adj}^2 = 1670$								

253

Calcul de T_X pour l'exemple

R _X	R _{X,adj}	Sort(R _{X,adj})
13	14	1
13	14	2
13	14	3
2	2	4
7	7	5
19	19	6
8	8.5	7
8	8.5	8
1	1	9
3	3	10
4	5	11
10	10	12
11	11	13
12	12	14
16	16	15
17	17	16
18	18	17
20	20	18
4	5	19
4	5	20

t₁=3 t₂=2 t₃=3

Nbd_X (Nombre de blocs de doublons en X) = 3

$$T_X = \sum_{j=1}^{Nbd} \frac{t_j^3 - t_j}{12}$$

$$T_X = \frac{3^3 - 3}{12} + \frac{2^3 - 2}{12} + \frac{3^3 - 3}{12}$$

$$T_X = 2 + 0.5 + 2$$

$$T_X = 4.5 ;$$

255

Calcul de T_Y pour l'exemple

R _Y	R _{Y_adj}	Sort(R _{Y_adj})
3	3	1
11	11	2
17	17	3
8	9	4,5
8	9	4,5
8	9	6
4	4,5	7
4	4,5	9
20	20	9
19	19	9
15	15	11
16	16	13
7	7	13
12	13	13
2	2	15
6	6	16
12	13	17
12	13	18
1	1	19
18	18	20

$t_1=2$ 4.5
 $t_2=3$ 9
 $t_3=3$ 13

Nbd_Y(Nombre de blocs de doublons en Y) = 3

$$T_Y = \sum_{j=1}^{Nbd_Y} \frac{t_j^3 - t_j}{12}$$

$$T_Y = \frac{t_1^3 - t_1}{12} + \frac{t_2^3 - t_2}{12} + \frac{t_3^3 - t_3}{12}$$

$$T_Y = \frac{2^3 - 2}{12} + \frac{3^3 - 3}{12} + \frac{3^3 - 3}{12}$$

$$T_Y = 0.5 + 2 + 2$$

$$T_Y = 4.5 ;$$

256

Calcul avec la formule ajustée de Spearman sur les rangs ajustés « Avec ex aequo »

$$\rho_s = \frac{\frac{N(N^2 - 1)}{6} - \sum d_{adj_i}^2 - T_X - T_Y}{\sqrt{\left(\frac{N(N^2 - 1)}{6} - 2T_X\right) \cdot \left(\frac{N(N^2 - 1)}{6} - 2T_Y\right)}}$$

$$\rho_s = \frac{1330 - 1670 - 4.5 - 4.5}{\sqrt{(1330 - 9)(1330 - 9)}} \approx -0,264$$

$$\frac{N(N^2 - 1)}{6} = \frac{20(20^2 - 1)}{6} = 1330$$

$$\sum d_{adj_i}^2 = 1670 ;$$

$$T_X = 4.5 ; T_Y = 4.5$$

257

La corrélation de Kendall-Tau

- ▶ Contrairement à Pearson, Kendall ne mesure pas la linéarité mais la cohérence d'ordre entre les valeurs.
- ▶ Le coefficient Tau de Kendall « τ » mesure le degré de concordance entre deux variables.
- ▶ Il évalue la force et la direction d'une relation monotone entre les variables.
- ▶ Plus le nombre de paires concordantes est élevé (et donc moins il y a d'inversions), plus la corrélation est forte.

258

Interprétation de Kendall-Tau et comparaison avec Spearman

- ▶ Le coefficient τ varie entre -1 et +1 :
 - ▶ +1 → concordance parfaite,
 - ▶ 0 → absence de relation monotone,
 - ▶ -1 → discordance parfaite.
- ▶ Kendall est particulièrement adapté pour :
 - ▶ les petits échantillons,
 - ▶ les situations avec valeurs aberrantes (plus robuste que Spearman et Pearson).
- ▶ Lien avec Spearman :
 - ▶ τ est souvent plus conservateur (valeurs absolues plus faibles que ρ_s).
 - ▶ Pour grandes tailles d'échantillons, τ et ρ_s donnent des conclusions similaires.

259

Variantes du coefficient de Kendall-Tau

- Il existe trois variantes du coefficient Kendall-Tau ,
 - Tau-a : pour des données **sans ex aequo**
 - cas très rare en données quantitatives continues
 - peu sensible aux valeurs aberrantes
 - Tau-b : pour des données **avec ex aequo**
 - à privilégier pour variables quantitatives
 - robuste aux valeurs aberrantes
 - Tau-c (ou Kendall-Stuart) :
 - utilisé surtout pour des variables ordinales
 - adaptée aux tableaux de contingence rectangulaires (nombre de rangs ≠ nombre de colonnes)
 - non approprié pour les variables quantitatives continues

260

Calcul du coefficient de Kendall Tau

- Pour des variables quantitatives, τ se calcule à partir des paires (x_i, y_i) .
- Les données sont d'abord classées avant comparaison des paires.
- Chaque paire (x_i, y_i) , (x_j, y_j) est dite :
 - **concordante** si $(x_i - x_j)(y_i - y_j) > 0$,
 - **discordante** si $(x_i - x_j)(y_i - y_j) < 0$.
- Kendall évalue la proportion relative de **paires ordonnées dans le même sens**.

261

Définition et calcul de Tau-a « sans ex aequo »

- Formule de τ_a (sans ex aequo) :

$$\tau_a = \frac{C-D}{\binom{N}{2}} = \frac{C-D}{\frac{N(N-1)}{2}} \Rightarrow \tau_a \in [-1, 1]$$

- Où

- C : nombre de paires **concordantes**,
- D : nombre de paires **discordantes**.

$$\binom{N}{2} = \frac{N!}{(N-2)!2!} = \frac{N(N-1)(N-2)!}{(N-2)!2!} = \frac{N(N-1)}{2}$$

- En cas d'absence d'ex aequo $\binom{N}{2} = C+D \Rightarrow \tau_a = \frac{C-D}{C+D}$

262

Définition et calcul de Tau-b « avec ex aequo »

- τ_b est la version corrigée l'effet des valeurs **ex aequo** dû au fait que :

$$\binom{N}{2} \neq C + D$$

- Formule de τ_b (avec ex aequo) :

$$\tau_b = \frac{C - D}{\sqrt{(C + D + t_x)(C + D + t_y)}}$$

- Où

- C : nombre de paires **concordantes**,
- D : nombre de paires **discordantes**.
- t_x, t_y : nombres de paires ex aequo respectivement sur X et sur Y.

263

Exemple numérique « sans ex aequo »

Note attribuée par un premier jury A et note attribuée par un deuxième jury B à des candidats.

Candidat	X : Jury A	Y : Jury B
1	12	14
2	15	18
3	16	15
4	10	11
5	18	20

264

Exemple de calcul de la corrélation de Kendall Tau avec rangs explicites « sans ex aequo »

Candidat	X : Jury A	Y : Jury B	Rang A	Rang B
4	10	11	1	1
1	12	14	2	2
2	15	18	3	4
3	16	15	4	3
5	18	20	5	5

$$\tau_a = \frac{C-D}{\binom{5}{2}} = \frac{9-1}{10} = 0,8$$

265

Exemple de calcul de la corrélation de Kendall Tau avec rangs implicites « sans ex aequo »

Candidat	X : Jury A	Y : Jury B
4	10	11
1	12	14
2	15	18
3	16	15
5	18	20

$$\tau_a = \frac{C-D}{\binom{5}{2}} = \frac{9-1}{10} = 0,8$$

266

Cas avec ex aequo avec Kendall tau-a « avec ex aequo »

I_i : Etudiant i
 X : Notes du DS
 Y : Notes du DST

$$\tau_a = \frac{71-106}{190} = -0.18$$

Qn	X	Y	C	D
I1	10	3	5 ✓	12 X
I2	10	8	8 ✓	9 X
I3	10	12	9 ✓	8 X
I4	2	7	7 ✓	7 X
I5	5	7	5 ✓	9 X
I6	14	7	7 ✓	7 X
I7	6	4	7 ✓	5 X
I8	6	4	7 ✓	5 X
I9	1	15	0 ✓	11 X
I10	3	14	0 ✓	10 X
I11	4	10	1 ✓	6 X
I12	7	11	1 ✓	7 X
I13	8	6	4 ✓	3 X
I14	9	9	1 ✓	3 X
I15	11	2	4 ✓	1 X
I16	12	5	3 ✓	1 X
I17	13	9	1 ✓	1 X
I18	16	9	1 ✓	1 X
I19	4	1	0 ✓	0 X
I20	4	13		
			$\Sigma = 71$	$\Sigma = 106$

Détail de calcul pour I1

10 = 10 & 8 > 3 ☹
 10 = 10 & 12 > 3 ☹
 2 < 10 & 7 > 3 X
 5 < 10 & 7 > 3 X
 14 > 10 & 7 > 3 ✓
 6 < 10 & 4 > 3 X
 6 < 10 & 4 > 3 X
 1 < 10 & 15 > 3 X
 3 < 10 & 14 > 3 X
 4 < 10 & 10 > 3 X
 7 < 10 & 11 > 3 X
 8 < 10 & 6 > 3 X
 9 < 10 & 9 > 3 X
 11 > 10 & 2 < 3 X
 12 > 10 & 5 > 3 ✓
 13 > 10 & 9 > 3 ✓
 16 > 10 & 9 > 3 ✓
 4 < 10 & 1 < 3 ✓
 4 < 10 & 13 > 3 X

267

Cas avec ex aequo avec Kendall tau-b « avec ex aequo »

	X	Y	C	D	t _x	t _y
I1	10	3	5 ✓	12 X	2 ⊖	0 ⊖
I2	10	8	8 ✓	9 X	1 ⊖	0 ⊖
I3	10	12	9 ✓	8 X	0 ⊖	0 ⊖
I4	2	7	7 ✓	7 X	0 ⊖	2 ⊖
I5	5	7	5 ✓	9 X	0 ⊖	1 ⊖
I6	14	7	7 ✓	7 X	0 ⊖	0 ⊖
I7	6	4	7 ✓	5 X	1 ⊖	0 ⊖
I8	6	4	7 ✓	5 X	0 ⊖	0 ⊖
I9	1	15	0 ✓	11 X	0 ⊖	0 ⊖
I10	3	14	0 ✓	10 X	0 ⊖	0 ⊖
I11	4	10	1 ✓	6 X	2 ⊖	0 ⊖
I12	7	11	1 ✓	7 X	0 ⊖	0 ⊖
I13	8	6	4 ✓	3 X	0 ⊖	0 ⊖
I14	9	9	1 ✓	3 X	0 ⊖	2 ⊖
I15	11	2	4 ✓	1 X	0 ⊖	0 ⊖
I16	12	5	3 ✓	1 X	0 ⊖	0 ⊖
I17	13	9	1 ✓	1 X	0 ⊖	1 ⊖
I18	16	9	1 ✓	1 X	0 ⊖	0 ⊖
I19	4	1	0 ✓	0 X	1 ⊖	0 ⊖
I20	4	13				
			Σ = 71	Σ = 106	Σ = 7	Σ = 7

I_i : Etudiant i
 X : Notes du DS
 Y : Notes du DST

$$\tau_b = \frac{C - D}{\sqrt{(C + D + t_x)(C + D + t_y)}}$$

$$\tau_b = \frac{71 - 106}{\sqrt{(71 + 106 + 7)(71 + 106 + 7)}}$$

$$\tau_b = -0.19$$

268

Corrélation et causalité

- La corrélation **ne signifie pas causalité**.
- Une corrélation forte n'implique pas nécessairement une relation de cause à effet.
- La **corrélation** mesure l'association entre deux variables : **comment elles varient ensemble**.
- La **causalité** implique qu'un **changement de la variable X** **provoque un changement de Y**.

269

Exemples

- **Nombre de cinémas et taux de diplomation** : tous deux plus élevés dans les grandes villes.
- **La consommation de glaces et les coups de soleil** : toutes les deux liées par l'été
- **Consommation d'électricité et ventes de ventilateurs** : toutes les deux liées à la chaleur.
- **Stress et consommation de sucre** : toutes les deux liés par la fatigue ou l'anxiété, sans relation directe simple.
- **Utilisation d'Internet et nombre de divorces** : toutes deux ont augmenté dans le temps, sans lien causal direct.
- **Ventes de parapluies et accidents de la route** : toutes deux liées aux jours de pluie.

270