




22/01/2026

RAPPORT DE PROJET :

INFO0708 :Ateliers IA

Cocu Ethan
URCA

Table des matières

I.	Installation de l'application.....	2
1.	Les Imports.....	2
2.	Lancé l'application	2
II.	Les fonction.....	2
1.	Interface	2
2.	Fonctionnalités réalisées	2
3.	Difficultés.....	3
4.	Fonctionnalités non faites	3
5.	Ajouts	3
6.	Conseils et explication.....	4
III.	Manuel d'utilisation	4

I. Installation de l'application

1. Les Imports

Pour python 3.9 ou plus

brew install python-tk

pip3 install numpy matplotlib num2words gensim wordcloud scipy

2. Lancé l'application

Quand on est dans le dossier contenant l'interface. Attention on considère que les fichiers contenant les fonctions faites durant les différentes séances sont dans le même dossier que l'interface.

python3 interface.py

II. Les fonction

1. Interface

Pour ce projet, j'ai développé une application de bureau (GUI).

Pour la base (fronted) de mon interface je me suis servie de la bibliothèque graphique

Tkinter et principalement de c'est widgets ttk. Pour la visualisation des données et des

comparaisons je me suis servie de la bibliothèque Matplotlib, intégré via

FigureCanvasTkAgg pour l'affichage dans Tkinter. Pour le calcul et le backend je me suis servi de Numpy pour les opérations vectorielles et j'ai intégré les modules fait durant les séances précédentes.

2. Fonctionnalités réalisées

L'onglet de Recherche : J'ai implémenté le chargement de corpus, que ce soit depuis un dossier ou un fichier unique. J'ai ajouté un filtre permettant de ne charger que les documents en français ou en anglais. Pour la recherche, j'ai permis à l'utilisateur de configurer ses préférences : choix du descripteur (TF-IDF, Word2Vec, etc.) et de la mesure de similarité (Cosinus, Jaccard). J'ai affiché les résultats dans un tableau interactif indiquant le score et un aperçu du texte.

L'onglet d'Exploration : J'ai créé cet espace pour vérifier le contenu du corpus. J'y ai placé une arborescence qui montre la structure des fichiers chargés. J'ai aussi programmé le calcul automatique de statistiques, comme la richesse lexicale ou le nombre de documents.

L'onglet de Comparaison : J'ai mis en place un système d'historique qui sauvegarde chaque recherche effectuée. J'ai permis à l'utilisateur de sélectionner plusieurs scénarios passés pour les comparer. L'application génère alors des graphiques pour analyser les différences de scores entre les méthodes (Boxplots des distributions de scores et Heatmap de similarité entre les résultats).

3. Difficultés

Le nettoyage du texte (Stopwords) : Nous avons rencontré un problème persistant avec les mots vides. Les fonctions de base laissaient passer des mots très courants comme "je", "de", "then" ou "is". Cela polluait les vecteurs et les nuages de mots.

Pour corriger cela, j'ai dû intervenir directement dans le code de l'interface. J'ai ajouté une liste stricte. Une fonction de nettoyage interne applique ce filtre radicalement avant toute opération de recherche.

L'affichage des graphiques : L'intégration de Matplotlib dans Tkinter a posé des soucis de superposition. Les nouveaux graphiques s'affichaient par-dessus les anciens sans effacer le fond, rendant l'image illisible.

J'ai résolu ce problème en modifiant la gestion de l'affichage. J'ai créé des boutons "lanceurs" spécifiques dans l'interface. Le code force désormais le nettoyage complet de la zone de dessin avant de tracer une nouvelle figure.

4. Fonctionnalités non faites

L'algorithme BM25 n'a pas été totalement intégré. Bien que le code soit présent dans le backend, le réglage des paramètres (\$k1\$ et \$b\$) était instable. Nous avons préféré désactiver cette option pour garantir la fiabilité des résultats avec TF-IDF et les Embeddings.

L'expansion de requête (ajout automatique de synonymes) n'a pas été implémentée dans l'interface finale par manque de temps.

5. Ajouts

J'ai intégré une console de logs en bas de l'écran. Elle affiche en temps réel les actions du moteur. Les erreurs apparaissent en rouge et les succès en vert, ce qui facilite grandement le débogage.

J'ai également ajouté une détection automatique des étudiants. Lors de l'exploration, un script analyse les noms de fichiers (ex: etuXX_lang.txt) pour compter combien d'étudiants distincts ont contribué au corpus.

Enfin, j'ai rendu le tableau de résultats interactif. Un double-clic sur une ligne ouvre une fenêtre popup permettant de lire le texte intégral du document.

6. Conseils et explication

Pour Euclidienne et Manathan les valeur sont inversé afin de faciliter le calcul.
L'interface trie toujours du plus grand au plus petit.


Pour une distance, la valeur 0 est la meilleure. Pour que 0 arrive avant 10, on les transforme en -0 et -10. Comme $-0 > -10$, le tri place le meilleur document (le plus proche) en premier.
Interprétation : Le signe "moins" est juste un artifice technique pour l'affichage et le tri.

Pour Jaccard, il ne faut jamais utilisé Word2Vec et Doc2Vec car ceux-ci génèrent des vecteurs avec des nombres négatifs. Quand Jaccard calcule le min ou le max avec des nombres négatifs, le résultat mathématique n'a plus de sens en tant que "pourcentage de similarité" et peut devenir négatif ou > 1 .

III. Manuel d'utilisation

L'application est divisée en trois zones principales pour faciliter la navigation :

- Le Panneau Latéral (Gauche) : Pour sélectionner les sources de données et filtrer par langue.
- La Zone de Travail (Centre) : Organisée en trois onglets (Recherche, Exploration, Comparaison).
- Le Journal d'Exécution (Bas) : Une console affichant en temps réel l'état du système.



Avant toute recherche, vous devez charger les données textuelles. Étapes à suivre :

- Source : Dans le panneau gauche, choisissez "Dossier (Racine)" pour un dossier simple ou "Dossier (Récursif)" pour inclure les sous-dossiers.
- Langue : Sélectionnez le filtre (ex: "Français (_fr)") si vous souhaitez ne garder que certains fichiers, ou laissez sur "Tous".
- Action : Cliquez sur le bouton bleu  CHARGER CORPUS.
- Vérification : Un message vert dans le journal et sous le bouton vous confirmera le nombre de documents chargés.

1. SOURCE & FILTRES

☐ Fichier unique
☐ Dossier (Racine)
☒ Dossier (Récursif)

Filtre Langue :

Tous (Mixte) ▼

 **CHARGER CORPUS**

CORPUS : 43 docs

Granularité: Document ▼

Document

Phrase

Top K:

m. Contenu (Double-clic pou

Les réglages disponibles pour la requêtes :

Descripteur : Choisissez la méthode de vectorisation.

Distance : Choisissez la métrique mathématique.

Nettoyage : "Standard" applique les filtres (stopwords, ponctuation), "Brut" garde le texte tel quel.

RECHERCHE EXPLORATION COR

Paramètres de Recherche

Descripteur: TF-IDF

Nettoyage: TF-IDF

Requête:

#

JS

Nettoyage: Standard

Requête:

#

#	Identifiant	Sim
---	-------------	-----

Distance: Cosinus

Granularité: Cosinus

Top

im.

Contenu (Double-clic


Une fois configuré, saisissez votre texte dans la barre de recherche.

Actions :

- Top K : Réglez le nombre de résultats souhaités (ex: 5) via le petit compteur à côté de la barre.
- Lancer : Cliquez sur le bouton vert LANCER.

- ence
égalité
modèles
rs
vert
juin d
intelligence
formation
produire
proximité
ont
formation
pratiques
pour l'innovation
nt Scier
rm
bordé

ence
égalité
modèles
rs
vert
juin d
intelligence
formation
produire
proximité
ont
formation
pratiques
pour l'innovation
nt Scier
rm
bordé




Cet onglet permet de vérifier la structure de vos fichiers et d'obtenir des statistiques automatiques.

À gauche, visualisez la hiérarchie exacte des fichiers chargés (arborescence).

Analyse : Cliquez sur ACTUALISER L'ANALYSE. Le tableau de droite affichera :

- Le nombre d'étudiants (basé sur les noms de fichiers etuXX).
- La répartition des langues.
- Les statistiques lexicales (Richesse TTR, Taux de Hapax).




L'onglet COMPARAISON permet d'analyser vos différentes tentatives (ex: comparer TF-IDF vs Word2Vec).

Historique : La liste affiche toutes vos recherches précédentes.


Sélection : Sélectionnez au moins deux lignes (maintenez la touche Ctrl ou Maj pour la sélection multiple).

Action : Cliquez sur le bouton orange COMPARER LA SÉLECTION.



Graphique Haut (Boxplot) : Compare la distribution des scores.

Graphique Bas (Heatmap) : Montre la similarité (recouvrement) entre les résultats des différents scénarios.



La console noire en bas de l'application est votre outil de diagnostic.

- Texte INFO (Blanc) : Actions normales.
- Texte SUCCESS (Bleu/Vert) : Opérations réussies (chargement, analyse).
- Texte ERROR (Rouge) : Problèmes bloquants (ex: fichier introuvable, erreur de calcul).
- Nettoyage : Utilisez le bouton "Vider Logs" dans le menu latéral si la console est trop remplie.

```
Journal d'exécution
[INFO] Cible : C:\Users\cocue\Documents\700\Corpus_Textes\Cas_2_Textes_Complets
[INFO] Mode : dossier_recuratif | Langue : all
[SUCCESS] Résultat : 43 charges. (0 ignorés pour langue 'all')
[INFO] Traitement (Granularité=document)...
[INFO] Base de travail : 43 unités.
[SUCCESS] Vocabulaire Final : 3119 mots.
[SUCCESS] Analyse terminée : 21 étudiants trouvés.
[INFO] Traitement (Granularité=document)...
[INFO] Base de travail : 43 unités.
[SUCCESS] Vocabulaire Final : 3119 mots.
[INFO] Vectorisation (tfidf)...
[INFO] Vectorisation (word2vec)...
```