

Recherche de documents « Document Retrieval »

Séance 7

Interface Homme-Machine pour l'exploitation du moteur de recherche

I. Introduction

Après avoir progressivement construit les différentes briques du moteur de recherche au cours des séances précédentes — pré-traitement linguistique, descripteurs symboliques, descripteurs vectoriels, indexation et calculs de similarité — cette séance vise à mettre en œuvre leur **exploitation interactive** à travers une interface Homme-Machine. Les structures produites lors des séances 1 à 6 (représentations textuelles, index lexicaux, vecteurs de documents, pré-calculs de similarité, modèles de plongements) constituent désormais un socle fonctionnel complet. L'enjeu de cette séance n'est plus d'introduire de nouveaux modèles, mais de mobiliser, combiner et piloter ces composants afin de répondre efficacement à des requêtes utilisateurs dans un cadre interactif.

La séance est consacrée à la conception et à la réalisation d'une interface permettant à un utilisateur :

- de formuler une requête de recherche ;
- de choisir et paramétrer différentes stratégies de recherche documentaire ;
- d'explorer, comparer et interpréter les résultats retournés par le moteur.

L'interface Homme-Machine peut prendre différentes formes selon les choix techniques effectués :

- une interface graphique locale (GUI) destinée à l'expérimentation et à l'analyse ;
- une application web simple permettant l'accès aux fonctionnalités du moteur via un navigateur.

Quel que soit le support retenu, l'objectif n'est pas de développer une application finalisée, mais un prototype fonctionnel et explicite, mettant en valeur les mécanismes de recherche implémentés tout au long du projet.

L'interface devra notamment permettre :

- la saisie ou la sélection d'une requête utilisateur (texte libre, requête issue du corpus, requête enrichie) ;
- la configuration des paramètres de recherche (méthode de représentation, type de similarité, gestion linguistique, corpus cible) ;
- le calcul et l'affichage des scores de similarité entre la requête et les documents ou phrases du corpus ;
- le classement des résultats et leur visualisation sous différentes formes ;
- la comparaison de plusieurs scénarios de recherche (approches symboliques, vectorielles ou hybrides).

Cette séance constitue ainsi une synthèse transversale du projet, où l'interface joue le rôle de médiateur entre l'utilisateur et les mécanismes internes du moteur de recherche. Elle met l'accent sur la compréhension, la traçabilité et l'analyse des résultats, et prépare l'utilisation du moteur dans un cadre exploratoire et expérimental.

II. Architecture générale de l'IHM

1. Principe de séparation entre interface et moteur

La mise en place d'une interface Homme-Machine repose sur un principe fondamental de conception des systèmes logiciels : la séparation logique entre les différentes couches fonctionnelles du système. Dans le cadre de ce projet, cette séparation permet de distinguer clairement :

- la **couche interface (IHM)**, responsable des interactions avec l'utilisateur (saisie des requêtes, choix des paramètres, affichage des résultats) ;
- la **couche traitement**, correspondant au moteur de recherche proprement dit, qui regroupe l'ensemble des fonctions de calcul, de similarité, de classement et de sélection des résultats ;
- la **couche données**, qui comprend le corpus, les fiches des unités linguistiques, les descripteurs calculés, les index et les structures de pré-calculs persistées sur disque.

Cette organisation n'introduit pas de nouveaux mécanismes algorithmiques, mais structure l'utilisation des composants déjà implémentés lors des séances précédentes. Elle vise à garantir que l'interface ne réalise aucun calcul de descripteur, de similarité ou d'indexation, mais se contente de piloter le moteur et d'exploiter les résultats qu'il produit.

La séparation entre interface et moteur présente plusieurs avantages essentiels dans le cadre de ce projet :

- **Visibilité du code** : chaque couche possède un rôle clairement identifié, ce qui facilite la compréhension globale du système et la maintenance du code.
- **Réutilisabilité du moteur** : le moteur de recherche peut être utilisé indépendamment de l'interface (par exemple pour des tests en ligne de commande, des scripts d'évaluation ou une autre interface).
- **Traçabilité des traitements** : les paramètres de recherche sont explicitement transmis au moteur, ce qui permet d'expliquer et de justifier les résultats affichés à l'utilisateur.
- **Évolutivité de l'interface** : de nouveaux modes d'interaction ou de visualisation peuvent être ajoutés sans modifier les fonctions de calcul sous-jacentes.

Dans cette logique, l'IHM agit comme un contrôleur, chargé de collecter les choix de l'utilisateur, de les transmettre au moteur sous une forme structurée, puis de présenter les résultats retournés sans en modifier le contenu.

L'interface doit permettre de déclencher des recherches sans exposer directement les structures internes du moteur à l'utilisateur. Concrètement, cela implique que :

- les paramètres de recherche sélectionnés dans l'interface (type de descripteur, type d'index, méthode de similarité, granularité document/phrased, etc.) sont regroupés dans une structure explicite ;
- l'IHM appelle une ou plusieurs fonctions du moteur en lui transmettant ces paramètres ;
- le moteur retourne les résultats sous une forme standardisée, indépendante de l'interface graphique utilisée.

Les résultats produits par le moteur doivent être facilement exploitables par l'IHM pour l'affichage, la comparaison et l'analyse, sans nécessiter de traitements supplémentaires complexes côté interface.

2. Organisation générale de l'interface

L'interface Homme-Machine est conçue pour permettre une interaction fluide avec le moteur de recherche tout en offrant un cadre clair pour l'expérimentation. Elle repose sur une organisation modulaire en onglets, chaque onglet représentant un type d'activité ou de scénario spécifique. Cette structure permet de séparer les fonctionnalités tout en facilitant la navigation et l'accès rapide aux différents outils du moteur.

L'onglet principal est dédié à la recherche documentaire, où l'utilisateur peut définir une requête et consulter les résultats issus des différentes méthodes de recherche (symbolique, vectorielle ou hybride). Les onglets complémentaires sont prévus pour :

- **Explorer** les données et les représentations internes du moteur (fiches, index, vecteurs) ;
- **Comparer** les résultats obtenus par différentes stratégies de recherche ou configurations de prétraitement ;
- **Visualiser** les similarités, voisinages sémantiques ou distributions de scores à l'aide de graphiques et tableaux interactifs.

Cette organisation modulaire favorise la lisibilité et la traçabilité des expérimentations. Chaque onglet fonctionne comme un espace de travail indépendant, capable d'afficher des résultats, de recevoir des paramètres et d'interagir avec le moteur, tout en partageant les structures centrales (index, fiches, modèles de plongements).

Voici quelques éléments recommandés pour la conception :

- **Barre latérale ou menu de navigation** : permet de basculer rapidement entre les onglets et d'accéder aux paramètres globaux du moteur.
- **Zone centrale de travail** : espace principal où sont affichés les résultats, graphiques, tableaux et visualisations interactives.
- **Panneaux de configuration** : zones dédiées à la sélection de paramètres de recherche, de filtres linguistiques, de types de descripteurs, ou de corpus cibles.

- **Panneaux d’affichage des résultats** : sections réservées à la présentation des résultats de recherche sous différentes formes (listes de documents, scores, graphiques de similarité, nuages de mots, cartes sémantiques).

Cette organisation générale garantit que l’utilisateur peut à la fois contrôler finement les paramètres de recherche et explorer les résultats de manière structurée, tout en facilitant l’intégration future de fonctionnalités supplémentaires sans bouleverser l’architecture de l’IHM.

III. Onglet principal : Recherche documentaire

1. Saisie et configuration de la requête

Avant de lancer la recherche, il est essentiel de définir la requête et ses paramètres afin d’assurer la cohérence avec les descripteurs calculés pour le corpus. Chaque requête est traitée comme une unité linguistique à part entière, représentée par une fiche de requête analogue aux fiches des documents ou phrases. Cette approche garantit la traçabilité des choix méthodologiques, la compatibilité avec les structures existantes et la possibilité d’expérimenter différents scénarios de recherche. Cette section détaille les différents paramètres à configurer avant tout calcul de similarité.

Une fois initialisée, la fiche de requête peut être réutilisée tant que ses paramètres ne sont pas modifiés, évitant ainsi des recalculs inutiles et inscrivant le traitement de la requête dans une logique de pipeline similaire à celle du corpus. Toute modification des paramètres réinitialise automatiquement le calcul des descripteurs de la requête pour maintenir la cohérence.

a) Paramétrage de la requête

La fiche de requête doit contenir toutes les informations nécessaires pour calculer ses descripteurs et effectuer les comparaisons avec le corpus. Les paramètres principaux sont :

- **Type d’unité linguistique** : phrase ou document.
- **Origine de la requête** :
 - saisie directement par l’utilisateur,
 - sélectionnée à partir du corpus existant,
 - chargée depuis un fichier externe.
- **Langue de la requête** : une langue unique « par exemple Français ou Anglais » ou multilingue.
- **Configuration de prétraitement** : choisir parmi les cinq configurations étudiées dans les séances précédentes.
- **Gestion des mots absents du vocabulaire (OOV)** : ignorer, remplacer par synonymes, ou signaler à l’utilisateur.

L’objectif est de construire une fiche de requête modulable, traçable et compatible avec les fiches du corpus, qui servira de base à tous les calculs de similarité.

- Écrire une fonction **initialiser_fiche_requete(id_requete, texte, type_unite="phrase", langue=None, config_id=None)** qui crée une fiche de requête vide ou pré-remplie avec les informations de base (texte, type d'unité, langue, configuration de prétraitement, statut de calcul).
- Écrire une fonction **choisir_type_requete(fiche_requete)** qui définit si la requête sera traitée comme une phrase ou un document.
- Écrire une fonction **choisir_source_requete(fiche_requete, source, chemin_fichier=None)** qui définit la provenance de la requête : saisie utilisateur, sélection depuis le corpus, ou chargement depuis un fichier.
- Écrire une fonction **definir_langue_requete(fiche_requete, langue)** qui assigne la langue de la requête. Cette information pourra être utilisée pour restreindre le corpus de recherche ou activer des stratégies de recherche multilingues.
- Écrire une fonction **choisir_configuration_pretraitement(fiche_requete, config_id)** qui associe une configuration de prétraitement à la requête compatible avec celles utilisées pour le calcul des descripteurs du corpus.
- Écrire une fonction **choisir_strategie_oov_requete(fiche_requete, strategie_oov)** qui définit la stratégie de gestion des mots absents du vocabulaire (OOV). Les stratégies possibles :
 - ignorer les mots absents,
 - utiliser des mécanismes de substitution (synonymes, sous-mots pour FastText),
 - signaler explicitement les mots absents à l'utilisateur.

2. Paramétrage du scénario de recherche

Le paramétrage du scénario de recherche consiste à définir l'espace et les conditions dans lesquels la requête sera comparée aux unités du corpus. Il permet de contrôler la portée de la recherche, d'adapter les calculs aux objectifs de l'utilisateur et d'explorer différents contextes d'analyse à partir d'une même fiche de requête.

a) Caractéristiques du corpus ciblé

Avant de lancer la recherche, il est nécessaire de définir précisément l'espace dans lequel le moteur va comparer la requête aux documents ou phrases du corpus. Ce paramétrage permet non seulement de concentrer la recherche sur les unités linguistiques pertinentes, mais également d'optimiser les performances en réduisant le nombre d'opérations de calcul de similarité.

Les principaux aspects à considérer sont :

- **Granularité de la recherche** : choisir si la comparaison se fait au niveau des phrases ou au niveau des documents. Cette décision influence la taille des matrices de descripteurs et la précision des résultats.
- **Portée de la recherche** : sélectionner un document unique, un sous-corpus spécifique ou le corpus global. Cela permet de restreindre la recherche à un ensemble pertinent et de comparer différents sous-ensembles du corpus.

- **Langues incluses** : décider si la recherche se limite à une langue unique ou s'étend à plusieurs langues. Ceci est particulièrement utile dans un corpus multilingue ou pour tester des stratégies de recherche multilingues.
- **Filtres additionnels** : appliquer des critères complémentaires, tels que la longueur des documents, l'appartenance à un sous-corpus particulier, ou d'autres métadonnées pertinentes. Ces filtres permettent de réduire le bruit et de mieux contrôler les résultats.

L'objectif de cette étape est de préparer un scénario de recherche clair et cohérent, en définissant l'espace sur lequel les similarités seront calculées et en optimisant l'efficacité des traitements.

- Écrire une fonction **definir_granularite_corpus (granularite = "document")** qui définit le niveau de granularité de la recherche : phrase ou document.
- Écrire une fonction **definir_portee_corpus(sous_corpus=None, langues=None)** qui permet de limiter la recherche à un sous-corpus particulier ou à certaines langues.
- Écrire une fonction **definir_filtres_corpus(filtres=None)** qui permet d'appliquer des critères supplémentaires pour restreindre la recherche, par exemple la taille des documents, l'appartenance à un sous-corpus particulier ou toute autre propriété pertinente. Le paramètre « filtres » peut être un dictionnaire, par exemple `filtres = { "taille_min": 50, "taille_max": 500, "sous_corpus": ..., etc }`.

b) Choix des descripteurs

Le choix des descripteurs conditionne la manière dont la requête sera comparée aux unités du corpus. Il est important de configurer correctement ce choix pour que les calculs de similarité soient cohérents avec les descripteurs déjà préparés lors des séances précédentes.

- **Descripteurs symboliques** : BOW, TF, TF-IDF, BM25.
- **Descripteurs vectoriels (embeddings)** : mots, phrases, Documents (Doc2Vec ou agrégation).
- **Paramètres d'agrégation pour embeddings** :
 - moyenne, somme pondérée, inférence Doc2Vec, ou autre stratégie adaptée.
- **Paramètres spécifiques aux modèles symboliques** : normalisation de norme L1/L2/aucune, pondération des termes selon TF ou TF-IDF ou BM25, filtrage des mots rares ou très fréquents si nécessaire
- **Normalisations supplémentaires (optionnelles)** pour descripteurs vectoriels et certaines distances métriques :
 - **Min–Max** : mise à l'échelle des composantes du vecteur.
 - **Standardisation (z-score)** : centrage et réduction, utile pour distances Euclidienne, Manhattan ou Minkowski.

Ces normalisations sont activables uniquement pour les descripteurs vectoriels et certaines distances métriques ; elles sont grisées dans l'IHM lorsque non applicables.

- **Pré-calcul des normalisations** : peut être activé pour la requête et/ou le corpus afin d'accélérer les calculs.

- Écrire une fonction **choisir_descripteurs(fiche_requete, descripteurs = ["TF-IDF"], methode_aggregation=None, normalisation_norme=None, normalisation_avancee=None)** qui associe à la requête les descripteurs à utiliser pour le calcul de similarité, la méthode d'agrégation si ce sont des embeddings, la méthode de normalisation de la norme et la normalisation statistique optionnelles.

L'objectif est de relier directement la configuration de la requête aux représentations du corpus, assurant que les comparaisons seront fiables et reproductibles.

c) Choix de la mesure de similarité

La mesure de similarité ou de distance définit comment la requête sera comparée aux unités du corpus. Elle influence directement le classement et l'interprétation des résultats, et permet d'explorer différents comportements du moteur selon les caractéristiques des descripteurs.

Selon les travaux de la séance 5, plusieurs mesures peuvent être utilisées :

- **Cosinus** : angle entre vecteurs, adapté aux descripteurs TF-IDF, BM25 et embeddings.
- **Distance Euclidienne** : pour embeddings denses.
- **Distance de Manhattan (City-block)** : somme des différences absolues entre vecteurs, parfois plus robuste aux valeurs extrêmes.
- **Distance de Minkowski** : généralisation d'Euclidienne et Manhattan, paramétrable par un exposant p.
- **Similarité de Jaccard** : adaptée aux représentations symboliques (ensembles de mots ou n-grams).
- **Scores pondérés ou combinés** : combinaison de plusieurs mesures pour créer un score global, utile pour les approches hybrides symbolique + vectorielle.

Dans l'IHM, toutes les mesures ne sont pas pertinentes pour tous les descripteurs :

- Pour **descripteurs symboliques** (TF, TF-IDF, BM25, BOW), seules certaines distances sont applicables (ex. Cosinus, Jaccard, scores pondérés).
- Pour **descripteurs vectoriels** (embeddings, Doc2Vec), toutes les distances métriques (Euclidienne, Manhattan, Minkowski) et Cosinus sont disponibles.
- Les options inapplicables doivent être **grisées** ou **désactivées** pour éviter des erreurs de paramétrage et guider l'expérimentation.
- Écrire une fonction **definir_distance (fiche_requete, type_distance="cosinus")** qui associe à la requête une mesure de similarité ou distance

parmi celles étudiées. L'interface devra gérer dynamiquement l'activation ou la désactivation des distances en fonction du type de descripteur sélectionné.

d) Paramètres avancés

Avant de lancer la recherche, certains paramètres supplémentaires peuvent être configurés pour affiner le comportement du moteur et permettre des expérimentations plus fines.

- **Expansion de requête** : Permet d'ajouter automatiquement des termes ou vecteurs proches à la requête initiale pour enrichir la recherche. Les paramètres incluent l'activation/désactivation de cette fonctionnalité et le nombre de termes ou vecteurs à ajouter.
- **Stratégie multi-langues** : Permet de gérer les requêtes multilingues. Selon le choix, les résultats peuvent être fusionnés dans un seul classement ou séparés par langue pour analyse comparative.
- **Pré-calculs sur les vecteurs** : Certaines opérations, comme la normalisation des vecteurs ou l'application de pondérations (TF-IDF, BM25), peuvent être effectuées avant la recherche pour accélérer les calculs. L'utilisateur peut décider si ces pré-calculs sont activés ou non. L'objectif est de préparer la requête et son traitement pour maximiser la pertinence et l'efficacité de la recherche.
- Écrire une fonction **definir_options_avancees(fiche_requete, expansion_requete=False, multi_langues=False, pre_calcul_normes=True)** qui permet de définir si une expansion de requête sera utilisée, si la requête est multi-langues et si les normes des vecteurs doivent être pré-calculées.

3. Calcul et classement des résultats

Une fois la requête et le scénario de recherche entièrement paramétrés, le moteur peut procéder au calcul des similarités entre la requête et les unités linguistiques du corpus ciblé. Cette étape constitue le cœur du moteur de recherche : elle transforme les représentations internes (descripteurs) en scores numériques exploitables, permettant d'ordonner les documents ou phrases selon leur pertinence par rapport à la requête. Le principe général repose sur l'attribution, à chaque unité du corpus, d'un score de similarité (ou de distance) calculé à partir des descripteurs sélectionnés et de la mesure définie précédemment. Ces scores sont ensuite utilisés pour produire un classement (ranking), généralement par ordre décroissant de pertinence.

Dans cette séance, l'objectif n'est pas de redévelopper les algorithmes de similarité étudiés lors des séances 5 et 6, mais de **les réutiliser et les piloter via l'IHM**, en assurant la cohérence entre les paramètres choisis et les résultats produits.

L'interface doit permettre :

- le déclenchement du calcul des scores de similarité entre la requête et les unités du corpus sélectionné ;

- l'utilisation des descripteurs, mesures de similarité et paramètres définis dans les étapes précédentes ;
- le tri automatique des résultats par score décroissant ;
- la **sélection d'un nombre limité de résultats (top-k)**, où la valeur de k est configurable par l'utilisateur ;
- la conservation des scores associés à chaque résultat afin de permettre leur interprétation et leur comparaison.

Le paramètre k joue un rôle important dans l'analyse des résultats : il permet d'observer la stabilité du classement, d'explorer la longue traîne du corpus et de comparer l'impact des différentes stratégies de recherche sur le nombre et la qualité des résultats retournés. L'IHM **doit vérifier que $k \leq \text{nombre d'unités du corpus}$** .

IV. Visualisation et interprétation des résultats

Cette section est consacrée à la visualisation et à l'interprétation des résultats produits par le moteur de recherche. L'objectif n'est pas uniquement d'afficher des documents ou des phrases, mais d'aider l'utilisateur à comprendre, analyser et comparer les résultats obtenus en fonction des paramètres choisis lors du scénario de recherche unique.

Les visualisations proposées sont organisées selon deux niveaux d'analyse complémentaires :

- La sous-section IV.1 correspond à l'affichage des résultats textuels. L'utilisateur définit une requête, lance la recherche et consulte les documents ou phrases retournés par le moteur. L'accent est mis sur la lisibilité des résultats, la compréhension des scores et le maintien du contexte des unités linguistiques.
- La sous-section IV.2 propose une visualisation lexicale des résultats via des représentations synthétiques (nuages de mots). Cette approche permet d'explorer le contenu textuel des documents ou phrases retournés, d'analyser le recouvrement lexical avec la requête, d'identifier les thématiques dominantes et de visualiser l'enrichissement thématique des résultats.

L'ensemble de cette section vise à renforcer l'analyse qualitative des résultats, à faciliter l'interprétation des scores et à encourager l'expérimentation méthodologique, en cohérence avec les visualisations développées lors des séances 5 et 6.

1. Affichage des résultats textuels

L'affichage des résultats doit être clair, structuré et suffisamment informatif pour permettre à l'utilisateur d'interpréter rapidement la pertinence des documents ou phrases retournés par le moteur de recherche. Cette étape intervient après le calcul et le classement des résultats, et ne modifie pas les scores ni l'ordre produit par le moteur.

Pour chaque résultat, l'interface affiche les éléments suivants :

- **Identifiant du document ou de la phrase** : permet de référencer précisément l'unité dans le corpus.
- **Extrait textuel** : portion représentative du document ou phrase retournée, éventuellement centrée autour des termes de la requête.
- **Score de similarité** : valeur numérique associée au résultat, permettant la comparaison relative entre unités.
- **Informations contextuelles** : langue, sous-corpus, longueur et métadonnées pertinentes.
- **Marques de surlignage ou mots-clés** : surlignage ou marquage visuel facilitant l'interprétation pour mettre en évidence les termes de la requête dans le texte.

L'utilisateur peut configurer plusieurs aspects de l'affichage via l'IHM :

- **Longueur de l'extrait affiché** et possibilité d'étendre l'affichage pour consulter le document ou la phrase complète.
- **Activation ou désactivation du surlignage** des mots de la requête dans les résultats.
- **Mode de tri visuel** : par exemple par score (par défaut) ou selon certaines métadonnées (ex. longueur, date), sans modifier le classement calculé.
- **Affichage du contexte complet ou seulement d'un extrait** autour des mots-clés.
- **Sélection de métadonnées à montrer** : langue, sous-corpus, date, longueur, etc.
- **Options d'export** : copier les résultats, générer un fichier CSV ou JSON pour analyses externes.

La logique d'affichage, de tri et de filtrage visuel dans l'IHM doit rester cohérente avec le scénario de recherche défini précédemment (langue, sous-corpus, paramètres de calcul), afin de garantir la lisibilité et la reproductibilité des résultats présentés.

2. Visualisation lexicale des résultats

Cette sous-section vise à explorer le contenu lexical des résultats retournés par le moteur, indépendamment de leur score numérique. Les visualisations lexicales permettent de mieux comprendre quels termes caractérisent les documents ou phrases les plus pertinents, et de mettre en relation le vocabulaire de la requête avec celui des résultats. Ces visualisations s'appuient sur les outils développés lors de la séance 6 et ne nécessitent pas de nouveaux calculs de descripteurs, mais uniquement une exploitation visuelle des représentations existantes. Les visualisations lexicales peuvent être produites à différents niveaux d'agrégation : pour un document individuel, pour l'ensemble des résultats affichés, ou en comparaison directe avec la requête.

a) Niveaux de visualisation lexicale

L'utilisateur peut choisir le niveau d'agrégation de la visualisation :

- **Nuage de mots par document ou phrase**
 - Un nuage est généré pour un résultat sélectionné dans la liste (ex. document classé #1).

- Objectif : analyser localement pourquoi ce résultat est jugé pertinent.
- Usage typique : inspection qualitative d'un document précis.
- **Nuage de mots global des résultats**
 - Un seul nuage est généré à partir de l'ensemble des documents ou phrases affichés (ex. les 5 documents visibles parmi les k retournés).
 - Les mots sont agrégés sur l'ensemble des résultats sélectionnés.
 - Objectif : identifier les thématiques dominantes des résultats retournés par la recherche.
- **Nuage comparatif requête / résultats**
 - Visualisation côte à côte ou superposée :
 - nuage de mots de la requête,
 - nuage de mots des résultats (agrégés).
 - Objectif : observer le recouvrement lexical, les termes communs et spécifiques.

b) Paramètres configurables dans l'IHM

Pour éviter toute ambiguïté, l'interface doit permettre de choisir explicitement :

- **Type de nuage :**
 - par document / phrase,
 - global (ensemble des résultats affichés),
 - comparatif requête vs résultats.
- **Sous-ensemble utilisé :**
 - documents affichés (ex. 5 visibles),
 - top-k complet,
 - sélection manuelle de résultats.
- **Méthode de pondération :**
 - fréquence brute,
 - TF,
 - TF-IDF.
- **Nombre maximal de mots affichés.**
- **Gestion des termes de la requête dans les nuages de mots :**
l'utilisateur peut choisir d'afficher ou de masquer les termes de la requête présents dans les textes retournés, afin de comparer recouvrement lexical et enrichissement thématique. Les termes de la requête ne sont jamais ajoutés artificiellement aux documents. Cette option permet de distinguer visuellement les mots partagés entre la requête et les documents de ceux qui caractérisent spécifiquement les résultats.

Le nombre de résultats affichés (ex. 5) est indépendant du nombre de résultats calculés (top-k). Les visualisations lexicales s'appliquent uniquement au sous-ensemble visible ou sélectionné par l'utilisateur. L'objectif n'est pas d'évaluer quantitativement la pertinence, mais de faciliter une analyse qualitative du contenu des résultats, en mettant en évidence les thématiques dominantes et les éventuels écarts entre la requête et les documents retournés.

V. Comparaison de scénarios de recherche

Cette section est dédiée à la comparaison de plusieurs scénarios de recherche déjà exécutés à partir d'une même requête. Chaque scénario correspond à une combinaison donnée de paramètres (descripteurs, mesures de similarité, méthodes d'agrégation, normalisations, configurations de prétraitement, filtres, top-k, etc.) ayant produit un ensemble de résultats et de scores. L'objectif n'est pas de reconfigurer la requête ou le moteur, mais d'exploiter les résultats existants pour analyser l'impact des choix méthodologiques étudiés lors des séances 1 à 6.

1. Principe de comparaison

Comparer plusieurs scénarios permet de mieux comprendre :

- l'influence des choix de descripteurs et de mesures de similarité,
- l'effet des paramètres avancés (expansion de requête, multi-langues, normalisations),
- la sensibilité aux prétraitements et aux filtres appliqués sur le corpus.

Fonctionnalités attendues dans l'interface :

- **Sélection de plusieurs scénarios** déjà exécutés. L'utilisateur choisit les combinaisons qu'il souhaite comparer.
- **Affichage comparatif des résultats** : possibilité de visualiser les résultats textuels et les scores côte à côte, pour observer rapidement les différences de classement et la pertinence relative.
- **Les menus de paramétrage des scénarios** (descripteurs, distances, normalisations, top-k, filtres) ne sont pas modifiables dans cette vue, afin d'éviter toute confusion entre configuration et analyse comparative.

2. Analyse qualitative et quantitative

L'analyse ne se limite pas aux scores numériques : elle combine une approche statistique et qualitative pour comprendre le comportement du moteur et la diversité des résultats.

a) Stabilité des résultats

- Identifier si le classement des top-k résultats change selon les paramètres ou les méthodes.
- Repérer les documents ou phrases persistants entre scénarios.
- Visualisation possible : heatmap ou matrice de similarité entre classements.

b) Diversité des documents retournés

- Observer si différents scénarios renvoient des documents différents ou similaires.
- Détecter les biais induits par certains descripteurs ou distances.
- Visualisation possible : histogrammes comparatifs, nuages de mots par scénario pour visualiser le vocabulaire dominant.

c) Sensibilité aux pré-traitements

- Comparer l'impact des configurations de prétraitement (normalisation, tokenisation, suppression des stop-words) sur le classement et les scores.
- Permet de justifier ou d'ajuster les choix de pipeline pour optimiser la pertinence.

3. Visualisation et options de comparaison

L'interface doit offrir plusieurs types de visualisations basées sur les scores et résultats des scénarios sélectionnés :

- **Histogrammes ou courbes de distributions des scores**
 - Affichage de la répartition des scores pour un corpus ou un sous-corpus.
 - Possibilité de comparer les scores obtenus avec différents descripteurs ou mesures de similarité.
 - Options de normalisation : nombre absolu ou proportionnel (pour comparer des corpus de tailles différentes).
- **Comparaison de méthodes**
 - Graphiques côte à côte ou superposés pour visualiser l'impact de différents descripteurs, distances ou paramètres avancés.
 - Permet de voir la stabilité du classement et l'effet des normalisations ou de l'expansion de requête.
- **Évolution des scores selon les paramètres**
 - Tracer les scores ou top-k en fonction de paramètres configurables par l'utilisateur, ces paramètres correspondent à des scénarios distincts déjà exécutés, comme :
 - la valeur de k,
 - le type de descripteur (TF-IDF, BM25, embeddings),
 - la méthode d'agrégation,
 - la distance métrique choisie.
- **Affichage des résultats textuels comparatifs**
 - Résultats et scores des différents scénarios affichés côte à côte pour une lecture directe et qualitative.

L'utilisateur de l'IHM aura la possibilité de configurer :

- **Type de graphique** : histogramme, boxplot, courbe.
- **Données à visualiser** : scores globaux, scores par sous-corpus, score moyen, top-k.

- **Paramètres de comparaison** : sélectionner plusieurs méthodes ou descripteurs à afficher simultanément.
- **Filtres supplémentaires** : langues, sous-corpus, longueur de documents.
- **Options de personnalisation visuelle** : couleurs, axes log/linéaire, labels.

Vous pouvez prévoir plusieurs fonctions dans le moteur :

- Extraction et la structuration des données pertinentes pour chaque type de visualisation.
- Préparation des sous-ensembles pour comparaison multi-méthodes ou multi-descripteurs.
- Passage des paramètres configurés par l'utilisateur aux fonctions de génération des graphiques.

VI. Onglets complémentaires d'exploration (libres mais valorisés)

Ces onglets permettent à l'utilisateur de prolonger l'analyse des résultats et de valoriser les travaux réalisés lors des séances 1 à 6. Ils offrent une exploration libre et interactive du corpus, des descripteurs et des représentations internes du moteur, favorisant l'observation de patterns, la compréhension des données et la production de statistiques globales.

Au-delà des visualisations et analyses standard, ces onglets donnent la possibilité de proposer des explorations originales et personnelles du corpus et des résultats. L'objectif est de valoriser le travail effectué précédemment et de réfléchir à de nouvelles perspectives d'analyse, que ce soit pour mieux comprendre le contenu des documents, extraire des informations particulières ou mettre en évidence des tendances lexicales et thématiques. Vous êtes encouragés à expérimenter librement, à créer des vues interactives ou des filtres dynamiques, et à imaginer des approches inédites, comme l'analyse de sous-corpus, la comparaison thématique ou la fouille de données spécifique. L'évaluation portera sur votre capacité à exploiter de manière pertinente les données et représentations déjà construites, tout en proposant une réflexion critique et créative sur ce qui peut enrichir l'exploration du corpus.