

INFO0801 : Machine Learning

Janvier 2026

Amor KEZIOU
Laboratoire de Mathématiques de Reims
amor.keziou@univ-reims.fr

Objectifs du module

- Maîtrise des techniques de machine learning en classification et scoring ;
- Savoir mettre en œuvre ces techniques à l'aide des logiciels R/Python pour répondre aux multiples problèmes réels du domaine d'application du “[machine learning](#)”.

Organisation du cours

- Partie 1 (logiciel utilisé : R)
 - CM : 10h
 - TD sur machine, 10h, avec le logiciel R.
- Partie 2 (logiciel utilisé : Python)
 - Avec Mme Itheri YAHIAOUI : 10h CM, 10hTD avec le logiciel Python.

Évaluation

- Première session :
 - CT (2h00) : 100%.
- Deuxième session :
 - EOT : 100%.

Plan du cours

- Introduction au machine learning : Exemples et motivation ;
- Le problème de régression ;
- Régression et problème de classification ;
- Régression logistique et classification ;
- Analyse discriminante linéaire, quadratique et K -plus proches voisins pour la classification ;
- Sélection de modèles pour la classification, par critère AIC, BIC, méthodes de pénalisation, et les méthodes de type validation croisée et bootstrap.

CM 1 : Machine learning : Exemples et motivations

À quoi sert l'apprentissage statistique ?

- Reconnaissance faciale (de manière automatique)
 - La base de données d'apprentissage : est un ensemble d'images et labels (noms)
 - Critère d'évaluation : le pourcentage des reconnaissances correctes des personnes sur les nouvelles images
- Reconnaissance des plantes
 - La base de données d'apprentissage : est un ensemble d'images de feuilles des plantes avec les noms
 - Critère d'évaluation : le pourcentage des reconnaissances correctes des plantes sur les nouvelles images de feuilles



- Reconnaissance de la parole, des caractères manuscrits, ...
- Diagnostic médical
- Détection de fraude
- Marketing, recommander des produits que le client aimerait, ...
- Prédiction du marché (prix de l'immobilier, ...)
- Sécurité informatique
- ...

Les étapes du processus d'apprentissage statistique

- Définir un ensemble de possibilités susceptibles d'expliquer le phénomène (préparation des données) ;
- Ajuster un modèle sur la base des exemples disponibles (estimation) ;
- Repenser l'ensemble des possibilités (sélection de modèles).

Les différents types d'apprentissage statistique

- **Apprentissage supervisé** : on dispose des valeurs des variables explicatives et de la variable cible sur chacun des exemples, et le but est de construire un modèle (à partir de la base d'apprentissage) pour prédire la variable cible ;
- **Apprentissage non supervisé** : on dispose seulement des valeurs des variables explicatives, et le but est d'essayer de découvrir des structures dans les données (clustering, segmentation, ...) ;
- **Apprentissage semi-supervisé** : le nombre d'exemples - pour lesquels on dispose à la fois des valeurs des variables explicatives et des valeurs de la variable cible - est limité, et on essaye d'améliorer la qualité de prédiction par l'ajout d'exemples avec seulement les valeurs des variables explicatives (données sans labels).

Le problème d'apprentissage, estimation et évaluation de l'erreur de prédiction

Considérons le problème par exemple de reconnaissance faciale.
On se donne un ensemble $\mathcal{F}$ d'applications

$$f(\cdot) : \mathcal{X} \longrightarrow \mathcal{L}$$

de l'ensemble des images $\mathcal{X}$ vers l'ensembles des labels $\mathcal{L}$ (Ici, $\mathcal{L}$ est un ensemble de noms de personnes).

- **Estimation** : Sur la base d'un échantillon d'apprentissage $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$, d'images et de labels, on cherche à trouver un estimateur $\hat{f}(\cdot) \in \mathcal{F}$;
- **Evaluation** : On mesure la qualité de prédiction du label y d'un nouveau individu sur lequel on observe seulement $\mathbf{x}$.

Considérons une famille paramétrique $f(\mathbf{x}; \mathbf{w})$ d'applications de $\mathcal{X}$ à valeurs dans $\mathcal{L}$, pour traiter un problème de classification binaire d'images (deux classes codées -1 et $+1$). Par exemple l'application paramétrique

$$f(\mathbf{x}; \mathbf{w}) := \text{sign}(\mathbf{w}^\top \mathbf{x}) =: \hat{y}, \quad (1)$$

où $\mathbf{x} \in \mathbb{R}^d$ est le vecteur des pixels d'une image et $\hat{y} \in \{-1, +1\}$. Le vecteur des paramètres $\mathbf{w} \in \mathbb{R}^d$ doit être ajusté, sur la base d'exemples $(\mathbf{x}_i, y_i)$, $i = 1, \dots, n$, de manière à ce que le modèle prédise au mieux les labels d'images, i.e., $\hat{y} := f(\mathbf{x}; \mathbf{w})$ soit le plus souvent égal au label réel y de l'image $\mathbf{x}$.

On peut définir le problème d'estimation plus explicitement en introduisant la **fonction de perte** suivante :

$$\ell(y, \hat{y}) := \begin{cases} 0, & \text{si } \hat{y} = y, \\ 1, & \text{si } \hat{y} \neq y. \end{cases} \quad (2)$$

L'**erreur empirique** (d'ajustement, d'apprentissage), calculée à partir de l'échantillon d'apprentissage, est donnée dans ce cas par

$$\frac{1}{n} \sum_{i=1}^n \ell(y_i, \hat{y}_i) = \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(\mathbf{x}_i; \mathbf{w})). \quad (3)$$

C'est une fonction de $\mathbf{w}$, et le problème d'estimation est donc ramené à minimiser cette fonction en $\mathbf{w}$.

Question : Mais pourquoi cherche-t-on à minimiser cette erreur alors que ce qui nous intéresse est seulement la qualité de prédiction pour les nouveaux individus et non pas sur les individus d'apprentissage ?

- On suppose que chaque observation $(\mathbf{x}_i, y_i)$ est tirée (de manière aléatoire est indépendante) de la même population. Cette population peut être représentée par une loi de probabilité $P(\mathbf{x}, y)$ de sorte que chaque observation $(\mathbf{x}_i, y_i)$ de la base d'apprentissage/test suive la loi $P(\mathbf{x}, y)$.



On a donc

$$\text{L'erreur empirique (d'apprentissage)} := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(\mathbf{x}_i; \mathbf{w}))$$

et

$$\text{L'erreur théorique (de test)} := \mathbb{E}_{(\mathbf{x}, y) \sim P} \{ \ell(y, f(\mathbf{x}; \mathbf{w})) \} .$$


On peut voir donc que l'erreur empirique (calculé sur quelques individus de la population) est une approximation de l'erreur théorique sur l'ensemble de la population.

Problème de régression

Le but est d'expliquer/prédire une variable numérique “continue” $y \in \mathbb{R}$ à l'aide d'un vecteur $\mathbf{x} := (x_1, \dots, x_p) \in \mathbb{R}^p$ de p variables “explicatives” numériques $x_1, \dots, x_p$.

Par exemple, expliquer/prédire la consommation en carburant des véhicules à l'aide de variables statistiques : cylindrée, largeur, longueur, poids, vitesse, ...

- Nous avons besoin de spécifier la classe de fonctions (e.g. linéaires) ;
- Choisir comment mesurer l'erreur de prédiction (choix de la fonction de perte $\ell(\cdot, \cdot)$) ;
- Résoudre les problèmes d'optimisation liés au problème.



- On commence par la **régression linéaire simple ou multiple** (qui est facile à étendre à d'autres modèles plus complexes)

$$f : \mathbb{R} \times \mathbb{R}^2 \rightarrow \mathbb{R}; \quad f(x; \mathbf{w}) := w_0 + w_1 x$$

ou

$$f : \mathbb{R}^p \times \mathbb{R}^{1+p} \rightarrow \mathbb{R}; \quad f(\mathbf{x}; \mathbf{w}) := w_0 + w_1 x_1 + \cdots + w_p x_p,$$

où $\mathbf{w} := (w_0, w_1, \dots, w_p)^\top \in \mathbb{R}^{1+p}$ est le vecteur des paramètres du modèle qu'on cherche à estimer.

On peut mesurer l'erreur de prédiction en terme de la fonction quadratique

$$\ell(y, \hat{y}) := (y - \hat{y})^2,$$

et dans ce cas l'**erreur empirique** devient (l'erreur quadratique moyenne)

$$\begin{aligned} J_n(\mathbf{w}) &:= \frac{1}{n} \sum_{i=1}^n (y_i - f(\mathbf{x}_i; \mathbf{w}))^2 \\ &= \frac{1}{n} \sum_{i=1}^n (y_i - w_0 - w_1 x_{i,1} - w_2 x_{i,2} - \cdots - w_p x_{i,p})^2. \end{aligned} \quad (4)$$

Le vecteur des paramètres $\mathbf{w} := (w_0, w_1, \dots, w_p)$ est estimé donc par (**moindres carrés**)

$$\hat{\mathbf{w}} := \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p}} J_n(\mathbf{w}).$$

Les différents types d'erreur en régression

En régression, il y a deux types d'erreurs

- L'**erreur structurelle** due au modèle

$$\min_{w_0, w_1} \mathbb{E}_{(x,y) \sim P} (y - w_0 - w_1 x)^2 = \mathbb{E}_{(x,y) \sim P} (y - w_0^* - w_1^* x)^2,$$

où (w_0^*, w_1^*) sont les paramètres optimaux du modèle de régression ;

- L'**erreur d'approximation** qui mesure l'écart entre la prédiction optimale et celle obtenue sur l'ensemble fini des données d'apprentissage

$$\mathbb{E}_{(x,y) \sim P} (w_0^* + w_1^* x - \hat{w}_0 - \hat{w}_1 x)^2,$$

où $(\hat{w}_0, \hat{w}_1)$ sont les estimateurs des paramètres du modèle calculés à partir de l'échantillon d'apprentissage (eux mêmes aléatoires).

Décomposition de l'erreur théorique d'un modèle de régression linéaire

L'**erreur théorique (de prévision ou de test)** d'un modèle de régression linéaire se décompose en la somme de l'**erreur structurelle** et de l'**erreur d'approximation**.

En effet, on a $\mathbb{E}_{(x,y) \sim P} (y - \hat{w}_0 - \hat{w}_1 x)^2$

$$\begin{aligned}
 &= \mathbb{E}_{(x,y) \sim P} ((y - w_0^* - w_1^* x) + (w_0^* + w_1^* x - \hat{w}_0 - \hat{w}_1 x))^2 \\
 &= \mathbb{E}_{(x,y) \sim P} (y - w_0^* - w_1^* x)^2 \\
 &\quad + \mathbb{E}_{(x,y) \sim P} 2(y - w_0^* - w_1^* x)(w_0^* + w_1^* x - \hat{w}_0 - \hat{w}_1 x) \\
 &\quad + \mathbb{E}_{(x,y) \sim P} (w_0^* + w_1^* x - \hat{w}_0 - \hat{w}_1 x)^2,
 \end{aligned}$$

et l'avant dernier terme est nul (à cause de la condition d'orthogonalité).

CM2 : Au-delà du modèle de régression linéaire

- Modèles de régression additifs, exemples
- Evaluation de l'erreur théorique d'un modèle par des méthodes de type "validation croisée"
- Fonction de perte quadratique et modèle de régression (théorique) optimal
- Modèle de régression linéaire du point de vue "statistique" : formulation du problème et estimation par maximum de vraisemblance
- Evaluation de la performance des estimateurs des paramètres d'un modèle par "Bootstrap"

La fonction de régression linéaire (simple ou multiple) s'écrit

$$f : \mathbb{R} \times \mathbb{R}^2 \rightarrow \mathbb{R}; \quad f(x; \mathbf{w}) := w_0 + w_1 x$$

ou

$$f : \mathbb{R}^p \times \mathbb{R}^{1+p} \rightarrow \mathbb{R}; \quad f(\mathbf{x}; \mathbf{w}) := w_0 + w_1 x_1 + \cdots + w_p x_p.$$

À partir d'un échantillon $(\mathbf{x}_i, y_i)$, $i = 1, \dots, n$, si on considère la fonction de perte quadratique, i.e., $\ell(y, \hat{y}) := (y - \hat{y})^2$, on obtient la forme explicite suivante des estimateurs des paramètres

$\mathbf{w} := (w_0, w_1, \dots, w_p)^\top$ du modèle : $\hat{\mathbf{w}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$, où $\mathbb{X}$ est le tableau de données (des variables explicatives), la première colonne étant le vecteur de dimension n , $(1, 1, \dots, 1)^\top$, i.e., la matrice (appelée **matrice de design**)

$$\mathbb{X} := \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ 1 & x_{2,1} & \cdots & x_{2,p} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n,1} & \cdots & x_{n,p} \end{bmatrix} \in \mathcal{M}_{n \times (1+p)}(\mathbb{R}), \text{ et } \mathbf{y} := \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \in \mathbb{R}^n.$$

Remarques

- Le vecteur des **résidus** $\hat{\epsilon}_i := y_i - f(\mathbf{x}_i; \hat{\mathbf{w}})$, $i = 1, \dots, n$, est orthogonal à n'importe quelle transformation linéaire des variables explicatives $x_{i,j}$, $i = 1, \dots, n$, $j = 1, \dots, p$;
- Les résidus sont centrés : $\frac{1}{n} \sum_{i=1}^n \hat{\epsilon}_i = 0$;
- On peut étendre les résultats précédents à des modèles linéaires plus généraux qui peuvent inclure des transformations non-linéaires des variables explicatives. Par exemple, si on veut étendre le modèle de régression linéaire simple à un **modèle de régression polynomial** d'ordre $m \in \mathbb{N}^*$, en restant linéaire aux paramètres, on utilise la fonction de régression

$$f : \mathbb{R} \times \mathbb{R}^{1+m} \rightarrow \mathbb{R}, \quad f(x; \mathbf{w}) := w_0 + w_1 x + w_2 x^2 + \dots + w_m x^m,$$

qui est linéaire par rapport aux paramètres, et non-linéaire par rapport à l'entrée x .

La solution est de la même forme que le cas précédent

$$\hat{\mathbf{w}} = \left(\mathbb{X}^\top \mathbb{X} \right)^{-1} \mathbb{X}^\top \mathbf{y},$$

avec

$$\mathbb{X} := \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^m \\ 1 & x_2 & x_2^2 & \cdots & x_2^m \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^m \end{bmatrix} \in \mathcal{M}_{n \times (1+m)}(\mathbb{R}).$$

Modèles de régression additifs

- Plus généralement, un modèle de régression peut inclure un ensemble de fonctions de base $\{\phi_1(\mathbf{x}), \dots, \phi_m(\mathbf{x})\}$, où chacune des fonctions $\phi_i(\cdot) : \mathbb{R}^p \rightarrow \mathbb{R}$ est une transformation du vecteur $\mathbf{x}$:

$$f(\mathbf{x}; \mathbf{w}) := w_0 + w_1 \phi_1(\mathbf{x}) + \dots + w_m \phi_m(\mathbf{x}).$$

- Exemples :
 - Si $p = 1$, et $\phi_j(x) = x^j$, $j = 1, \dots, m$, alors

$$f(x; \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \dots + w_m x^m.$$

- Si $m = p$, $\phi_j(\mathbf{x}) = x_j$, $j = 1, \dots, m$, alors

$$f(\mathbf{x}; \mathbf{w}) = w_0 + w_1 x_1 + \dots + w_p x_p.$$

- Les fonctions de base peuvent capturer divers caractéristiques des individus (sur la base des variables explicatives). Par exemple, on peut essayer d'évaluer les entreprises en fonction de descriptions textuelles :

$\mathbf{x} :=$ un document texte

$$\phi_j(\mathbf{x}) := \begin{cases} 1 & \text{si le mot } j \text{ figure dans le document} \\ 0 & \text{sinon} \end{cases}$$

et

$$f(\mathbf{x}; \mathbf{w}) = w_0 + \sum_{j \in \{\text{ensemble de mots}\}} w_j \phi_j(\mathbf{x}).$$

- On peut aussi construire des modèles de prédiction en évaluant les similitudes des exemples avec des “**prototypes**”. Par exemple, la fonction de régression peut prendre la forme


$$f(\mathbf{x}; \mathbf{w}) = w_0 + w_1 \phi_1(\mathbf{x}) + \cdots + w_m \phi_m(\mathbf{x}),$$

où les fonctions de base sont des fonctions “**radiales**”

$$\phi_k(\mathbf{x}) := \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{x} - \mathbf{x}_k\|^2 \right\}, k = 1, \dots, m,$$

qui mesure la similarité de $\mathbf{x}$ aux prototypes $\mathbf{x}_k$, $k = 1, \dots, m$; le paramètre σ^2 contrôle la vitesse de décroissance vers zéro de la fonction de base en fonction de la distance de $\mathbf{x}$ par rapport au prototype $\mathbf{x}_k$. (des points de l'échantillon d'apprentissage, ou les centres de groupes homogènes d'individus, peuvent servir de prototypes).

- On peut schématiser un modèle additif de régression comme suit



- En **réseaux de neurones**, les fonctions de base elles mêmes dépendent de paramètres qu'il faut estimer ...

Evaluation de l'erreur théorique d'un modèle par des méthodes de type “validation croisée”

- Considérons un modèle de régression linéaire polynomial.




Figure – Ajustement par un polynôme de degré 1 (à gauche), degré 2 (à droite)




Figure – Ajustement par un polynôme de degré 5 (à gauche), degré 7 (à droite)

Complexité des modèles et **sur-ajustement**




Figure – Ajustement par un polynôme de degré 7, problème de **sur-ajustement** !

- Avec un nombre limité d'exemples, le modèle de régression polynomial (avec grande dimension) peut avoir une **erreur empirique** (d'ajustement) proche de zéro, alors que l'**erreur théorique** (de test) pourrait être très importante :

$$\text{L'erreur empirique (d'ajustement)} := \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i; \hat{\mathbf{w}}))^2 \approx 0$$

$$\text{L'erreur théorique (de prévision)} := \mathbb{E}_{(x,y) \sim P} (y - f(x; \hat{\mathbf{w}}))^2 \gg 0$$

- On dit dans ce cas qu'on est face à un problème de **sur-ajustement** (appelé aussi problème de **sur-apprentissage**!).

Comment sélectionner le meilleur modèle, et éviter le problème de sur-ajustement ?

Il faut estimer correctement l'**erreur théorique** de chaque modèle, et choisir le modèle ayant l'erreur estimée la plus faible. Les méthodes de validation croisée permettent d'estimer efficacement cette erreur. On présente ici trois méthodes :

- **Méthode 1 : (l'approche de l'ensemble de validation)**. Cette approche est très simple. Elle consiste à diviser de manière aléatoire l'ensemble d'observations en deux parties : un ensemble d'apprentissage ($\mathcal{A}$) et un ensemble de validation ($\mathcal{V}$). Le modèle est construit à partir des données d'apprentissage, et il est ensuite utilisé pour prédire la variable réponse des données de l'ensemble de validation. L'**erreur théorique**, que l'on note $\mathcal{E}$, est alors estimée par l'écart moyen entre les valeurs prédites et les valeurs observées de la variable réponse des données de l'ensemble de validation :

$$\hat{\mathbf{w}} := \arg \min_{\mathbf{w}} \frac{1}{\text{Card}(\mathcal{A})} \sum_{i \in \mathcal{A}} \ell(y_i, f(\mathbf{x}_i; \mathbf{w}))$$

et

$$\hat{\mathcal{E}} := \frac{1}{\text{Card}(\mathcal{V})} \sum_{i \in \mathcal{V}} \ell(y_i, f(\mathbf{x}_i; \hat{\mathbf{w}})).$$

Cette méthode est simple, mais elle a deux inconvénients :

- L'estimation de l'erreur théorique dépend de la partition, et elle peut varier beaucoup si on considère une partition différente ;
- Dans cette approche seulement une partie des données est utilisée pour ajuster le modèle, ce qui peut mener à une sur-estimation de l'erreur.

Les deux méthodes suivantes répondent à ces problèmes.

- **Méthode 2 : (leave-one-out cross-validation (LOOCV)).**

Comme la méthode précédente, la méthode **LOOCV** consiste à diviser l'ensemble des observations en deux parties.

Cependant, au lieu de créer deux parties de tailles comparables, une seule observation $(\mathbf{x}_1, y_1)$ est utilisée pour la validation et tout le reste est utilisé pour l'apprentissage (pour estimer le modèle). Donc le modèle est ajusté sur la base des $(n - 1)$ observations restantes, et une prédiction $\hat{y}_1$ est calculée en fonction de $\mathbf{x}_1$. Plus précisément, si on note $\hat{\mathbf{w}}^{(-1)}$ l'estimateur obtenu en utilisant toutes les observations sauf l'observation $(\mathbf{x}_1, y_1)$, alors $\hat{y}_1 := f(\mathbf{x}_1; \hat{\mathbf{w}}^{(-1)})$. Puisque l'observation $(\mathbf{x}_1, y_1)$ n'a pas été utilisée pour ajuster le modèle, alors $e_1 := \ell(y_1, \hat{y}_1) = \ell(y_1, f(\mathbf{x}_1; \hat{\mathbf{w}}^{(-1)}))$ est une estimation approximativement sans biais de l'erreur théorique, mais elle n'est pas précise puisque elle est basée sur une seule observation.

On répète alors la procédure précédente en choisissant $(\mathbf{x}_2, y_2)$ pour la validation, et les observations restantes pour ajuster le modèle, et on calcule $e_2 := \ell(y_2, \hat{y}_2) = \ell(y_2, f(\mathbf{x}_2; \hat{\mathbf{w}}^{(-2)}))$. En répétant la procédure n fois, on obtient n estimations, $e_1, e_2, \dots, e_n$, de l'erreur théorique $\mathcal{E}$. Le LOOCV donne l'estimation suivante de l'erreur théorique

$$\hat{\mathcal{E}} := \frac{1}{n} \sum_{i=1}^n e_i = \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(\mathbf{x}_i; \hat{\mathbf{w}}^{(-i)})). \quad (5)$$

Cette méthode a au moins deux avantages par rapport à la méthode 1 précédente (l'approche de l'ensemble de validation).

- En LOOCV, l'estimation de l'erreur théorique est plus précise, car à chaque fois on utilise toutes les données (sauf une) pour estimer les paramètres du modèle, alors que la méthode 1 utilise seulement une partie des données pour l'estimation des paramètres du modèle ;

- Contrairement à la méthode 1 de l'ensemble de validation - qui donne des résultats différents en changeant la répartition des données entre les deux ensembles apprentissage/validation - le LOOCV donne le même résultat s'il est appliqué plusieurs fois sur la même base de données.

Cependant, le LOOCV est coûteux en temps de calcul en général, en particulier si n est grand, puisque le calcul des estimateurs des paramètres du modèle est répété n fois. Ce problème peut être évité dans le cas d'un modèle de régression (linéaire en $\mathbf{w}$) et une fonction de perte quadratique. En effet, on peut montrer que l'estimation précédente (5) peut s'écrire sous la forme plus simple

$$\begin{aligned}\hat{\mathcal{E}} &:= \frac{1}{n} \sum_{i=1}^n (y_i - f(\mathbf{x}_i; \hat{\mathbf{w}}^{(-i)}))^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - f(\mathbf{x}_i; \hat{\mathbf{w}})}{1 - h_i} \right)^2,\end{aligned}\tag{6}$$

où $\hat{\mathbf{w}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$ est l'estimateur des moindres-carrés utilisant toutes les données, et h_i est le i^{eme} élément diagonal de la matrice $\mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$, pour tout $i = 1, \dots, n$.

- **Méthode 3 : (K -fold cross-validation (K -fold CV))**. Cette méthode est une alternative aux deux méthodes (LOOCV et celle de l'ensemble de validation). Elle consiste à diviser de manière aléatoire le tableau des données en K groupes ("folds") de même effectif (ou presque). Notons $G_1, \dots, G_K$ ces groupes. Le premier groupe est considéré comme un ensemble de validation, les $K - 1$ autres groupes sont utilisés pour ajuster le modèle. Une première approximation de l'erreur théorique est donnée par

$$e_1 = \frac{1}{\text{Card}(G_1)} \sum_{i \in G_1} \ell(y_i, f(\mathbf{x}_i; \hat{\mathbf{w}}^{(-1)})).$$

Cette procédure est répétée K fois, et à chaque fois, un groupe différent est traité comme ensemble de validation et les autres comme ensemble d'apprentissage ;

Ceci permet d'avoir K estimations de l'erreur théorique

$$e_k = \frac{1}{\text{Card}(G_k)} \sum_{i \in G_k} \ell(y_i, f(\mathbf{x}_i; \hat{\mathbf{w}}^{(-k)})), \quad \forall k = 1, \dots, K.$$

L'estimation de l'erreur théorique $\mathcal{E}$ par la K-fold CV est calculée alors en moyennant les valeurs précédentes

$$\begin{aligned} \hat{\mathcal{E}} &:= \frac{1}{K} \sum_{k=1}^K e_k \\ &= \frac{1}{K} \sum_{k=1}^K \frac{1}{\text{Card}(G_k)} \sum_{i \in G_k} \ell(y_i, f(\mathbf{x}_i; \hat{\mathbf{w}}^{(-k)})). \end{aligned} \quad (7)$$

Remarque

Il n'est pas difficile de voir que la méthode **K -fold CV** = la méthode **LOOCV** si $K = n$. Dans la pratique, on applique une méthode **K -fold CV** souvent avec $K = 10$. L'avantage de ce choix est de réduire le temps de calcul pour l'estimation des paramètres du modèle, en particulier si n est grand.

Le bootstrap

- Le bootstrap est un outil performant pour évaluer l'incertitude d'un estimateur ou d'une méthode d'apprentissage. Par exemple, il peut être utilisé pour estimer les variances et les biais des estimateurs des paramètres d'un modèle de densité de probabilité ou d'un modèle de régression ;
- Nous allons illustrer la méthode du bootstrap dans le cas simple de l'estimation paramétrique d'une densité de probabilité. Soit X une variable aléatoire réelle dont la densité de probabilité est supposée appartenir à un modèle paramétrique (une famille paramétrique de densités de probabilité) $\{x \in \mathbb{R} \mapsto f(x, \theta); \theta \in \Theta \subset \mathbb{R}\}$. Notons θ_v la vraie valeur inconnue du paramètre θ .

- Soit $D_n := \{x_1, \dots, x_n\}$ un échantillon i.i.d. de X .
L'estimateur du **maximum de vraisemblance** (MV) $\hat{\theta}$ de θ_v est défini comme suit

$$\hat{\theta} := \arg \sup_{\theta \in \Theta} L_n(D_n, \theta) := \arg \sup_{\theta \in \Theta} \prod_{i=1}^n f(x_i, \theta).$$

- Il est naturel de vouloir évaluer l'efficacité de l'estimateur $\hat{\theta}$, i.e., estimer l'erreur théorique

$$\begin{aligned} \mathbb{E} \left\{ \left(\hat{\theta} - \theta_v \right)^2 \right\} &= \mathbb{E} \left\{ \left(\hat{\theta} - \mathbb{E}(\hat{\theta}) \right)^2 \right\} + \left\{ \mathbb{E}(\hat{\theta}) - \theta_v \right\}^2 \\ &=: \text{Var}(\hat{\theta}) + \text{biais}(\hat{\theta})^2. \end{aligned}$$

La méthode du bootstrap, pour estimer $\text{Var}(\hat{\theta})$, consiste à générer un “grand” nombre R d'échantillons “bootstrapés” (chacun de taille n) :

$$D_r^* := \{x_{1,r}^*, \dots, x_{n,r}^*\}, \quad r = 1, \dots, R.$$

Chacun des échantillons bootstrapés est obtenu en effectuant n tirages avec remise dans l'ensemble des observations $\{x_1, \dots, x_n\}$. On calcule alors R nouveaux estimateurs (bootstrapés),

$$\hat{\theta}_r^* := \arg \sup_{\theta \in \Theta} L(D_r^*, \theta) = \arg \sup_{\theta \in \Theta} \prod_{i=1}^n f(x_{i,r}^*, \theta), \quad r = 1, \dots, R,$$

chacun des estimateurs $\hat{\theta}_r^*$, $r = 1, \dots, R$, est calculé à partir de l'échantillon bootstrapé $D_r^* := \{x_{1,r}^*, \dots, x_{n,r}^*\}$. La variance $\text{Var}(\hat{\theta})$ est estimée alors par

$$\widehat{\text{Var}}(\hat{\theta}) := \frac{1}{R-1} \sum_{r=1}^R \left(\hat{\theta}_r^* - \frac{1}{R} \sum_{b=1}^R \hat{\theta}_b^* \right)^2.$$

De même, le biais peut être estimé par

$$\widehat{\text{biais}}(\hat{\theta}) := \left(\frac{1}{R} \sum_{r=1}^R \hat{\theta}_r^* \right) - \hat{\theta}.$$




Fonction de perte quadratique et modèle théorique optimal

- Qu'est-ce que nous obtenons si on a une infinité d'observations (toute la population) et aucune condition sur le modèle ?

$$\text{minimiser } \mathbb{E}_{(x,y) \sim P} (y - f(x))^2$$

sur l'ensemble de fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$.





Pour minimiser en f l'erreur théorique

$$\mathbb{E}_{(\mathbf{x}, y) \sim P} (y - f(\mathbf{x}))^2 = \mathbb{E}_{\mathbf{x} \sim P_{\mathbf{x}}} \left[\mathbb{E}_{y \sim P_{y|\mathbf{x}}} (y - f(\mathbf{x}))^2 \right]$$

on peut pour tout $\mathbf{x}$ fixé, minimiser en $f(\mathbf{x})$, l'erreur $\mathbb{E}_{y \sim P_{y|\mathbf{x}}} (y - f(\mathbf{x}))^2$, dans ce cas l'optimum vérifie

$$\begin{aligned} \frac{\partial}{\partial f(\mathbf{x})} \mathbb{E}_{y \sim P_{y|\mathbf{x}}} (y - f(\mathbf{x}))^2 &= -2 \mathbb{E}_{y \sim P_{y|\mathbf{x}}} (y - f(\mathbf{x})) \\ &= -2 (\mathbb{E} \{y | \mathbf{x}\} - f(\mathbf{x})) = 0. \end{aligned}$$

D'où l'optimum est donné par

$$f^*(\mathbf{x}) = \mathbb{E} \{y | \mathbf{x}\}.$$

Un point de vue statistique au problème de régression linéaire

- Dans un modèle de régression, on modélise à la fois la fonction de régression et le bruit

$$y = f(\mathbf{x}; \mathbf{w}) + \epsilon, \quad (8)$$


avec $\mathbb{E}(\epsilon | \mathbf{x}) = 0$, et $\text{Var}(\epsilon | \mathbf{x}) =: \sigma^2$ ne dépendant pas de $\mathbf{x}$ (hypothèse d'**homoscédasticité**).

- Tout ce qui n'est pas capturé par la fonction de régression est considéré comme du bruit.

- Le modèle $f(\mathbf{x}; \mathbf{w})$ essaye de capturer la moyenne de l'observation y sachant l'entrée $\mathbf{x}$:

$$\begin{aligned}\mathbb{E}\{y \mid \mathbf{x}\} &= \mathbb{E}\{f(\mathbf{x}; \mathbf{w}) + \epsilon \mid \mathbf{x}\} \\ &= f(\mathbf{x}; \mathbf{w}),\end{aligned}$$

où $\mathbb{E}\{y \mid \mathbf{x}\}$ est l'espérance conditionnelle de y sachant $\mathbf{x}$ évaluée suivant le modèle $f(\mathbf{x}; \mathbf{w})$ (et non pas suivant la loi P)



- Si on suppose, dans le modèle (8), que $\epsilon \sim \mathcal{N}(0, \sigma^2)$, alors la loi conditionnelle de la variable réponse y , sachant $\mathbf{x}$, est une loi normale de moyenne $f(\mathbf{x}; \mathbf{w})$ et variance σ^2

$$p(y | \mathbf{x}; \mathbf{w}, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - f(\mathbf{x}; \mathbf{w}))^2 \right\}$$

(on modélise également l'incertitude dans les prédictions, pas seulement l'espérance conditionnelle) ;

- Quelle fonction de perte ? Quelle méthode d'estimation ?

Estimation par maximum de vraisemblance

- À partir d'un échantillon $D_n := \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$, on cherche le vecteur paramètre $\mathbf{w}$ qui maximise la vraisemblance (conditionnelle)

$$L_n(D_n; \mathbf{w}, \sigma^2) := \prod_{i=1}^n p(y_i | \mathbf{x}_i; \mathbf{w}, \sigma^2).$$

- Il est souvent plus facile (est équivalent) de maximiser la log-vraisemblance

$$\begin{aligned} \ell_n(D; \mathbf{w}, \sigma^2) &:= \log L_n(D_n; \mathbf{w}, \sigma^2) = \sum_{i=1}^n \log p(y_i | \mathbf{x}_i; \mathbf{w}, \sigma^2) \\ &= \sum_{i=1}^n \left(-\frac{1}{2\sigma^2} (y_i - f(\mathbf{x}_i; \mathbf{w}))^2 - \log \sqrt{2\pi\sigma^2} \right) \\ &= \left(-\frac{1}{2\sigma^2} \right) \sum_{i=1}^n (y_i - f(\mathbf{x}_i; \mathbf{w}))^2 - n \log \sqrt{2\pi\sigma^2}. \end{aligned}$$



- Maximiser la vraisemblance est équivalent à minimiser la fonction de perte empirique si la fonction de perte est de la forme (**fonction de perte logarithmique**)

$$\ell(y, f(\mathbf{x}; \mathbf{w})) := -\log p(y | \mathbf{x}; \mathbf{w}, \sigma^2).$$

- Notons $\hat{\mathbf{w}}$ l'estimateur du maximum de vraisemblance de $\mathbf{w}$ (qui est égal à l'estimateur des moindres carrés sous l'hypothèse de normalité du résidus : $\epsilon \sim \mathcal{N}(0, \sigma^2)$). On peut montrer par dérivation de la log-vraisemblance (par rapport à σ^2) que l'estimateur du maximum de vraisemblance de σ^2 est égal à

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - f(\mathbf{x}_i; \hat{\mathbf{w}}))^2.$$

Classification via régression logistique

- Dans un problème de régression, lorsque la variable réponse Y est qualitative (avec un nombre M fini de modalités $C_0, \dots, C_{M-1}$) ou (numérique discrète avec nombre de modalités "petit"), on appelle cela un problème de **classification**. Notons, $\mathbf{X} := (X_1, \dots, X_p)^\top$ le vecteur des variables explicatives. On cherche à prédire, pour un nouveau individu, sa modalité en fonction du vecteur $\mathbf{X}$. On cherche donc à classer l'individu dans l'une des modalités en fonction de la valeur $\mathbf{x}$ du vecteur $\mathbf{X}$ qu'on observe sur cet individu.
- Pourquoi le modèle de régression (linéaire) n'est pas approprié pour répondre à ce problème ? La raison est la suivante. Dans le modèle de régression (linéaire) classique, la variable réponse est numérique. Donc une variable réponse qualitative doit être transformée en une variable numérique.

Notons que cela détermine entièrement la deuxième probabilités $p_0(\mathbf{x}) := \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x})$ puisque $p_0(\mathbf{x}) + p_1(\mathbf{x}) = 1$.

- Là encore le modèle de régression linéaire $f(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + \dots + w_p x_p$ n'est pas approprié pour modéliser la probabilité $p_1(\mathbf{x}) := \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$, qui prend ses valeurs dans l'intervalle $[0, 1]$, alors que le modèle linéaire peut bien donner des valeurs négatives ou supérieures à 1. On utilise alors le modèle suivant (dit de **régression logistique**)

$$f(\mathbf{x}, \mathbf{w}) = \frac{\exp\{w_0 + w_1 x_1 + \dots + w_p x_p\}}{1 + \exp\{w_0 + w_1 x_1 + \dots + w_p x_p\}} \in [0, 1],$$

qui prend bien ses valeurs dans l'intervalle $[0, 1]$, et qui est donc plus approprié pour modéliser la probabilité $p_1(\mathbf{x})$:

$$p_1(\mathbf{x}) = f(\mathbf{x}, \mathbf{w}) := \frac{\exp\{w_0 + w_1 x_1 + \dots + w_p x_p\}}{1 + \exp\{w_0 + w_1 x_1 + \dots + w_p x_p\}} + \epsilon, \quad (9)$$

$$\begin{aligned} p_0(\mathbf{x}) &= 1 - p_1(\mathbf{x}) \\ &= 1 - f(\mathbf{x}, \mathbf{w}) + \epsilon \\ &= \frac{1}{1 + \exp\{w_0 + w_1 x_1 + \cdots + w_p x_p\}} + \epsilon. \end{aligned}$$

D'où la relation suivante, qui permet de modéliser, le rapport $p_1(\mathbf{x})/p_0(\mathbf{x})$ (appelé 'odds') :

$$\begin{aligned} \frac{p_1(\mathbf{x})}{p_0(\mathbf{x})} &= \frac{p_1(\mathbf{x})}{1 - p_1(\mathbf{x})} \\ &= \frac{f(\mathbf{x}, \mathbf{w})}{1 - f(\mathbf{x}, \mathbf{w})} + \epsilon \\ &= \exp \{w_0 + w_1 x_1 + \cdots + w_p x_p\} + \epsilon. \end{aligned} \quad (10)$$

Avec une transformation logarithmique, on obtient de l'équation précédente

$$\log \frac{p_1(\mathbf{x})}{p_0(\mathbf{x})} = \log \frac{p_1(\mathbf{x})}{1 - p_1(\mathbf{x})} = w_0 + w_1 x_1 + \cdots + w_p x_p + \epsilon. \quad (11)$$

qui modélise $\log \frac{p_1(x)}{p_0(x)}$, appelé 'log-odds' ou 'logit'.

Estimation des paramètres du modèle de régression logistique par MV

On utilise la méthode du maximum de vraisemblance (MV). La loi de Y sachant $\mathbf{X} = \mathbf{x}$ est une loi de Bernoulli de paramètre $\mathbb{P}(Y = 1|\mathbf{X} = \mathbf{x}) = f(\mathbf{x}, \mathbf{w})$. Donc elle peut s'écrire sous la forme

$$\mathbb{P}(Y = y|\mathbf{X} = \mathbf{x}) = f(\mathbf{x}, \mathbf{w})^y (1 - f(\mathbf{x}, \mathbf{w}))^{(1-y)} =: g(\mathbf{x}, y, \mathbf{w}), \quad y \in \{0, 1\}.$$

Soit $(\mathbf{x}_i, y_i), i = 1, \dots, n$, un échantillon de $(\mathbf{X}, Y)$, (un échantillon représentatif). La vraisemblance (conditionnelle) s'écrit donc

$$\begin{aligned} L_n(\mathbf{w}) &:= \prod_{i=1}^n g(\mathbf{x}_i, y_i, \mathbf{w}) \\ &= \prod_{i=1}^n f(\mathbf{x}_i, \mathbf{w})^{y_i} (1 - f(\mathbf{x}_i, \mathbf{w}))^{1-y_i}. \end{aligned} \quad (12)$$

D'où la log-vraisemblance prend la forme

$$\begin{aligned}\ell_n(\mathbf{w}) &:= \log L_n(\mathbf{w}) \\ &= \sum_{i=1}^n y_i \log f(\mathbf{x}_i, \mathbf{w}) + (1 - y_i) \log (1 - f(\mathbf{x}_i, \mathbf{w})).\end{aligned}\tag{13}$$

L'estimateur du maximum de vraisemblance de $\mathbf{w}$ est donné donc par

$$\begin{aligned}\hat{\mathbf{w}} &:= \arg \sup_{\mathbf{w} \in \mathbb{R}^{1+p}} \ell_n(\mathbf{w}) \\ &= \arg \sup_{\mathbf{w} \in \mathbb{R}^{1+p}} \sum_{i=1}^n y_i \log f(\mathbf{x}_i, \mathbf{w}) + (1 - y_i) \log (1 - f(\mathbf{x}_i, \mathbf{w})).\end{aligned}\tag{14}$$

On en déduit les valeurs prédites suivantes des probabilités $p_1(\mathbf{x})$ et $p_0(\mathbf{x})$ pour une valeur $\mathbf{X} = \mathbf{x} \in \mathbb{R}^p$ donnée :

$$\hat{p}_1(\mathbf{x}) := f(\mathbf{x}, \hat{\mathbf{w}}); \quad \hat{p}_0(\mathbf{x}) := 1 - f(\mathbf{x}, \hat{\mathbf{w}}).$$

En remplaçant dans le modèle logit (11), on obtient le modèle “linéaire” suivant

$$z_i := \log \frac{\hat{p}_1(\mathbf{x}_i)}{1 - \hat{p}_1(\mathbf{x}_i)} = \hat{w}_0 + \hat{w}_1 x_{i,1} + \cdots + \hat{w}_p x_{i,p} + \epsilon_i, \quad (15)$$

$i = 1, \dots, n$. L'EMV $\hat{\mathbf{w}}$ de $\mathbf{w}$, défini par (14), peut être calculé sous R à l'aide de la fonction 'glm()' en spécifiant la famille de loi binomiale, suivant la syntaxe suivante

```
> glm(formula = Y ~ ., family = binomial, data = NomDeLaBD).
```


Classifieur Bayésien

- Problème de classification : On observe le vecteur $\mathbf{X}$ sur un nouveau individu (i). Notons $\mathbf{x}_i$ la valeur observée. On cherche à classer l'individu (i) dans l'une des classes C_0 ou C_1 (ou de manière équivalente prédire la valeur y_i de Y , 0 ou 1). On peut montrer que le classifieur (théorique) optimal, i.e., celui qui minimise l'erreur théorique de test, est le classifieur qui consiste à affecter l'individu (i) dans la classe dont la probabilité conditionnellement à $\mathbf{X} = \mathbf{x}_i$ est la plus grande. Précisément, la valeur prédite (théorique) y_i^* sera définie par

$$y_i^* := \arg \sup_{y \in \{0,1\}} \mathbb{P}(Y = y | \mathbf{X} = \mathbf{x}_i).$$

Autrement dit, on donne à y_i la valeur 1 si $\mathbb{P}(Y = 1 | \mathbf{X} = \mathbf{x}_i) > \mathbb{P}(Y = 0 | \mathbf{X} = \mathbf{x}_i)$, et la valeur 0 dans le cas contraire, ou de manière équivalente (dans ce cas binaire) donner à y_i la valeur 1 si $\mathbb{P}(Y = 1 | \mathbf{X} = \mathbf{x}_i) > 0.5$ et la valeur 0 si $\mathbb{P}(Y = 1 | \mathbf{X} = \mathbf{x}_i) \leq 0.5$.

Pour rendre effectif le classifieur Bayésien (optimal) précédent, on estime les deux probabilités conditionnelles

$p_1(\mathbf{x}_i) := \mathbb{P}(Y = 1 | \mathbf{X} = \mathbf{x}_i)$ et $p_0(\mathbf{x}_i) := \mathbb{P}(Y = 0 | \mathbf{X} = \mathbf{x}_i)$, à l'aide du modèle de régression logistique, comme suit

$$\hat{p}_1(\mathbf{x}_i) = f(\mathbf{x}_i, \hat{\mathbf{w}}), \quad \text{et} \quad \hat{p}_0(\mathbf{x}_i) = 1 - f(\mathbf{x}_i, \hat{\mathbf{w}}), \quad (16)$$

et on définit la valeur prédite $\tilde{y}_i$ (si l'échantillonnage de $(\mathbf{X}, Y)$ est représentatif, i.e., i.i.d.) par

$$\tilde{y}_i := \arg \sup_{y \in \{0,1\}} \hat{p}_y(\mathbf{x}_i), \quad (17)$$

ce qui est équivalent (dans ce cas binaire) à

$$\tilde{y}_i = \begin{cases} 1 & \text{si } \hat{p}_1(\mathbf{x}_i) > 0.5; \\ 0 & \text{si } \hat{p}_1(\mathbf{x}_i) \leq 0.5. \end{cases} \quad (18)$$

- Dans la pratique, l'échantillonnage de $(\mathbf{X}, Y)$ peut ne pas être i.i.d. C'est le cas lorsque les classes C_0 et C_1 sont fixées à priori, et seulement $\mathbf{X}$ est échantillonné de manière i.i.d. (ce mode d'échantillonnage est dit **rétrospectif**). Dans ce cas, les estimateurs précédents, de $\mathbf{w}$ et des probabilités $p_1(\mathbf{x})$ et $p_2(\mathbf{x})$, ne sont plus valables. En fait, on peut montrer que $\hat{w}_1, \dots, \hat{w}_p$ ne changent pas de valeurs (et restent donc valables) par contre $\hat{w}_0$ doit être remplacé par

$$\tilde{w}_0 := \hat{w}_0 - \log \frac{n_1}{n_0} + \log \frac{\mathbb{P}(Y = 1)}{\mathbb{P}(Y = 0)},$$

où n_0 est le nombre d'individus pour lesquels $y_i = 0$, n_1 le nombre d'individus pour lesquels $y_i = 1$, et $\mathbb{P}(Y = 1)$ et $\mathbb{P}(Y = 0)$ sont les probabilités à priori des classes C_1 et C_0 , qui sont supposées connues (ou doivent être estimées).

Notons $\tilde{\mathbf{w}}$ le nouveau estimateur (adapté à l'échantillonnage rétrospectif) du vecteur des paramètres $\mathbf{w}$. On estime alors $p_1(\mathbf{x}_i)$ et $p_0(\mathbf{x}_i)$ par

$$\tilde{p}_1(\mathbf{x}_i) = f(\mathbf{x}_i, \tilde{\mathbf{w}}) \quad \text{et} \quad \tilde{p}_0(\mathbf{x}_i) = 1 - f(\mathbf{x}_i, \tilde{\mathbf{w}}),$$

et on classe l'individu (i) selon la règle (comme auparavant)

$$\tilde{y}_i = \begin{cases} 1 & \text{si } \tilde{p}_1(\mathbf{x}_i) > 0.5; \\ 0 & \text{si } \tilde{p}_1(\mathbf{x}_i) \leq 0.5. \end{cases} \quad (19)$$

- Une autre alternative pour tenir compte de l'échantillonnage rétrospectif, sans modifier les estimateurs, et de définir le classifieur avec un seuil $c \in]0, 1[$

$$\tilde{y}_i = \begin{cases} 1 & \text{si } \hat{p}_1(\mathbf{x}_i) > c; \\ 0 & \text{si } \hat{p}_1(\mathbf{x}_i) \leq c, \end{cases} \quad (20)$$

et on choisit le seuil c qui minimise l'erreur théorique de prévision estimée (par l'une des méthodes de VC).

Tests de nullité des coefficients w_i en régression logistique

Considérons toujours le cas binaire. Rappelons que le modèle de régression logistique s'écrit

$$p_1(\mathbf{x}) = f(\mathbf{x}, \mathbf{w}) = \frac{\exp\{w_0 + w_1x_1 + \dots + w_px_p\}}{1 + \exp\{w_0 + w_1x_1 + \dots + w_px_p\}} + \epsilon,$$

ou par transformation logit

$$\log \frac{p_1(\mathbf{x})}{p_0(\mathbf{x})} = \log \frac{p_1(\mathbf{x})}{1 - p_1(\mathbf{x})} = w_0 + w_1x_1 + \dots + w_px_p + \epsilon.$$

On cherche à tester l'hypothèse de nullité d'un coefficient donné. Prenons par exemple w_1 :

$$\mathcal{H}_0 : w_1 = 0$$

contre l'hypothèse alternative

$$\mathcal{H}_1 : w_1 \neq 0.$$

où $\mathbb{X}$ est la matrice de design, la première colonne correspond à la constante 1, et $\mathbb{V}$ est la matrice diagonale de termes diagonaux

$$(\hat{p}_1(\mathbf{x}_1)\hat{p}_0(\mathbf{x}_1), \hat{p}_1(\mathbf{x}_2)\hat{p}_0(\mathbf{x}_2), \dots, \hat{p}_1(\mathbf{x}_n)\hat{p}_0(\mathbf{x}_n)).$$

C'est une matrice carrée de dimension $(1 + p) \times (1 + p)$. Notons $\hat{\sigma}_0^2, \hat{\sigma}_1^2, \dots, \hat{\sigma}_p^2$ les termes diagonaux de cette matrice. On a alors, pour tous $j = 0, 1, \dots, p$, la convergence en loi, quand $n \rightarrow +\infty$,

$$\sqrt{n} \frac{\hat{w}_j - w_j^*}{\hat{\sigma}_j} \rightarrow \mathcal{N}(0, 1).$$

Pour tester donc l'hypothèse nulle $\mathcal{H}_0 : w_1 = 0$, on utilise le fait que, sous $\mathcal{H}_0$, on a la convergence en loi

$$\sqrt{n} \frac{\hat{w}_1}{\hat{\sigma}_1} \rightarrow \mathcal{N}(0, 1).$$

Notons $Z_n := \sqrt{n} \frac{\hat{w}_1}{\hat{\sigma}_1}$.

Test du rapport de vraisemblance

Considérons les deux hypothèses

$$\mathcal{H}_0 : w_1 = 0 \quad \text{contre} \quad \mathcal{H}_1 : w_1 \neq 0.$$

Notons $\mathbb{W} := \mathbb{R}^{1+p}$ et $\mathbb{W}_0 := \mathbb{R} \times \{0\} \times \mathbb{R}^{p-1}$. On peut alors écrire les deux hypothèses précédentes sous la forme équivalente suivante

$$\mathcal{H}_0 : \mathbf{w} \in \mathbb{W}_0 \quad \text{contre} \quad \mathcal{H}_1 : \mathbf{w} \in \mathbb{W}/\mathbb{W}_0.$$

Le rapport de vraisemblances, associé aux hypothèses précédentes, s'écrit alors

$$R_n := \frac{\sup_{\mathbf{w} \in \mathbb{W}} L_n(\mathbf{w})}{\sup_{\mathbf{w} \in \mathbb{W}_0} L_n(\mathbf{w})}.$$

La statistique du rapport de vraisemblances s'écrit donc

$$\begin{aligned} S_n &:= 2 \log R_n = 2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) - 2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) \\ &= -2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) - \left(-2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) \right) \\ &=: D_{\text{ModeleReduit}} - D_{\text{ModeleComple}}. \end{aligned} \tag{21}$$

Les deux dernières quantités s'appellent, “la **déviance du modèle réduit**”, respectivement, “la **déviance du modèle complet**”.

On montre que, si $\mathcal{H}_0$ est vraie, alors la statistique S_n converge en loi, quand $n \rightarrow \infty$, vers une loi du $\chi^2(d)$, à d degrés de liberté, avec $d = \dim(\mathbb{W}) - \dim(\mathbb{W}_0) = (1 + p) - (p) = 1$. Soit Z une variable suivant la loi du $\chi^2(1)$. La P -value de ce test est alors donnée par

$$P\text{-value} = \mathbb{P}(Z > S_n),$$

et on adopte la règle de décision suivante :

- La statistique du RV permet également de tester l'hypothèse de nullité simultanée d'un sous-ensemble de paramètres.
Considérons par exemple les deux hypothèses

$$\mathcal{H}_0 : w_1 = 0 \text{ et } w_2 = 0 \quad \text{contre} \quad \mathcal{H}_1 : w_1 \neq 0 \text{ ou } w_2 \neq 0.$$

Notons $\mathbb{W} := \mathbb{R}^{1+p}$ et $\mathbb{W}_0 := \mathbb{R} \times \{0\} \times \{0\} \times \mathbb{R}^{p-2}$. La statistique du rapport de vraisemblance s'écrit dans ce cas

$$\begin{aligned} S_n &:= 2 \log R_n = 2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) - 2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) \\ &= -2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) - \left(-2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) \right) \\ &=: D_{\text{ModeleReduit}} - D_{\text{ModeleComple}}. \end{aligned} \tag{22}$$

On montre que, si $\mathcal{H}_0$ est vraie, alors la statistique S_n convergence en loi, quand $n \rightarrow \infty$, vers une loi du $\chi^2(d)$, à d degrés de liberté, avec $d = \dim(\mathbb{W}) - \dim(\mathbb{W}_0) = (1 + p) - (p - 1) = 2$.

Soit Z une variable suivant la loi du $\chi^2(2)$. La P – value de ce test est alors donnée par

$$P - \text{value} = \mathbb{P}(Z > S_n).$$

Test de validité du modèle global

Modèle de RL :

$$p_1(\mathbf{x}) = f(\mathbf{x}, \mathbf{w}) = \frac{\exp\{w_0 + w_1x_1 + \dots + w_px_p\}}{1 + \exp\{w_0 + w_1x_1 + \dots + w_px_p\}} + \epsilon,$$

ou par transformation logit

$$\log \frac{p_1(\mathbf{x})}{1 - p_1(\mathbf{x})} = w_0 + w_1x_1 + \dots + w_px_p + \epsilon.$$

Ici on cherche à tester l'hypothèse de nullité de tous les coefficients w_j , $j = 1, \dots, p$ (sauf l'intercept w_0) :

$\mathcal{H}_0 : w_1 = \dots = w_p = 0$ contre $\mathcal{H}_1 : \exists j \in \{1, \dots, p\}$ tel que $w_j \neq 0$.

Notons $\mathbb{W} := \mathbb{R}^{1+p}$ et $\mathbb{W}_0 := \mathbb{R} \times \{0\} \times \dots \times \{0\}$. La statistique du rapport de vraisemblance correspondante s'écrit

$$\begin{aligned} S_n &:= 2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) - 2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) \\ &= -2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) - \left(-2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) \right) \\ &= D_{\text{ModelTrivial}} - D_{\text{ModelComplet}}, \end{aligned} \tag{23}$$

où “ $D_{\text{ModelTrivial}}$ ” est la déviance du modèle trivial, i.e., le modèle qui utilise seulement l’intercept. Cette quantité est calculée par la fonction “`glm()`” est stockée dans la composante nommée “`null.deviance`”.

“ $D_{\text{ModelComplet}}$ ” est la déviance du modèle complet calculée également par la fonction “`glm()`” est stockée dans la composante nommée “`deviance`”.

On montre que la statistique S_n précédente, si $\mathcal{H}_0$ est vraie, converge en loi, quand $n \rightarrow \infty$, vers une loi du $\chi^2(d)$ à d degrés de liberté avec $d = \dim(\mathbb{W}) - \dim(\mathbb{W}_0) = (1 + p) - (1) = p$. Soit Z une variable aléatoire suivant la loi $\chi^2(p)$. La P – value du test précédent est alors donnée par

$$P - \text{value} = \mathbb{P}(Z > S_n).$$

Et on suit la règle suivante

- Si $P - \text{value} < \alpha$, on rejette $\mathcal{H}_0$;
- Si $P - \text{value} \geq \alpha$, on accepte $\mathcal{H}_0$,
 α étant le risque de premier espèce.

Sélection de modèles (ou de variables) en RL selon les critères AIC et BIC

On se donne une liste de p variables $X_1, \dots, X_p$ susceptibles d'expliquer une variable (binaire) Y (via un modèle de régression logistique). On cherche "le meilleur" sous-ensemble de variables qui conduit au meilleur modèle de prédiction de Y . On a le choix entre plusieurs modèles : les modèles qui utilisent une seule variable, les modèles qui utilisent 2 variables, En tout, il y a $m := 2^p - 1$ modèles possibles. Notons $M_1, \dots, M_m$ ces modèles. L'AIC d'un modèle M_k , $k = 1, \dots, m$, est défini par

$$AIC(M_k) := -2 \sup_{\mathbf{w} \in \mathbb{R}^{1+n_k}} \ell_n(\mathbf{w}) + 2(1 + n_k),$$

où n_k est le nombre de variables explicatives du modèle M_k . La sélection par critère AIC consiste à prendre le modèle d'AIC minimal, i.e., le modèle M_{k^*} avec

$$k^* := \arg \min_{k \in \{1, \dots, m\}} AIC(M_k). \quad (24)$$

Le BIC d'un modèle M_k , $k = 1, \dots, m$, est défini par

$$BIC(M_k) := -2 \sup_{\mathbf{w} \in \mathbb{R}^{1+n_k}} \ell_n(\mathbf{w}) + \log(n)(1 + n_k),$$

où n_k est le nombre de variables explicatives du modèle M_k . La sélection par critère BIC consiste à prendre le modèle de BIC minimal, i.e., le modèle M_{k^*} avec

$$k^* := \arg \min_{k \in \{1, \dots, m\}} BIC(M_k). \quad (25)$$

- Les deux critères de sélection AIC et BIC ne conduisent pas forcément au même modèle optimal ;
- Les modèles optimaux donnés par ces critères peuvent être différents du modèle d'erreur théorique (de test) minimale ;
- Une bonne alternative, à ces critères, est d'utiliser la méthode K-fold CV pour estimer l'erreur théorique (de test) de chacun des modèles M_k , $k = 1, \dots, m$, et choisir le modèle d'erreur minimale.

Une recherche exhaustive des modèles optimaux (24) et (25), suivant les critères AIC ou BIC par exemple, nécessite de comparer $2^p - 1$ modèles possibles.

Algorithme de recherche exhaustive

1. Construire les $2^p - 1$ modèles ;
2. Choisir celui qui optimise un critère donné.

Sous R, on utilise la fonction `glmulti()`, en spécifiant les arguments `family = binomial` et `method = "h"`.

Algorithme génétique

Lorsque p est élevé, l'algorithme précédent de recherche exhaustive prend beaucoup de temps. L'algorithme génétique (pour la recherche de l'optimum) constitue une alternative intéressante au algorithme précédent. Il peut être appliqué en utilisant la même fonction `glmulti()` pour l'argument `method = "g"`.

Les méthodes de recherche pas-à-pas suivantes permettent de diminuer le nombre de comparaisons (donc le temps de calcul), mais aucune garantie de convergence vers les modèles optimaux :

1 - Méthode ascendante de sélection (forward selection)

- Modèle sans variables ;
- Insertion de la variable qui diminue le plus le critère ;
- Insertion de la deuxième variable qui diminue le plus le critère, ... arrêt quand on ne diminue plus le critère.

2 - Méthode descendante d'élimination (backward elimination)

- Modèle complet ;
- Enlever la variable qui diminue le plus le critère ;
- Enlever la deuxième variable qui diminue le plus le critère, ...
arrêt quand on ne diminue plus le critère.

3 - Méthode ascendante bidirectionnelle (bidirectional selection)

- Ascendante avec remise en cause à chaque étape des variables déjà incluses ;
- Permet d'exclure des variables qui redeviennent plus significatives compte tenu de celle qui vient d'être intégrée.

4 - Méthode descendante bidirectionnelle (bidirectional elimination)

- Descendante avec remise en cause à chaque étape des variables déjà exclues ;
- Permet de réintégrer des variables qui redeviennent significatives compte tenu de celle qui vient d'être exclue.

Remarques

- Les quatre méthodes précédentes peuvent être réalisées pour les deux critères AIC (avec $k = 2$) et BIC (avec $k = \log(n)$), sous R, à l'aide de la fonction "step()" avec les options "direction = forward", "direction = backward" et "direction = both".
- Ces méthodes peuvent aboutir à des modèles non optimaux et différents.

Modèle logistique multinomial

On cherche à expliquer/prédire une variable réponse Y à M modalités, $Y = 1, \dots, M$, ($M \geq 2$), à l'aide de p variables explicatives numériques $X_1, \dots, X_p$.

Notons $\mathbf{X} := (X_1, \dots, X_p) \in \mathbb{R}^p$, le vecteur (ligne) des variables explicatives. Soit i un individu sur lequel on observe la valeur $\mathbf{x} \in \mathbb{R}^p$ du vecteur aléatoire $\mathbf{X}$. Le classifieur Bayésien (théorique optimal) consiste à classer i dans la modalité $Y = m^*$ pour laquelle $\mathbb{P}(Y = m^* | \mathbf{X} = \mathbf{x})$ est maximale parmi toutes les probabilités conditionnelles

$$p_m(\mathbf{x}) := \mathbb{P}(Y = m | \mathbf{X} = \mathbf{x}), m = 1, \dots, M.$$

i.e.,

$$m^* = \arg \max_{m=1, \dots, M} \mathbb{P}(Y = m | \mathbf{X} = \mathbf{x}).$$

D'où la nécessité d'estimer ces probabilités. Nous allons utiliser l'approche paramétrique suivante, utilisant le modèle de **régression logistique multinomial**.

La loi conditionnelle, $\mathcal{L}(Y | \mathbf{X} = \mathbf{x})$, de Y sachant $\mathbf{X} = \mathbf{x}$, est une **loi multinomiale** de paramètres

$$p_m(\mathbf{x}) := \mathbb{P}(Y = m | \mathbf{X} = \mathbf{x}), \quad m = 1, \dots, M.$$

Les probabilités conditionnelles $p_m(\mathbf{x})$, $m = 2, \dots, M$, sont modélisées par (modèle de régression logistique multinomial) :

$$\begin{aligned} p_m(\mathbf{x}) &= \frac{\exp\{w_{m,0} + w_{m,1}x_1 + \dots + w_{m,p}x_p\}}{1 + \sum_{m=2}^M \exp\{w_{m,0} + w_{m,1}x_1 + \dots + w_{m,p}x_p\}} \\ &=: p_m(\mathbf{x}, \mathbf{w}), \end{aligned} \quad (26)$$

où $\mathbf{w} := (\mathbf{w}_2, \dots, \mathbf{w}_M) \in \mathbb{W} \subseteq \mathbb{R}^{(M-1)(1+p)}$, $\mathbb{W}$ étant le domaine du vecteur $\mathbf{w}$ des paramètres du modèle, et

$\mathbf{w}_m := (w_{m,0}, w_{m,1}, \dots, w_{m,p}) \in \mathbb{W}_m \subseteq \mathbb{R}^{1+p}$, $m = 2, \dots, M$.

D'où,

$$\begin{aligned}
 p_1(\mathbf{x}, \mathbf{w}) &= 1 - \sum_{m=2}^M p_m(\mathbf{x}, \mathbf{w}) \\
 &= \frac{1}{1 + \sum_{m=2}^M \exp\{w_{m,0} + w_{m,1} x_1 + \cdots + w_{m,p} x_p\}}.
 \end{aligned}$$

Remarques

- Pour $M = 2$, on retrouve le modèle de régression logistique binaire ;
- La modélisation précédente est équivalente à la modélisation des “log-ratios”, $\log \frac{p_m(\mathbf{x}, \mathbf{w})}{p_1(\mathbf{x}, \mathbf{w})}$, $m = 2, \dots, M$, par

$$\log \frac{p_m(\mathbf{x}, \mathbf{w})}{p_1(\mathbf{x}, \mathbf{w})} = w_{m,0} + w_{m,1} x_1 + \cdots + w_{m,p} x_p.$$

Ici $Y = 1$ est choisie comme modalité de référence.

- La modélisation ne dépend pas du choix de la modalité de référence ;
- Ce modèle comprend $(M - 1)(1 + p)$ paramètres à estimer (à partir des données d'apprentissage).

Avec la modélisation précédente, la loi conditionnelle $\mathcal{L}(Y | \mathbf{X})$ peut alors s'écrire sous la forme

$$f(\mathbf{x}, y, \mathbf{w}) = p_1(\mathbf{x}, \mathbf{w}) \mathbb{1}_{\{1\}}(y) + \sum_{m=2}^M p_m(\mathbf{x}, \mathbf{w}) \mathbb{1}_{\{m\}}(y),$$

$\mathbf{x} \in \mathcal{X} \subseteq \mathbb{R}^p$, $y \in \{1, 2, \dots, M\}$.

Soit $(\mathbf{X}_i, Y_i)$, $i = 1, \dots, n$, un échantillon i.i.d. de $(\mathbf{X}, Y)$.

Le vecteur $\mathbf{w}$ des paramètres du modèle est estimé alors (par maximum de vraisemblance) comme suit

$$\hat{\mathbf{w}} := \arg \max_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}), \quad (27)$$

où

$$\ell_n(\mathbf{w}) := \sum_{i=1}^n \log f(\mathbf{X}_i, Y_i, \mathbf{w}).$$

Probabilités estimées et prévision (classement)

- On obtient les estimateurs suivants (des probabilités conditionnelles)

$$\hat{\mathbb{P}}(Y = m \mid \mathbf{X} = \mathbf{x}) := p_m(\mathbf{x}, \hat{\mathbf{w}}), \quad m = 1, \dots, M.$$

- Pour un nouveau individu i , sur lequel on observe la valeur $\mathbf{x}_i$ de $\mathbf{X}$, on prédit la valeur correspondante y_i de Y par

$$\tilde{y}_i := \arg \max_{y=1,\dots,M} p_m(\mathbf{x}, \hat{\mathbf{w}}).$$

Mise en œuvre sous R

- On peut ajuster le modèle de régression logistique multinomial à l'aide des fonctions `multinom()` du package `nnet` ou `vglm()` du package `vgam`.

Tests d'hypothèses par statistique du rapport des vraisemblances

- Soit $\mathbb{W}_0$ un sous-domaine de $\mathbb{W}$ tel que $\dim(\mathbb{W}_0) < \dim(\mathbb{W}) =: (M - 1)(1 + p)$. Considérons les deux hypothèses

$$\mathcal{H}_0 : \mathbf{w} \in \mathbb{W}_0 \quad \text{contre} \quad \mathcal{H}_1 : \mathbf{w} \in \mathbb{W}/\mathbb{W}_0.$$

- La statistique du rapport des vraisemblances correspondante s'écrit

$$\begin{aligned}
 S_n &:= 2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) - 2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) \\
 &= -2 \sup_{\mathbf{w} \in \mathbb{W}_0} \ell_n(\mathbf{w}) - \left(-2 \sup_{\mathbf{w} \in \mathbb{W}} \ell_n(\mathbf{w}) \right) \\
 &=: \text{la déviance du modèle réduit} \\
 &\quad - \text{la déviance du modèle complet.}
 \end{aligned}$$

- Sous $\mathcal{H}_0$, la loi de la statistique S_n converge vers la loi du $\chi^2(d)$ avec $d = (M - 1)(1 + p) - \dim(\mathbb{W}_0)$. Notons S_n^{obs} la valeur observée de S_n . La P -value correspondante est définie alors par $P\text{-value} := \mathbb{P}(Z > S_n^{obs})$, où Z est une variable aléatoire suivant la loi du $\chi^2(d)$.

Mise en œuvre sous R

- On peut réaliser les tests précédents à l'aide de la fonction `lrtest_vglm()` du package `vglm`.

Les classifieurs ADL, ADQ et K-NN

Le cadre

- $p \geq 1$ variables explicatives/prédictives
 $\mathbf{X} := (X_1, \dots, X_p) \in \mathcal{X} \subseteq \mathbb{R}^p$;
- une variable réponse à $M \geq 2$ modalités : $Y \in \{1, \dots, M\}$.
- On dispose d'un échantillon i.i.d., $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$, de $(\mathbf{X}, Y)$.

- Notons, pour représenter la loi conditionnelle $\mathcal{L}(\mathbf{X} | Y)$,

$$f_m(\mathbf{x}) := \mathbb{P}(\mathbf{X} = \mathbf{x} | Y = m); \quad m = 1, \dots, M, \quad \mathbf{x} \in \mathcal{X} \subseteq \mathbb{R}^p$$

- Par le théorème de Bayes, on peut alors écrire

$$p_m(\mathbf{x}) := \mathbb{P}(Y = m | \mathbf{X} = \mathbf{x}) = \frac{\pi_m f_m(\mathbf{x})}{\sum_{\ell=1}^M \pi_\ell f_\ell(\mathbf{x})}, \quad (28)$$

où $\pi_\ell := \mathbb{P}(Y = \ell)$, $\ell = 1, \dots, M$, sont les probabilités a priori des classes $\{Y = 1\}, \dots, \{Y = M\}$.

Analyse discriminante linéaire (ADL)

- On présente d'abord le cas $p = 1$: on suppose que, $\forall m \in \{1, \dots, M\}$, $\mathcal{L}(X | Y = m)$ est gaussienne $\mathcal{N}(\mu_m, \sigma_m^2)$, de même variance ($\sigma_1^2 = \dots = \sigma_M^2 =: \sigma^2$), i.e.,

$$f_m(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x - \mu_m)^2}{\sigma^2}\right) =: f(x, \mu_m, \sigma^2).$$

- On obtient donc par substitution dans (28), $\forall m = 1, \dots, M$,

$$p_m(x) := \mathbb{P}(Y = m | X = x) = \frac{\pi_m f(x, \mu_m, \sigma^2)}{\sum_{\ell=1}^M \pi_\ell f(x, \mu_\ell, \sigma^2)}. \quad (29)$$

Estimation des probabilités conditionnelles et prévision

- Au vu de la relation précédente, les probabilités conditionnelles sont estimées par

$$\hat{\mathbb{P}}(Y = m | X = x) = \frac{\pi_m f(x, \hat{\mu}_m, \hat{\sigma}^2)}{\sum_{\ell=1}^M \pi_\ell f(x, \hat{\mu}_\ell, \hat{\sigma}^2)}, \quad (30)$$

où

$$\hat{\mu}_\ell := \frac{1}{n_\ell} \sum_{i=1}^n x_i \mathbb{1}_{\{y_i=\ell\}}, \quad \ell = 1, \dots, M,$$

et

$$\hat{\sigma}^2 := \frac{1}{n - M} \sum_{\ell=1}^M \sum_{i=1}^n (x_i - \hat{\mu}_\ell)^2 \mathbb{1}_{\{y_i=\ell\}}.$$

Les probabilités a priori π_ℓ , $\ell = 1, \dots, M$, dans (30), sont supposées connues. Sinon, elles sont estimées par

$$\hat{\pi}_\ell := \frac{\sum_{i=1}^n \mathbb{1}_{\{y_i=\ell\}}}{n} \quad (\text{pour un échantillonnage i.i.d.}).$$

Prévision

- Pour un nouveau individu i , sur lequel on observe la valeur x_i de X , on prédit la valeur correspondante y_i de Y par

$$\tilde{y}_i := \arg \max_{m=1,\dots,M} \hat{\mathbb{P}}(Y = m | X = x_i), \quad (31)$$

où $\hat{\mathbb{P}}(Y = m | X = x_i)$ est défini par la formule (30).

- Le classifieur (31) est équivalent à (maximiser la fonction **linéaire**, en x_i , suivante)

$$\tilde{y}_i := \arg \max_{m=1,\dots,M} \frac{\hat{\mu}_m}{\hat{\sigma}^2} x_i - \frac{\hat{\mu}_m^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_m). \quad (32)$$

- Dans le cas $p \geq 2$, on suppose que, $\forall m = 1, \dots, M$, $\mathcal{L}(\mathbf{X} | Y = m)$ est gaussienne multi-variée $\mathcal{N}_p(\mu_m, \Sigma_m)$, $\mu_m \in \mathbb{R}^p$, de même matrice de variance $(\Sigma_1 = \dots = \Sigma_M =: \Sigma)$, i.e.,

$$\begin{aligned} f_m(\mathbf{x}) &= \frac{1}{\sqrt{(2\pi)^p \det(\Sigma)}} \exp \left(-\frac{1}{2}(\mathbf{x} - \mu_m^\top) \Sigma^{-1} (\mathbf{x}^\top - \mu_m) \right) \\ &=: f(\mathbf{x}, \mu_m, \Sigma). \end{aligned}$$

- Pour un nouveau individu i , sur lequel on observe la valeur $\mathbf{x}_i$ du vecteur $\mathbf{X}$, on prédit la valeur correspondante y_i de Y par

$$\tilde{y}_i := \arg \max_{m=1, \dots, M} \frac{\hat{\pi}_m f(\mathbf{x}_i, \hat{\mu}_m, \hat{\Sigma})}{\sum_{\ell=1}^M \hat{\pi}_\ell f(\mathbf{x}_i, \hat{\mu}_\ell, \hat{\Sigma})}, \quad (33)$$

où $\hat{\mu}_\ell := \frac{1}{n_\ell} \sum_{i=1}^n \mathbf{x}_i \mathbb{1}_{\{y_i=\ell\}}$, $\ell = 1, \dots, M$, et $\hat{\Sigma}$ est l'estimateur empirique (corrigé) de Σ .

- Le classifieur ci-dessus est équivalent à (maximiser la fonction linéaire)

$$\tilde{y}_i := \arg \max_{m=1,\dots,M} \mathbf{x}_i^T \hat{\Sigma}^{-1} \hat{\mu}_m - \frac{1}{2} \hat{\mu}_m^T \hat{\Sigma}^{-1} \hat{\mu}_m + \log \hat{\pi}_m. \quad (34)$$

Analyse discriminante quadratique (ADQ)

- Même modèle que l'ADL, avec des matrices de variances $\Sigma_1, \dots, \Sigma_M$ qui peuvent être différentes.
- Pour un nouveau individu i , sur lequel on observe la valeur $\mathbf{x}_i$ du vecteur $\mathbf{X}$, on prédit la valeur correspondante y_i de Y par

$$\tilde{y}_i := \arg \max_{m=1, \dots, M} \frac{\hat{\pi}_m f(\mathbf{x}_i, \hat{\mu}_m, \hat{\Sigma}_m)}{\sum_{\ell=1}^M \hat{\pi}_\ell f(\mathbf{x}_i, \hat{\mu}_\ell, \hat{\Sigma}_\ell)}, \quad (35)$$

où $\hat{\mu}_\ell := \frac{1}{n_\ell} \sum_{i=1}^n \mathbf{x}_i \mathbb{1}_{\{y_i=\ell\}}$, et $\hat{\Sigma}_\ell$ est l'estimateur empirique (corrigé du biais) de Σ_ℓ , $\ell = 1, \dots, M$.

- Le classifieur ci-dessus (35) est équivalent à (maximiser la fonction **quadratique**)

$$\tilde{y}_i := \arg \max_{m=1, \dots, M} -\frac{1}{2}(\mathbf{x}_i - \hat{\mu}_m^\top) \hat{\Sigma}_m^{-1} (\mathbf{x}_i - \hat{\mu}_m) - \frac{1}{2} \log \det(\hat{\Sigma}_m) + \log \hat{\pi}_m.$$

Remarques

- Si les classes sont bien séparées, les estimateurs, des paramètres du modèle de régression logistique, sont instables. L'analyse discriminante (ADL/ADQ) ne souffre pas de ce problème.
- Si la loi conditionnelle $\mathcal{L}(\mathbf{X} \mid Y = m)$ est gaussienne (ou approximativement gaussienne), $\forall m$, alors l'analyse discriminante (ADL/ADQ) donne de très bons résultats (même pour n petit).
- L'analyse discriminante (ADL/ADQ) est beaucoup utilisée dans le cas où le nombre de classes est grand (même si la loi n'est pas gaussienne!).

Le classifieur K -NN

- On a

$$p_m(\mathbf{x}) := \mathbb{P}(Y = m \mid \mathbf{X} = \mathbf{x}) = \mathbb{E} \left(\mathbb{1}_{\{Y=m\}} \mid \mathbf{X} = \mathbf{x} \right).$$

- On estime cette espérance conditionnelle par la méthode “non-paramétrique” du K -NN (K Nearest Neighbors, K plus proches voisins) : Pour une valeur entière donnée K , on cherche l'ensemble $\mathcal{N}_{\mathbf{x}}$, de cardinal K , de toutes les observations $\mathbf{x}_j$ les plus “proches” de $\mathbf{x}$ (au sens d'une **norme** de $\mathbb{R}^p$). L'espérance conditionnelle précédente est estimée alors par

$$\hat{p}_m(\mathbf{x}) := \frac{1}{K} \sum_{j=1}^n \mathbb{1}_{\{y_j=m\}} \mathbb{1}_{\{\mathbf{x}_j \in \mathcal{N}_{\mathbf{x}}\}}. \quad (36)$$

- Pour un nouveau individu i , sur lequel on observe la valeur $\mathbf{x}_i$ du vecteur $\mathbf{X}$, on prédit la valeur correspondante y_i de Y par

$$\tilde{y}_i := \arg \max_{m=1,\dots,M} \hat{p}_m(\mathbf{x}_i), \quad (37)$$

où $\hat{p}_m(\cdot)$ est définie par (36).

Remarques

- Les données (des variables explicatives) sont souvent normalisées ;
- La méthode dépend du choix de la distance (ou de la norme), entre vecteurs de $\mathbb{R}^p$;
- La méthode dépend fortement du paramètre K . On choisit K minimisant l'erreur de prévision estimée (par validation croisée) ;
- La méthode pourrait donner des résultats satisfaisants, si M et p sont petits, et n est grand.

Modèles de régression logistique pénalisés

Le cadre

- On cherche à expliquer/prédire une variable réponse Y à M modalités, $Y = 1, \dots, M$, ($M \geq 2$), à l'aide de p variables explicatives numériques $X_1, \dots, X_p$.

Notons $\mathbf{X} := (X_1, \dots, X_p) \in \mathbb{R}^p$, le vecteur (ligne) des variables explicatives.

- On dispose d'un échantillon i.i.d. $(\mathbf{X}_i, Y_i)$, $i = 1, \dots, n$, de $(\mathbf{X}, Y)$.
- Les probabilités conditionnelles $p_m(\mathbf{x}) := \mathbb{P}(Y = m | \mathbf{X} = \mathbf{x})$, $m = 1, \dots, M$, seront modélisées à l'aide du modèle de régression logistique (multinomial); c.f. (26).

En grande dimension

- Lorsque le nombre p de variables explicatives est grand, l'erreur d'approximation (variance) peut augmenter sensiblement, l'erreur structurelle (biais) diminue.
- L'objectif des méthodes de pénalisation est de **contraindre** les valeurs des estimateurs (des paramètres des modèles considérés) de manière à réduire l'erreur d'approximation (quitte à augmenter un peu l'erreur structurelle) ;
- On impose alors une contrainte sur les paramètres du modèles (sauf pour les paramètres de l'intercept)

$$(w_{2,1}, \dots, w_{2,p}, \dots, w_{M,1}, \dots, w_{M,p}) =: (\bar{\mathbf{w}}_2, \dots, \bar{\mathbf{w}}_M) =: \bar{\mathbf{w}}.$$

- Soient $\|\cdot\|$ une norme de $\mathbb{R}^{(M-1)p}$, et $b > 0$ un seuil strictement positif.

- L'estimateur du MV $\hat{\mathbf{w}}$, c.f. (27), sera modifié comme suit

$$\hat{\mathbf{w}}_{\text{pen}}(b) := \arg \max_{\mathbf{w} \in \mathbb{W} \text{ t.q. } \|\bar{\mathbf{w}}\| \leq b} \ell_n(\mathbf{w}). \quad (38)$$

- ou de façon équivalente (pour un $\lambda > 0$)

$$\hat{\mathbf{w}}_{\text{pen}}(\lambda) := \arg \max_{\mathbf{w} \in \mathbb{W}} \frac{1}{n} \ell_n(\mathbf{w}) - \lambda \|\bar{\mathbf{w}}\|. \quad (39)$$

Remarques

- Les définitions précédentes (38) et (39) sont équivalentes, dans le sens où pour tout $b > 0$ il existe un unique $\lambda > 0$ tel que les deux estimateurs coïncident ;
- Les coefficients $w_{2,0}, \dots, w_{M,0}$ (de l'intercept) ne sont pas pris en compte dans la pénalité ;
- Les variables explicatives sont le plus souvent réduites pour éviter les problèmes d'échelle dans la pénalité ;
- Le paramètre de pénalisation λ est choisi de manière à minimiser l'erreur de prévision (estimée par VC) ;
- La régression logistique Ridge est obtenue pour le choix de la norme L_2 ;
- La régression logistique Lasso est obtenue pour le choix de la norme L_1 .

Les machines à vecteurs de support (SVM)

Les SVM

- généralisent les classifieurs linéaires ;
- s'adaptent aux données de grandes dimensions grâce à la technique “**du noyau**” ;
- sont des techniques de classification supervisée ;
- se basent sur une approche **géométrique** (maximiser la “**marge**”) ;
- se généralisent à la classification multi-groupe.

Soit $\mathbf{X} := (X_1, \dots, X_p)^\top \in \mathbb{R}^p$ un vecteur aléatoire (**colonne**); et Y une variable aléatoire binaire prenant les valeurs -1 et 1 . On observe le vecteur aléatoire $(\mathbf{X}, Y)$ sur n individus de manière i.i.d. Notons ces observations $(\mathbf{x}(1), y(1)), \dots, (\mathbf{x}(n), y(n))$. L'objectif est de construire un modèle sur la base de cet échantillon d'apprentissage qui prédit au mieux Y en fonction de $\mathbf{x}$. Considérons le séparateur linéaire :

$$f(\mathbf{x}, w_0, \mathbf{w}) := w_0 + w_1 x_1 + \dots + w_p x_p =: w_0 + \mathbf{w}^\top \mathbf{x}.$$

- La valeur prédite de y , pour un $\mathbf{x}$ donné, sera définie par

$$\tilde{y} := \text{signe}(f(\mathbf{x}, w_0, \mathbf{w})).$$

- L'ensemble

$$\{\mathbf{x} \in \mathbb{R}^p \text{ tel que } f(\mathbf{x}, w_0, \mathbf{w}) = 0\}$$


est appelé **hyperplan** "séparant" ;

- Si les points $\mathbf{x}(1), \dots, \mathbf{x}(n)$ sont linéairement séparables, on doit avoir

$$y(i) f(\mathbf{x}(i), w_0, \mathbf{w}) > 0, \quad \forall i = 1, \dots, n,$$

i.e.,

$$y(i) \left(w_0 + \mathbf{w}^\top \mathbf{x}(i) \right) > 0, \quad \forall i = 1, \dots, n.$$




- Il peut y avoir une infinité d'hyperplans séparants (dans le cas où les points sont séparables). **Lequel choisir ?**

On suppose dorénavant que les points sont (strictement) séparables linéairement. On choisit l'hyperplan qui maximise la “**marge**” (la distance entre l'hyperplan et les points les plus proches). Ces derniers sont appelés les **vecteurs de support**. C'est l'hyperplan d'équation

$$f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}}) := \hat{\mathbf{w}}_0 + \hat{\mathbf{w}}^\top \mathbf{x} = 0, \quad (40)$$

où

$$(\hat{\mathbf{w}}_0, \hat{\mathbf{w}}) := \arg \sup_{(\mathbf{w}_0, \mathbf{w}) \in \mathbb{R}^{1+p}} \min_{i=1, \dots, n} \min_{\{\mathbf{x}; \mathbf{w}_0 + \mathbf{w}^\top \mathbf{x} = 0\}} \|\mathbf{x} - \mathbf{x}(i)\|$$



- La distance euclidienne d'un point $\mathbf{x}(i)$, de l'hyperplan $\{\mathbf{x} \in \mathbb{R}^p; w_0 + \mathbf{w}^\top \mathbf{x} = 0\}$, est égale à

$$\frac{y(i) (w_0 + \mathbf{w}^\top \mathbf{x}(i))}{\|\mathbf{w}\|}.$$

- L'hyperplan maximisant la marge est donc celui défini par les paramètres

$$(\hat{w}_0, \hat{\mathbf{w}}) := \arg \sup_{(w_0, \mathbf{w}) \in \mathbb{R}^{1+p}} \frac{1}{\|\mathbf{w}\|} \min_{i=1, \dots, n} y(i) (w_0 + \mathbf{w}^\top \mathbf{x}(i)).$$

- On normalise $(w_0, \mathbf{w})$ de sorte que tous les vecteurs supports satisfont

$$\begin{cases} w_0 + \mathbf{w}^\top \mathbf{x}^+(i) &= 1; \\ w_0 + \mathbf{w}^\top \mathbf{x}^-(i) &= -1. \end{cases}$$

Ce qui implique, pour tous les autres individus (i),

$$y(i) (w_0 + \mathbf{w}^\top \mathbf{x}(i)) > 1.$$

- Avec la normalisation précédente, on peut montrer que la marge est égale à $\frac{1}{\|\mathbf{w}\|}$. Le problème d'optimisation (40) est équivalent donc à

$$\begin{cases} \inf_{(w_0, \mathbf{w}) \in \mathbb{R}^{1+p}} \frac{1}{2} \|\mathbf{w}\|^2, & \text{sous les contraintes} \\ y(i) (w_0 + \mathbf{w}^\top \mathbf{x}(i)) \geq 1, \forall i = 1, \dots, n. \end{cases} \quad (41)$$

- Le lagrangien associé s'écrit

$$L(w_0, \mathbf{w}, \lambda) := \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \lambda_i \left(y(i) (w_0 + \mathbf{w}^\top \mathbf{x}(i)) - 1 \right).$$

D'où, le problème (41) est équivalent au problème dual (sans contraintes)

$$\inf_{(w_0, \mathbf{w}) \in \mathbb{R}^{1+p}} \sup_{\lambda \in \mathbb{R}_+^n} L(w_0, \mathbf{w}, \lambda). \quad (42)$$

- Les conditions de Kuhn-Tucker (K-T) impliquent

$$\begin{cases} \sum_{i=1}^n \lambda_i y(i) \mathbf{x}(i) &= \mathbf{w} \\ \sum_{i=1}^n \lambda_i y(i) &= 0. \end{cases} \quad (43)$$

- Le problème précédent est donc équivalent à

$$\sup_{\lambda \in \mathbb{R}_+^n; \sum_{i=1}^n \lambda_i y(i) = 0} \left\{ \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j y(i) y(j) \mathbf{x}(i)^\top \mathbf{x}(j) \right\}. \quad (44)$$

- D'après les conditions de K-T, on a

$$\lambda_i \left(y(i) \left(w_0 + \mathbf{w}^\top \mathbf{x}(i) \right) - 1 \right) = 0, \forall i = 1, \dots, n.$$

D'où, $\lambda_i = 0$ pour tout i tel que $y(i) (w_0 + \mathbf{w}^\top \mathbf{x}(i)) \neq 1$. i.e., tous les λ_i , qui ne sont pas associés aux vecteurs de support, sont nuls. Autrement dit, seulement les λ_i associés aux vecteurs de support (VS) participent à la construction du classifieur.


Notons $\hat{\lambda}_1, \dots, \hat{\lambda}_n$ la solution optimale du problème (44). Le classifieur obtenu s'écrit donc sous la forme

$$\hat{y} = \text{signe}(f(\mathbf{x}, \hat{w}_0, \hat{\mathbf{w}})) = \text{signe} \left(\hat{w}_0 + \sum_{i \in VS} \hat{\lambda}_i \mathbf{x}(i)^{\top} \mathbf{x} \right).$$

- Lorsque les points $\mathbf{x}(1), \dots, \mathbf{x}(n)$ ne sont pas (strictement) séparables linéairement, on modifie le problème d'optimisation précédent (41) comme suit

$$\begin{cases} \inf_{(w_0, \mathbf{w}) \in \mathbb{R}^{1+p}, \xi \in \mathbb{R}_+^n} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ \text{sous les contraintes "relaxées"} \\ y(i) (w_0 + \mathbf{w}^\top \mathbf{x}(i)) - 1 + \xi_i \geq 0, \forall i = 1, \dots, n. \end{cases} \quad (45)$$

Dans le problème précédent, "C" est un paramètre (réel strictement positif) de pénalisation qu'on choisit par validation croisée.



- Le problème (45) précédent est équivalent à

$$\inf_{(w_0, \mathbf{w}) \in \mathbb{R}^{1+p}} C \sum_{i=1}^n \left(1 - y(i) \left(w_0 + \mathbf{w}^\top \mathbf{x}(i) \right) \right)^+ + \frac{1}{2} \|\mathbf{w}\|^2,$$

- qui est équivalent à la minimisation de la fonction de perte empirique pénalisée

$$\inf_{(w_0, \mathbf{w}) \in \mathbb{R}^{1+p}} \frac{1}{n} \sum_{i=1}^n \ell_{SVM} \left(y(i) \left(w_0 + \mathbf{w}^\top \mathbf{x}(i) \right) \right) + \lambda \frac{1}{2} \|\mathbf{w}\|^2,$$

où $\lambda := 1/(nC)$, et $\ell_{SVM}(\cdot)$ est la fonction de perte définie par

$$\ell_{SVM}(z) := (1 - z)^+ := \begin{cases} 1 - z & \text{si } 1 - z \geq 0 \\ 0 & \text{si } 1 - z < 0. \end{cases}$$

- En régression logistique ridge, la maximisation de la vraisemblance (pénalisée) est équivalente à

$$\inf_{(w_0, \mathbf{w}) \in \mathbb{R}^{1+p}} \frac{1}{n} \sum_{i=1}^n \ell_{RL} \left(y(i) \left(w_0 + \mathbf{w}^\top \mathbf{x}(i) \right) \right) + \lambda \frac{1}{2} \|\mathbf{w}\|^2,$$

où $\ell_{RL}(\cdot)$ est la fonction de perte définie par

$$\ell_{RL}(z) := -\log(\exp(z)/(1 + \exp(z))), \quad \forall z \in \mathbb{R}.$$

Classifieur non linéaire ; méthode à noyau

Lorsque les points $\mathbf{x}(1), \dots, \mathbf{x}(n)$ ne sont pas linéairement séparables dans $\mathbb{R}^P$, on les projette dans un autre espace de dimension supérieure (éventuellement infinie) (pour les rendre linéairement séparables ou presque)

$$\mathbf{x} \in \mathbb{R}^P \quad \rightarrow \quad \phi(\mathbf{x}) \in \{\text{espace de dimension supérieure}\}.$$

Par exemple la transformation

$$\mathbf{x} := (x_1, x_2) \in \mathbb{R}^2 \quad \rightarrow \quad \phi(\mathbf{x}) := \left(x_1^2, x_2^2, \sqrt{2}x_1x_2, \sqrt{2}x_1, \sqrt{2}x_2, 1 \right) \in \mathbb{R}^6. \quad (46)$$




Figure – Non linéairement séparables dans l'espace des $\mathbf{x}$




Figure – Linéairement séparables dans l'espace des $\phi(\mathbf{x})$

Ensuite, on cherche dans ce nouveau espace l'hyperplan séparateur

$$f(\mathbf{x}, w_0, \mathbf{w}) = w_0 + \mathbf{w}^\top \phi(\mathbf{x})$$

qui vérifie

$$y(i) f(\mathbf{x}, w_0, \mathbf{w}) > 0, \quad \forall i = 1, \dots, n,$$

ce qui revient à (comme auparavant)

$$\sup_{\lambda \in \mathbb{R}_+^n; \sum_{i=1}^n \lambda_i y(i) = 0} \left\{ \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j y(i) y(j) \phi(\mathbf{x}(i))^\top \phi(\mathbf{x}(j)) \right\}. \quad (47)$$

La fonction

$$(\mathbf{x}, \mathbf{x}') \in \mathbb{R}^p \times \mathbb{R}^p \mapsto K(\mathbf{x}, \mathbf{x}') := \phi(\mathbf{x})^\top \phi(\mathbf{x}') \in \mathbb{R}$$

est appelée “**noyau**”. (la valeur de $K(\mathbf{x}, \mathbf{x}')$ est un produit scalaire dans le nouveau espace).

- Par exemple le noyau, associé à la transformation (46) précédente, est

$$\begin{aligned} K(\mathbf{x}, \mathbf{x}') &:= \phi(\mathbf{x})^\top \phi(\mathbf{x}') \\ &= x_1^2 x_1'^2 + x_2^2 x_2'^2 + 2x_1 x_2 x_1' x_2' + 2x_1 x_1' + 2x_2 x_2' + 1 \\ &= (1 + x_1 x_1' + x_2 x_2')^2 \\ &= (1 + \mathbf{x}^\top \mathbf{x}')^2. \end{aligned} \tag{48}$$

Ce noyau est appelé “noyau polynomial” de degré 2.

- Remarquons, d’après la dernière relation, que pour calculer $K(\mathbf{x}, \mathbf{x}')$, nous n’avons pas besoin de connaître explicitement la transformation $\phi(\cdot)$!

Exemples de noyaux

1. **Linéaire** : $K(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{v}$;
2. **Polynomial** : $K(\mathbf{u}, \mathbf{v}) = (\mathbf{u}^\top \mathbf{v} + a)^d$, $d \in \mathbb{N}^*$, $a \in \mathbb{R}$;
3. **Radial** : $K(\mathbf{u}, \mathbf{v}) = \exp(-\gamma \|\mathbf{u} - \mathbf{v}\|^2)$, $\gamma \in \mathbb{R}_+^*$; (dans ce cas, l'espace des $\phi(\mathbf{x}(i))$ est de dimension infinie) ;
4. **Sigmoid** : $K(\mathbf{u}, \mathbf{v}) = \tanh(\gamma \mathbf{u}^\top \mathbf{v} + a)$, $\gamma \in \mathbb{R}_+^*$, $a \in \mathbb{R}$.

Pour obtenir des résultats satisfaisants en SVM

- **Normaliser** les données $\mathbf{x}(1), \dots, \mathbf{x}(n)$;
- Tester plusieurs noyaux, en particulier le noyau radial (si $p \ll n$) ;
- Choisir les bons paramètres (C, γ) par validation croisée, en effectuant une recherche exhaustive dans une grille (par exemple $C = 2^{-5}, 2^{-3}, \dots, 2^{15}$ et $\gamma = 2^{-15}, 2^{-13}, \dots, 2^3$) ;
- Si les données sont de grande dimension ($p \gg n$), l'utilisation d'un noyau linéaire peut suffire à séparer avec bonne performance les données.

On cherche à estimer les probabilités d'appartenance aux classes $\{Y = 1\}$ et $\{Y = -1\}$, conditionnellement à $\{\mathbf{X} = \mathbf{x}\}$, en utilisant le classifieur SVM :

$$\mathbf{x} \in \mathbb{R}^P \mapsto f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}}). \quad (49)$$

Considérons un nouveau individu sur lequel on a observé la valeur $\mathbf{x}$ du vecteur $\mathbf{X}$ des variables explicatives. On prédit, la valeur y de Y du nouveau individu, selon la règle

$$\tilde{y} = \begin{cases} 1 & \text{si } f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}}) \geq 0, \\ -1 & \text{si } f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}}) < 0. \end{cases}$$

Pour obtenir une estimation de $\mathbb{P}(Y = 1 | \mathbf{X} = \mathbf{x})$, on “mappe” $f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})$, dans l'intervalle $[0, 1]$, à l'aide de la fonction sigmoïde, comme suit

$$\hat{\mathbb{P}}(Y = 1 | \mathbf{X} = \mathbf{x}) := \frac{\exp\{f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})\}}{1 + \exp\{f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})\}}.$$

On peut aller plus loin, en modélisant la probabilité précédente par une expression paramétrique, et estimer ensuite les paramètres, a et b , par maximum de vraisemblance (modèle de régression logistique) :

$$\mathbb{P}(Y = 1 | \mathbf{X} = \mathbf{x}) = \frac{\exp\{a + b f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})\}}{1 + \exp\{a + b f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})\}}.$$

Notons $\hat{a}$ et $\hat{b}$ les estimateurs MV, calculés à partir des données d'apprentissage. La probabilité $\mathbb{P}(Y = 1 | \mathbf{X} = \mathbf{x})$ est alors estimée par

$$\hat{\mathbb{P}}(Y = 1 | \mathbf{X} = \mathbf{x}) = \frac{\exp\{\hat{a} + \hat{b} f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})\}}{1 + \exp\{\hat{a} + \hat{b} f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})\}},$$

où $f(\mathbf{x}, \hat{\mathbf{w}}_0, \hat{\mathbf{w}})$ est le classifieur SVM.



Techniques de scoring

Le scoring

Un score permet d'attribuer à chaque individu une note estimant la probabilité d'un **évènement cible** :

- remboursement d'un crédit ;
- souscription à une assurance ;
- consommation d'un certain produit ;
- changement d'opérateur (en téléphonie) ;
- ...

Étapes de construction d'un score

1. Construction de la base de données :
 - Définition de l'événement à étudier (ou la variable cible Y) ;
 - Définition de la population éligible ;
 - Construction de variables explicatives ;
2. Modélisation
 - Construction de plusieurs modèles (candidats) ;
 - Choix du "meilleur" modèle (sélection de modèles) ;
 - Interprétation du modèle choisi ;
3. Utilisation du score
 - Application du score ;
 - Suivi de la performance du score - mise à jour du score.

Événement à étudier

L'évènement à étudier (ou **événement cible**) n'est pas forcément présent dans la base de données initiales. Il doit être défini en fonction de l'objectif de l'étude. Cette étape permet la construction de la variable à expliquer Y .

Exemple : crédit scoring

- L'objectif est de prévenir le risque d'impayés pour les clients à qui on accorde un crédit.
- La base de données renseigne uniquement sur le nombre d'impayés pour les clients présents dans l'historique.
- On construira une variable Y qui vaut 1 si un client a connu un nombre d'impayés inférieur à un certain seuil K , et 0 sinon (la valeur du seuil K dépend des objectifs de la banque).

- En général, cette variable à expliquer est binaire et permet de comparer (discriminer) deux sous-populations (individus ayant réalisé l'évènement qui auront la valeur "1", ceux ne l'ayant pas réalisé auront la valeur "0").

Population éligible

- La définition de la population éligible permet d'identifier l'ensemble d'individus à inclure dans l'étude.
- Elle est constituée d'individus dont les caractéristiques doivent être identiques à celles des individus sur lesquels le score sera appliqué.

Exemples de critères à utiliser

- Liés à l'évènement à étudier : intégrer uniquement les individus pour lesquels l'évènement peut se réaliser ;
- Liés à des choix stratégiques (experts métiers).

- À l'issue de cette phase, on dispose d'une variable à expliquer et d'un certain nombre de variables explicatives.
- L'objectif est de "trouver" une fonction $f(\cdot)$ telle que
variable réponse $\approx f(\text{variables explicatives})$.
- Nécessité de poser un modèle statistique puis d'estimer $f(\cdot)$ dans le modèle considéré.
- Il est souvent nécessaire de "travailler" au préalable sur les variables explicatives.

Variables explicatives

- Elles correspondent à tous les indicateurs mesurables pouvant potentiellement expliquer/prédire l'événement cible considéré.
- Il est généralement possible d'ajuster directement un modèle sur ces variables brutes...
- mais... il est souvent préférable de “travailler” sur ces variables (les étudier, en supprimer, en transformer, ...) pour pouvoir obtenir des modèles plus performants par la suite.

Construction de variables

- En plus des variables brutes, il est souvent utile de construire de nouveaux indicateurs (nouvelles variables) :
 - Moyenne/médiane de plusieurs variables
 - Ratio/taux d'accroissements
 - Croisements de variables
 - ...

Exemple

- On souhaite expliquer la fidélité de clients vis à vis d'un produit ou d'un forfait :
 - On dispose de la date de souscription de ce forfait → Calculer "l'âge de souscription" à la date de référence du client.

- Chaque variable doit ensuite être “fiabilisée” à l’aide de statistiques descriptives :
 - Calcul d’indicateurs de tendance centrale - de dispersion
 - Analyses factorielles (ACP/ACM).
- Cette analyse doit permettre de détecter et de traiter les points suivants :
 - variables “inutiles” /co-linéarité entre variables explicatives
 - valeurs manquantes/aberrantes/extrêmes
 - modalités à faibles effectifs
 - ...

Discrétisation

- Selon le modèle utilisé par la suite, les variables explicatives quantitatives peuvent être discrétisées (regroupées en classe).

Avantages

- Prise en compte d'effets non linéaires (intéressant pour la régression logistique) ;
- Permet de gérer facilement les valeurs manquantes.

Inconvénients

- Augmentation du nombre de paramètres à estimer (pour les modèles paramétriques) et donc de la variance des estimateurs ;
- Il n'existe pas de règles universelles optimales de discrétisation (ou de regroupement par classes, tailles des classes ?, nombre de classes ?, ...).

À l'issue des étapes précédentes, on dispose enfin de sa base de données : Elle est constituée de l'observation, sur n individus, de p variables explicatives $X_1, \dots, X_p$ et d'une variable réponse Y . Ces données peuvent être résumées à l'aide d'une matrice de la forme

$$\begin{bmatrix} x_{1,1} & \dots & x_{1,p} & y_1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{n,1} & \dots & x_{n,p} & y_n \end{bmatrix}$$

Le problème

Il consiste à expliquer/prédire Y à l'aide de $X_1, \dots, X_p$ à partir des données ci-dessus.

Quelques exemples

Risque bancaire

- Un individu souhaite demander un crédit bancaire.
- Le banquier souhaite construire un “score” estimant la probabilité que le client puisse rembourser ce crédit, en fonction d’informations sur le client (âge, sexe, CSP, revenus...)

Marketing

- Une entreprise souhaite booster les ventes d’un produit auprès de ces clients.
- Elle souhaite envoyer une promotion à ses clients les plus “appétents” à ce produit.
- Question : comment sélectionner les clients les plus appétents à ce produit ?

Churn

- Utilisé par les services clients en téléphonie ;
- L'objectif est de tenter d'identifier les clients susceptibles de partir vers la concurrence afin d'essayer de les retenir (en leur proposant une offre par exemple) ;
- Appeler tous les clients régulièrement a un coût, il est donc nécessaire de cibler les bons clients au bon moment ;
- Question : Comment identifier ces “mauvais” clients ?

- Pour ces 3 problèmes (et pour bien d'autres encore), il s'agit de faire un choix entre deux issues :
 - acceptation ou rejet du crédit ;
 - envoi ou non de la promotion au client ;
 - proposer ou non une offre au client.

Ces trois exemples peuvent être traités à l'aide d'un modèle de "régression" comprenant

- une variable à expliquer binaire Y en lien avec la réponse que l'on doit donner :
 - Y vaut 1 si le client est "bon", 0 si il est mauvais ;
 - Y vaut 1 si le client a déjà consommé le produit, 0 sinon ;
 - Y vaut 0 si le client est fidèle à l'opérateur, 1 si il en a changé.
- p variables explicatives susceptibles d'aider à comprendre Y :
 - âge, revenus...
 - fréquence d'achat, âge, domicile...
 - âge de souscription à l'opérateur, âge, CSP...

- Ces variables sont observées sur n individus. Cela nous amène à considérer un n échantillon $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ supposé i.i.d tel que
 - $\mathbf{X}_i := (X_{i,1}, \dots, X_{i,p})$ est un vecteur aléatoire à valeurs dans $\mathbb{R}^p$ représentant les variables explicatives du i -ème individu ;
 - Y_i est une variable aléatoire binaire représentant la variable à expliquer du i -ème individu.

Remarques

- L'indépendance revient à supposer que les individus n'ont pas d'influence les uns sur les autres (le fait qu'un individu i rembourse mal ses crédits n'influence pas les remboursements d'un autre individu j).
- "identiquement distribué" revient à dire que les n individus sont issus d'une "même population".

Le modèle logistique

- De nombreux modèles statistiques permettent de traiter ce genre de problème.
- Par exemple, le modèle de régression logistique : La loi conditionnelle de Y sachant $\mathbf{X} = \mathbf{x}$ est une loi de Bernoulli de paramètre $p(\mathbf{x}) := \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$ telle que

$$\log \frac{p(\mathbf{x})}{1 - p(\mathbf{x})} = w_0 + w_1 x_1 + \cdots + w_p x_p.$$

- Les paramètres w_j sont estimés par maximum de vraisemblance à l'aide d'un n -échantillon $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ de $(\mathbf{X}, Y)$.
- On peut faire de la prévision selon la règle (de classification)

$$\hat{Y} = \begin{cases} 1 & \text{si } \hat{p}(\mathbf{x}) > 0.5, \\ 0 & \text{sinon.} \end{cases}$$

L'approche scoring

L'approche précédente n'est pas totalement satisfaisante :

- selon les objectifs du moment, une banque peut être plus ou moins clémente pour accorder un crédit.
- au cours d'une campagne publicitaire, on peut être tenté de solliciter des clients pour lesquels on est loin d'être certain qu'ils souscrivent au produit.
- oublier un churn est plus grave que solliciter un client qui reste fidèle.
- D'où la nécessité de disposer d'un outil plus "flexible" : l'**approche scoring** consiste à donner une note à chaque individu qui soit en relation avec la variable Y .

Définition d'un score

- Un **score** est une fonction $S : \mathbf{x} \in \mathbb{R}^p \mapsto S(\mathbf{x}) \in \mathbb{R}$;
- Etant données un n -échantillon $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$, le travail consiste à construire une fonction $S(\mathbf{x})$ qui permettent d'expliquer Y au "mieux".
- Une fois le score construit, la décision s'effectue selon la règle

$$\hat{Y} = \begin{cases} 1 & \text{si } \hat{S}(\mathbf{x}) > s, \\ 0 & \text{sinon,} \end{cases}$$

où s est un seuil choisi par l'utilisateur.

- La construction de scores s'effectue généralement avec les modèles de classification (binaire) classiques.

- La fonction de score théorique “optimale” est définie par (voir théorème ci-après)

$$S(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}).$$

- Cette fonction est bien entendue inconnue et le problème est d'estimer $S(\cdot)$ à l'aide d'un n -échantillon i.i.d $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$.
- De nombreux modèles d'analyse discriminante permettent d'estimer $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$. L'estimation de S sera généralement basée sur les méthodes d'analyse discriminante (modèle logistique, LDA, QDA, K-NN, SVM, Arbres de décision, Forêts aléatoires, adaboost, ...).

Remarques

- La valeur de la note $S(\mathbf{x})$ n'a pas de réelle importance en scoring. L'important est la manière dont le score va classer des individus $\mathbf{x}_1, \dots, \mathbf{x}_n$.
- Il n'est pas forcément nécessaire d'estimer S . On peut se contenter d'une transformation bijective de S .

Lien score/règle de classification

- Etant donné un score S , on peut déduire une règle de classification en fixant un seuil s (la réciproque n'est pas vraie) :

$$g_s(\mathbf{x}) = \begin{cases} 1 & \text{si } \hat{S}(\mathbf{x}) > s, \\ 0 & \text{sinon.} \end{cases}$$

- Cette règle définit la **table de confusion**

	$g_s(\mathbf{X}) = 0$	$g_s(\mathbf{X}) = 1$
$Y = 0$	OK	E_1
$Y = 1$	E_2	OK

- Pour chaque seuil s , on distingue alors deux types d'erreur

$$\alpha(s) = \mathbb{P}(g_s(\mathbf{X}) = 1 \mid Y = 0) = \mathbb{P}(S(\mathbf{X}) \geq s \mid Y = 0)$$

et

$$\beta(s) = \mathbb{P}(g_s(\mathbf{X}) = 0 \mid Y = 1) = \mathbb{P}(S(\mathbf{X}) < s \mid Y = 1).$$

- **Interprétation** : $\alpha(s)$ représente le taux des **faux positifs** ; $\beta(s)$ donne le taux des **faux négatifs**.

On définit également

- La **spécificité** : $sp(s) := \mathbb{P}(S(\mathbf{X}) < s \mid Y = 0) = 1 - \alpha(s)$,
(le taux **des vrais négatifs**);
- La **sensibilité** : $se(s) := \mathbb{P}(S(\mathbf{X}) \geq s \mid Y = 1) = 1 - \beta(s)$,
(le taux **des vrais positifs**).

Définitions : Score parfait et Score aléatoire

- Un score $S(\cdot)$ est dit **parfait** si et seulement s'il existe un seuil $s^* \in \mathbb{R}$ tel que

$$\mathbb{P}(Y = 1 \mid S(\mathbf{X}) \geq s^*) = 1 \quad \text{et} \quad \mathbb{P}(Y = 0 \mid S(\mathbf{X}) < s^*) = 1.$$

- Un score $S(\cdot)$ est dit **aléatoire** ssi les v.a. $S(\mathbf{X})$ et Y sont indépendantes.

Performance d'un score

Elle se mesure généralement en visualisant les erreurs $\alpha(s)$ et $\beta(s)$ et/ou la spécificité et la sensibilité pour tous les seuils s .

Définition : la courbe ROC

Elle permet de représenter sur un graphe 2d les deux types d'erreur pour tous les seuils s . C'est une courbe 2d, paramétrée par le seuil s , d'équations

$$\begin{cases} x(s) = \alpha(s) = 1 - sp(s) = \mathbb{P}(S(\mathbf{X}) > s \mid Y = 0) \\ y(s) = 1 - \beta(s) = se(s) = \mathbb{P}(S(\mathbf{X}) \geq s \mid Y = 1). \end{cases}$$

Remarques

- La courbe ROC d'un score parfait correspond à l'ensemble

$$\{0\} \times [0, 1] \cup]0, 1] \times \{1\}.$$

- La courbe ROC d'un score aléatoire correspond à la première bissectrice :

$$\{(x, y) \in [0, 1]^2 \text{ tels que } y = x\}.$$

- La courbe ROC d'un score $S(\cdot)$ se situe généralement entre ces deux courbes.
- On mesurera la performance d'un score par sa capacité à se rapprocher de la droite d'équation $y = 1$ le plus vite possible.

Définition : AUC

- L'aire sous la courbe ROC d'un score $S(\cdot)$, notée $AUC(S)$ est souvent utilisée pour mesurer sa performance ;
- Pour un score S parfait, on a $AUC(S) = 1$;
- Pour un score S aléatoire, on a $AUC(S) = 0.5$.

Proposition

Etant données deux observations $(\mathbf{X}_1, Y_1)$ et $(\mathbf{X}_2, Y_2)$ indépendantes et de même loi que $(\mathbf{X}, Y)$, on a alors

$$AUC(S) = \mathbb{P}(S(\mathbf{X}_1) \geq S(\mathbf{X}_2) \mid (Y_1, Y_2) = (1, 0)).$$

- Le critère $AUC(S)$, à maximiser, peut être interprété comme une fonction de perte pour un score S ;
- Se pose donc la question d'existence d'un score théorique optimal S^* vis-à-vis de ce critère.

Théorème (score théorique optimal)

Soit le score $S^*(\mathbf{x}) := \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$. On a alors pour toute fonction de score S

$$AUC(S^*) \geq AUC(S).$$

Le théorème précédent montre que le score défini par

$$S^* : \mathbf{x} \in \mathbb{R}^p \mapsto S^*(\mathbf{x}) := \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$$

est optimal au sens du critère AUC.

Conséquence

Le problème pratique consiste donc à construire un “bon”
estimateur $S_n(\mathbf{x}) := S_n(\mathbf{x}, D_n)$ de

$$S^*(\mathbf{x}) := \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}).$$

La plupart des modèles permettant d'expliquer, une variable binaire par d'autres variables (explicatives), peuvent être utilisés pour construire des fonctions de score :

- Le **score logistique** :

$$\hat{S}(\mathbf{x}) := \frac{\exp\{\hat{w}_0 + \hat{w}_1 x_1 + \cdots + \hat{w}_p x_p\}}{1 + \exp\{\hat{w}_0 + \hat{w}_1 x_1 + \cdots + \hat{w}_p x_p\}},$$

où $(\hat{w}_0, \hat{w}_1, \dots, \hat{w}_p)$ sont les estimateurs de maximum de vraisemblance (conditionnelle).

- Le **score K-NN** : Soit $K \in \mathbb{N}^*$ un entier donné.

$$\hat{S}(\mathbf{x}) := \frac{1}{K} \sum_{i=1}^n \mathbb{1}_{\{Y_i=1\}} \mathbb{1}_{\{\mathbf{x}_i \in \mathcal{N}(\mathbf{x})\}},$$

où $\mathcal{N}(\mathbf{x})$ est l'ensemble constitué des K observations, les plus proches de $\mathbf{x}$, parmi toutes les observations (d'apprentissage).
 $\mathbf{X}_i, i = 1 \dots, n.$

- Le **score LDA** :

$$\hat{S}(\mathbf{x}) := \mathbf{x} \hat{\Sigma}^{-1} \hat{\mu}_1 - \frac{1}{2} \hat{\mu}_1^\top \hat{\Sigma}^{-1} \hat{\mu}_1 + \log \hat{\pi}_1.$$

- Le **score QDA** :

$$\hat{S}(\mathbf{x}) := -\frac{1}{2} (\mathbf{x} - \hat{\mu}_1^\top) \hat{\Sigma}_1^{-1} (\mathbf{x}^\top - \hat{\mu}_1) - \frac{1}{2} \log |\hat{\Sigma}_1| + \log \hat{\pi}_1.$$

- Voir aussi les scores par **SVM**, **Adaboost**, **Forêts aléatoires**, ...

- Comment comparer des scores $\hat{S}_1, \dots, \hat{S}_L$ (construits par différentes méthodes) ?
- La comparaison des scores s'effectue avec un échantillon $(\mathbf{X}_i, Y_i)$ indépendant de celui utilisé pour construire les fonctions de score $\hat{S}_\ell, \ell = 1, \dots, L$.
- Pour comparer des scores, on peut se baser sur la courbe ROC et la courbe "Lift" (qu'il faudrait estimer à partir des données de test).

Définition : la courbe Lift

La **courbe Lift** d'une fonction de score S est une courbe $2d$ paramétrée, par le seuil s , d'équations

$$\begin{cases} x(s) = \mathbb{P}(S(\mathbf{X}) > s); \\ y(s) = se(s) = \mathbb{P}(S(\mathbf{X}) > s \mid Y = 1). \end{cases}$$

- **Interprétation** : Si on cible $x(s)\%$ des individus de la population, on détecterait $y(s)\%$ des **vrais positifs**.

- Les courbes ROC et Lift nécessitent l'estimation de probabilités inconnues. Par exemple, la courbe ROC d'un score S nécessite l'estimation des probabilités $\mathbb{P}(S(\mathbf{X}) > s \mid Y = 0)$ et $\mathbb{P}(S(\mathbf{X}) \geq s \mid Y = 1)$, pour tout seuil s .
- Pour cela, on utilise l'approche Apprentissage/Validation :
 - On sépare les données en deux parties
 - Un **échantillon d'apprentissage** $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ pour construire un estimateur $\hat{S}$ de la fonction score S ;
 - Un **échantillon de test** $(\mathbf{X}_{n+1}, Y_{n+1}), \dots, (\mathbf{X}_{n+m}, Y_{n+m})$ pour estimer la courbe ROC du score S .

- Les coordonnées de la courbe ROC, d'un score S , pour un seuil donné s ,

$$\begin{cases} x(s) = \alpha(s) = 1 - sp(s) = \mathbb{P}(S(\mathbf{X}) > s \mid Y = 0); \\ y(s) = 1 - \beta(s) = se(s) = \mathbb{P}(S(\mathbf{X}) \geq s \mid Y = 1), \end{cases}$$

sont estimées par

$$\begin{cases} \hat{x}(s) = \frac{1}{\text{Card}\{i: Y_{n+i}=0\}} \sum_{i=1}^m \mathbb{1}_{\{\hat{S}(\mathbf{x}_{n+i}) > s\}} \mathbb{1}_{\{Y_{n+i}=0\}}; \\ \hat{y}(s) = \frac{1}{\text{Card}\{i: Y_{n+i}=1\}} \sum_{i=1}^m \mathbb{1}_{\{\hat{S}(\mathbf{x}_{n+i}) \geq s\}} \mathbb{1}_{\{Y_{n+i}=1\}}. \end{cases}$$

- Interprétation** : $\hat{x}(s)$ représente la proportion **des faux positifs** ; $\hat{y}(s)$ donne la proportion **des vrais positifs** (parmi les individus de l'ensemble de test).
- L'estimation de la courbe Lift peut se faire de la même façon, en remplaçant les probabilités théoriques par les probabilités empiriques (calculées à partir de l'échantillon de test).

- On peut utiliser aussi les critères : AUC et AUL, l'aire sous les courbes ROC et Lift estimées, pour comparer les scores.
- Pour tracer la courbe ROC estimée d'un score S , on représente dans le plan les points de coordonnées $(\hat{x}(s), \hat{y}(s))$ pour toute valeur du seuil s de l'intervalle $[a, b]$, dans l'ordre décroissant de s , avec

$$a = \min\{\hat{S}(\mathbf{X}_{n+i}), i = 1, \dots, m\}$$

et

$$b = \max\{\hat{S}(\mathbf{X}_{n+i}), i = 1, \dots, m\},$$

$\hat{S}(\mathbf{X}_{n+i}), i = 1, \dots, m$, étant les valeurs du score calculées sur les individus de l'ensemble de test.

Références bibliographiques

- James, G., Witten, D., Hastie, T. & Tibshirani, R. (2013). An introduction to statistical learning (Vol. 112). New York : Springer ;
- Friedman, J., Hastie, T. & Tibshirani, R. (2001). The elements of statistical learning (Vol. 1, No. 10). New York, NY, USA : Springer series in statistics ;
- Bruce, Peter and Andrew Bruce. (2017). Practical Statistics for Data Scientists ;
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society, Series B, 58 : 267-288 ;

- Cornillon, P. A. et al. (2018). R pour la statistique et la science des données. Presses universitaires de Rennes ;
- Saporta, G. (2006). Probabilités, analyse des données et Statistique. Editions TECHNIP ;
- Sites web :
 - “[http ://eric.univ-lyon2.fr/ ricco/cours/index.html](http://eric.univ-lyon2.fr/ricco/cours/index.html)” ;
 - “[https ://perso.univ-rennes2.fr/laurent.rouviere](https://perso.univ-rennes2.fr/laurent.rouviere)”
 - “[http ://www.rdatamining.com/home](http://www.rdatamining.com/home)” ,
 - “[http ://www.sthda.com/french/](http://www.sthda.com/french/)” ,
 - “[http ://www.statsoft.com/Textbook](http://www.statsoft.com/Textbook)” , ...