

TD1 : Régression linéaire multiple

30/01/2026

Le but de ce premier TD est de présenter quelques techniques d'apprentissage statistique dans le contexte de la régression linéaire multiple, et de leur mise en oeuvre à l'aide du logiciel R. Nous allons illustrer ces techniques pour la base de données **Carseats** du package **ISLR**.

On cherche à expliquer/prédire une variable statistique Y à l'aide de p variables statistiques numériques $X_1, \dots, X_p$. Lorsque la variable Y est numérique "continue", on parle de problème de régression. Y s'appelle la variable à expliquer (ou encore, variable réponse, dépendante, endogène), et $X_1, \dots, X_p$ les variables explicatives (variables de contrôle, indépendantes, exogènes, régresseurs, prédicteurs). Notons le vecteur aléatoire (ligne)

$$\mathbf{X} := (X_1, \dots, X_p) \in \mathbb{R}^p$$

des variables explicatives. Le problème de régression consiste à trouver une fonction $f : \mathbb{R}^p \rightarrow \mathbb{R}$ telle que $Y \approx f(\mathbf{X})$:

$$Y = f(X_1, \dots, X_p) + \varepsilon,$$

où ε est une variable aléatoire, non observable, représentant le terme d'erreur (le bruit).

Pour la fonction de perte quadratique, la fonction

$$f^* := \arg \inf_f \mathbb{E}((Y - f(\mathbf{X}))^2)$$

optimale est l'espérance conditionnelle de Y sachant $\mathbf{X} = \mathbf{x}$, i.e.,

$$\forall \mathbf{x} \in \mathbb{R}^p, f^*(\mathbf{x}) = \mathbb{E}(Y | \mathbf{X} = \mathbf{x}).$$

Si la fonction de régression optimale $f^*(\cdot)$ est paramétrique et est linéaire, i.e., de la forme

$$f(\mathbf{x}) =: f(\mathbf{x}, \mathbf{w}) := w_0 + w_1 x_1 + \dots + w_p x_p,$$

on obtient le modèle de régression linéaire multiple (RLM) réécrit sous la forme

$$Y = w_0 + w_1 X_1 + \dots + w_p X_p + \varepsilon,$$

avec $\mathbb{E}(\varepsilon | \mathbf{X} = \mathbf{x}) = 0$. Le problème est alors d'estimer les paramètres

$$\mathbf{w} := (w_0, w_1, \dots, w_p)^\top \in \mathbb{R}^{1+p}$$

à partir de n observations,

$$(\mathbf{X}_1, Y_1) \in \mathbb{R}^{p+1}, \dots, (\mathbf{X}_n, Y_n) \in \mathbb{R}^{p+1},$$

du vecteur aléatoire $(\mathbf{X}, Y) \in \mathbb{R}^{p+1}$. Nous allons utiliser les notations matricielles suivantes

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n, \quad \mathbb{X} := \begin{bmatrix} 1 & X_{1,1} & \dots & X_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n,1} & \dots & X_{n,p} \end{bmatrix}, \quad \mathbf{w} := \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_p \end{bmatrix} \in \mathbb{R}^{1+p}, \quad \boldsymbol{\varepsilon} := \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \in \mathbb{R}^n,$$

qui représentent, respectivement, le vecteur des valeurs observées de la variable réponse Y , la matrice de design (matrice de dimension $n \times (1 + p)$), le vecteur des paramètres du modèle de RLM, et enfin le vecteur des termes d'erreur du modèle, $\varepsilon_1, \dots, \varepsilon_n$, non observables. Le modèle de RLM, associé aux données, s'écrit donc sous la forme matricielle suivante

$$\mathbf{Y} = \mathbb{X} \mathbf{w} + \boldsymbol{\varepsilon}.$$

L'estimateur MC

L'estimateur des moindres carrés, $\widehat{\mathbf{w}}$ du vecteur $\mathbf{w}$, est défini par

$$\begin{aligned}\widehat{\mathbf{w}} &:= \arg \min_{(w_0, w_1, \dots, w_p) \in \mathbb{R}^{1+p}} \frac{1}{n} \sum_{i=1}^n (Y_i - w_0 - w_1 X_{i,1} - \dots - w_p X_{i,p})^2 \\ &=: \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p}} \frac{1}{n} \|\mathbf{Y} - \mathbb{X} \mathbf{w}\|^2. \\ &= (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}.\end{aligned}\tag{1}$$

La dernière égalité a lieu si la matrice $\mathbb{X}^\top \mathbb{X}$ est inversible, ce qui est équivalent à supposer que les colonnes de $\mathbb{X}$ sont linéairement indépendantes (donc le nombre d'observations n doit être supérieur à $1 + p$, p étant le nombre de variables explicatives). Cette hypothèse garantit l'existence et l'unicité de l'estimateur MC précédent.

Lien avec l'estimation par maximum de vraisemblance (MV)

On suppose que les termes d'erreur,

$$\varepsilon_1, \dots, \varepsilon_n,$$

sont i.i.d de même loi normale $\mathcal{N}(0, \sigma^2)$, $\mathbb{E}(\varepsilon | \mathbf{X} = \mathbf{x}) = 0$, et $\text{Var}(\varepsilon | \mathbf{X} = \mathbf{x}) = \sigma^2$ ne dépendant pas de $\mathbf{x}$ (hypothèse d'homoscédasticité). Par conséquent, la loi de Y , conditionnellement à $\mathbf{X} = \mathbf{x}$, est une loi normale d'espérance $w_0 + w_1 x_1 + \dots + w_p x_p$ et de variance σ^2 . La log-vraisemblance (conditionnelle) s'écrit donc sous la forme

$$\mathcal{L}_n(\mathbf{w}, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{n}{2} \log(2\pi) - \frac{1}{2\sigma^2} \|\mathbf{Y} - \mathbb{X} \mathbf{w}\|^2.$$

On peut voir dans ce cas que l'estimateur du maximum de vraisemblance (MV), de $\mathbf{w}$, coïncide avec l'estimateur des MC : Notons $(\tilde{\mathbf{w}}, \tilde{\sigma}^2)$ l'EMV de $(\mathbf{w}, \sigma^2)$, i.e.,

$$(\tilde{\mathbf{w}}, \tilde{\sigma}^2) := \arg \max_{\mathbf{w} \in \mathbb{R}^{1+p}, \sigma^2 \in \mathbb{R}_+^*} \mathcal{L}_n(\mathbf{w}, \sigma^2).$$

Il est clair que l'EMV

$$\tilde{\mathbf{w}} = \arg \min_{\mathbf{w}} \|\mathbf{Y} - \mathbb{X} \mathbf{w}\|^2 =: \widehat{\mathbf{w}} =: EMC.$$

L'EMV $\tilde{\sigma}^2$, de σ^2 , vaut

$$\tilde{\sigma}^2 = \frac{1}{n} \|\mathbf{Y} - \mathbb{X} \widehat{\mathbf{w}}\|^2.$$

La log-vraisemblance du modèle (évaluée à l'EMV) est égale donc à

$$\mathcal{L}_n(\tilde{\mathbf{w}}, \tilde{\sigma}^2) = -\frac{n}{2} \log \frac{\|\widehat{\boldsymbol{\varepsilon}}\|^2}{n} - \frac{n}{2} (1 + \log(2\pi)),\tag{2}$$

où

$$\widehat{\boldsymbol{\varepsilon}} := (\widehat{\varepsilon}_1, \dots, \widehat{\varepsilon}_n)^\top := \mathbf{Y} - \mathbb{X} \widehat{\mathbf{w}} =: \mathbf{Y} - \widehat{\mathbf{Y}}$$

représentant le vecteur des résidus : les écarts entre les valeurs observées $\mathbf{Y} := (Y_1, \dots, Y_n)^\top$, de la variable réponse Y , et les valeurs ajustées

$$\widehat{\mathbf{Y}} := \mathbb{X} \widehat{\mathbf{w}} =: (\widehat{Y}_1, \dots, \widehat{Y}_n)^\top.$$

Propriétés des estimateurs MC

Si les trois conditions suivantes sont vérifiées

- (i) Les erreurs, $\varepsilon_i, i = 1, \dots, n$, sont non corrélées;
- (ii) $\mathbb{E}(\varepsilon_i | \mathbb{X}) = 0$, $\text{Var}(\varepsilon_i | \mathbb{X}) = \sigma^2$, $i = 1, \dots, n$, ne dépendant pas de $\mathbf{X}$ (hypothèse d'homoscédasticité);

alors on a les propriétés suivantes

- (1) $\hat{\mathbf{w}}$ est un estimateur sans biais de $\mathbf{w}$;
- (2) La matrice de variance-covariance de $\hat{\mathbf{w}}$, conditionnellement à $\mathbb{X}$, est donnée par

$$\text{Var}(\hat{\mathbf{w}} | \mathbb{X}) = \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}.$$

Lois des estimateurs MC

Dans cette section, on suppose que les termes d'erreur, $\varepsilon_1, \dots, \varepsilon_n$, sont i.i.d (et indépendantes de $\mathbb{X}$) de même loi normale $\mathcal{N}(0, \sigma^2)$, de variance σ^2 ne dépendant pas de $\mathbf{x}$ (hypothèse d'homoscédasticité). Soit

$$\hat{\boldsymbol{\varepsilon}} := \mathbf{Y} - \mathbb{X} \hat{\mathbf{w}} =: \mathbf{Y} - \hat{\mathbf{Y}}$$

le vecteur des résidus, et $\hat{\sigma}^2$ l'estimateur, de σ^2 , défini par

$$\hat{\sigma}^2 := \frac{1}{n - p - 1} \|\hat{\boldsymbol{\varepsilon}}\|^2.$$

Notons que les résultats de cette section restent valables (asymptotiquement, i.e. pour n suffisamment grand) si les erreurs $\varepsilon_1, \dots, \varepsilon_n$ sont i.i.d centrées de variance σ^2 (ne dépendant pas de $\mathbf{x}$, homoscédasticité), même si la normalité n'est pas vérifiée. Les erreurs $\varepsilon_1, \dots, \varepsilon_n$ ne sont pas observables. Elles sont alors approchées par les résidus, pour tester par exemple les hypothèses d'homoscédasticité ou de non-corrélation des erreurs.

Proposition

On a

- (1) $\hat{\mathbf{w}}$ est un vecteur gaussien d'espérance $\mathbf{w}$ et de matrice de variance-covariance $\sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}$;
- (2) La statistique $(n - p - 1) \frac{\hat{\sigma}^2}{\sigma^2}$ suit la loi du $\chi^2_{(n-p-1)}$ (la loi du χ^2 à $n - p - 1$ degrés de liberté);
- (3) $\hat{\mathbf{w}}$ et $\hat{\sigma}^2$ sont indépendants.

Intervalle de confiance et tests

On note $\hat{\sigma}_j^2 := \hat{\sigma}^2 \left[(\mathbb{X}^\top \mathbb{X})^{-1} \right]_{j,j}$, pour $j = 0, 1, \dots, p$. On a

$$\forall j = 0, \dots, p, \text{ la statistique } \frac{\hat{w}_j - w_j}{\hat{\sigma}_j} \text{ suit la loi } \mathcal{T}_{(n-p-1)},$$

(la loi de Student à $n - p - 1$ degrés de liberté), ce qui permet de construire des intervalles de confiance, au niveau $1 - \alpha$, pour les paramètres w_j , et de réaliser des tests d'hypothèses du type $\mathcal{H}_0 : w_j = 0$ contre $\mathcal{H}_1 : w_j \neq 0$.

Intervalle de confiance, au niveau $1 - \alpha$, pour w_j

$$\left[\hat{w}_j - t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma}_j, \hat{w}_j + t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma}_j \right],$$

où $t_{(n-p-1)}(1 - \alpha/2)$ est le quantile d'ordre $1 - \alpha/2$ de la loi de Student à $(n-p-1)$ degrés de liberté.

Test de Student

Considérons le problème de test de l'hypothèse nulle

$$\mathcal{H}_0 : w_j = 0 \quad \text{contre l'alternative} \quad \mathcal{H}_1 : w_j \neq 0.$$

Notons $t := \frac{\widehat{w}_j}{\widehat{\sigma}_j}$ (la statistique de Student). Sous $\mathcal{H}_0$, la statistique de Student t suit la loi $\mathcal{T}_{(n-p-1)}$. Notons t_{obs} la valeur observée de la statistique t . La P-value du test (de Student) est donnée alors par

$$\text{P-value} = \mathbb{P}(|T| > |t_{obs}|),$$

où T est une variable aléatoire suivant la loi $\mathcal{T}_{(n-p-1)}$.

Prévision et intervalles de confiance

On dispose d'une nouvelle observation $\mathbb{X}_{n+1} := (1, X_{n+1,1}, \dots, X_{n+1,p})$. On prédit la valeur Y_{n+1} correspondante par

$$\widehat{Y}_{n+1} := \mathbb{X}_{n+1} \widehat{\mathbf{w}}.$$

Intervalle d'estimation, au niveau $1 - \alpha$, pour Y_{n+1} :

$$\left[\widehat{Y}_{n+1} - t_{(n-p-1)}(1 - \alpha/2) \widehat{\sigma} \sqrt{\mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top}, \widehat{Y}_{n+1} + t_{(n-p-1)}(1 - \alpha/2) \widehat{\sigma} \sqrt{\mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top} \right];$$

Intervalle de prévision, au niveau $1 - \alpha$, pour Y_{n+1} :

$$\left[\widehat{Y}_{n+1} - t_{(n-p-1)}(1 - \alpha/2) \widehat{\sigma} \sqrt{1 + \mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top}, \widehat{Y}_{n+1} + t_{(n-p-1)}(1 - \alpha/2) \widehat{\sigma} \sqrt{1 + \mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top} \right].$$

Équation de l'analyse de variance

On a d'après le théorème de Pythagore

$$\begin{aligned} \|\mathbf{Y} - \overline{\mathbf{Y}}\mathbf{1}\|^2 &= \|\widehat{\mathbf{Y}} - \overline{\mathbf{Y}}\mathbf{1}\|^2 + \|\widehat{\boldsymbol{\varepsilon}}\|^2 \\ SST &= SSR + SSE. \end{aligned}$$

(somme totale des carrés = somme des carrés de la régression + somme des carrés résiduels)

(total sum of squares = regression sum of squares + sum of squared errors)

Coefficient de détermination R^2

Le coefficient de détermination R^2 est défini par

$$R^2 := \frac{\|\widehat{\mathbf{Y}} - \overline{\mathbf{Y}}\mathbf{1}\|^2}{\|\mathbf{Y} - \overline{\mathbf{Y}}\mathbf{1}\|^2} =: \frac{SSR}{SST}.$$

Il vérifie les propriétés suivantes

- (i) $0 \leq R^2 \leq 1$;
- (ii) Si $R^2 = 1$, la variabilité de la variable réponse est entièrement expliquée par le modèle;
- (iii) Si $R^2 = 0$, toute la variabilité se trouve dans le bruit (le terme d'erreur).

Test du modèle global

Le modèle de RLM s'écrit

$$Y_i = w_0 + w_1 X_{i,1} + \dots + w_p X_{i,p} + \varepsilon_i, \quad i = 1, \dots, n,$$

où les termes d'erreurs $\varepsilon_i, i = 1, \dots, n$, sont supposés ici i.i.d. de même loi $\mathcal{N}(0, \sigma^2)$.

On veut tester

$$\mathcal{H}_0 : w_1 = \dots = w_p = 0 \quad \text{contre} \quad \mathcal{H}_1 : \exists j \in \{1, \dots, p\} \text{ t.q. } w_j \neq 0.$$

Sous $\mathcal{H}_0$, la statistique de Fisher

$$F := \frac{R^2}{1 - R^2} \frac{n - p - 1}{p} \quad \text{suit la loi } \mathcal{F}_{(p, n-p-1)} \quad (\text{la loi de Fisher à } p \text{ et } n - p - 1 \text{ degrés de liberté}).$$

On rejette $\mathcal{H}_0$ si $F > F_{(p, n-p-1)}(1 - \alpha)$, où $F_{(p, n-p-1)}(1 - \alpha)$ est le quantile d'ordre $(1 - \alpha)$ de la loi $\mathcal{F}_{(p, n-p-1)}$. Notons F_{obs} la valeur observée de la statistique F . La P-value est donc donnée par $\text{P-value} = \mathbb{P}(Z > F_{obs})$, où Z est une variable aléatoire suivant la loi $\mathcal{F}_{(p, n-p-1)}$.

Tests entre modèles emboîtés

On veut tester le modèle réduit $\mathcal{M}_0$

$$Y_i = w_0 + w_{q+1} X_{i,q+1} + \dots + w_p X_{i,p} + \varepsilon_i,$$

avec $1 \leq q < p$, à l'intérieur du modèle plus large $\mathcal{M}$

$$Y_i = w_0 + w_1 X_{i,1} + \dots + w_p X_{i,p} + \varepsilon_i.$$

Cela revient à tester (à l'intérieur du modèle $\mathcal{M}$) l'hypothèse nulle

$$\mathcal{H}_0 : w_1 = \dots = w_q = 0 \quad \text{contre} \quad \mathcal{H}_1 : \exists j \in \{1, \dots, q\} \text{ t.q. } w_j \neq 0.$$

Pour réaliser le test précédent, on utilise la statistique de Fisher suivante

$$F := \frac{\|\hat{\mathbf{Y}}_0 - \hat{\mathbf{Y}}\|^2 / q}{\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 / (n - p - 1)}$$

qui suit la loi $\mathcal{F}_{(q, n-p-1)}$, sous $\mathcal{H}_0$. ($\hat{\mathbf{Y}}_0$ désigne le vecteur des valeurs ajustées du modèle réduit).

On rejette $\mathcal{H}_0$ si $F > F_{(q, n-p-1)}(1 - \alpha)$. Notons F_{obs} la valeur observée de la statistique F . La P-value est donc définie par $\text{P-value} := \mathbb{P}(Z > F)$, où Z est une variable aléatoire suivant la loi $\mathcal{F}_{(q, n-p-1)}$.

Ce test peut se faire sous R à l'aide de la fonction `anova()` qu'on applique à des modèles linéaires calculés avec la fonction `lm()`.

Exercice 1

- (1) Construire le modèle de RLM de la variable `Sales` en fonction de toutes les variables de la base de données `Carseats` : utiliser la fonction `lm()`;
- (2) Commenter tous les résultats;
- (3) Vérifier graphiquement : (i) la non-corrélation des erreurs (utiliser la fonction `acf()`); (ii) la relation linéaire entre la variable réponse et les variables explicatives; (iii) l'hypothèse d'homoscédasticité des erreurs (appliquer la fonction `plot()` au modèle calculé par la fonction `lm()`);
- (4) Tester l'hypothèse de non corrélation des erreurs (Utiliser le test de Durbin-Watson);

- (5) Tester l'hypothèse d'homoscédasticité des erreurs: utiliser le test de Breusch-Pagan (fonction `bptest()` du package `lmtest`);
- (6) Vérifier graphiquement l'hypothèse de normalité des erreurs : utiliser la représentation Q-Q plot, et comparer l'histogramme des erreurs et la densité gaussienne;
- (7) Donner les résultats du test de Student de l'hypothèse nulle de non-significativité de chacune des variables explicatives. Ordonner les variables explicatives de la plus significative à la moins significative;
- (8) Donner les résultats du test de Fisher de l'hypothèse nulle de non-significativité de chacune des variables explicatives. Ordonner les variables explicatives de la plus significative à la moins significative;
- (9) Comparer les résultats des deux questions précédentes, et commenter.

Sélection de modèles (ou de variables) en RLM

Taille d'un modèle et précision

Lorsque la taille du modèle est petite (ou nombre petit de variables explicatives) :

- (i) variance faible, biais très élevé (erreur quadratique élevée);
- (ii) erreur théorique de prévision élevée;
- (iii) erreur empirique (d'ajustement) élevée.

Lorsque la taille du modèle est grande (ou nombre élevé de variables explicatives) :

- (i) variance très élevée, biais faible (erreur quadratique élevée);
- (ii) erreur théorique de prévision élevée;
- (iii) erreur empirique (d'ajustement) très faible (problème de sur-ajustement).

D'où la nécessité de développer des procédures de sélection de modèles (de variables).

Le cadre

On considère un modèle de RLM

$$Y = w_0 + w_1 X_1 + \dots + w_p X_p + \varepsilon.$$

On dispose d'un échantillon $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ du vecteur $(\mathbf{X}, Y) =: (X_1, \dots, X_p, Y) \in \mathbb{R}^p \times \mathbb{R}$.

L'objectif est d'obtenir le sous-ensemble de variables explicatives qui conduit au "meilleur" modèle RLM au sens d'un critère donné.

Avec p variables explicatives candidates, $X_1, \dots, X_p$, on peut construire $2^p - 1$ modèles de régression linéaires différents (les modèles à une variable, à deux variables, ..., à p variables).

Exemples de critères de sélection de modèles

- (1) L'Akaike Information Criterion (AIC), d'un modèle de RLM, constitué de k variables explicatives, est défini par

$$AIC = -2 \mathcal{L}_n(\hat{\mathbf{w}}, \tilde{\sigma}^2) + 2(k + 2),$$

où $\mathcal{L}_n(\hat{\mathbf{w}}, \tilde{\sigma}^2)$ est la log-vraisemblance du modèle, définie ci-dessus, sous les hypothèses d'homoscédasticité et de normalité des erreurs;

- (2) Le Bayesian Information Criterion (BIC) :

$$BIC = -2 \mathcal{L}_n(\hat{\mathbf{w}}, \tilde{\sigma}^2) + \log(n)(k + 2);$$

(3) R^2 -ajusté :

$$R_a^2 := 1 - \frac{n-1}{n-k-1} (1 - R^2) ;$$

(4) Le C_p de Mallows d'un modèle de régression utilisant k variables explicatives ($1 \leq k \leq p$) est donné par :

$$C_p := \frac{1}{n} \left(\|\mathbf{Y} - \hat{\mathbf{Y}}_0 \mathbf{1}\|^2 + 2(1+k)\hat{\sigma}^2 \right),$$

où $\hat{\mathbf{Y}}_0$ est le vecteur des valeurs ajustées selon le modèle utilisant les k variables explicatives;

(5) Le critère F de Fisher : Notons $\hat{\mathbf{Y}}$ le vecteur des valeurs ajustées selon le modèle de RLM complet à p variables explicatives, et $\hat{\mathbf{Y}}_0$ le vecteur des valeurs ajustées selon le modèle réduit à $p - q$ variables explicatives ($1 \leq q < p$). Le critère F du modèle réduit est défini par

$$F := \frac{\|\hat{\mathbf{Y}}_0 - \hat{\mathbf{Y}}\|^2/q}{\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2/(n-p-1)}.$$

Algorithme de recherche exhaustive

- (1) Construire les $2^p - 1$ modèles;
- (2) Choisir celui qui optimise un critère donné.

Exercice 2

- (1) Donner les modèles optimaux selon les critères R^2 -ajusté, BIC et C_p , par recherche exhaustive : utiliser la fonction `regsubsets()` du package `leaps`;
- (2) Reprendre la question précédente en utilisant cette fois-ci la fonction `glmulti()` du package `glmulti`.

Algorithme de recherche pas-à-pas

L'approche exhaustive permet de comparer tous les modèles; l'inconvénient est que le temps de calcul devient très important si le nombre de variables est grand;

Lorsque le nombre de variables est grand, on privilégie souvent les méthodes pas-à-pas qui consistent à construire les modèles de façon récursive, en ajoutant/supprimant une variable explicative à chaque étape.

Méthode ascendante (forward selection, version 1)

- (1) Construire $\mathcal{M}_0$ le modèle trivial (avec uniquement l'intercept);
- (2) Pour $k = 0, \dots, p-1$:
 - (i) Construire les $p - k$ modèles consistant à ajouter une variable dans $\mathcal{M}_k$;
 - (ii) Choisir, parmi ces $p - k$ modèles, le modèle $\mathcal{M}_{k+1}$ qui optimise un critère donné;
- (3) Choisir, parmi $\mathcal{M}_1, \dots, \mathcal{M}_p$, le meilleur modèle au sens du critère considéré.

Méthode descendante (backward elimination, version 1)

- (1) Construire $\mathcal{M}_p$ le modèle complet (avec les p variables);
- (2) Pour $k = p, \dots, 2$:
 - (i) Construire les k modèles consistant à supprimer une variable dans $\mathcal{M}_k$;
 - (ii) Choisir, parmi ces k modèles, le modèle $\mathcal{M}_{k-1}$ qui optimise un critère donné;
- (3) Choisir, parmi $\mathcal{M}_1, \dots, \mathcal{M}_p$, le meilleur modèle au sens du critère considéré.

Exercice 3 Appliquer les deux algorithmes précédents pour sélectionner les modèles optimaux selon les critères BIC, C_p et R^2 -ajusté : Utiliser la fonction `regsubsets()`.

Méthode ascendante (forward selection, version 2)

- (1) Modèle sans variables;
- (2) Insertion de la variable qui diminue le plus le critère;
- (3) Insertion de la deuxième variable qui diminue le plus le critère, ... arrêt quand on ne diminue plus le critère.

Méthode descendante (backward elimination, version 2)

- (1) Modèle complet;
- (2) Enlever la variable qui diminue le plus le critère;
- (3) Enlever la deuxième variable qui diminue le plus le critère, ... arrêt quand on ne diminue plus le critère.

Exercice 4 Appliquer les deux algorithmes précédents pour sélectionner les modèles optimaux selon les critères AIC, BIC et Fisher : Utiliser la fonction `step()`.

Méthode ascendante bidirectionnelle (bidirectional selection)

- (1) Ascendante avec remise en cause à chaque étape des variables déjà incluses ;
- (2) Permet d'exclure des variables qui redeviennent plus significatives compte tenu de celle qui vient d'être intégrée.

Méthode descendante bidirectionnelle (bidirectional elimination)

- (1) Descendante avec remise en cause à chaque étape des variables déjà exclues ;
- (2) Permet de réintégrer des variables qui redeviennent significatives compte tenu de celle qui vient d'être exclue.

Exercice 5 Appliquer les deux algorithmes précédents pour sélectionner les modèles optimaux selon les critères AIC, BIC et Fisher : Utiliser la fonction `step()`.

Sélection par algorithme génétique

- (1) On l'utilise quand le nombre de variables devient de plus en plus grand et qu'une recherche exhaustive est impossible et une recherche pas à pas peut mener à une solution qui n'est pas tout à fait optimale;
- (2) Cet algorithme est implémenté dans la fonction `glmulti()` du package `glmulti` en spécifiant l'argument `method = "g"`;
- (3) Cette méthode est donc supposée trouver le meilleur modèle sans avoir besoin de calculer le critère à considérer sur tous les modèles possibles (recherche exhaustive).

Exercice 6

Appliquer l'algorithme précédent pour sélectionner les modèles optimaux selon les critères AIC et BIC : Utiliser la fonction `glmulti()` du package `glmulti`.

Exercice 7

Reprendre toutes les questions de l'exercice 1 en utilisant cette fois-ci seulement le sous-ensemble de variables explicatives sélectionnées par le critère BIC.

Méthodes d'estimation de l'erreur théorique d'un modèle par validation croisée

On présente ici trois méthodes différentes, de validation croisée, pour l'estimation de l'erreur théorique (de test ou de prévision) d'un modèle :

Méthode 1 : de l'ensemble de validation

Cette approche est simple. Elle consiste à diviser de manière aléatoire l'ensemble d'observations en deux parties : un ensemble d'apprentissage ($\mathcal{A}$) et un ensemble de validation (ou de test) ($\mathcal{V}$). Le modèle est construit à partir des données d'apprentissage, et il est ensuite utilisé pour prédire la variable réponse des données de l'ensemble de validation. L'erreur théorique du modèle considéré, que l'on note $\mathcal{E}$, est alors estimée par l'écart moyen entre les valeurs prédites et les valeurs observées de la variable réponse des données de l'ensemble de validation :

$$\hat{\mathbf{w}} := \arg \min_{\mathbf{w}} \frac{1}{\text{Card}(\mathcal{A})} \sum_{i \in \mathcal{A}} (Y_i - f(\mathbf{X}_i, \mathbf{w}))^2$$

et

$$\hat{\mathcal{E}} := \frac{1}{\text{Card}(\mathcal{V})} \sum_{i \in \mathcal{V}} (Y_i - f(\mathbf{X}_i, \hat{\mathbf{w}}))^2.$$

Cette méthode est simple, mais elle a au moins deux inconvénients :

- (i) L'estimation de l'erreur théorique dépend de la partition, et cette estimation peut varier beaucoup si on considère une partition différente;
- (ii) Dans cette approche seulement une partie des données est utilisée pour ajuster le modèle, ce qui peut mener à une sur-estimation de l'erreur.

Exercice 8

Ecrire un programme R qui permet d'évaluer l'erreur théorique de prévision, du modèle complet et du modèle sélectionné suivant le critère BIC, de la base de données `Carseats`, en utilisant la technique de l'ensemble de validation précédente : utiliser 2/3 d'observations pour l'apprentissage et 1/3 pour la validation.

Méthode 2 : leave-one-out cross-validation (LOOCV)

Comme la méthode précédente, la méthode LOOCV consiste à diviser l'ensemble des observations en deux parties. Cependant, au lieu de créer deux parties de tailles "comparables", une seule observation ($\mathbf{X}_1, Y_1$) est utilisée pour la validation et tout le reste est utilisé pour l'apprentissage (pour estimer les paramètres du modèle). Donc le modèle est ajusté sur la base des $(n - 1)$ observations restantes, et une prédiction $\hat{Y}_1$ est calculée en fonction de $\mathbf{X}_1$. Plus précisément, si on note $\hat{\mathbf{w}}^{(-1)}$ l'estimateur obtenu en utilisant toutes les observations sauf l'observation $(\mathbf{X}_1, Y_1)$, alors $\hat{Y}_1 := f(\mathbf{X}_1, \hat{\mathbf{w}}^{(-1)})$. Puisque l'observation $(\mathbf{X}_1, Y_1)$ n'a pas été utilisée pour ajuster le modèle, alors

$e_1 := (Y_1 - \hat{Y}_1)^2 = (Y_1 - f(\mathbf{X}_1, \hat{\mathbf{w}}^{(-1)}))^2$ est une estimation approximativement sans biais de l'erreur théorique, mais elle n'est pas précise puisque elle est basée sur une seule observation. On répète alors la procédure précédente en choisissant $(\mathbf{X}_2, Y_2)$ pour la validation, et les observations restantes pour ajuster le modèle, et on calcule $e_2 := (Y_2 - \hat{Y}_2)^2 = (Y_2 - f(\mathbf{X}_2, \hat{\mathbf{w}}^{(-2)}))^2$. En répétant la procédure n fois, on obtient n estimations, $e_1, e_2, \dots, e_n$, de l'erreur théorique $\mathcal{E}$. Le LOOCV donne l'estimation suivante de l'erreur théorique

$$\hat{\mathcal{E}} := \frac{1}{n} \sum_{i=1}^n e_i = \frac{1}{n} \sum_{i=1}^n \left(Y_i - f(\mathbf{X}_i, \hat{\mathbf{w}}^{(-i)}) \right)^2. \quad (3)$$

Cette méthode a au moins deux avantages par rapport à la méthode 1 précédente (l'approche de l'ensemble de validation) :

- (i) En LOOCV, l'estimation des paramètres du modèle est plus précise, car à chaque fois on utilise toutes les données (sauf une), alors que la méthode 1 utilise seulement une partie des données pour l'estimation des paramètres du modèle;
- (ii) Contrairement à la méthode 1 de l'ensemble de validation - qui donne des résultats différents en changeant la répartition des données entre les deux ensembles apprentissage/validation - le LOOCV donne le même résultat s'il est appliqué plusieurs fois sur la même base de données.

Par ailleurs, le LOOCV est coûteux en temps de calcul en général, en particulier si n est grand, puisque le calcul des estimateurs des paramètres du modèle est répété n fois. Cependant, ce problème de recalcul peut être évité dans le cas d'un modèle de régression (linéaire en $\mathbf{w}$) et une fonction de perte quadratique. En effet, on peut montrer que l'estimation précédente peut s'écrire sous la forme plus simple

$$\begin{aligned}\hat{\mathcal{E}} &:= \frac{1}{n} \sum_{i=1}^n \left(Y_i - f(\mathbf{X}_i, \hat{\mathbf{w}}^{(-i)}) \right)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - f(\mathbf{X}_i, \hat{\mathbf{w}})}{1 - h_i} \right)^2,\end{aligned}\tag{4}$$

où $\hat{\mathbf{w}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}$, est l'estimateur des moindres-carrés utilisant toutes les données, et h_i est le i^{eme} élément diagonal de la matrice $\mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$, pour tout $i = 1, \dots, n$.

Exercice 9

Comparer le modèle complet et le modèle optimal (selon le BIC), de la base **Carseats**, en terme d'erreur théorique estimée par la méthode LOOCV.

Méthode 3 : K-fold CV

Cette méthode est une alternative aux deux méthodes précédentes LOOCV et Apprentissage/Validation. Elle consiste à diviser de manière aléatoire le tableau des données en K groupes (folds) de même effectif (ou presque). Notons $G_1, \dots, G_K$ ces groupes. Le premier groupe est considéré comme un ensemble de validation, les $K - 1$ autres groupes sont utilisés pour ajuster le modèle. Une première approximation de l'erreur théorique est donnée par

$$e_1 = \frac{1}{\text{Card}(G_1)} \sum_{i \in G_1} \left(Y_i - f(\mathbf{X}_i, \hat{\mathbf{w}}^{(-1)}) \right)^2.$$

Cette procédure est répétée K fois, et à chaque fois, un groupe différent est traité comme ensemble de validation et les autres comme ensemble d'apprentissage; Ceci permet d'avoir K "estimations" de l'erreur théorique de prévision

$$e_k = \frac{1}{\text{Card}(G_k)} \sum_{i \in G_k} \left(Y_i - f(\mathbf{X}_i, \hat{\mathbf{w}}^{(-k)}) \right)^2, \quad \forall k = 1, \dots, K.$$

L'estimation de l'erreur théorique par la K-fold CV est calculée en moyennant les valeurs précédentes

$$\begin{aligned}\hat{\mathcal{E}} &:= \frac{1}{K} \sum_{k=1}^K e_k \\ &= \frac{1}{K} \sum_{k=1}^K \frac{1}{\text{Card}(G_k)} \sum_{i \in G_k} \left(Y_i - f(\mathbf{X}_i, \hat{\mathbf{w}}^{(-k)}) \right)^2.\end{aligned}\tag{5}$$

Exercice 10

Comparer le modèle complet et le modèle optimal (selon le BIC), de la base **Carseats**, en terme d'erreur théorique estimée par la méthode K-fold CV.

Régression en grande dimension

Lorsque le nombre de variables explicatives p est grand, les estimateurs MC des paramètres du modèle RLM

$$Y = w_0 + w_1 X_1 + \cdots + w_p X_p + \varepsilon$$

possèdent généralement une grande variance.

Idée des méthodes de régression pénalisée

Pour réduire la variance de l'estimateur MC (quitte à augmenter un "peu" le biais), on impose une contrainte sur les paramètres $(w_1, \dots, w_p)$ du type $\|(w_1, \dots, w_p)\|_? \leq b$, où $b > 0$ est un seuil donné, et $\|\cdot\|_?$ est une norme sur $\mathbb{R}^p$.

L'estimateur MC "pénalisé" sera alors défini par

$$\hat{\mathbf{w}}_{\text{pen}} := \arg \min_{\{\mathbf{w} \in \mathbb{R}^{1+p} \text{ t.q. } \|(w_1, \dots, w_p)\|_? \leq b\}} \frac{1}{n} \|\mathbf{Y} - \mathbb{X}\mathbf{w}\|^2.$$

Plusieurs questions se posent alors : quelle norme utiliser pour la contrainte? existence, unicité et calcul de la solution $\hat{\mathbf{w}}_{\text{pen}}$ du problème de minimisation précédent? le choix du seuil b ?

Régression ridge

La régression ridge consiste à minimiser le critère des moindres carrés pénalisé par la norme L_2 du vecteur $(w_1, \dots, w_p)$. L'estimateur ridge de $\mathbf{w} := (w_0, w_1, \dots, w_p)^\top$ est défini alors comme suit

$$\hat{\mathbf{w}}^R := \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p} \text{ t.q. } \sum_{j=1}^p w_j^2 \leq b} \sum_{i=1}^n \left(Y_i - w_0 - \sum_{j=1}^p w_j X_{i,j} \right)^2 \quad (6)$$

ou de façon équivalente

$$\hat{\mathbf{w}}^R := \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p}} \left\{ \sum_{i=1}^n \left(Y_i - w_0 - \sum_{j=1}^p w_j X_{i,j} \right)^2 + \lambda \sum_{j=1}^p w_j^2 \right\}. \quad (7)$$

Les deux définitions précédentes sont équivalentes dans le sens où pour tout $b > 0$ il existe un unique $\lambda > 0$ tels que les deux solutions coïncident.

Remarques

- (1) Le coefficient w_0 (de l'intercept) n'est pas pris en compte dans la pénalité;
- (2) L'estimateur ridge dépend évidemment du paramètre b (ou λ) : $\hat{\mathbf{w}}^R := \hat{\mathbf{w}}^R(b) := \hat{\mathbf{w}}^R(\lambda)$;
- (3) Les variables explicatives sont le plus souvent réduites pour éviter les problèmes d'échelle dans la pénalité;
- (4) Sous R, le calcul des estimateurs ridge peut se faire à l'aide de la fonction `glmnet()` du package `glmnet` en spécifiant l'argument `alpha = 0`.

Propriétés de l'estimateur ridge

- (1) Lorsque les variables explicatives sont centrées-réduites, l'estimateur ridge s'écrit

$$\hat{\mathbf{w}}^R = \hat{\mathbf{w}}^R(\lambda) = (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}_{1+p})^{-1} \mathbb{X}^\top \mathbf{Y}.$$

(2) On en déduit

$$\text{biais}(\hat{\mathbf{w}}^R) = -\lambda (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}_{1+p})^{-1} \mathbf{w}$$

et

$$\text{Var}(\hat{\mathbf{w}}^R) = \sigma^2 (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}_{1+p})^{-1} \mathbb{X}^\top \mathbb{X} (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}_{1+p})^{-1}.$$

(3) Si $\lambda = 0$, on retrouve le biais (null) et la variance de l'estimateur MC;

(4) Si λ augmente, le biais augmente et la variance diminue;

(5) Si λ diminue, le biais diminue et la variance augmente;

(6) Si $\lambda \approx 0$, alors $\hat{\mathbf{w}}^R \approx \hat{\mathbf{w}}$ l'estimateur MC. Si λ est grand, alors $\hat{\mathbf{w}}^R \approx \mathbf{0}$.

Choix du paramètre de pénalisation λ

Le choix de λ peut se faire, par validation croisée, de la manière suivante

- (i) Estimation de l'erreur théorique (par validation croisée) pour toutes les valeurs de λ ;
- (ii) Choix de λ pour lequel l'erreur estimée est minimale.

Cela peut se faire sous R à l'aide de la fonction `cv.glmnet()` du package `glmnet`.

Exercice 11

- (1) Appliquer la régression ridge pour expliquer/prédire la variable `Sales` en fonction des variables de la bd `Carseats`.
- (2) Comparer les trois modèles suivants, en terme d'erreur théorique estimée par K-fold CV :
 - (i) le modèle de régression ridge optimal;
 - (ii) le modèle RLM complet;
 - (iii) le modèle de RLM optimal au sens du critère BIC.

Régression Lasso

La régression lasso consiste à minimiser le critère des moindres carrés pénalisé par la norme L_1 du vecteur $(w_1, \dots, w_p)$.

L'estimateur lasso $\hat{\mathbf{w}}^L$ est défini par

$$\hat{\mathbf{w}}^L := \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p} \text{ t.q. } \sum_{j=1}^p |w_j| \leq b} \sum_{i=1}^n \left(Y_i - w_0 - \sum_{j=1}^p w_j X_{i,j} \right)^2 \quad (8)$$

ou de façon équivalente

$$\hat{\mathbf{w}}^L := \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p}} \left\{ \sum_{i=1}^n \left(Y_i - w_0 - \sum_{j=1}^p w_j X_{i,j} \right)^2 + \lambda \sum_{j=1}^p |w_j| \right\}. \quad (9)$$

Remarques

- (1) Comme pour la régression ridge, si λ augmente, alors le biais augmente et la variance diminue. Si λ diminue, le biais diminue et la variance augmente;
- (2) Comme pour la régression ridge, les variables explicatives sont le plus souvent réduites pour éviter les problèmes d'échelle dans la pénalité;

- (3) Le choix de λ peut se faire par validation croisée;
- (4) Contrairement au ridge, si λ augmente, alors le nombre de coefficients nuls augmente. Donc le lasso permet de faire de la sélection de variables (contrairement au ridge);
- (5) Sous R, on utilise la fonction `glmnet()` en spécifiant l'argument `alpha = 1`;
- (6) Le choix de λ minimisant l'erreur théorique estimée (par validation croisée), peut se faire à l'aide de la fonction `cv.glmnet()` en spécifiant l'argument `alpha = 1`.

Exercice 12

- (1) Appliquer la régression lasso pour expliquer/prédire la variable `Sales` en fonction des variables de la bd `Carseats`.
- (2) Comparer les quatre modèles suivants, en terme d'erreur théorique estimée par K-fold VC :
 - (i) le modèle de régression ridge optimal;
 - (ii) le modèle de régression lasso optimal;
 - (iii) le modèle RLM complet;
 - (iv) le modèle de RLM optimal au sens du critère BIC.

Régression group-lasso

Dans certains cas, les variables explicatives appartiennent à des groupes de variables prédéfinis; c'est le cas par exemple des variables indicatrices des modalités d'une même variable qualitative (on veut les sélectionner toutes ou les exclure toutes). En présence de d variables réparties en L groupes $\mathbf{X}_1, \dots, \mathbf{X}_L$ de cardinal $d_1, \dots, d_L$, on note $\mathbf{w}_\ell := (w_{\ell,1}, \dots, w_{\ell,d_\ell})^\top$, le vecteur des coefficients associé au groupe $\mathbf{X}_\ell$, $\ell = 1, \dots, L$. Les estimateurs group-lasso s'obtiennent en minimisant, en $(w_0, \mathbf{w}_1, \dots, \mathbf{w}_L)$, le critère suivant

$$(w_0, \mathbf{w}_1, \dots, \mathbf{w}_L) \mapsto \sum_{i=1}^n \left(Y_i - w_0 - \sum_{\ell=1}^L \mathbf{X}_{i,\ell} \mathbf{w}_\ell \right)^2 + \lambda \sum_{\ell=1}^L \sqrt{d_\ell} \|\mathbf{w}_\ell\|_2.$$

Puisque $\|\mathbf{w}_\ell\|_2 = 0$ ssi $w_{\ell,1} = \dots = w_{\ell,d_\ell} = 0$, la méthode group-lasso encourage la mise à zéro des coefficients d'un même groupe.

Pour calculer les estimateurs group-lasso, on peut utiliser la fonction `gglasso()` du package `gglasso`.

Exercice 13

- (1) Construire le modèle de régression group-lasso en considérant que les variables indicatrices des modalités de la variable `ShelveLoc` font partie d'un même groupe.
- (2) Comparer le modèle group-lasso optimal obtenu avec tous les modèles de l'exercice 11 en terme de l'erreur théorique estimée par K-fold CV.