

UNIVERSITÉ DE REIMS CHAMPAGNE-ARDENNE

MASTER 1 — INTELLIGENCE ARTIFICIELLE

Projet 805 — Gestion de projet

Cartographie des zones blanches 4G sur les grands axes routiers français

*Croisement géospatial des données ARCEP
et OpenStreetMap*

Thomas CHEVALIER

Ethan COCU

Sous l'encadrement de

Hacène FOUCHAL

Année universitaire 2025–2026

Table des matières

1	Gestion de projet	2
1.1	Présentation de l'équipe et des rôles	2
1.2	Objectifs SMART	2
1.3	Planification et jalons	2
1.4	Suivi et communication	3
1.5	Difficultés de gestion rencontrées	3
2	Introduction	3
2.1	Contexte	3
2.2	Objectifs	4
2.3	Hypothèses de travail	4
3	Données sources	4
3.1	Cartes de couverture ARCEP	4
3.2	Réseau routier	5
3.3	Contours administratifs IGN	5
4	Méthodologie	5
4.1	Vue d'ensemble du pipeline	5
4.2	Étape 1 — Fusion des couvertures opérateurs	6
4.3	Étape 2 — Croisement tuilé et parallèle avec le réseau routier	7
4.4	Étape 3 — Analyse territoriale et placement d'antennes	8
5	Résultats	9
5.1	Statistiques globales	9
5.2	Cartographie	10
5.3	Analyse spatiale	12
5.4	Ventilation par territoire	12
5.5	Préconisation : implantation de nouvelles antennes	14
6	Choix techniques et difficultés	15
6.1	De l'overlay global à l'overlay tuilé	15
6.2	Difficultés rencontrées	16
7	Conclusion et perspectives	17
7.1	Synthèse	17
7.2	Limites	18
7.3	Perspectives	18
	Annexe : reproduction des résultats	18

1 Gestion de projet

1.1 Présentation de l'équipe et des rôles

Le projet a été réalisé en binôme dans le cadre de l'UE INFO0806, sous l'encadrement du professeur Hacène Fouchal. La répartition des responsabilités suit une matrice RACI simplifiée :

TABLE 1 – Matrice RACI du projet.

Tâche	T. Chevalier	E. Cocu	H. Fouchal
Analyse des besoins et rédaction CDC	R	R	A
Collecte et préparation des données	R	C	I
Développement pipeline étape 1	R	R	I
Développement pipeline étape 2	C	R	I
Optimisation (overlay tuilé parallèle)	R	R	I
Analyse territoriale et set cover	R	C	I
Analyse des résultats	R	R	A
Rédaction du rapport	R	C	A

Concrètement, la répartition du travail a été la suivante : **Thomas Chevalier** s'est chargé de la collecte des données, de l'étape 1 (fusion des couvertures) et de la rédaction du rapport ; **Ethan Cocu** a développé l'étape 2 (routes couvertes) et l'étape 3 (placement des antennes). L'analyse des besoins et les décisions structurantes ont été menées conjointement.

1.2 Objectifs SMART

Les objectifs du projet ont été formulés selon la méthode SMART :

- **Spécifique** : cartographier les zones blanches 4G sur le réseau des grands axes routiers de la France métropolitaine, à partir des données open data ARCEP.
- **Mesurable** : calculer un taux de couverture par longueur cumulée de route, sur l'ensemble des autoroutes et axes principaux identifiés dans OpenStreetMap.
- **Acceptable** : les données ARCEP sont librement accessibles et les outils Python (GeoPandas, Shapely) sont maîtrisés par l'équipe.
- **Réaliste** : le projet est dimensionné pour un binôme étudiant sur un semestre, avec un encadrant disponible pour validation.
- **Temporellement défini** : livraison du rapport et du pipeline finalisé pour la fin du mois de mai 2026.

1.3 Planification et jalons

Le projet s'est déroulé sur le second semestre de l'année universitaire 2025–2026. Les séances de travail encadrées (INFO0806-TP) ont servi de jalons réguliers pour faire le point sur l'avancement. Le tableau suivant présente le rétro-planning du projet :

TABLE 2 – Rétro-planning du projet.

Phase	Période	Livrable / Jalon	Statut
Analyse des besoins	Janvier 2026	Définition du périmètre	✓
Cahier des charges	Février 2026	Mini CDC envoyé (18/02/2026)	✓
Collecte des données	Fév. – Mars 2026	Données ARCEP T3 2025 récupérées	✓
Développement étape 1	Mars 2026	Pipeline fusion opérateurs	✓
Développement étape 2	Mars – Avril 2026	Pipeline croisement routier	✓
Optimisation	Avril 2026	Overlay tuilé multithreadé	✓
Analyse territoriale	Avril – Mai 2026	Stats dépt/région + set cover	✓
Analyse et rédaction	Mai 2026	Rapport final	✓
Livraison	Mai 2026	Dépôt rapport + code	✓

1.4 Suivi et communication

Le suivi du projet a reposé sur les séances INFO0806-TP, qui constituaient des points d’avancement réguliers avec l’encadrant. En complément, des échanges par mail ont permis de valider les orientations principales, notamment la remise d’un mini cahier des charges préliminaire le 18 février 2026 présentant l’objet du projet, les données envisagées et les premiers objectifs techniques.

1.5 Difficultés de gestion rencontrées

La principale difficulté de pilotage a été la gestion de l’incertitude sur les temps de traitement : la première version du pipeline géospatial a révélé des durées d’exécution bien supérieures aux estimations initiales (plusieurs semaines pour les overlays, contre quelques heures anticipées). Cela a conduit à revoir le planning en cours de projet, dans une logique Agile de réajustement continu inspirée du cycle PDCA : plutôt que de se contenter d’un résultat lent mais correct, nous avons consacré une itération supplémentaire à la refonte de l’étape de croisement en un *overlay* tuilé et multithreadé (cf. section 6). Cet investissement a non seulement débloqué la livraison, mais aussi libéré le temps nécessaire à l’ajout d’une analyse territoriale et d’une préconisation d’implantation d’antennes, fonctionnalités non prévues au cahier des charges initial.

2 Introduction

2.1 Contexte

La couverture mobile constitue aujourd’hui un service essentiel, comparable aux réseaux d’énergie ou de transport. Sur le réseau routier, elle conditionne le fonctionnement des services d’appel d’urgence (eCall), de navigation en temps réel, de paiement aux péages dématérialisés, mais aussi plus largement de tous les usages connectés des automobilistes. Les zones non couvertes — appelées *zones blanches* — représentent donc un enjeu à la fois de sécurité, d’aménagement du territoire et d’équité d’accès aux services numériques.

L’Autorité de régulation des communications électroniques, des postes et de la distribution de la presse (ARCEP) publie trimestriellement les cartes de couverture théorique des quatre opérateurs de réseau mobile (ORM) déployant en France métropolitaine. Ces données, mises à disposition en *open data* au format GeoPackage, permettent de réaliser des analyses croisées avec d’autres jeux géographiques.

2.2 Objectifs

Le projet poursuit quatre objectifs :

1. construire une couche unifiée de couverture 4G nationale par union des quatre opérateurs ;
2. croiser cette couche avec le réseau des grands axes routiers (autoroutes et axes principaux) afin d’identifier les segments couverts et non couverts ;
3. quantifier et cartographier les zones blanches résiduelles sur le réseau routier principal, puis les ventiler par département et par région ;
4. proposer une implantation optimisée de nouvelles antennes permettant de résorber l’ensemble des zones blanches identifiées.

2.3 Hypothèses de travail

Nous considérons qu’un segment de route est *couvert* dès lors qu’il intersecte la zone de couverture théorique d’*au moins un* des quatre opérateurs. Cette définition est volontairement permissive : elle représente la couverture maximale accessible à un usager indifférent à l’opérateur (par exemple via l’itinérance d’urgence pour les appels d’urgence). Les données ARCEP étant des couvertures *théoriques* (simulations de propagation), elles ne tiennent pas compte des dégradations réelles liées au trafic, aux conditions météorologiques ou aux obstacles temporaires.

3 Données sources

3.1 Cartes de couverture ARCEP

Les couvertures théoriques 4G ont été récupérées sur le portail *data.arcep.fr*¹. Nous avons utilisé les fichiers du troisième trimestre 2025, plus récent jeu disponible au démarrage du projet. Chaque opérateur publie un GeoPackage contenant l’ensemble des polygones de couverture sur la métropole, projetés en Lambert-93 (EPSG :2154).

TABLE 3 – Fichiers de couverture ARCEP utilisés (T3 2025).

Opérateur	Fichier source	Format
Bouygues Telecom	2025_T3_couv_Metropole_BOUY_4G_data.gpkg	GeoPackage
Free Mobile	2025_T3_couv_Metropole_FREE_4G_data.gpkg	GeoPackage
Orange France	2025_T3_couv_Metropole_OF_4G_data.gpkg	GeoPackage
SFR	2025_T3_couv_Metropole_SFR0_4G_data.gpkg	GeoPackage

1. https://data.arcep.fr/mobile/couvertures_theoriques/last/Metropole/00_Metropole/index.html

3.2 Réseau routier

Le réseau routier a été constitué à partir d’une extraction OpenStreetMap (OSM) de la France, filtrée sur les classes routières *autoroutes* et *axes principaux* (`highway=motorway` et `highway=trunk` ainsi que leurs liens d’accès). Le filtrage permet de se concentrer sur le réseau structurant, où l’enjeu de couverture est le plus critique. Le résultat est sauvegardé dans le fichier `grand_axe_2154.gpkg`, déjà reprojeté en Lambert-93 pour rester cohérent avec les couches ARCEP. Le jeu compte **382 786** segments de route après filtrage, pour une longueur cumulée de **106 563 km**.

3.3 Contours administratifs IGN

Pour ventiler les résultats par territoire, nous utilisons les limites administratives *Admin Express* de l’IGN (départements et régions), récupérées dynamiquement via le service WFS de la Géoplateforme² au format GeoJSON, déjà projeté en Lambert-93 (EPSG :2154). Les contours téléchargés sont mis en cache localement (`admin_france.gpkg`) afin d’éviter de réinterroger le service à chaque exécution. Les départements et régions d’outre-mer sont écartés pour rester cohérents avec le périmètre métropolitain des autres couches, ce qui laisse **96 départements** répartis en **13 régions**.

4 Méthodologie

4.1 Vue d’ensemble du pipeline

Le traitement se décompose en trois étapes successives, chacune implémentée par un script Python autonome (figure 1).

2. <https://data.geopf.fr/wfs/ows>




FIGURE 1 – Architecture du pipeline en trois étapes.

4.2 Étape 1 — Fusion des couvertures opérateurs

La fusion des quatre couches de couverture pose un défi de volumétrie : chaque GeoPackage opérateur contient plusieurs centaines de milliers de polygones, et une union naïve sur l'ensemble fait exploser la consommation mémoire. Notre script adopte une stratégie de fusion incrémentale :

1. **Lecture allégée** : seule la colonne géométrie est conservée, les attributs métier (qualité, technologie, etc.) sont ignorés.
2. **Réparation des géométries** : les polygones invalides (auto-intersections fréquentes après simplification cartographique amont) sont corrigés via `buffer(0)`.
3. **Simplification** : une tolérance de Douglas-Peucker de 50 m est appliquée. Ce compromis préserve la cohérence visuelle à l'échelle nationale tout en réduisant la complexité des polygones d'un facteur important.
4. **Dissolve par opérateur** : chaque opérateur est réduit à un unique `MultiPolygon` via `union_all()`, puis écrit sur disque.
5. **Union finale** : les quatre `MultiPolygon` dissous sont relus et fusionnés en une seule géométrie représentant la couverture cumulée.

Un système de *checkpoints* permet de reprendre le calcul après interruption : si le fichier dissous d'un opérateur existe déjà sur disque, l'étape est sautée. Cette précaution s'est révélée précieuse au vu des temps de traitement (cf. section 6).

Pour chaque opérateur, la séquence appliquée est : lecture de la géométrie seule, réparation via `buffer(0)`, simplification à 50 m, puis dissolution en un unique `MultiPolygon` sauvegardé sur disque comme checkpoint.

4.3 Étape 2 — Croisement tuilé et parallèle avec le réseau routier

La seconde étape calcule, pour chaque segment de route, la portion couverte et la portion non couverte par la couverture unifiée. C’est l’étape la plus coûteuse en calcul ; sa conception a été entièrement repensée par rapport à la première version (cf. section 6). Quatre points méritent d’être détaillés.

Gestion défensive des CRS. *En clair* : le fichier de couverture annonçait un mauvais « système de coordonnées » (la manière dont les positions sont exprimées sur la carte), ce qui aurait fait disparaître les données si on l’avait cru sur parole. Nous le détectons et le corrigeons automatiquement.

Plus précisément, le GeoPackage de couverture fusionnée présente une anomalie connue : sa métadonnée CRS peut être absente ou renseignée comme `Undefined geographic SRS` (système géographique générique non défini), alors même que les coordonnées sont en mètres Lambert-93. Une reprojection naïve produirait une géométrie vide. Nous testons donc l’enveloppe des coordonnées via la fonction `looks_like_lonlat()` : si les bornes restent dans l’intervalle lon/lat $[-180; 180] \times [-90; 90]$, la couche est considérée géographique ; sinon elle est reconnue comme projetée et le CRS est forcé à EPSG :2154 par *override* (sans reprojection effective). Pour notre jeu, les coordonnées observées (de l’ordre de [99 041; 1 242 423] en X et [6 046 546; 7 110 497] en Y) déclenchent l’override Lambert-93.

Réparation vectorisée et parallèle des géométries. Les exports ARCEP contiennent des polygones « cassés » (contours qui se recoupent) qui font planter les calculs géométriques. La couverture est donc d’abord réparée par une fonction appliquée à tout un tableau de géométries d’un coup (et non polygone par polygone) : `shapely.buffer(arr, 0)` corrige la majorité des cas, avec repli sur `shapely.make_valid()` pour les géométries restant invalides ou vides. Surtout, cette réparation est répartie en blocs traités *en parallèle* sur tous les cœurs du processeur en même temps — ce que Python ne permet normalement pas, mais que Shapely 2 autorise ici car il « libère le verrou » (GIL) pendant ses calculs internes.

Tuilage spatial. Le goulot d’étranglement de la première version était la construction d’un `MultiPolygon global` de couverture, puis son intersection avec l’ensemble des routes. Nous l’évitons par un découpage en grille régulière 8×8 (64 tuiles) couvrant l’emprise du réseau routier. Un index spatial `STRtree` (comparable à l’index d’un livre : il retrouve instantanément quels polygones de couverture se situent près d’une route donnée), construit sur les polygones de couverture et lu en lecture seule, permet, pour chaque tuile, de ne sélectionner que les routes et les polygones qui l’intersectent. L’union de couverture n’est alors calculée que *localement*, sur le sous-ensemble pertinent : elle comporte infiniment moins de sommets que l’union globale, et une simplification de Douglas-Peucker à 200 m y est appliquée pour accélérer encore les opérations.

En clair, plutôt que de comparer chaque route à *toute* la couverture 4G de la France en une seule fois — opération gigantesque —, on découpe le pays en 64 cases et, dans chacune, on ne confronte que les routes et les couvertures qui s’y trouvent. C’est le même principe que résoudre un grand puzzle en le séparant d’abord en petites zones.

Overlay vectorisé par tuile. Pour chaque tuile, les routes sont d’abord découpées (`intersection` avec la boîte de la tuile), puis deux opérations vectorisées sont calculées contre l’union locale :

- `shapely.intersection(routes, couverture_locale)` produit les portions de routes *couvertes* ;

- `shapely.difference(routes, couverture_locale)` produit les portions *non couvertes*. Seuls les résultats linéaires non vides (`LineString`, `MultiLineString`) sont conservés. L’attribut `covered` (1/0) et la longueur `len_m` (en mètres) sont ajoutés à chaque portion. Les 64 tuiles étant indépendantes, elles sont dispatchées sur le pool de threads ; les résultats partiels sont enfin concaténés en deux couches de sortie (`routes_couvertes.gpkg` et `routes_non_couvertes.gpkg`), ce qui permet le calcul direct du taux de couverture global.

4.4 Étape 3 — Analyse territoriale et placement d’antennes

La troisième étape, implémentée dans `analyse_zones_blanches.py`, exploite les couches produites en étape 2 pour en tirer une lecture territoriale et opérationnelle.

Affectation administrative. Pour savoir dans quel département tombe chaque tronçon de route, on le résume à son point central (son *centroïde*), puis on regarde dans quel contour départemental ce point se trouve. Les points tombant juste à côté d’une frontière (à cause des simplifications) sont rattachés au département le plus proche, dans la limite de 5 km ; les très rares cas restants sont marqués `INCONNU`. La région se déduit ensuite du code du département.

Statistiques par territoire. Pour chaque département et chaque région, le script agrège le nombre de segments non couverts, la longueur cumulée non couverte (km), les longueurs moyenne et médiane des segments non couverts (m), la longueur totale du réseau (couvert + non couvert) et le pourcentage non couvert. Les résultats sont exportés en CSV (`stats_departements.csv`, `stats_regions.csv`).

Placement d’antennes par *greedy Set Cover*. Combien d’antennes faudrait-il, et où, pour combler tous les trous de couverture ? La question correspond à un problème classique d’informatique, la *couverture d’ensemble* : on cherche le plus petit nombre d’antennes couvrant l’ensemble des tronçons non couverts. On suppose qu’une antenne « éclaire » tout ce qui se trouve à moins de **1 500 m** d’elle. Le problème exact étant très long à résoudre, on emploie une méthode *gloutonne*, simple et efficace : à chaque étape, on place une antenne sur le tronçon non couvert le plus long encore en attente, puis on marque comme desservis tous les tronçons à portée de cette antenne ; on recommence jusqu’à ce que tout soit couvert. Commencer par les tronçons les plus longs permet de traiter en priorité les cas les plus pénalisants. Les positions obtenues sont enregistrées dans `nouvelles_antennes.gpkg`, et leur décompte par territoire dans `rapport_antennes.csv`.

5 Résultats

5.1 Statistiques globales

Le traitement final produit les chiffres synthétisés dans la table 4.

TABLE 4 – Statistiques globales du croisement routes $\times$ couverture 4G.

Indicateur	Valeur
Nombre total de segments de route (en entrée)	382 786
Portions de route couvertes (en sortie)	381 446
Portions de route non couvertes (en sortie)	4 456
Longueur totale du réseau étudié	106 563,4 km
Longueur couverte	105 771,7 km
Longueur non couverte	791,7 km
Taux de couverture global	99,26 %

Les portions de route en sortie ne coïncident pas exactement avec les segments d'entrée : le tuilage et la découpe couvert/non couvert fractionnent certains segments, si bien que le total des portions diffère légèrement du nombre de segments initiaux. Le réseau structurant français est couvert à plus de 99 % par au moins un opérateur, ce qui reflète l'effort de déploiement opéré dans le cadre du *New Deal Mobile* de 2018 et les obligations de couverture des axes routiers prioritaires intégrées aux licences 4G. Les quelque **792 km** restants se concentrent dans des configurations géographiques spécifiques détaillées ci-après.

5.2 Cartographie




FIGURE 2 – Routes couvertes (rose) et non couvertes (jaune) sur les grands axes français. À cette échelle, le rose domine quasi totalement, conformément au taux de couverture de 99,26 %. Les segments jaunes apparaissent principalement sur les littoraux, en zones de montagne et dans les départements ruraux.




FIGURE 3 – Routes couvertes uniquement. La densité du réseau structurant ressort clairement, avec les étoiles autour des grandes métropoles (Paris, Lyon, Bordeaux, Toulouse) et le maillage autoroutier reliant les pôles régionaux.




FIGURE 4 – Routes non couvertes uniquement.

5.3 Analyse spatiale

La cartographie isolée des zones blanches (figure 4) révèle plusieurs motifs récurrents :

- **Reliefs** : les segments traversant le Massif central, les Pyrénées, les Alpes et les contreforts du Jura présentent une concentration de zones blanches, en cohérence avec les contraintes topographiques bien documentées.
- **Zones rurales à faible densité** : des points épars en Champagne-Ardenne, en Bourgogne et dans le Centre-Val de Loire, correspondant probablement à des sections courtes entre cellules.

L'analyse confirme que les obligations *New Deal* sur les axes prioritaires sont globalement tenues, le résidu se concentrant sur des configurations physiquement contraintes ou économiquement marginales.

5.4 Ventilation par territoire

L'affectation administrative des zones blanches (étape 3) permet de hiérarchiser les territoires. La table 5 présente les 13 régions métropolitaines, triées par longueur de routes non couvertes. La figure 5 en donne une lecture graphique combinée avec le nombre d'antennes préconisées

(cf. section suivante).

TABLE 5 – Zones blanches 4G par région (tri par longueur non couverte décroissante).

Région	Seg. NC	Long. NC (km)	% non couv.	Antennes
Grand Est	1 012	249,5	2,10	234
Nouvelle-Aquitaine	516	113,4	0,88	202
Auvergne-Rhône-Alpes	738	105,3	0,81	160
Occitanie	597	99,5	0,90	206
Hauts-de-France	308	54,1	0,59	64
Provence-Alpes-Côte d’Azur	407	51,6	0,86	89
Bourgogne-Franche-Comté	289	39,7	0,51	137
Centre-Val de Loire	158	32,3	0,46	104
Bretagne	175	20,0	0,32	67
Normandie	124	19,1	0,27	65
Corse	28	2,7	0,42	11
Pays de la Loire	42	2,3	0,03	29
Île-de-France	62	2,2	0,04	29
France métropolitaine	4 456	791,7	0,74	1 397




FIGURE 5 – Longueur de routes non couvertes par région, annotée du nombre d’antennes nécessaires et du taux de non-couverture. Le Grand Est concentre à lui seul près d’un tiers des zones blanches du réseau structurant.

À l’échelle départementale, la dispersion est forte (table 6). La Lozère présente le *taux* de non-

couverture le plus élevé (10,06 %), conséquence d’un réseau structurant peu dense traversant un relief marqué. En *volume*, le Haut-Rhin (86,9 km), les Pyrénées-Atlantiques (78,1 km) et la Moselle (67,2 km) dominent, traduisant des linéaires de montagne (Vosges, Pyrénées) ou frontaliers.

TABLE 6 – Dix départements au plus fort taux de non-couverture.

Dépt.	Région	Long. NC (km)	% non couv.	Seg. NC
Lozère (48)	Occitanie	37,5	10,06	132
Haut-Rhin (68)	Grand Est	86,9	8,92	233
Pyrénées-Atlantiques (64)	Nouvelle-Aquitaine	78,1	6,82	226
Ardennes (08)	Grand Est	47,8	5,56	120
Territoire de Belfort (90)	Bourgogne-Franche-Comté	8,5	4,72	43
Moselle (57)	Grand Est	67,2	3,80	317
Savoie (73)	Auvergne-Rhône-Alpes	34,7	3,17	47
Ain (01)	Auvergne-Rhône-Alpes	33,7	2,46	410
Pyrénées-Orientales (66)	Occitanie	20,4	2,23	119
Alpes-de-Haute-Provence (04)	Provence-Alpes-Côte d’Azur	13,8	2,06	32

5.5 Préconisation : implantation de nouvelles antennes

L’algorithme glouton de couverture d’ensemble (étape 3) estime qu’il faudrait **1 397 nouvelles antennes** (rayon 1 500 m) pour résorber l’intégralité des 4 456 portions non couvertes. La figure 6 en cartographie l’implantation, qui épouse logiquement la géographie des zones blanches : axes de montagne, littoraux et secteurs ruraux peu denses.

Le nombre d’antennes par territoire ne suit pas strictement la longueur non couverte, mais bien la *fragmentation* des zones blanches. Ainsi le Grand Est, où les zones blanches sont à la fois nombreuses et étendues, requiert le plus d’antennes (234). À l’inverse, l’Aveyron arrive en tête des départements (45 antennes) pour seulement 10 km non couverts : ses zones blanches sont éparpillées en une multitude de courts tronçons, chacun exigeant sa propre antenne, alors qu’un département comme le Haut-Rhin résorbe un linéaire plus long avec proportionnellement moins d’antennes grâce à des segments plus contigus. Cette préconisation constitue une borne haute : elle ignore la portée réelle variable des antennes selon le relief et la possibilité de mutualiser une implantation avec les pylônes existants.




FIGURE 6 – Implantation des 1 397 nouvelles antennes (points rouges) proposées par le *greedy Set Cover*, sur fond de réseau couvert (gris) et de zones blanches (orange). La forme du territoire est dessinée par le seul réseau routier structurant.

6 Choix techniques et difficultés

6.1 De l’overlay global à l’overlay tuilé

La première version de l’étape 2 reposait sur la chaîne classique de GeoPandas : construction d’un `MultiPolygon` global de couverture (*dissolve*), puis `gpd.overlay` en *intersection* et en *difference* contre l’ensemble des routes. Lancée en arrière-plan via `nohup`, elle a révélé des durées prohibitives (table 7).

TABLE 7 – Temps d’exécution observés sur la *première* version de l’étape 2 (overlay global, abandonnée).

Phase	Durée
Lecture des routes	~2 min
Lecture de la couverture	~2,5 min
Réparation des géométries	~33 min
Dissolve de la couverture	~5 h 44 min
Simplification de l’union	~5 min
Overlay <i>intersection</i> (routes couvertes)	~10 jours
Overlay <i>difference</i> (routes non couvertes)	~8 jours
Écriture des sorties	~1,5 min
Total	~20 jours

Les deux overlays constituaient de loin le goulot d’étranglement. Cela tient à la nature de l’opération : pour chaque segment de route, GEOS doit calculer une intersection géométrique exacte avec un `MultiPolygon` extrêmement complexe (la couverture fusionnée, faite de plusieurs millions de sommets). Même avec un index spatial, le coût par segment reste élevé, et l’opération s’exécute sur un seul cœur.

Refonte tuilée et multithreadée. La version finale de `routes_couvertes.py` (décrite plus haut, méthodologie étape 2) lève ce verrou par trois leviers complémentaires :

- **Suppression de l’union globale.** Aucune couverture globale n’est plus construite : chaque tuile ne réalise qu’une *union locale* des polygones qui la touchent, comportant infiniment moins de sommets. Le coût d’intersection par segment s’effondre.
- **Tuilage spatial.** La grille 8×8 borne le travail à des sous-problèmes indépendants et géographiquement compacts, où l’index `STRtree` élague l’essentiel des candidats.
- **Parallélisme réel.** Shapely 2 relâchant le GIL pendant les appels GEOS, les 64 tuiles (comme la réparation des géométries) sont traitées en parallèle sur tous les cœurs via un `ThreadPoolExecutor`, sans la surcharge mémoire d’un multiprocessing.

Ces optimisations — précisément les pistes que la première version reléguait aux perspectives — ramènent le croisement de *plusieurs semaines* à une *exécution unique*, soit un gain de un à deux ordres de grandeur. La durée exacte dépend du nombre de cœurs de la machine et n’a pas fait l’objet d’un *benchmark* formel sur la version finale, mais le calcul, autrefois étalé sur près de trois semaines, tient désormais en une seule session de traitement.

6.2 Difficultés rencontrées

Volumétrie mémoire en étape 1. La première version du script de fusion chargeait les quatre opérateurs en mémoire avant l’union finale, ce qui dépassait les capacités de notre machine. La version finale dissout chaque opérateur séparément et n’agrège que les quatre géométries simplifiées en mémoire au moment de l’union finale.

Géométries invalides. Les exports ARCEP contiennent un nombre non négligeable de polygones invalides (auto-intersections, anneaux dégénérés). Sans correction, Shapely lève des exceptions `TopologyException` en cascade. Notre stratégie — `shapely.buffer(arr, 0)` vectorisé, repli sur `make_valid()` pour les géométries restant invalides ou vides, puis filtrage des résultats non polygonaux — a permis de tout traiter sans perte significative, et son application par blocs parallèles a rendu cette passe négligeable dans le temps total.

CRS mal taggé. Comme évoqué en méthodologie, le GeoPackage de couverture fusionnée pouvait être lu avec un CRS générique `Undefined geographic SRS` (voire absent), malgré des coordonnées clairement projetées. L’heuristique `looks_like_lonlat()` corrige ce cas par un `override EPSG :2154` sans reprojection.

Partage thread-safe de l’index spatial. Le passage au multithreading impose de ne partager entre threads que des structures en lecture seule. L’index `STRtree` de la couverture est donc construit une seule fois dans le thread principal, puis interrogé (`query, dwithin`) sans modification par les workers ; les écritures se limitent à des sous-tableaux `numpy` disjoints, évitant tout verrou.

Choix de la tolérance de simplification. La première version simplifiait l’*union globale* à 50 m. La version tuilée simplifie au contraire chaque *union locale* à 200 m : appliquée à l’échelle d’une tuile et uniquement pour accélérer l’overlay (et non pour le rendu cartographique), une tolérance plus grossière reste sans effet visible sur les longueurs calculées tout en réduisant nettement le nombre de sommets manipulés par GEOS.

7 Conclusion et perspectives

7.1 Synthèse

Le projet a abouti à une cartographie nationale des zones blanches 4G sur le réseau des grands axes, avec un taux de couverture cumulée des quatre opérateurs de **99,26 %**, soit environ **792 km** de routes principales non couvertes. Le pipeline développé est entièrement reproductible : il prend en entrée les GeoPackages ARCEP bruts et une extraction OSM, et produit en sortie deux couches géographiques (routes couvertes, routes non couvertes), des statistiques par département et par région, ainsi qu’une préconisation d’implantation de **1 397** nouvelles antennes pour résorber l’ensemble des zones blanches.

Sur le plan technique, le projet a mis en évidence l’importance des stratégies d’optimisation lorsqu’on travaille sur de très grands jeux de données géographiques. La refonte de l’étape de croisement — passage d’un *overlay* global de plusieurs semaines à un *overlay* tuilé et multithreadé s’exécutant en une seule session — illustre à elle seule le gain qu’apportent le tuilage spatial, l’union locale, l’indexation `STRtree` et le parallélisme réel permis par la libération du GIL dans GEOS, en complément de la gestion défensive des métadonnées CRS et des opérations vectorisées.

7.2 Limites

- **Couvertures théoriques** : les données ARCEP sont issues de simulations de propagation, et non de mesures terrain. La couverture réelle peut différer.
- **4G uniquement** : la 5G et la 3G n'ont pas été intégrées. Un usager dont le terminal bascule en 3G en zone 4G blanche peut percevoir la couverture comme satisfaisante.
- **Définition permissive** : un segment est considéré couvert dès qu'un seul des quatre opérateurs le couvre, ce qui surestime la couverture du point de vue d'un usager fidèle à un seul opérateur.
- **Simplification 200 m** : la simplification locale appliquée par tuile accélère l'overlay mais rend les contours couvert/non couvert non exacts au mètre près à grande échelle (zoom local).
- **Modèle d'antennes simplifié** : le *Set Cover* suppose un rayon de couverture uniforme de 1 500 m et ignore le relief, la portée réelle variable des antennes et les pylônes existants mutualisables. Le chiffre de 1 397 antennes constitue donc une borne haute indicative, non un plan de déploiement.

7.3 Perspectives

Le tuilage spatial parallèle, envisagé comme perspective dans une version antérieure de ce rapport, a été implémenté et constitue désormais le cœur de l'étape 2. Plusieurs autres extensions restent envisageables :

- **Analyse par opérateur** : conserver les quatre couvertures séparées pour produire un score de couverture par segment (de 0 à 4 opérateurs).
- **Raffinement du placement d'antennes** : remplacer le rayon fixe par une portée dépendant du relief, intégrer les pylônes existants comme sites candidats prioritaires et pondérer par un coût d'implantation, pour passer d'une borne haute à un véritable scénario de déploiement.
- **Croisement démographique** : intersecter les zones blanches avec la grille de population INSEE pour évaluer combien d'habitants traversent quotidiennement une zone blanche.
- **Comparaison temporelle** : reproduire l'analyse sur plusieurs trimestres successifs pour mesurer l'évolution de la couverture.
- **Extension à la 5G** : intégrer les couches 5G ARCEP, désormais disponibles pour les quatre opérateurs.

Annexe : reproduction des résultats

Le pipeline est organisé en trois scripts Python autonomes :

- `merge_coverage_optimized.py` (étape 1) : prend en entrée les quatre GeoPackages opérateurs ARCEP, applique réparation, simplification (50 m) et *dissolve* par opérateur avec checkpoints intermédiaires, puis produit la couverture fusionnée `couverture_4G_totale.gpkg` (réutilisée comme `coverage_4G_france.gpkg` en entrée de l'étape 2). Durée estimée : environ 6 heures.

- `routes_couvertes.py` (étape 2) : prend en entrée la couverture fusionnée et l'extraction OSM des grands axes (`grand_axe_2154.gpkg`), et produit `routes_couvertes.gpkg` et `routes_non_couvertes.gpkg` via l'overlay tuilé multithreadé. Durée : une seule session de traitement (contre ~ 20 jours pour la version initiale non tuilée). Paramètres principaux : grille 8×8 , tolérance de simplification locale 200 m, nombre de threads égal au nombre de cœurs.
- `analyse_zones_blanches.py` (étape 3) : prend en entrée les deux couches précédentes, télécharge les contours administratifs IGN (cache `admin_france.gpkg`), et produit `stats_departements.csv`, `stats_regions.csv`, `rapport_antennes.csv` et `nouvelles_antennes.gpkg`. Paramètre principal : rayon d'antenne 1500 m. Un accès réseau à la Géoplateforme est requis au premier lancement (ou un `admin_france.gpkg` fourni manuellement).

Les prérequis sont Python 3.9+ avec les bibliothèques `geopandas`, `shapely` (version ≥ 2.0), `pyogrio`, `numpy` et `pandas`.