

Introduction à l'IA

Mars 2024

Amor KEZIOU
Laboratoire de Mathématiques de Reims
amor.keziou@univ-reims.fr

Plan du cours

- Introduction à l'apprentissage statistique : Exemples et motivation ;
- Le problème de régression.

CM 1 : Apprentissage statistique et Data mining : Exemples et motivations

À quoi sert l'apprentissage statistique ?

- Reconnaissance faciale (de manière automatique)
 - La base de données d'apprentissage : est un ensemble d'images et labels (noms)
 - Critère d'évaluation : le pourcentage des reconnaissances correctes des personnes sur les nouvelles images
- Reconnaissance des plantes
 - La base de données d'apprentissage : est un ensemble d'images de feuilles des plantes avec les noms
 - Critère d'évaluation : le pourcentage des reconnaissances correctes des plantes sur les nouvelles images de feuilles

- Reconnaissance de la parole, des caractères manuscrits, ...
- Diagnostic médical
- Détection de fraude
- Marketing, recommander des produits que le client aimerait, ...
- Prédiction du marché (prix de l'immobilier, ...)
- Sécurité informatique
- ...

Les étapes du processus d'apprentissage statistique

- Définir un ensemble de possibilités susceptibles d'expliquer le phénomène (préparation des données) ;
- Ajuster un modèle sur la base des exemples disponibles (estimation) ;
- Repenser l'ensemble des possibilités (sélection de modèles).

Les différents types d'apprentissage statistique

- **Apprentissage supervisé** : on dispose des valeurs des variables explicatives et de la variable cible sur chacun des exemples, et le but est de construire un modèle (à partir de la base d'apprentissage) pour prédire la variable cible ;
- **Apprentissage non supervisé** : on dispose seulement des valeurs des variables explicatives, et le but est d'essayer de découvrir des structures dans les données (clustering, segmentation, ...) ;
- **Apprentissage semi-supervisé** : le nombre d'exemples - pour lesquels on dispose à la fois des valeurs des variables explicatives et des valeurs de la variable cible - est limité, et on essaye d'améliorer la qualité de prédiction par l'ajout d'exemples avec seulement les valeurs des variables explicatives (données sans labels).

Le problème de régression

- On cherche à expliquer/prédire une variable statistique Y à l'aide de p variables statistiques numériques $X_1, \dots, X_p$;
- Notons $\mathcal{X} \subset \mathbb{R}^p$ le domaine du vecteur $\mathbf{X} := (X_1, \dots, X_p)$, et $\mathcal{Y}$ le domaine de Y ;
- Vocabulaire :
 - lorsque Y est quantitative “continue” ($\mathcal{Y} \subset \mathbb{R}$), on parle de **modèle de régression** ;
 - lorsque Y est qualitative (ou quantitative) avec $\text{Card}(\mathcal{Y})$ fini et “petit”, on parle d'**analyse discriminante**, ou **classification supervisée** ;
 - Y est appelée : **la variable réponse**, la variable cible, la variable endogène, la variable à expliquer, la variable dépendante, ...
 - les variables $X_1, \dots, X_p$ sont appelées : **les variables explicatives**, les variables exogènes, les variables “indépendantes”, les variables de contrôle, les régresseurs, les prédicteurs, ...

Exemple 1

On cherche à expliquer/prédire la concentration en ozone (Y), à l'aide de plusieurs variables explicatives :

- X_1 : température,
- X_2 : vitesse du vent,
- X_3 : jour de l'année,
- X_4 : humidité,
- X_5 : visibilité,
- $X_6, X_7, \dots$

Questions

Comment expliquer (modéliser) la concentration en ozone (Y) à l'aide de ces variables ? Quel est le modèle/le sous-ensemble de variables explicatives qui explique/prédit au “mieux” la concentration en ozone ? (sélection de modèles/sélection de variables).

Le problème de régression :

- Il s'agit de trouver une fonction $f : \mathbb{R}^p \mapsto \mathbb{R}$ telle que $Y \approx f(X_1, \dots, X_p)$;
- Sauf dans des cas très particuliers, le lien n'est jamais parfait

$$Y = f(X_1, \dots, X_p) + \varepsilon.$$

Les données :

- On dispose d'un n -échantillon i.i.d. $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ du vecteur aléatoire $(\mathbf{X}, Y) \in \mathbb{R}^p \times \mathbb{R}$. Notons les données $D_n := \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\}$. L'objectif est alors de trouver la “meilleure” fonction $\hat{f}_n(\cdot) : \mathbf{x} \in \mathbb{R}^p \mapsto \hat{f}_n(\mathbf{x}) := \hat{f}_n(\mathbf{x}; D_n)$, fonction de $\mathbf{x}$ et des données, telle que $\hat{f}_n(\mathbf{X}_i) \approx Y_i, \forall i = 1, \dots, n, \quad \hat{f}_n(\mathbf{X}) \approx Y.$

Cette fonction de prévision $\hat{f}_n : \mathbf{x} \in \mathbb{R}^p \mapsto \mathbb{R}$ dépend des données $D_n := \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\} : \hat{f}_n(\mathbf{x}) := \hat{f}_n(\mathbf{x}; D_n)$.

Fonction de perte

- Nécessité de se donner un **critère** qui permet de mesurer la qualité des fonctions de prévision f ;
- Le plus souvent, on utilise une **fonction de perte** $\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_+$ telle que

$$\begin{cases} \ell(y, y') = 0 & \text{si } y = y' \\ \ell(y, y') > 0 & \text{si } y \neq y'. \end{cases}$$

Risque théorique, ou erreur théorique (de test, de prévision)

- Étant donné une **fonction de perte** $\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_+$, la performance d'une fonction de prévision $f : \mathcal{X} \rightarrow \mathcal{Y}$ est mesurée par

$$\mathcal{R}(f) := \mathbb{E}[\ell(Y, f(\mathbf{X}))],$$

où $(\mathbf{X}, Y)$ est indépendant des $(\mathbf{X}_i, Y_i)$, $i = 1, \dots, n$, et est de même loi P ;

- $\mathcal{R}(f)$ est appelé **risque théorique** ou **erreur théorique de prévision**, de f .

Aspect théorique

- Pour une fonction de perte $\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_+$, le problème **théorique** consiste à trouver

$$f^* := \arg \min_f \mathcal{R}(f);$$

- Une telle fonction f^* (si elle existe) est appelée fonction **théorique** de prévision **optimale** pour la fonction de perte ℓ ;
- La fonction de prévision optimale f^* dépend de la loi P , du vecteur aléatoire $(\mathbf{X}, Y)$, qui est en pratique **inconnue** ;

- L'objectif est donc de trouver, à partir des données D_n , un **estimateur** $\hat{f}_n : \mathbf{x} \in \mathcal{X} \mapsto \hat{f}_n(\mathbf{x}) := \hat{f}_n(\mathbf{x}; D_n) \in \mathcal{Y}$, de la fonction de prévision $f : \mathbf{x} \in \mathcal{X} \mapsto f(\mathbf{x}) \in \mathcal{Y}$, de risque le plus faible possible :

$$\begin{aligned}\mathcal{R}(\hat{f}_n) &:= \mathbb{E} \left[\ell \left(Y, \hat{f}_n(\mathbf{X}; D_n) \right) \right] \\ &\approx \mathbb{E} [\ell(Y, f^*(\mathbf{X}))] =: \mathcal{R}(f^*). \end{aligned} \quad (1)$$

Définition : algorithme de prévision

- Un algorithme de prévision est représenté par une suite $(\hat{f}_n)_n$ d'applications (mesurables) telles que pour tout $n \geq 1$

$$\hat{f}_n : \mathcal{X} \times (\mathcal{X} \times \mathcal{Y})^n \rightarrow \mathcal{Y};$$

- On dit que la suite $(\hat{f}_n)_n$ est **consistante** si

$$\lim_{n \rightarrow \infty} \mathcal{R}(\hat{f}_n) = \mathcal{R}(f^*).$$

Choix de la fonction de perte

- Dans la définition précédente, la performance d'un estimateur de la fonction de prévision est définie vis-à-vis d'un **critère** (représenté par une fonction de perte ℓ) ;
- Un estimateur performant pour un critère ne sera pas forcément performant pour un autre ;
- **Conséquence** : avant de chercher à construire un estimateur, il est capital de savoir mesurer la performance (choisir la fonction de perte ℓ).

Choix de la fonction de perte en régression

- En régression ($\mathcal{Y} = \mathbb{R}$), la fonction de **perte quadratique** est la plus souvent utilisée. Elle est définie par

$$\begin{aligned}\ell &: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}_+ \\ (y, y') &\mapsto \ell(y, y') := (y - y')^2\end{aligned}$$

- Le **risque théorique** d'une fonction de prévision $f : \mathcal{X} \rightarrow \mathbb{R}$ est donnée par (appelée risque quadratique théorique)

$$\mathcal{R}(f) := \mathbb{E} \left[(Y - f(\mathbf{X}))^2 \right].$$

Méthodes d'estimation de la fonction de prévision en régression

Le cadre

- On dispose de données

$$D_n := \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\}$$

qui sont supposées être i.i.d. de même loi que $(\mathbf{X}, Y)$ à valeurs dans $\mathcal{X} \times \mathcal{Y} = \mathbb{R}^p \times \mathbb{R}$;

- On considère la fonction de perte quadratique

$$\ell(\cdot, \cdot) : (y, y') \in \mathbb{R} \times \mathbb{R} \mapsto \ell(y, y') := (y - y')^2 \in \mathbb{R}_+.$$

Objectif

- Construire, à partir des données D_n , un estimateur $\hat{f}_n(\cdot) := \hat{f}_n(\cdot; D_n)$, de la fonction de prévision, qui soit le plus proche possible de la fonction optimal

$$f^* := \arg \min_f \mathbb{E} \left[(Y - f(\mathbf{X}))^2 \right],$$

de sorte que $\mathcal{R}(\hat{f}_n)$ soit le plus petit possible.

Modèles de régression

- Poser un modèle de régression revient à supposer que la fonction de prévision $f(\cdot)$ appartient à un certain espace $\mathcal{M}$;
- Le travail sera alors de trouver, à partir des données D_n , parmi les éléments f du modèle $\mathcal{M}$, la “meilleure” fonction $\hat{f}_n(\cdot)$.

Modèles non paramétriques

- L'espace $\mathcal{M}$ est de dimension infinie ;
- Exemple : On pose $Y = f(X_1, \dots, X_p) + \varepsilon$, où f appartient à l'espace des fonctions continues $\mathbb{R}^p \rightarrow \mathbb{R}$.

Modèles paramétriques

- L'espace $\mathcal{M}$ est de dimension finie ;
- Exemple : On suppose que la fonction de prévision optimale $f^*(\mathbf{x}) := \mathbb{E}(Y \mid \mathbf{X} = \mathbf{x})$ est linéaire :

$$f^*(\mathbf{x}) = w_0 + w_1 x_1 + \dots + w_p x_p;$$

- Cette modélisation est souvent réécrite sous la forme

$$Y = f(X_1, \dots, X_p; \mathbf{w}) + \varepsilon = w_0 + w_1 X_1 + \dots + w_p X_p + \varepsilon, \quad (2)$$

avec $\mathbb{E}[\varepsilon \mid \mathbf{X} = \mathbf{x}] = 0$ et $\text{Var}[\varepsilon \mid \mathbf{X} = \mathbf{x}] = \sigma^2$, ne dépendant pas de $\mathbf{x}$ (hypothèse d'**homoscédasticité**).

- Le problème est alors d'estimer le paramètre $\mathbf{w} := (w_0, w_1, \dots, w_p)^\top \in \mathbb{R}^{1+p}$ à l'aide des données $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$;
- Le modèle ci-dessus s'appelle **le modèle de régression linéaire**.

On considère d'abord le cas plus simple d'un modèle de régression linéaire simple (RLS), i.e.,

$$Y = w_0 + w_1 X + \varepsilon,$$

où X est réelle, $\mathbb{E}[\varepsilon | X = x] = 0$, et $\text{Var}[\varepsilon | X = x] = \sigma^2$, ne dépendant pas de x (hypothèse d'**homoscédasticité**).

Estimation par moindres carrés

- Elle consiste à minimiser en $(w_0, w_1) \in \mathbb{R}^2$ la moyenne des carrés des erreurs

$$\frac{1}{n} \sum_{i=1}^n \varepsilon_i^2 := \frac{1}{n} \sum_{i=1}^n (Y_i - w_0 - w_1 X_i)^2,$$

qui fournit les estimateurs

$$\hat{w}_0 = \bar{Y} - \hat{w}_1 \bar{X}; \quad \hat{w}_1 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(X_i - \bar{X})}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

Propriétés des estimateurs MC

Sous les conditions

- Les erreurs $\varepsilon_i, i = 1, \dots, n$, sont non corrélées,
- $\mathbb{E}(\varepsilon_i | X = x) = 0, \text{Var}(\varepsilon_i | X = x) = \sigma^2, i = 1, \dots, n$, (ne dépendant pas de x : hypothèse d'homoscédasticité),

on a les propriétés suivantes

- $\hat{w}_0$ et $\hat{w}_1$ sont des estimateurs sans biais de w_0 et w_1 ;
- Les variances (conditionnellement aux $X_1, \dots, X_n$) sont données par

$$\text{Var}(\hat{w}_0 | X_1, \dots, X_n) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right),$$

$$\text{Var}(\hat{w}_1 | X_1, \dots, X_n) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

Vocabulaire

- $\hat{w}_0 + \hat{w}_1 X_i =: \hat{Y}_i$ s'appelle la **valeur ajustée** de l'observation Y_i ;
- $\hat{\varepsilon}_i := Y_i - \hat{Y}_i$ s'appelle **résidu** ;
- Étant donné X_{n+1} une nouvelle valeur de la variable X ; on cherche à estimer la valeur $Y_{n+1} := w_0 + w_1 X_{n+1}$; un estimateur naturel est la **prévision** associée

$$\hat{Y}_{n+1} := \hat{w}_0 + \hat{w}_1 X_{n+1}.$$

- Cette valeur s'appelle la **valeur prédite** de Y (donnée par le modèle) quand $X = X_{n+1}$.

Propriété

On a

$$\text{Var} \left(\hat{Y}_{n+1} \mid X_1, \dots, X_n, X_{n+1} \right) = \sigma^2 \left(\frac{1}{n} + \frac{(X_{n+1} - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right).$$

Cette variance de la prévision est d'autant plus faible que

- σ^2 est petit ;
- X_{n+1} est proche du centre de gravité $\bar{X}$ des X_i . (C'est plus difficile de bien prédire vers les extrêmes).

Questions

- Comment mesurer la qualité du modèle ?
- Comment tester la valeur des coefficients du modèle ?
- Peut-on obtenir des intervalles de confiance pour les paramètres w_j ?

Condition

On suppose que les erreurs $\varepsilon_i, i = 1, \dots, n$, sont i.i.d. (et indépendantes de $X_1, \dots, X_n$) de même loi normale $\mathcal{N}(0, \sigma^2)$, de variance σ^2 (ne dépendant pas de x).

Si cette condition est vérifiée, alors on a

Cas 1 : si σ^2 connue

- $\mathcal{L}(\hat{w}_0 | X_1, \dots, X_n) = \mathcal{N}(w_0, \text{Var}(\hat{w}_0 | X_1, \dots, X_n))$ et $\mathcal{L}(\hat{w}_1 | X_1, \dots, X_n) = \mathcal{N}(w_1, \text{Var}(\hat{w}_1 | X_1, \dots, X_n))$.

Cas 2 : si σ^2 inconnue

On estime σ^2 par $\hat{\sigma}^2 := \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2$, et on a

- $(n-2) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{(n-2)}$, (une loi du χ^2 à $n-2$ ddl);
- $(\hat{w}_0, \hat{w}_1)$ et $\hat{\sigma}^2$ sont indépendants;
- $\frac{\hat{w}_0 - w_0}{\hat{\sigma}_{\hat{w}_0}} \sim \mathcal{T}_{(n-2)}$, et $\frac{\hat{w}_1 - w_1}{\hat{\sigma}_{\hat{w}_1}} \sim \mathcal{T}_{(n-2)}$, $\mathcal{T}_{(n-2)}$ étant la loi de Student à $(n-2)$ ddl.

Au vu des résultats précédents, on obtient les intervalles de confiance suivants, au niveau $(1 - \alpha)$, des paramètres w_0 et w_1 :

Intervalles de confiance pour les paramètres w_0 et w_1

- Pour w_0 :

$$\left[\hat{w}_0 - t_{(n-2)}(1 - \alpha/2) \hat{\sigma}_{\hat{w}_0}, \hat{w}_0 + t_{(n-2)}(1 - \alpha/2) \hat{\sigma}_{\hat{w}_0} \right],$$

où $t_{(n-2)}(1 - \alpha/2)$ est le quantile d'ordre $(1 - \alpha/2)$ de la loi de Student à $(n - 2)$ ddl ;

- Pour w_1 :

$$\left[\hat{w}_1 - t_{(n-2)}(1 - \alpha/2) \hat{\sigma}_{\hat{w}_1}, \hat{w}_1 + t_{(n-2)}(1 - \alpha/2) \hat{\sigma}_{\hat{w}_1} \right].$$

On souhaite tester l'hypothèse nulle

$$\mathcal{H}_0 : w_1 = 0 \quad \text{contre l'alternative} \quad \mathcal{H}_1 : w_1 \neq 0.$$

On utilise la statistique (de Student) $t := \frac{\hat{w}_1}{\hat{\sigma}_{\hat{w}_1}}$ qui suit une loi de Student à $(n - 2)$ ddl si $\mathcal{H}_0$ est vraie.

La P -value de ce test est alors définie par

$$P\text{-value} := \mathbb{P}(|T| > |t_{obs}|),$$

où T est une v.a. suivant la loi de Student à $(n - 2)$ ddl. On utilise alors la règle de décision suivante

- on rejette $\mathcal{H}_0$ si la P -value $< \alpha$;
- on accepte $\mathcal{H}_0$ si la P -value $\geq \alpha$,

α étant le risque de première espèce, i.e., la probabilité de rejeter $\mathcal{H}_0$ alors qu'elle est vraie (cette valeur est prise souvent dans la pratique égale à 0.01 ou 0.05).

Retour à l'exemple 1

- On cherche à expliquer/prédire la concentration en ozone (Y) à l'aide de 9 variables explicatives possibles : X_1 : température ; X_2 : vitesse du vent ; X_3 : ... ; ...
- On dispose de $n = 330$ mesures (observations) du vecteur $(\mathbf{X}, Y) := (X_1, \dots, X_9, Y)$; c.f. la base de données dénommée “LAozoneData” disponible en ligne sur Moodle en format “.xlsx” ; voici les 6 premières lignes de cette base

```
library(xlsx)
LAozoneData <- read.xlsx("LAozoneData.xlsx", sheetIndex = 1, header = T)
head(LAozoneData, 6)
```

##	ozone	vh	wind	humidity	temp	ibh	dpg	ibt	vis	doy
## 1	3	5710	4	28	40	2693	-25	87	250	3
## 2	5	5700	3	37	45	590	-24	128	100	4
## 3	5	5760	3	51	54	1450	25	139	60	5
## 4	6	5720	4	69	35	1568	15	121	60	6
## 5	4	5790	6	19	45	2631	-33	123	100	7
## 6	4	5790	3	25	55	554	-28	182	250	8

Figure – La base de données “LAozoneData”

Nous allons, dans un premier temps, utiliser seulement la variable explicative “ X : temperature” pour expliquer/prédire la variable “ Y : concentration en ozone” à l’aide d’un modèle de régression linéaire (simple). Sous R, on utilise la fonction “`lm()`”.

Représentons d’abord les $n = 330$ observations dans le plan à l’aide des deux variables $(X, Y) \in \mathbb{R}^2$:

```
library(ggplot2)
ggplot(data = LAozoneData, mapping = aes(x = temp, y = ozone)) + geom_point()
```




Figure – Nuage des points : ozone versus température

```
ggplot(data = LAozoneData, mapping = aes(x = temp, y = ozone)) + geom_point() +  
  geom_smooth(method = lm, se = FALSE)
```




Figure – Ajustement par une droite

On construit maintenant le modèle de régression linéaire simple de la variable 'ozone' en fonction de la variable 'temp' :

```
modele.reg.simple <- lm(formula = ozone ~ temp, data = LAozoneData)
summary(modele.reg.simple)

##
## Call:
## lm(formula = ozone ~ temp, data = LAozoneData)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -10.9939  -3.8202  -0.1796   3.1951  15.0112
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -14.93745     1.21247  -12.32  <2e-16 ***
## temp         0.43257     0.01912   22.63  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.014 on 328 degrees of freedom
## Multiple R-squared:  0.6095, Adjusted R-squared:  0.6083
## F-statistic: 511.9 on 1 and 328 DF, p-value: < 2.2e-16
```

Figure – Résultats du modèle de régression linéaire simple

La régression linéaire multiple (RLM)

Retour à l'exemple 1

- La température n'est pas la seule variable permettant d'expliquer ou de prédire la concentration en ozone ;
- D'autres variables peuvent être prise en compte (humidité, visibilité, jour de l'année, ...) ;
- D'où la nécessité d'étendre le modèle linéaire simple à plus d'une seule variable explicative.

Notations

- Y : variable statistique réelle (à expliquer/prédire) ;
- $\mathbf{X} := (X_1, \dots, X_p) \in \mathbb{R}^p$: le vecteur, des variables explicatives, à valeurs dans $\mathbb{R}^p$;
- On dispose de n observations $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ i.i.d. de même loi que $(\mathbf{X}, Y) \in \mathbb{R}^p \times \mathbb{R}$.

Le modèle de régression linéaire multiple

Il s'écrit

$$Y = w_0 + w_1 X_1 + \dots + w_p X_p + \varepsilon,$$

où $\mathbb{E}(\varepsilon | \mathbf{X} = \mathbf{x}) = 0$, et $\text{Var}(\varepsilon | \mathbf{X} = \mathbf{x}) = \sigma^2$, ne dépendant pas de $\mathbf{x}$ (hypothèse d'**homoscédasticité**).

Notation matricielle

- On note

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n, \mathbf{X} := \begin{bmatrix} 1 & X_{1,1} & \cdots & X_{1,p} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n,1} & \cdots & X_{n,p} \end{bmatrix} \in \mathcal{M}_{n \times (1+p)}(\mathbb{R}),$$

$$\mathbf{w} := \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_p \end{bmatrix} \in \mathbb{R}^{1+p}, \quad \boldsymbol{\varepsilon} := \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \in \mathbb{R}^n,$$

qui représentent, respectivement, le vecteur des valeurs observées de la variable réponse Y , la **matrice de design**, le vecteur des paramètres du modèle, et enfin le vecteur des termes d'erreur du modèle, $\varepsilon_1, \dots, \varepsilon_n$, **non observables**.

Le modèle de RLM, associé aux données, s'écrit donc sous la forme matricielle suivante

$$\mathbf{Y} = \mathbb{X} \mathbf{w} + \varepsilon.$$

Définition

On appelle **estimateur des moindres carrés** $\hat{\mathbf{w}}$, de $\mathbf{w} := (w_0, w_1, \dots, w_p)^\top$, la statistique suivante

$$\begin{aligned} \hat{\mathbf{w}} &:= \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p}} \frac{1}{n} \sum_{i=1}^n (Y_i - w_0 - w_1 X_{i,1} - \dots - w_p X_{i,p})^2 \\ &= \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p}} \frac{1}{n} \|\mathbf{Y} - \mathbb{X} \mathbf{w}\|^2. \end{aligned}$$

Proposition

Si la matrice de design $\mathbb{X}$ est de rang $1 + p$ (ce qui nécessite $n > p$), alors l'estimateur des MC, de $\mathbf{w}$, existe et est unique et est donné par

$$\hat{\mathbf{w}} := (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}.$$

Propriétés des estimateurs MC

Sous les conditions

- Les erreurs $\varepsilon_i, i = 1, \dots, n$, sont non corrélées,
- $\mathbb{E}(\varepsilon_i | \mathbb{X}) = 0, \text{Var}(\varepsilon_i | \mathbb{X}) = \sigma^2, i = 1, \dots, n$,

on a les propriétés suivantes

- $\hat{\mathbf{w}}$ est un estimateur sans biais de $\mathbf{w}$;
- La matrice de variance-covariance de $\hat{\mathbf{w}}$, conditionnellement à $\mathbb{X}$, est donnée par

$$\text{Var}(\hat{\mathbf{w}} | \mathbb{X}) = \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}.$$

Lois des estimateurs MC

On suppose que le vecteur des erreurs ε est indépendant de $\mathbb{X}$, et que $\varepsilon \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbb{I}_n)$, une loi gaussienne sur $\mathbb{R}^n$ centrée de matrice de variance-covariance $\sigma^2 \mathbb{I}_n$.

- Soit $\hat{\varepsilon} := \mathbf{Y} - \mathbb{X} \hat{\mathbf{w}} =: \mathbf{Y} - \hat{\mathbf{Y}}$ le vecteur des résidus, et $\hat{\sigma}^2$ l'estimateur, de σ^2 , définie par

$$\hat{\sigma}^2 := \frac{1}{n - (1 + p)} \|\hat{\varepsilon}\|^2 = \frac{1}{n - (1 + p)} \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

Proposition

- $\hat{\mathbf{w}}$ suit, conditionnellement à $\mathbb{X}$, une loi gaussienne d'espérance $\mathbf{w}$ et de matrice de variance-covariance $\sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}$;
- $(n - p - 1) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{(n-p-1)}$;
- $\hat{\mathbf{w}}$ et $\hat{\sigma}^2$ sont indépendants.

Intervalles de confiance et tests

On note $\hat{\sigma}_j^2 := \hat{\sigma}^2 \left[(\mathbb{X}^\top \mathbb{X})^{-1} \right]_{j,j}$, pour $j = 0, 1, \dots, p$. On a

$$\forall j = 0, \dots, p, \quad \frac{\hat{w}_j - w_j}{\hat{\sigma}_j} \sim \mathcal{T}_{(n-p-1)},$$

ce qui permet de construire des intervalles de confiance, au niveau $1 - \alpha$, pour les paramètres w_j , et de réaliser des tests d'hypothèses du type $\mathcal{H}_0 : w_j = 0$ contre $\mathcal{H}_1 : w_j \neq 0$.

Intervalle de confiance, au niveau $1 - \alpha$, pour w_j

$$\left[\hat{w}_j - t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma}_j, \hat{w}_j + t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma}_j \right].$$

Test de Student

Considérons le problème de test de l'hypothèse

$$\mathcal{H}_0 : w_j = 0 \text{ contre l'alternative } \mathcal{H}_1 : w_j \neq 0.$$

Soit $t := \frac{\hat{w}_j}{\hat{\sigma}_j}$ (la statistique de Student). La P -value du test (de Student) est donnée par

$$P - \text{value} = \mathbb{P}(|T| > |t_{obs}|),$$

où T est une variable aléatoire suivant la loi $\mathcal{T}_{(n-p-1)}$.

Retour à l'exemple 1

- On cherche à expliquer/prédire la concentration en ozone Y à l'aide de 9 variables explicatives possibles : X_1 : température ; X_2 : vitesse du vent ; X_3 : ... ; ...
- On dispose de $n = 330$ mesures (observations) du vecteur $(X_1, \dots, X_9, Y)$.

Nous allons utiliser toutes les variables explicatives $(X_1, \dots, X_9) =: \mathbf{X}$ pour expliquer/prédire la variable réponse “ Y : concentration en ozone”, à l'aide d'un modèle de régression linéaire multiple. La base de données “LAozoneData” est constituée de $n = 330$ observations du vecteur aléatoire $(\mathbf{X}, Y)$:

Voici la structure de la base de données “LAozoneData”

```
str(LAozoneData)
```

```
## 'data.frame':   330 obs. of  10 variables:
## $ ozone      : num  3 5 5 6 4 4 6 7 4 6 ...
## $ vh         : num  5710 5700 5760 5720 5790 5790 5700 5700 5770 5720 ...
## $ wind       : num  4 3 3 4 6 3 3 3 8 3 ...
## $ humidity   : num  28 37 51 69 19 25 73 59 27 44 ...
## $ temp       : num  40 45 54 35 45 55 41 44 54 51 ...
## $ ibh        : num  2693 590 1450 1568 2631 ...
## $ dpq        : num  -25 -24 25 15 -33 -28 23 -2 -19 9 ...
## $ ibt        : num  87 128 139 121 123 182 114 91 92 173 ...
## $ vis        : num  250 100 60 60 100 250 120 120 120 150 ...
## $ doy        : num  3 4 5 6 7 8 9 10 11 12 ...
```

Figure – Structure de la base des données “LAozoneData”

On construit ici le modele de RLM

```
modele.reg.multiple <- lm(formula = ozone ~ ., data = LAozoneData)
summary(modele.reg.multiple)

##
## Call:
## lm(formula = ozone ~ ., data = LAozoneData)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -12.2407  -2.8832  -0.3353   2.7409  13.3523
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  18.3792938  29.5045242   0.623  0.53377
##   vh         -0.0051340   0.0053950  -0.952  0.34200
##   wind        -0.0198304   0.1238829  -0.160  0.87292
## humidity     0.0804923   0.0188345   4.274 2.54e-05 ***
## temp         0.2743349   0.0497361   5.516 7.17e-08 ***
## ibh          -0.0002497   0.0002950  -0.846  0.39798
## dpq          -0.0036968   0.0112925  -0.327  0.74360
## ibt           0.0292640   0.0136115   2.150  0.03231 *
## vis          -0.0080742   0.0037565  -2.149  0.03235 *
## doy          -0.0088490   0.0027199  -3.253  0.00126 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.441 on 320 degrees of freedom
## Multiple R-squared:  0.7011, Adjusted R-squared:  0.6927
## F-statistic: 83.4 on 9 and 320 DF, p-value: < 2.2e-16
```

Figure – Résultats du modèle de RLM

Questions

- Le modèle linéaire repose sur certaines hypothèses (non corrélation des termes d'erreur, relation linéaire entre la variable réponse et les variables explicatives, homoscedasticité, indépendance des erreurs, normalité des erreurs, ...). Comment les vérifier ?
- Analyse des résidus ; détection des **outliers** (valeurs aberrantes de la variable réponse), détection des **points leviers extrêmes** (valeurs extrêmes des variables explicatives), détection des **points trop influents**, ...
- À partir de p variables explicatives, il est possible de construire $2^p - 1$ modèles de régression linéaires possibles ; comment choisir le “meilleur” sous-ensemble de variables explicatives à inclure dans le modèle ? (sélection de modèles, de variables, ...), détection des points **trop influents** (qui peuvent être des outliers ou points levier extrêmes)

Les résidus vérifient les propriétés suivantes

- $\sum_{i=1}^n \hat{\varepsilon}_i = 0, \quad \hat{\varepsilon}^\top \mathbb{X} := (\mathbf{Y} - \mathbb{X} \hat{\mathbf{w}})^\top \mathbb{X} = \mathbf{0};$
- $\forall i = 1, \dots, n, \mathbb{E}(\hat{\varepsilon}_i) = 0;$
- Sous les hypothèses d'homoscédasticité, et de non corrélation des erreurs ε_i , on a $\text{Var}(\hat{\varepsilon} | \mathbb{X}) = \sigma^2 (\mathbb{I}_n - \mathbb{X} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top).$

Le test de Durbin-Watson suppose le lien (modèle auto-régressif d'ordre 1) suivant entre les erreurs

$$\varepsilon_i = \rho \varepsilon_{i-1} + u_i, \quad i = 2, \dots, n,$$

où $u_2, \dots, u_n$ est un **bruit blanc**, i.e., une suite de v.a. centrées, de même variance (finie), non corrélées, indépendantes des ε_i , $i = 1, \dots, n$. Le paramètre ρ représente ainsi l'auto-corrélation : $\text{Cor}(\varepsilon_i, \varepsilon_{i-1}) = \rho$, $i = 2, \dots, n$.

La **statistique de Durbin-Watson** est définie par

$$S_{DW} := \frac{\sum_{i=2}^n (\hat{\varepsilon}_i - \hat{\varepsilon}_{i-1})^2}{\sum_{i=1}^n \hat{\varepsilon}_i^2}.$$

Elle prend ses valeurs entre 0 et 4. Le coefficient d'auto-corrélation ρ peut être estimé par $1 - S_{DW}/2$. L'hypothèse nulle est retenue si la statistique a une valeur proche de 2.

Pour réaliser ce test, sous R, on utilise la fonction "`dwtest()`", du package "`lmtest`", comme suit

```
library(lmtest)
modele.reg.multiple <- lm(formula = ozone ~ . , data = LAozoneData)
dwtest(modele.reg.multiple, alternative = c("two.sided"))


##
## Durbin-Watson test
##
## data: modele.reg.multiple
## DW = 1.4699, p-value = 3.837e-07
## alternative hypothesis: true autocorrelation is not 0
```

D'après ce test, les erreurs sont (fortement) corrélées.

Graphiquement, pour “vérifier” l’hypothèse de non-corrélation des erreurs, on peut tracer la fonction d’auto-corrélations des erreurs, à l’aide de la fonction “acf()” de R, comme suit

```
acf(modele.reg.multiple$residuals, main = "Autocorrélations des erreurs")
```

Autocorrélations des erreurs



Test d'homoscédasticité des erreurs en régression : test de Breusch-Pagan

- Considérons le test de l'hypothèse nulle

$$\mathcal{H}_0 : \text{"l'erreur } \varepsilon \text{ est homoscédastique"}$$

contre l'alternative

$$\mathcal{H}_1 : \text{"l'erreur est hétéroscédastique"}.$$

Pour tester l'hypothèse nulle ci-dessus (d'homoscédasticité), on peut utiliser, à partir des résidus, ou de leurs versions **studentisées**

$$\frac{\hat{\varepsilon}_i}{\hat{\sigma}\sqrt{1-h_{i,i}}}, i = 1, \dots, n,$$

$h_{i,i}$ étant le i -ème élément diagonal de la matrice $\mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$, la statistique de **Breusch-Pagan** qui suit, asymptotiquement, sous $\mathcal{H}_0$, une loi du χ_p^2 , $p+1$ étant le nombre de paramètres à estimer dans le modèle de RLM.

Cela peut se faire, sous R, à l'aide de la fonction “bptest()” du package “lmtest”, comme suit (à partir des résidus non studentisées)

```
modele.reg.multiple <- lm(formula = ozone ~ . , data = LAozoneData)
bptest(modele.reg.multiple, studentize = FALSE)

##
## Breusch-Pagan test
##
## data: modele.reg.multiple
## BP = 52.284, df = 9, p-value = 3.994e-08
```

où la version studentisée (i.e. avec des résidus studentisées)

```
modele.reg.multiple <- lm(formula = ozone ~ . , data = LAozoneData)
bptest(modele.reg.multiple)

##
## studentized Breusch-Pagan test
##
## data: modele.reg.multiple
## BP = 53.028, df = 9, p-value = 2.887e-08
```

La P-value est proche de zéro, on rejette alors l'hypothèse nulle d'homoscédasticité.

Test de normalité des erreurs en régression

Considérons le test d'adéquation de l'hypothèse nulle $\mathcal{H}_0$: "l'erreur ε est normale" contre l'alternative $\mathcal{H}_1$: "l'erreur ε n'est pas normale". Les observations (résidus) $\hat{\varepsilon}_1, \dots, \hat{\varepsilon}_n$, ou leurs versions studentisées

$$\frac{\hat{\varepsilon}_i}{\hat{\sigma} \sqrt{1 - h_{i,i}}}, i = 1, \dots, n,$$

$h_{i,i}$ étant le i -ème élément diagonal de la matrice $\mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$, sont ensuite utilisées pour réaliser le test de normalité. Le test de **Shapiro-Wilk** est souvent utilisé ; sous R, on utilise la fonction `'shapiro.test()'` :





Test de normalité de l'erreur, à l'aide des résidus

```
shapiro.test(residuals(modele.reg.multiple))  
  
##  
## Shapiro-Wilk normality test  
##  
## data:  residuals(modele.reg.multiple)  
## W = 0.99697, p-value = 0.797
```

Test de normalité de l'erreur, à l'aide des résidus studentisés

```
shapiro.test(rstudent(modele.reg.multiple))  
  
##  
## Shapiro-Wilk normality test  
##  
## data:  rstudent(modele.reg.multiple)  
## W = 0.99705, p-value = 0.8138
```

Les graphiques suivants peuvent donner des indications quant à la validité ou non des hypothèses du modèle RL



Dans chacune des figures précédentes, on a présenté les 3 observations les plus extrêmes selon certains critères ; les critères utilisés, pour réaliser les graphiques précédents, peuvent être obtenues, à l'aide de la fonction 'augment()', comme suit

```
library(broom)
model.reg.multiple.metriques <- augment(modele.reg.multiple)
head(model.reg.multiple.metriques[,11:17])
```



```
## # A tibble: 6 x 7
##   .fitted .se.fit .resid  .hat .sigma .cooksd .std.resid
##   <dbl>   <dbl> <dbl> <dbl> <dbl>   <dbl>   <dbl>
## 1    2.13    0.800  0.867  0.0324  4.45 0.000132    0.198
## 2    7.22    0.820 -2.22  0.0341  4.45 0.000915   -0.509
## 3   10.8    0.756 -5.75  0.0290  4.44 0.00516    -1.31
## 4    6.65    1.08 -0.646  0.0588  4.45 0.000140   -0.150
## 5    4.60    0.992 -0.604  0.0498  4.45 0.000102   -0.140
## 6    8.90    0.837 -4.90  0.0355  4.44 0.00464    -1.12
```



On utilise essentiellement

- **.fitted** : les valeurs ajustées ;
- **.resid** : les résidus ;
- **.hat** : les valeurs “hat” (les statistiques du levier) qui sont utilisées pour détecter les points leviers extrêmes (les valeurs extrêmes des prédicteurs) ;
- **.std.resid** : les résidus studentisés, qui peuvent être utilisés pour détecter les outliers (valeurs extrêmes de la variable réponse) ;
- **.cooks** : la distance de Cook qui est utilisée pour détecter les observations **excessivement influentes** (qui peuvent être des outliers ou points leviers extrêmes).

Dans ce qui suit, on montre comment utiliser ces figures pour vérifier les hypothèses du modèle de RLM, détecter des outliers/points levier extrêmes/points excessivement influents :

Hypothèse de linéarité entre variable réponse et variables explicatives


```
plot(modele.reg.multiple,1)
```



- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡


Hypothèse d'homogénéité des variances (homoscédasticité)

```
plot(modele.reg.multiple,3)  
abline(h = sqrt(3), col = "blue", lty = 2, lwd = 3)
```



Hypothèse de normalité de l'erreur

```
plot(modele.reg.multiple,2)
```




- **Interprétation** : Si tous les points se situent approximativement le long de la droite, cela indique que le terme d'erreur suit une loi normale. C'est le cas ici.

Outliers et points leviers extrêmes

- Sont considérées outliers, les observations dont les résidus studentisés **sont supérieurs à 3** en valeur absolue (c.f. James et al. 2014) ;
- Une observation, dont la valeur de la “statistique du levier (ou hat.value)” est élevée, a des valeurs extrêmes en termes des variables explicatives. Une hat.value (ou statistique du levier), **supérieure à $2(p + 1)/n$** , indique un point levier extrême (c.f. P. Bruce and A. Bruce 2017) ;
- Le graphique suivant peut être utilisé pour détecter les outliers et les points leviers extrêmes :

Outliers et points leviers extrêmes

```
plot(modele.reg.multiple,5)
abline(h = c(-3,3), v = 2*(9 + 1)/330, col = c("blue","blue","green"), lty = c(2,2,2),
       lwd = c(3,3,3))
```



Interprétation :

- Tous les points ayant un “leverage” supérieur à $2 * (p + 1) / n = 2 * (9 + 1) / 330 = 0.06$ sont considérés comme des points leviers extrêmes ;
- Tous les points ayant un résidu studentisé supérieur à 3 en valeur absolue sont considérés comme outliers.



Points influents

- La distance de Cook est souvent utilisée pour mesurer l'influence d'une observation dans le modèle ;
- Une observation est considérée comme **excessivement influente** si sa distance de Cook est **supérieure à $4/(n - p - 1)$** .

On peut utiliser le graphique suivant

Points influents

```
par(mfrow = c(1,2))  
plot(modele.reg.multiple,4) #Distance de Cook  
abline(h = 4/(330-9-1), col = c("blue"), lty = 2, lwd = 3)  
plot(modele.reg.multiple,5) #Résidus versus Leverage  
abline(h = c(-3,3), v = 2*(9 + 1)/330, col = c("blue","blue","green"), lty = c(2,2,2),  
       lwd = c(3,3,3))
```



Équation de l'analyse de variance

On a d'après le théorème de Pythagore

$$\begin{aligned}\|\mathbf{Y} - \overline{\mathbf{Y}}\mathbf{1}\|^2 &= \|\hat{\mathbf{Y}} - \overline{\mathbf{Y}}\mathbf{1}\|^2 + \|\hat{\boldsymbol{\varepsilon}}\|^2 \\ TSS &= RSS + SSE.\end{aligned}$$

(somme totale des carrés = somme des carrés de la régression +
somme des carrés résiduels)

(total sum of squares = regression sum of squares + sum of
squared errors)

Coefficient de détermination R^2

$$R^2 := \frac{\|\hat{\mathbf{Y}} - \bar{\mathbf{Y}}\mathbf{1}\|^2}{\|\mathbf{Y} - \bar{\mathbf{Y}}\mathbf{1}\|^2} =: \frac{RSS}{TSS}.$$

- $0 \leq R^2 \leq 1$;
- Si $R^2 = 1$, la variabilité de la variable réponse est entièrement expliquée par le modèle ;
- Si $R^2 = 0$, toute la variabilité se trouve dans le bruit.

Test du modèle global

- Le modèle :

$$Y_i = w_0 + w_1 X_{i,1} + \cdots + w_p X_{i,p} + \varepsilon_i, \quad i = 1, \dots, n,$$

avec $\varepsilon_i, i = 1, \dots, n$, i.i.d. de loi $\mathcal{N}(0, \sigma^2)$,
(conditionnellement aux régresseurs).

- On veut tester

$$\mathcal{H}_0 : w_1 = \cdots = w_p = 0 \quad \text{contre} \quad \mathcal{H}_1 : \exists j \in \{1, \dots, p\} \text{ t.q. } w_j \neq 0.$$

- Sous $\mathcal{H}_0$, la **statistique de Fisher**

$$F := \frac{R^2}{1 - R^2} \frac{n - p - 1}{p} = \frac{\|\bar{Y}\mathbf{1} - \hat{\mathbf{Y}}\|^2/p}{\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2/(n - p - 1)}$$

suit $\mathcal{F}_{(p, n-p-1)}$, la loi de Fisher à p et $n - p - 1$ ddl.

- On rejette $\mathcal{H}_0$ si $F_{obs} > F_{(p,n-p-1)}(1 - \alpha)$, où $F_{(p,n-p-1)}(1 - \alpha)$ est le quantile d'ordre $(1 - \alpha)$ de la loi $\mathcal{F}_{(p,n-p-1)}$;
- La P-value associée est donc donnée par

$$P\text{-Value} = \mathbb{P}(Z > F_{obs}),$$

où Z est une v.a suivant la loi $\mathcal{F}_{(p,n-p-1)}$.

Test entre modèles emboîtés

- On veut tester le modèle “réduit” $\mathcal{M}_0$

$$Y_i = w_0 + w_{q+1}X_{i,q+1} + \cdots + w_pX_{i,p} + \varepsilon_i.$$

à “l'intérieur du modèle” plus large $\mathcal{M}$

$$Y_i = w_0 + w_1X_{i,1} + \cdots + w_pX_{i,p} + \varepsilon_i;$$

- Cela revient à tester (à l'intérieur du modèle $\mathcal{M}$) l'hypothèse nulle

$$\mathcal{H}_0 : w_1 = \cdots = w_q = 0$$

contre l'alternative

$$\mathcal{H}_1 : \exists j \in \{1, \dots, q\} \text{ t.q. } w_j \neq 0.$$

- Pour réaliser le test précédent, on utilise la statistique de Fisher suivante

$$F := \frac{\|\hat{\mathbf{Y}}_0 - \hat{\mathbf{Y}}\|^2 / q}{\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 / (n - p - 1)}$$

qui suit la loi $\mathcal{F}_{q, n-p-1}$, sous $\mathcal{H}_0$.

($\hat{\mathbf{Y}}_0$ désigne le vecteur des valeurs ajustées du modèle réduit).

- On rejette $\mathcal{H}_0$ si $F_{obs} > F_{(q, n-p-1)}(1 - \alpha)$.
- La P -value est donc définie par

$$P\text{-value} := \mathbb{P}(Z > F_{obs}),$$

où Z est une v.a. suivant la loi $\mathcal{F}_{(q, n-p-1)}$.

- Ce test peut se faire sous R à l'aide de la fonction 'anova()' qu'on applique à des modèles linéaires calculés avec la fonction 'lm()' :

Retour à l'exemple 1 : test du modèle global

```
modele.complet <- lm(formula = ozone ~ . , data = LAozoneData)
modele.trivial <- lm(formula = ozone ~ 1, data = LAozoneData)
anova(modele.trivial, modele.complet)

## Analysis of Variance Table
##
## Model 1: ozone ~ 1
## Model 2: ozone ~ vh + wind + humidity + temp + ibh + dpg + ibt + vis +
##      doy
##      Res.Df    RSS Df Sum of Sq      F    Pr(>F)
## 1         329 21115.4
## 2         320  6311.2   9      14804 83.403 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Retour à l'exemple 1 : test entre deux modèles emboîtés

```
modele.complet <- lm(formula = ozone ~ . , data = LAozoneData)
modele.reduit <- lm(formula = ozone ~ . -dpg-vis, data = LAozoneData)
anova(modele.reduit, modele.complet)

## Analysis of Variance Table
##
## Model 1: ozone ~ (vh + wind + humidity + temp + ibh + dpg + ibt + vis +
##      doy) - dpg - vis
## Model 2: ozone ~ vh + wind + humidity + temp + ibh + dpg + ibt + vis +
##      doy
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      322 6404.7
## 2      320 6311.2  2    93.508 2.3706 0.09506 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Tests simples, relatifs aux paramètres du modèle de RLM : on utilise la statistique de Student ou Fisher ?

Ici les résultats du test de Student :

```
modele.complet <- lm(formula = ozone ~ ., data = LAozoneData)
summary(modele.complet)

##
## Call:
## lm(formula = ozone ~ ., data = LAozoneData)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -12.2407  -2.8832  -0.3353   2.7409  13.3523
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 18.3792938 29.5045242   0.623  0.53377
## vh          -0.0051340  0.0053950  -0.952  0.34200
## wind        -0.0198304  0.1238829  -0.160  0.87292
## humidity     0.0804923  0.0188345   4.274 2.54e-05 ***
## temp         0.2743349  0.0497361   5.516 7.17e-08 ***
## ibh          -0.0002497  0.0002950  -0.846  0.39798
## dpq         -0.0036968  0.0112925  -0.327  0.74360
## ibt          0.0292640  0.0136115   2.150  0.03231 *
## vis         -0.0080742  0.0037565  -2.149  0.03235 *
## doy         -0.0088490  0.0027199  -3.253  0.00126 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.441 on 320 degrees of freedom
## Multiple R-squared:  0.7011, Adjusted R-squared:  0.6927
## F-statistic: 83.4 on 9 and 320 DF, p-value: < 2.2e-16
```

Voici les résultats du test de Fisher

```
modele.complet <- lm(formula = ozone ~ . , data = LAozoneData)
anova(modele.complet)

## Analysis of Variance Table
##
## Response: ozone
##          Df Sum Sq Mean Sq  F value    Pr(>F)
## vh         1  7788.8   7788.8  394.9172 < 2.2e-16 ***
## wind        1   406.5    406.5   20.6130 7.969e-06 ***
## humidity    1 3100.3   3100.3  157.1959 < 2.2e-16 ***
## temp        1 2415.2   2415.2  122.4578 < 2.2e-16 ***
## ibh         1   735.0    735.0   37.2678 2.978e-09 ***
## dpg         1    12.5     12.5    0.6313 0.427464
## ibt         1    76.4     76.4    3.8745 0.049888 *
## vis         1    60.8     60.8    3.0810 0.080167 .
## doy         1   208.8    208.8  10.5851 0.001262 **
## Residuals 320 6311.2     19.7
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Remarque

- Il est préférable d'utiliser le test de Fisher (au lieu du test de Student), en particulier dans le cas de régression linéaire multiple (avec variables explicatives dépendantes).