

# TD1 : Modèle de régression linéaire

14/03/2024

Le but de ce premier TD est de présenter le modèle de régression linéaire et de sa mise en oeuvre à l'aide du logiciel **R**. Nous allons illustrer ces techniques pour la base de données **Carseats** du package **ISLR**.

On cherche à expliquer/prédire une variable statistique  $Y$  à l'aide de  $p$  variables statistiques numériques  $X_1, \dots, X_p$ . Lorsque la variable  $Y$  est numérique "continue", on parle de problème de régression.  $Y$  s'appelle la variable à expliquer (ou encore, variable réponse, dépendante, endogène...), et  $X_1, \dots, X_p$  les variables explicatives (variables de contrôle, indépendantes, exogènes, régresseurs, prédicteurs...). Notons le vecteur aléatoire (ligne)

$$\mathbf{X} := (X_1, \dots, X_p) \in \mathbb{R}^p$$

des variables explicatives. Le problème de régression consiste à trouver une fonction  $f : \mathbb{R}^p \rightarrow \mathbb{R}$  telle que  $Y \approx f(\mathbf{X})$  :

$$Y = f(X_1, \dots, X_p) + \varepsilon,$$

où  $\varepsilon$  est une variable aléatoire, non observable, représentant le terme d'erreur (le bruit).

Pour la fonction de perte quadratique, la fonction optimale est définie par

$$f^* := \arg \inf_f \mathbb{E}((Y - f(\mathbf{X}))^2).$$

Si la fonction de régression optimale  $f^*(\cdot)$  est paramétrique et est linéaire, i.e., de la forme

$$f(\mathbf{x}) =: f(\mathbf{x}, \mathbf{w}) := w_0 + w_1 x_1 + \dots + w_p x_p,$$

on obtient le modèle de régression linéaire multiple (RLM) réécrit sous la forme

$$Y = w_0 + w_1 X_1 + \dots + w_p X_p + \varepsilon,$$

avec  $\mathbb{E}(\varepsilon | \mathbf{X} = \mathbf{x}) = 0$ . Le problème est alors d'estimer les paramètres

$$\mathbf{w} := (w_0, w_1, \dots, w_p)^\top \in \mathbb{R}^{1+p}$$

à partir de  $n$  observations,

$$(\mathbf{X}_1, Y_1) \in \mathbb{R}^{p+1}, \dots, (\mathbf{X}_n, Y_n) \in \mathbb{R}^{p+1},$$

du vecteur aléatoire  $(\mathbf{X}, Y) \in \mathbb{R}^{p+1}$ . Nous allons utiliser les notations matricielles suivantes

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n, \quad \mathbb{X} := \begin{bmatrix} 1 & X_{1,1} & \dots & X_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n,1} & \dots & X_{n,p} \end{bmatrix}, \quad \mathbf{w} := \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_p \end{bmatrix} \in \mathbb{R}^{1+p}, \quad \boldsymbol{\varepsilon} := \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \in \mathbb{R}^n,$$

qui représentent, respectivement, le vecteur des valeurs observées de la variable réponse  $Y$ , la matrice de design (matrice de dimension  $n \times (1 + p)$ ), le vecteur des paramètres du modèle de RLM, et enfin le vecteur des termes d'erreur du modèle,  $\varepsilon_1, \dots, \varepsilon_n$ , non observés. Le modèle de RLM, associé aux données, s'écrit donc sous la forme matricielle suivante

$$\mathbf{Y} = \mathbb{X} \mathbf{w} + \boldsymbol{\varepsilon}.$$

## L'estimateur MC

L'estimateur des moindres carrés,  $\hat{\mathbf{w}}$  du vecteur  $\mathbf{w}$ , est défini par

$$\begin{aligned}\hat{\mathbf{w}} &:= \arg \min_{(w_0, w_1, \dots, w_p) \in \mathbb{R}^{1+p}} \frac{1}{n} \sum_{i=1}^n (Y_i - w_0 - w_1 X_{i,1} - \dots - w_p X_{i,p})^2 \\ &=: \arg \min_{\mathbf{w} \in \mathbb{R}^{1+p}} \frac{1}{n} \|\mathbf{Y} - \mathbb{X} \mathbf{w}\|^2. \\ &= (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}.\end{aligned}\tag{1}$$

La dernière égalité a lieu si la matrice  $\mathbb{X}^\top \mathbb{X}$  est inversible, ce qui est équivalent à supposer que les colonnes de  $\mathbb{X}$  sont linéairement indépendantes (donc le nombre d'observations  $n$  doit être supérieur à  $1 + p$ ,  $p$  étant le nombre de variables explicatives). Cette hypothèse garantit l'existence et l'unicité de l'estimateur MC précédent.

## Propriétés des estimateurs MC

Si les conditions suivantes sont vérifiées

- (i) Les erreurs,  $\varepsilon_i, i = 1, \dots, n$ , sont non corrélées;
- (ii)  $\mathbb{E}(\varepsilon_i | \mathbb{X}) = 0$ ,  $\text{Var}(\varepsilon_i | \mathbb{X}) = \sigma^2$ ,  $i = 1, \dots, n$ , ne dépendant pas de  $\mathbb{X}$  (hypothèse d'homoscédasticité);

alors on a les propriétés suivantes

- (1)  $\hat{\mathbf{w}}$  est un estimateur sans biais de  $\mathbf{w}$ ;
- (2) La matrice de variance-covariance de  $\hat{\mathbf{w}}$ , conditionnellement à  $\mathbb{X}$ , est donnée par

$$\text{Var}(\hat{\mathbf{w}} | \mathbb{X}) = \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}.$$

## Lois des estimateurs MC

Dans cette section, on suppose que les termes d'erreur,  $\varepsilon_1, \dots, \varepsilon_n$ , sont i.i.d. (et indépendantes de  $\mathbb{X}$ ) de même loi normale  $\mathcal{N}(0, \sigma^2)$ , de variance  $\sigma^2$  ne dépendant pas de  $\mathbf{x}$  (hypothèse d'homoscédasticité). Soit

$$\hat{\boldsymbol{\varepsilon}} := \mathbf{Y} - \mathbb{X} \hat{\mathbf{w}} =: \mathbf{Y} - \hat{\mathbf{Y}}$$

le vecteur des résidus, et  $\hat{\sigma}^2$  l'estimateur, de  $\sigma^2$ , défini par

$$\hat{\sigma}^2 := \frac{1}{n - p - 1} \|\hat{\boldsymbol{\varepsilon}}\|^2.$$

Notons que les résultats de cette section restent valables (asymptotiquement, i.e., pour  $n$  suffisamment grand) si les erreurs  $\varepsilon_1, \dots, \varepsilon_n$  sont i.i.d. centrées de variance  $\sigma^2$  (ne dépendant pas de  $\mathbf{x}$ , homoscédasticité), même si la normalité n'est pas vérifiée. Les erreurs  $\varepsilon_1, \dots, \varepsilon_n$  ne sont pas observables. Elles sont alors approchées par les résidus, pour tester par exemple les hypothèses d'homoscédasticité ou de non-corrélation des erreurs.

## Proposition

On a

- (1)  $\hat{\mathbf{w}}$  est un vecteur gaussien d'espérance  $\mathbf{w}$  et de matrice de variance-covariance  $\sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}$ ;
- (2) La statistique  $(n - p - 1) \frac{\hat{\sigma}^2}{\sigma^2}$  suit la loi du  $\chi^2_{(n-p-1)}$  (la loi du  $\chi^2$  à  $n - p - 1$  degrés de liberté);
- (3)  $\hat{\mathbf{w}}$  et  $\hat{\sigma}^2$  sont indépendants.

## Intervalles de confiance et tests

On note  $\hat{\sigma}_j^2 := \hat{\sigma}^2 \left[ (\mathbb{X}^\top \mathbb{X})^{-1} \right]_{j,j}$ , pour  $j = 0, 1, \dots, p$ . On a

$$\forall j = 0, \dots, p, \text{ la statistique } \frac{\hat{w}_j - w_j}{\hat{\sigma}_j} \text{ suit la loi } \mathcal{T}_{(n-p-1)},$$

(la loi de Student à  $n - p - 1$  degrés de liberté), ce qui permet de construire des intervalles de confiance, au niveau  $1 - \alpha$ , pour les paramètres  $w_j$ , et de réaliser des tests d'hypothèses du type  $\mathcal{H}_0 : w_j = 0$  contre  $\mathcal{H}_1 : w_j \neq 0$ .

### Intervalle de confiance, au niveau $1 - \alpha$ , pour $w_j$

$$\left[ \hat{w}_j - t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma}_j, \hat{w}_j + t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma}_j \right],$$

où  $t_{(n-p-1)}(1 - \alpha/2)$  est le quantile d'ordre  $1 - \alpha/2$  de la loi de Student à  $(n-p-1)$  degrés de liberté.

### Test de Student

Considérons le problème de test de l'hypothèse nulle  $\mathcal{H}_0 : w_j = 0$  contre l'alternative  $\mathcal{H}_1 : w_j \neq 0$ .

Notons  $t := \frac{\hat{w}_j}{\hat{\sigma}_j}$  (la statistique de Student). La P-value du test (de Student) est donnée par

$$\text{P-value} = \mathbb{P}(|T| > |t_{obs}|),$$

où  $T$  est une variable aléatoire suivant la loi  $\mathcal{T}_{(n-p-1)}$ .

## Prévision et intervalles de confiance

On dispose d'une nouvelle observation  $\mathbb{X}_{n+1} := (1, X_{n+1,1}, \dots, X_{n+1,p})$ . On prédit la valeur  $Y_{n+1}$  correspondante par

$$\hat{Y}_{n+1} := \mathbb{X}_{n+1} \hat{\mathbf{w}}.$$

Intervalle d'estimation, au niveau  $1 - \alpha$ , pour  $Y_{n+1}$  :

$$\left[ \hat{Y}_{n+1} - t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma} \sqrt{\mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top}, \hat{Y}_{n+1} + t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma} \sqrt{\mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top} \right];$$

Intervalle de prévision, au niveau  $1 - \alpha$ , pour  $Y_{n+1}$  :

$$\left[ \hat{Y}_{n+1} - t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma} \sqrt{1 + \mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top}, \hat{Y}_{n+1} + t_{(n-p-1)}(1 - \alpha/2) \hat{\sigma} \sqrt{1 + \mathbb{X}_{n+1} (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}_{n+1}^\top} \right].$$

## Équation de l'analyse de variance

On a d'après le théorème de Pythagore

$$\begin{aligned} \|\mathbf{Y} - \bar{\mathbf{Y}}\mathbf{1}\|^2 &= \|\hat{\mathbf{Y}} - \bar{\mathbf{Y}}\mathbf{1}\|^2 + \|\hat{\boldsymbol{\varepsilon}}\|^2 \\ SST &= SSR + SSE. \end{aligned}$$

(somme totale des carrés = somme des carrés de la régression + somme des carrés résiduels)

(total sum of squares = regression sum of squares + sum of squared errors)

## Coefficient de détermination $R^2$

Le coefficient de détermination  $R^2$  est défini par

$$R^2 := \frac{\|\hat{\mathbf{Y}} - \bar{\mathbf{Y}}\mathbf{1}\|^2}{\|\mathbf{Y} - \bar{\mathbf{Y}}\mathbf{1}\|^2} =: \frac{SSR}{SST}.$$

Il vérifie les propriétés suivantes

- (i)  $0 \leq R^2 \leq 1$ ;
- (ii) Si  $R^2 = 1$ , la variabilité de la variable réponse est entièrement expliquée par le modèle;
- (iii) Si  $R^2 = 0$ , toute la variabilité se trouve dans le bruit (le terme d'erreur).

## Test du modèle global

Le modèle de RLM s'écrit

$$Y_i = w_0 + w_1 X_{i,1} + \cdots + w_p X_{i,p} + \varepsilon_i, \quad i = 1, \dots, n,$$

où les termes d'erreurs  $\varepsilon_i, i = 1, \dots, n$ , sont supposés ici i.i.d. de même loi  $\mathcal{N}(0, \sigma^2)$ .

On veut tester

$$\mathcal{H}_0 : w_1 = \cdots = w_p = 0 \quad \text{contre} \quad \mathcal{H}_1 : \exists j \in \{1, \dots, p\} \text{ t.q. } w_j \neq 0.$$

Sous  $\mathcal{H}_0$ , la statistique de Fisher

$$F := \frac{R^2}{1 - R^2} \frac{n - p - 1}{p} \text{ suit la loi } \mathcal{F}_{(p, n-p-1)} \text{ (la loi de Fisher à } p \text{ et } n - p - 1 \text{ degrés de liberté).}$$

On rejette  $\mathcal{H}_0$  si  $F_{obs} > F_{(p, n-p-1)}(1 - \alpha)$ , où  $F_{(p, n-p-1)}(1 - \alpha)$  est le quantile d'ordre  $(1 - \alpha)$  de la loi  $\mathcal{F}_{(p, n-p-1)}$ .

La P-value est donc donnée par

$$\text{P-value} = \mathbb{P}(Z > F_{obs}),$$

où  $Z$  est une variable aléatoire suivant la loi  $\mathcal{F}_{(p, n-p-1)}$ .

## Tests entre modèles emboîtés

On veut tester le modèle réduit  $\mathcal{M}_0$

$$Y_i = w_0 + w_{q+1} X_{i,q+1} + \cdots + w_p X_{i,p} + \varepsilon_i,$$

avec  $1 \leq q < p$ , à l'intérieur du modèle plus large  $\mathcal{M}$

$$Y_i = w_0 + w_1 X_{i,1} + \cdots + w_p X_{i,p} + \varepsilon_i.$$

Cela revient à tester (à l'intérieur du modèle  $\mathcal{M}$ ) l'hypothèse nulle

$$\mathcal{H}_0 : w_1 = \cdots = w_q = 0 \quad \text{contre} \quad \mathcal{H}_1 : \exists j \in \{1, \dots, q\} \text{ t.q. } w_j \neq 0.$$

Pour réaliser le test précédent, on utilise la statistique de Fisher suivante

$$F := \frac{\|\hat{\mathbf{Y}}_0 - \hat{\mathbf{Y}}\|^2/q}{\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2/(n - p - 1)}$$

qui suit la loi  $\mathcal{F}_{(q, n-p-1)}$ , sous  $\mathcal{H}_0$ . ( $\hat{\mathbf{Y}}_0$  désigne le vecteur des valeurs ajustées du modèle réduit).

On rejette  $\mathcal{H}_0$  si  $F_{obs} > F_{(q,n-p-1)}(1 - \alpha)$ .

La P-value est donc définie par

$$\text{P-value} := \mathbb{P}(Z > F_{obs}),$$

où  $Z$  est une variable aléatoire suivant la loi  $\mathcal{F}_{(q,n-p-1)}$ .

Ce test peut se faire sous R à l'aide de la fonction `anova()` qu'on applique à des modèles linéaires calculés avec la fonction `lm()`.

## Exercice

- (1) Transformer les variables qualitatives de la base de données `Carseats` en variables numériques (Utiliser la fonction `model.matrix()`). Nommer `Carseats.num.data` la nouvelle base de données.
- (2) Construire le modèle de RLM de la variable `Sales` en fonction de toutes les variables de la base de données `Carseats.num.data` : utiliser la fonction `lm()`;
- (3) Commenter les résultats;
- (4) Vérifier graphiquement : (i) la non-corrélation des erreurs (utiliser la fonction `acf()`); (ii) la relation linéaire entre la variable réponse et les variables explicatives; (iii) l'hypothèse d'homoscédasticité des erreurs (appliquer la fonction `plot()` au modèle calculé par la fonction `lm()`);
- (5) Tester l'hypothèse de non corrélation des erreurs (Utiliser le test de Durbin-Watson);
- (6) Tester l'hypothèse d'homoscédasticité des erreurs: utiliser le test de Breusch-Pagan (fonction `bptest()` du package `lmtest`);
- (7) Vérifier graphiquement l'hypothèse de normalité du terme d'erreur : utiliser la représentation Q-Q plot, et comparer l'histogramme des erreurs et la densité gaussienne;
- (8) Tester l'hypothèse de normalité du terme d'erreur : utiliser le test de Shapiro-Wilk;
- (9) Donner les résultats du test de Student de l'hypothèse nulle de non-significativité de chacune des variables explicatives. Ordonner les variables explicatives de la plus significative à la moins significative;
- (10) Donner les résultats du test de Fisher de l'hypothèse nulle de non-significativité de chacune des variables explicatives. Ordonner les variables explicatives de la plus significative à la moins significative;
- (11) Comparer les résultats des deux questions précédentes, et commenter;
- (12) Parmi les deux tests précédents, lequel choisiriez-vous? Justifiez.