



UNIVERSITÉ DE REIMS CHAMPAGNE-ARDENNE  
UFR SCIENCES EXACTES ET NATURELLES  
2024 - Semaine 10

TD/TP - INTRODUCTION INTELLIGENCE ARTIFICIELLE  
Messaoudi Chaima

TP/TD N°  
Date:07/03/2024

# 1 Exercice: Prétraitement

**Dataset** : tweets.txt

**Fonction à implémenter** : cleanWord

**Objectif** : Le but de cet exercice est de créer une fonction en Python appelée cleanWord qui effectue plusieurs étapes de prétraitement sur une chaîne de texte provenant du fichier tweets.txt. La fonction doit enlever les ponctuations, découper les mots (tokenization), mettre les mots en minuscule, éliminer les stop words et appliquer le stemming sur les mots. Enfin, la fonction doit retourner la liste des mots résultants sous forme d'une chaîne.

## 1.1 Instructions

1. Charger le contenu du fichier tweets.txt dans une variable texte.
2. Implémenter la fonction cleanWord avec les spécifications suivantes :
  - Prendre en entrée une chaîne de texte.
  - Enlever les ponctuations.
  - Découper les mots en utilisant une méthode de tokenization (vous pouvez utiliser une bibliothèque existante comme NLTK ou spaCy).
  - Mettre les mots en minuscule.
  - Éliminer les stop words (utilisez une liste de stop words existante, par exemple, celle fournie par NLTK).
  - Appliquer le stemming sur les mots (utilisez un algorithme de stemming, par exemple, celui fourni par NLTK).
  - Retourner la liste des mots résultants sous forme d'une chaîne.
3. Appliquer la fonction cleanWord sur la variable texte.
4. Afficher le résultat obtenu.

## 1.2 Conseils

Vous pouvez utiliser la bibliothèque NLTK pour le stemming et les stop words. La tokenization peut être réalisée avec la méthode `word_tokenize` de NLTK. Assurez-vous d'installer la bibliothèque NLTK si ce n'est pas déjà fait en utilisant la commande `pip install nltk`.

## 1.3 Exemple de code

```

1 import nltk
2 from nltk.tokenize import word_tokenize
3 from nltk.corpus import stopwords
4 from nltk.stem import PorterStemmer
5
6 # Assurez-vous que NLTK est telecharge
7 nltk.download('punkt')
8 nltk.download('stopwords')
9
10 def cleanWord(text):
11     # Votre implementation ici
12
13 # Charger le contenu du fichier tweets.txt dans une variable texte
14
15 # Appliquer la fonction cleanWord sur la variable texte
16
17 # Afficher le resultat obtenu

```

Listing 1: Pretraitement

## 1.4 Remarque

Assurez-vous que le fichier tweets.txt contient des tweets en format texte avant d'exécuter l'exercice. Vous pouvez personnaliser le contenu du fichier pour inclure des exemples de tweets.

## 2 L'analyse des sentiments(8pts)

**Dataset:** US Airlines Twitter Sentiment Analysis

**Objectif:** l'objectif de cet exercice est de réaliser une analyse de sentiment sur les tweets des compagnies aériennes américaines en utilisant des techniques de prétraitement, de vectorisation, et de machine learning.

### 2.1 Instructions

1. Importation des bibliothèques:
  - Importer les bibliothèques nécessaires, telles que pandas, matplotlib, seaborn, scikit-learn, etc.
2. Chargement du Dataset:
  - Charger le dataset "US Airlines Twitter Sentiment Analysis" dans une structure de données appropriée (par exemple, un DataFrame).
3. Visualisation des données:
  - Visualiser le nombre de tweets pour chaque compagnie aérienne.
  - Visualiser la distribution des sentiments dans l'ensemble du dataset.
  - Visualiser la répartition des sentiments pour chaque compagnie aérienne.(0.25)
4. Prétraitement des données :
  - Utiliser des expressions régulières pour nettoyer le texte des tweets (supprimer les caractères spéciaux, les liens, etc.).
  - Utiliser TfidfVectorizer de Scikit-Learn pour convertir le texte en vecteurs TF-IDF.
5. Division des données:
  - Diviser les données en ensembles d'entraînement et de test.
6. Entraînement du modèle :
  - Utiliser un modèle de classification(exemple:RandomForestClassifier de scikit-learn) pour entraîner un modèle de classification de sentiment.
7. Prédiction et évaluation du modèle:
  - Faire des prédictions sur l'ensemble de test.
  - Évaluer le modèle en utilisant la matrice de confusion, la mesure de précision, la mesure F1, etc.
8. Affichage des résultats :
  - Afficher les résultats de l'évaluation du modèle.

### 2.2 Conseils

- Consultez la documentation de Scikit-Learn pour comprendre comment utiliser TfidfVectorizer et RandomForestClassifier
- Utilisez les fonctions de visualisation de données de matplotlib et seaborn pour créer des graphiques informatifs.